Q10 Naive Bayes :

Rappelez le principe de l'apprentissage supervisé. Quel est le protocole de gestion des données dans ce contexte ?

Données labélisées
entraîner hold out test

Qu'est-ce que l'algorithme de Naive Bayes ?

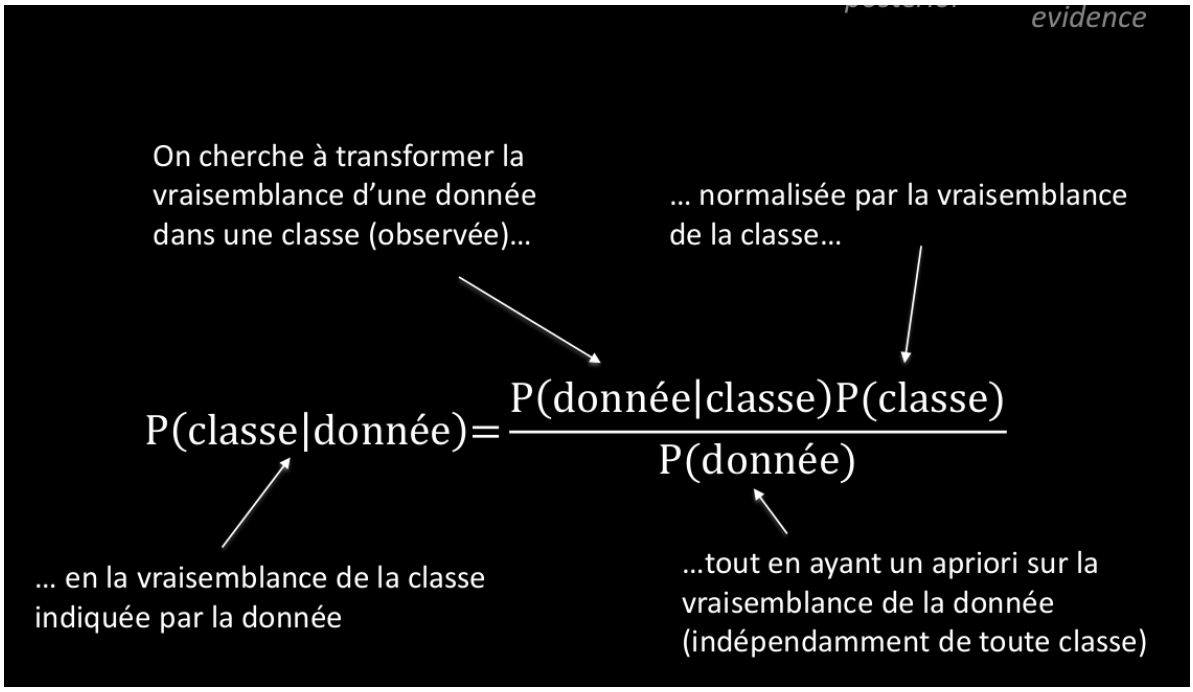

classification_Bayésienne

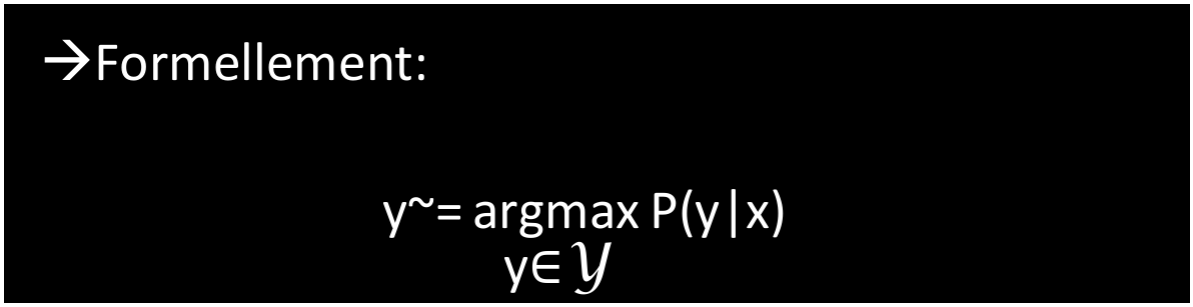

classification_Bayésienne_formule

Quelles sont les hypothèses sous-jacentes ?

Le classifieur diminue la complexité en faisant l'hypothèse d'indépendace conditionnelle des caractéristiques

Quels sont les paramètres ?

Suivant le modèle Gaussien, les paramètres du Naiv Bayes son la moyenne et l'écart type:

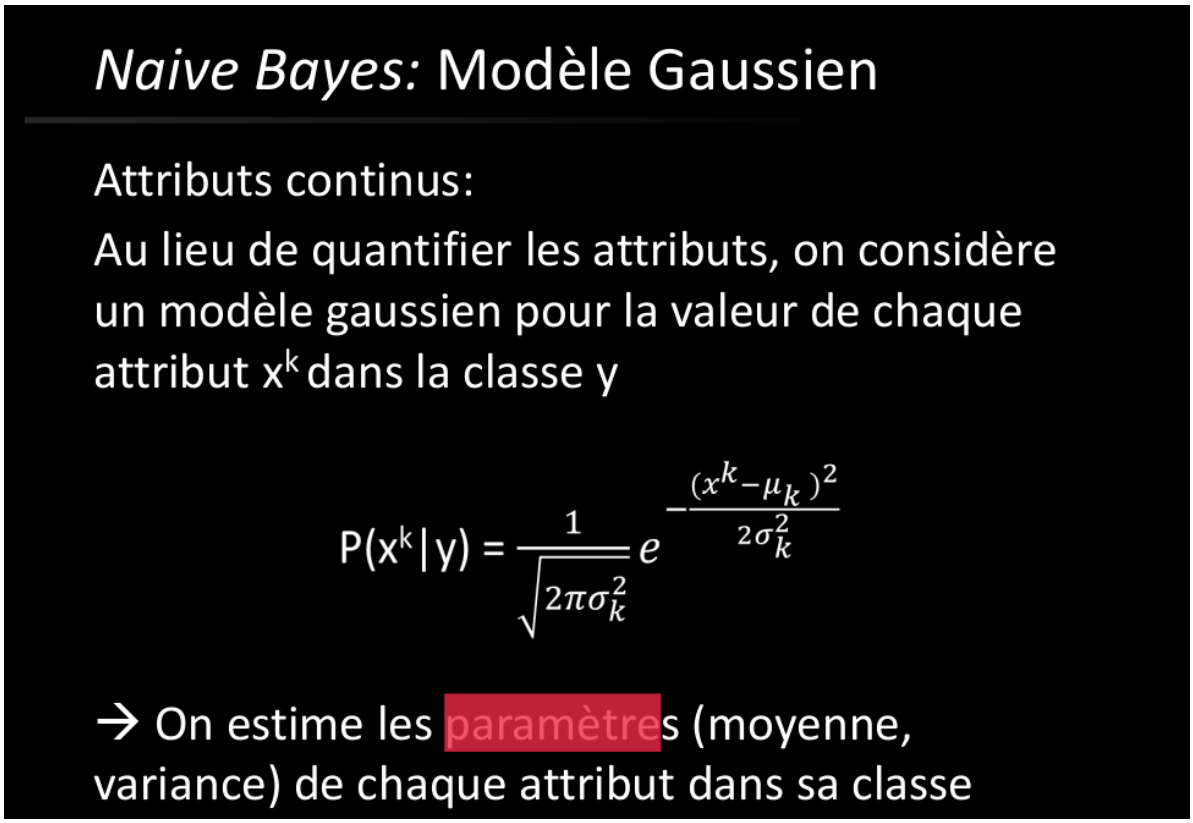

Naiv_Bayes_modele_gaussien

Comment l'exprimer en tant que réseau bayésien ?

Naive Bayes peut être représenté comme un PGM simple.

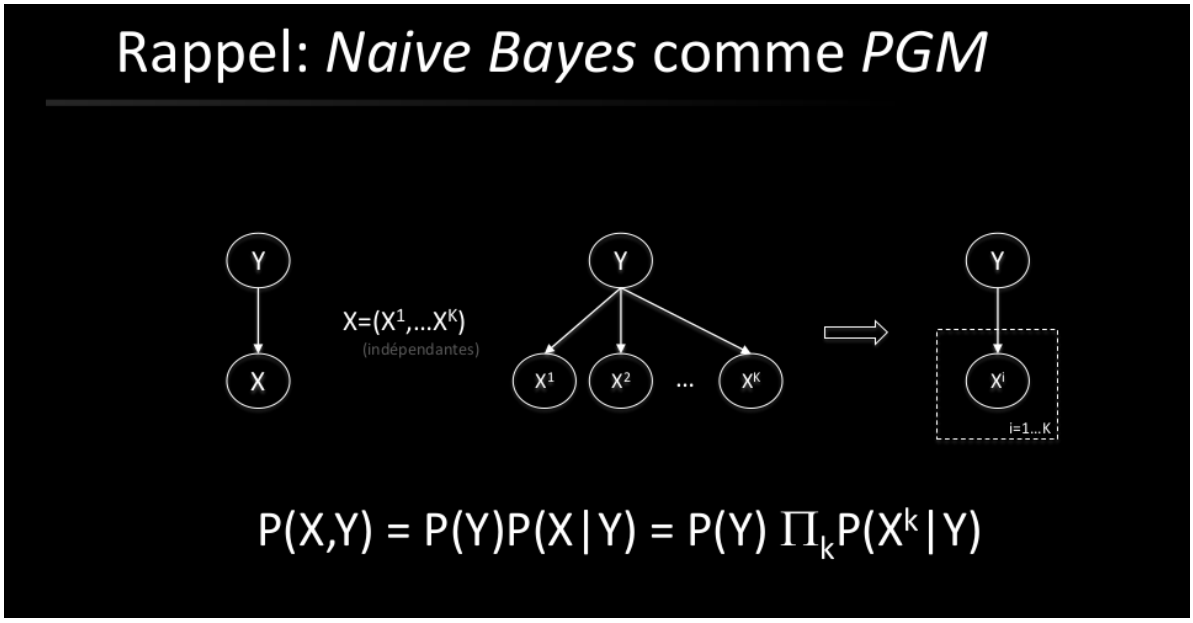

Naive_Bayes_PGM

Qu'est-ce que le sur-apprentissage ?

On fait du sur-apprentissage lorsqu'on cherche à faire un découpage strict

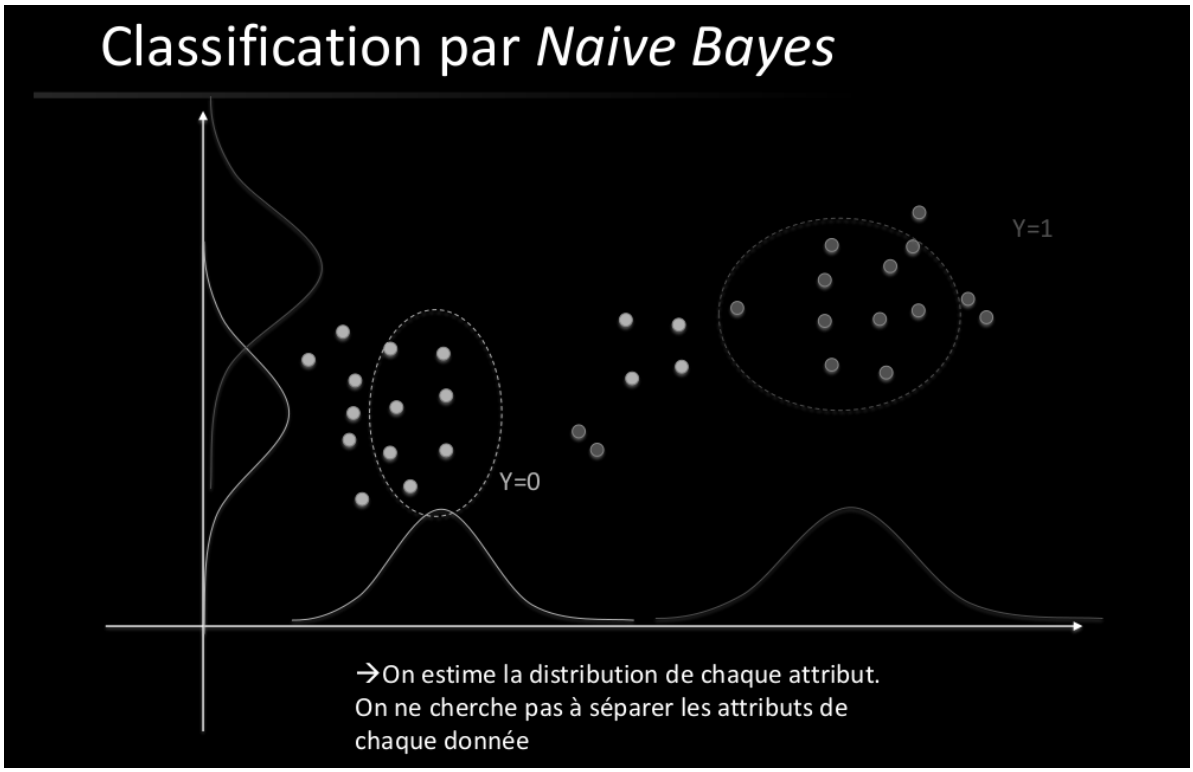

Naiv_Bayes_sur_apprentissage

On va essayer de faire un mappeur qui va nous permettre de classer les éléments données

on va obtenir la valeur maximal (probabilité maximale) selon les données x
Trouver le seuil pour minimiser les faux positifs et les faux négatifs

On essaie de généraliser la connaissance selon ce qu'on connait. on peut suprimer P(x) pour diminuer la complexiter car on cherche le maximum.

Cette approche part du principe que l'échantillonnage est équitable. On s'intéresse dans les cas ou ce biais est minime.

On suppose l'indépendance conditionnelle des attribut (ce qui n'est pas toujours vrai par exemple age, poid, taille, sont pas indépendants).
On peut donc simiplifier p.15

estimation, juste une proba des individus sur l'espace Y

On peut estimer sur le Training set E
exemple: P(Y=pomme)= proportion de pomme dans le training set

Chaque groupe des élément est représenté par une loi gaussienne d'un écart type sigma (diagonale, comme indépendant)

Naiv Bayes avec une gaussienne donne une division plutôt linéaire.