Intelligence Artificielle

Introduction à l'Apprentissage

Stephane Marchand-Maillet

Contenu

- Types d’apprentissage
- Composantes de l’apprentissage
- Evaluation
- Généralisation et sur-apprentissage

Apprentissage *vs* recherche

Algorithmes de recherche:

- Enumérations organisées pour chercher une solution
- On injecte de la connaissance par le modélisation des états et en utilisant des heuristiques

→ Exploration de l'univers d'états

Apprentissage:

- On collecte de données

→Echantillonnage de l'univers d'états

→On essaie d'inférer (généraliser) de la connaissance à partir de ces exemples

- On injecte de la connaissance en utilisant des modèles qui ont potentiellement généré les données

Exemple

Jeu d'échecs:

- Recherche: On utilise l'algorithme MiniMax avec une heuristique pondérant les pièces pour leur importance stratégique
  - Branchement = 35, Horizon = 20, 2.10^{30} tests

  → La connaissance est dans la maximisation de l'utilité (et heuristique)

- Apprentissage: On apprend, à partir de parties jouées dont on connait le résultat, un modèle de joueur (p.exple: réseau de neurones) qui en fonction d'un contexte (position des pièces) joue un coup

  → La connaissance est dans les parties jouées qui permettent d'inférer des décisions

Modèles et caractéristiques

On modélise le contexte (ses échantillons, les données) par des caractéristiques supposées être pertinentes (pour le problème):

Exemple: modèle d'une personne

- Médical: taille, poids, âge, genre,…
- Marketing: âge, genre, revenu,…
- Politique: rural/urbain, âge, revenu,…

→ La couleur des cheveux est peu pertinente

Pertinence ~ corrélation avec l'objectif en question
~ contenu d'information

Remarque importante:

Attention aux biais (sociétaux) internes aux données

Exemple: le modèle Gaussien

On veut prédire une caractéristique d'un objet
On lui associe un modèle

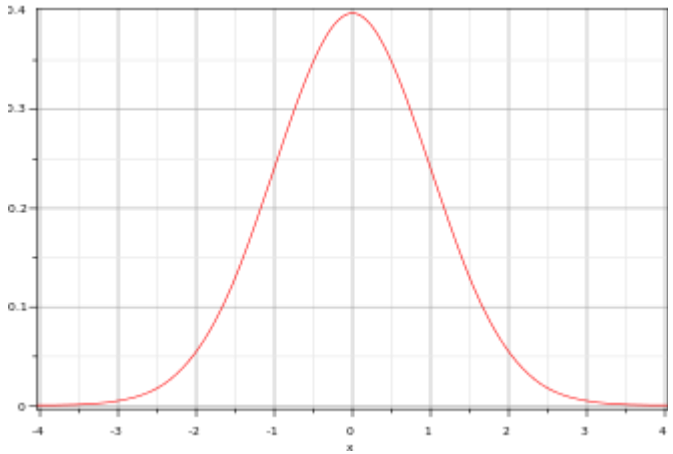

Exemple: diamètre d'une pomme

- On collecte plusieurs de ces objets
- On mesure la caractéristique

→ Prédiction basique: moyenne
→ Ordre supérieur: introduction de la variance

Modèle Gaussien: «La valeur de caractéristique devient exponentiellement moins probable au fur et à mesure qu'elle s'écarte de la moyenne»

$$P(v)=\frac{1}{Z}e^{-\frac{(v-\mu)^2}{2\sigma^2}}$$

→ Apprentissage: on optimise les paramètres $\theta=[\mu,\sigma]$ avec les données
→ Hypothèse d'un prototype «moyen» dont les observations sont une «déformation»

→ Ici, on interdit les distributions bimodales (exple: taille d'une personne)

Apprentissage

On part de données et on cherche:

- une association que l'on connait
  - →Apprentissage supervisé: on connait la décision associée à certains exemples de nos données
  - →Méthodes: classification, régression,…

- une structure que l'on veut découvrir
  - →Apprentissage non-supervisé: on cherche des structures dans les données qui nous permettront de mieux les comprendre
  - →Méthodes: clustering, embedding,…

Apprentissage non-supervisé

Clustering

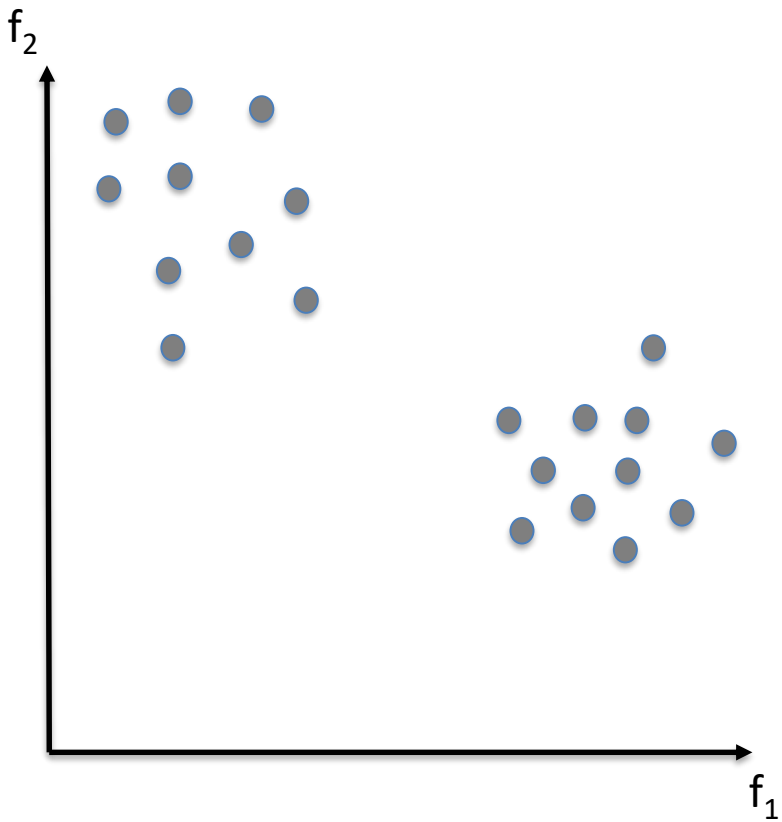

Etant données des données dans leur espace de représentation….

Exemples: communautés, profils, …

Apprentissage non-supervisé

Clustering

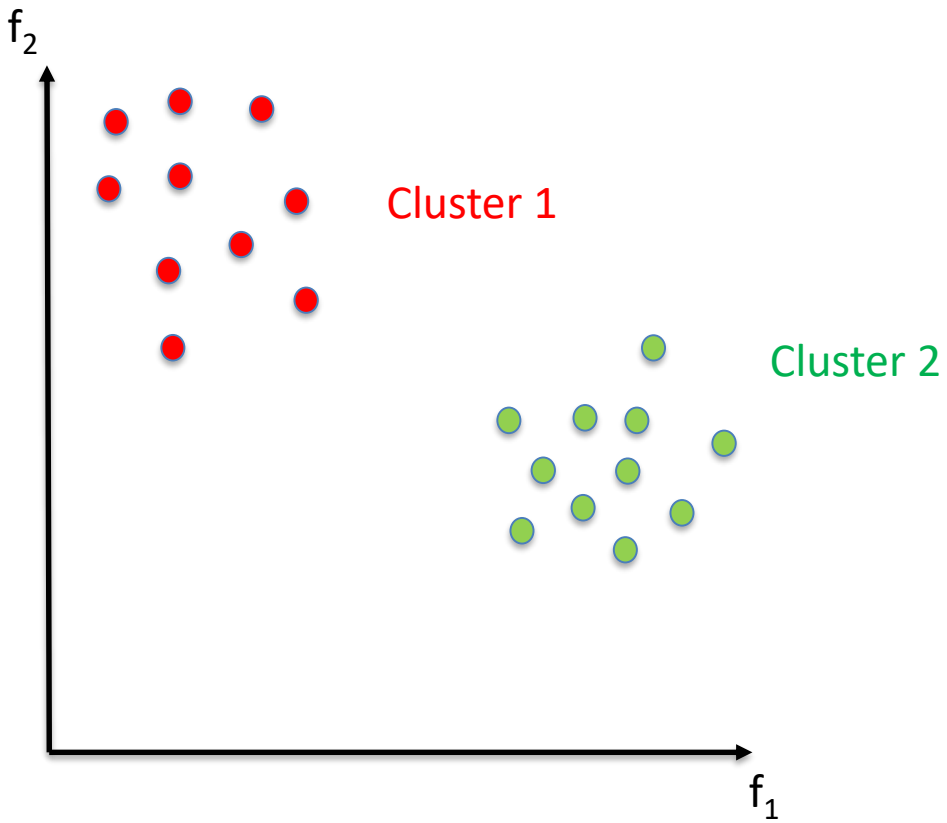

… on cherche à leur associer des labels

(pas abordé dans ce cours)

Apprentissage non-supervisé

Embedding

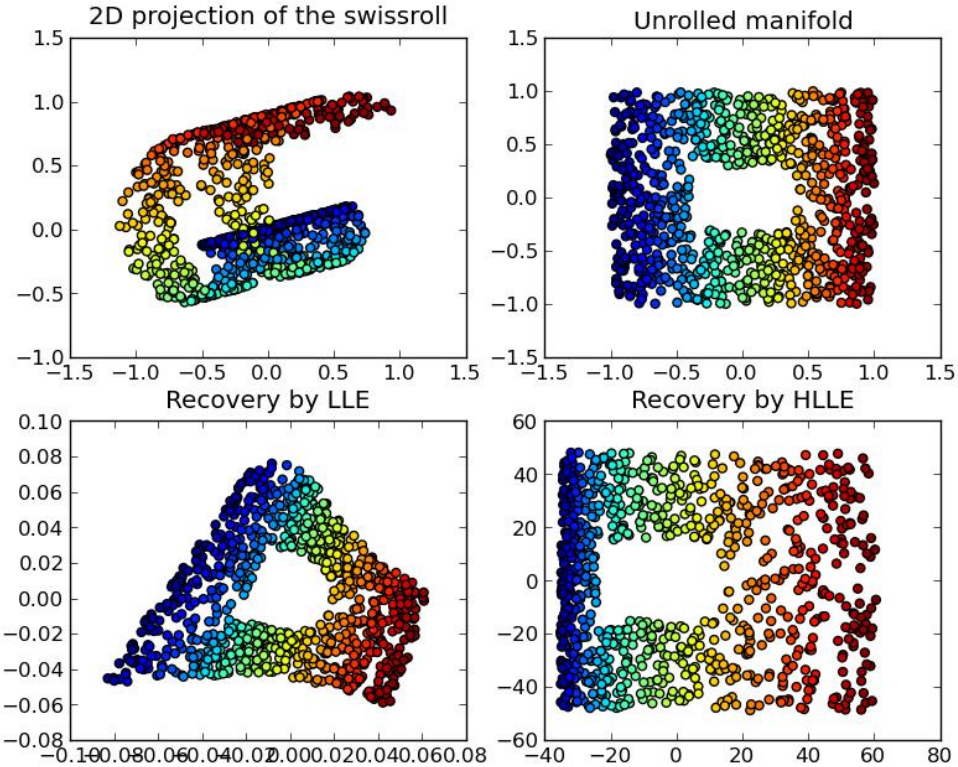

On cherche des représentations pertinentes pour les données

(pas abordé dans ce cours)

Apprentissage supervisé

Classification:

On connait les *classes* (décisions, labels) $Y=\{y_i\}$ pour certaines *données* (exemples, contextes) $X=\{x_i\}$, on s'en sert pour apprendre une « fonction » qui attribuera des *classes* aux *données* non classifiées (prédiction)

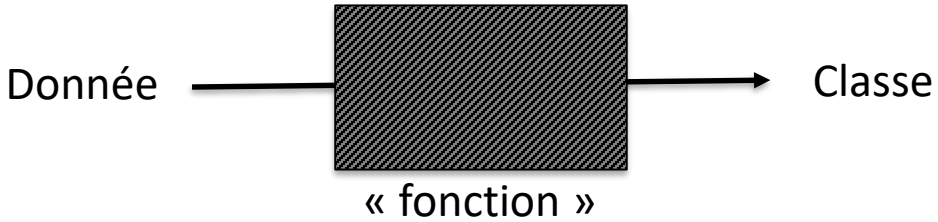

Exemples:

- Classification d'images (labélisation)
  - Classe y_i = « chat », « chien », « arbre », …
- Prise de décision selon des capteurs (diagnostic)
  - Classe y_i = « oui », « non », « sain », « malade », …

Exemple: classification

Données classifiées

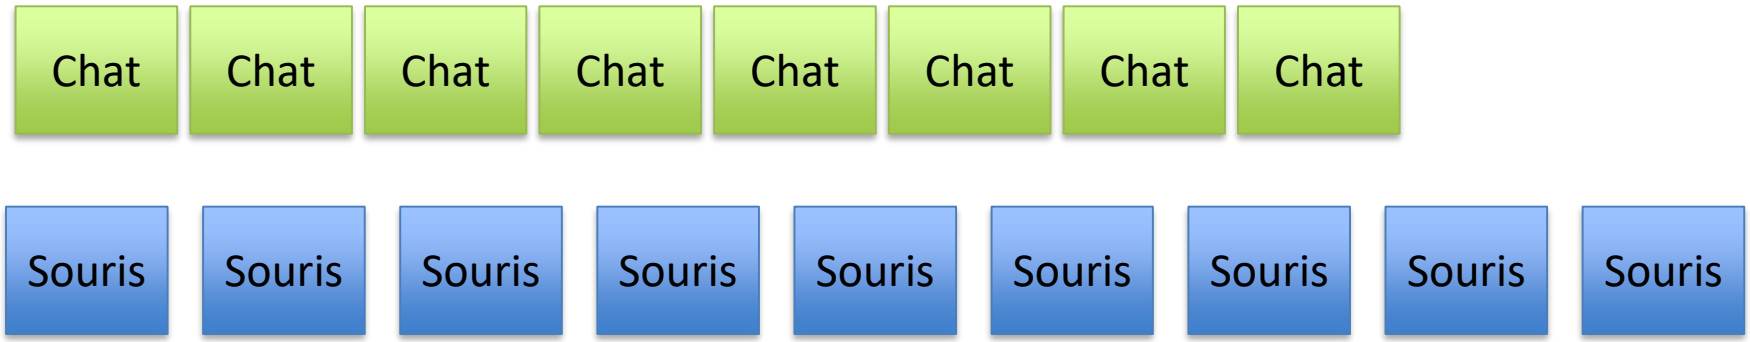

Données non-classifiées

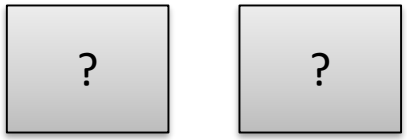

Exemple: classification

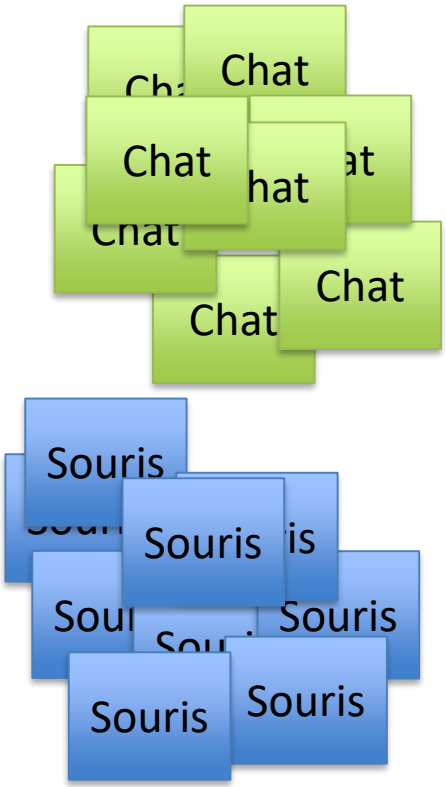

On représente les données classifiées

Exemple: classification

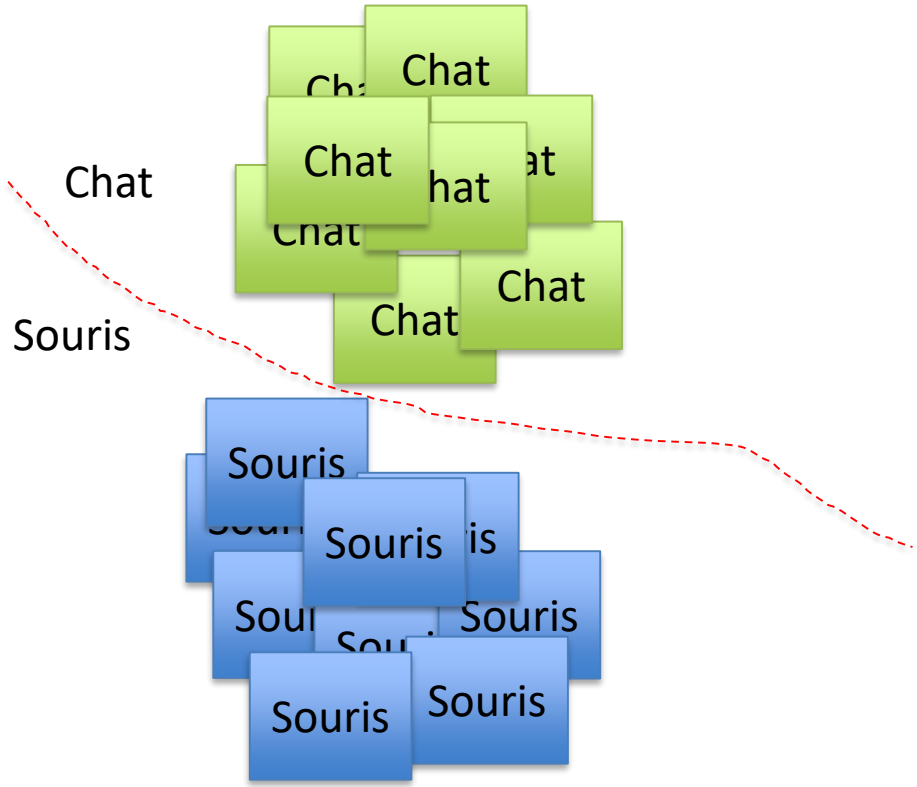

On apprend une fonction de classification

Note: on peut utiliser les données non-classifiées pour l'apprentissage (apprentissage semi-supervisé)

Exemple: classification

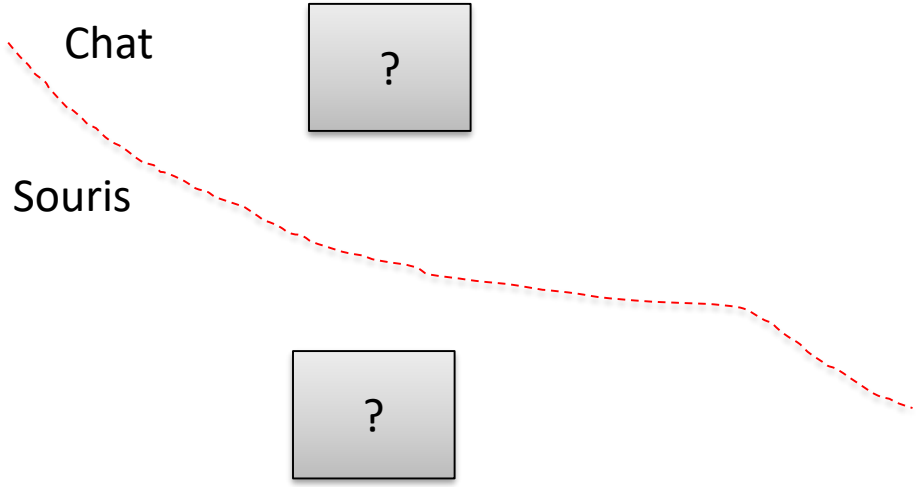

On représente les données non-classifiées

Exemple: classification

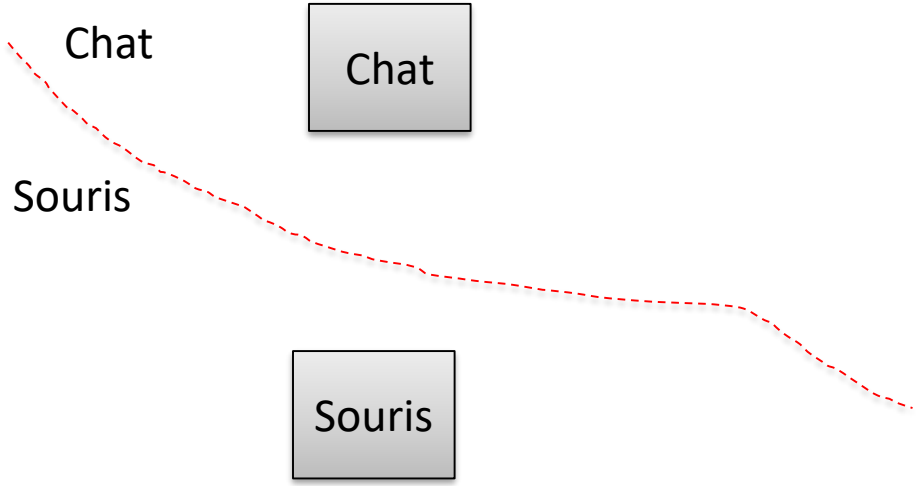

On peut classifier ces données (prédiction de classe)

Apprentissage supervisé

Régression:

On connait les *sorties* (valeurs) y_i pour certaines *données* (exemples, contextes) x_i, on s'en sert pour apprendre une « fonction » qui attribuera (prédira) des *valeurs* aux *données* inconnues

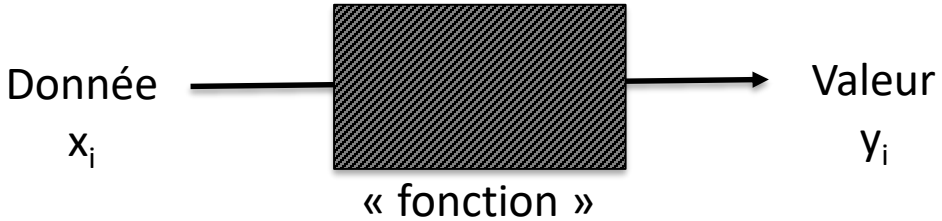

→Equivalent à une classification avec *classes continues*

Exemple: Régression

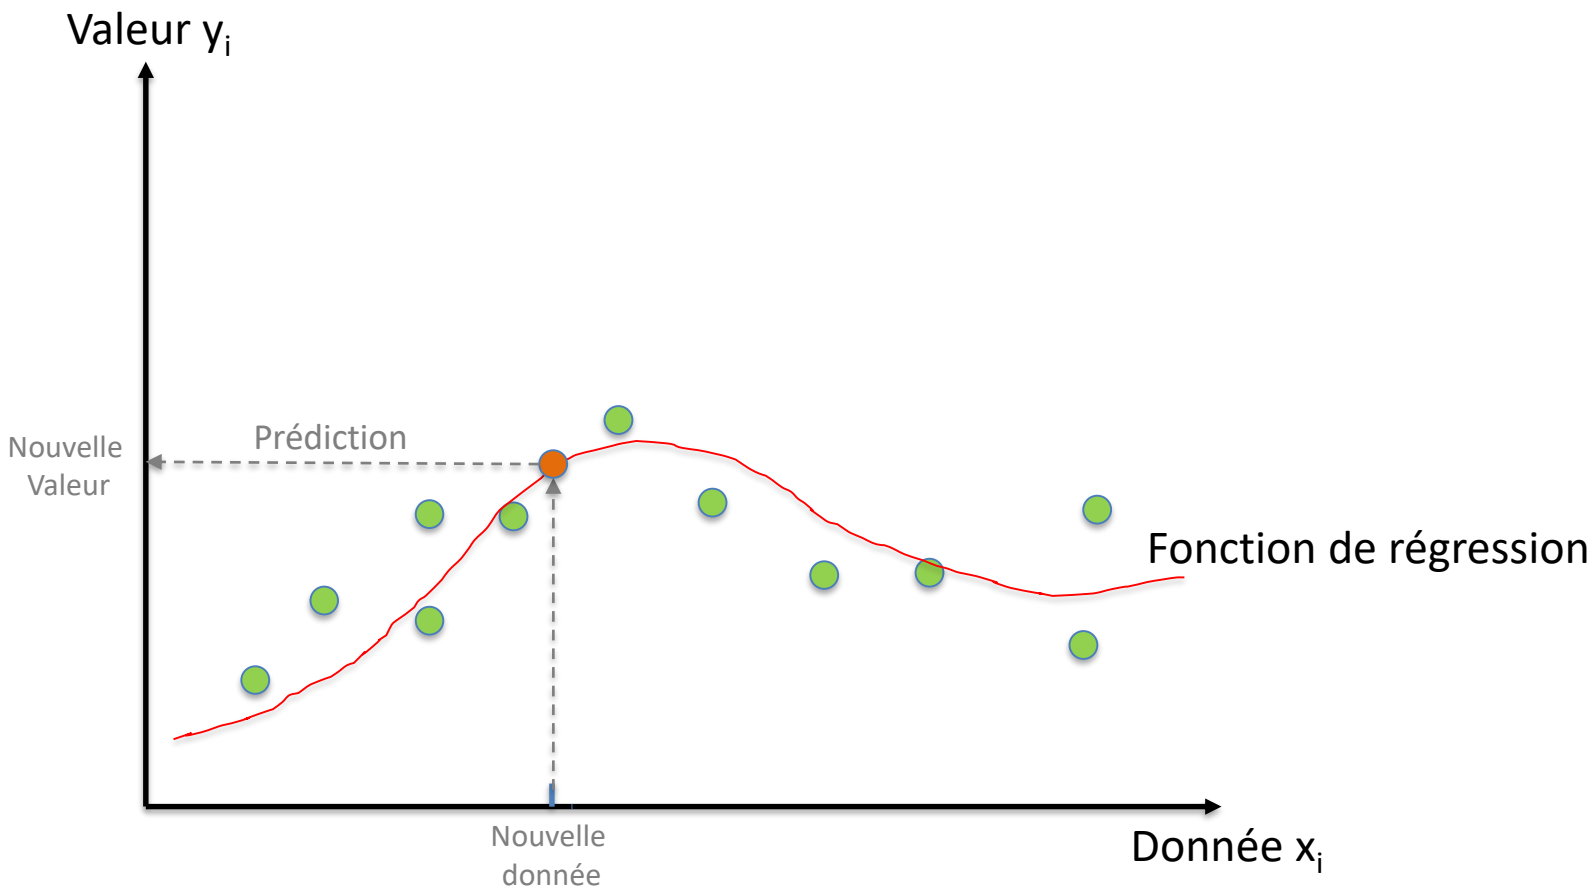

Dualité classification-régression

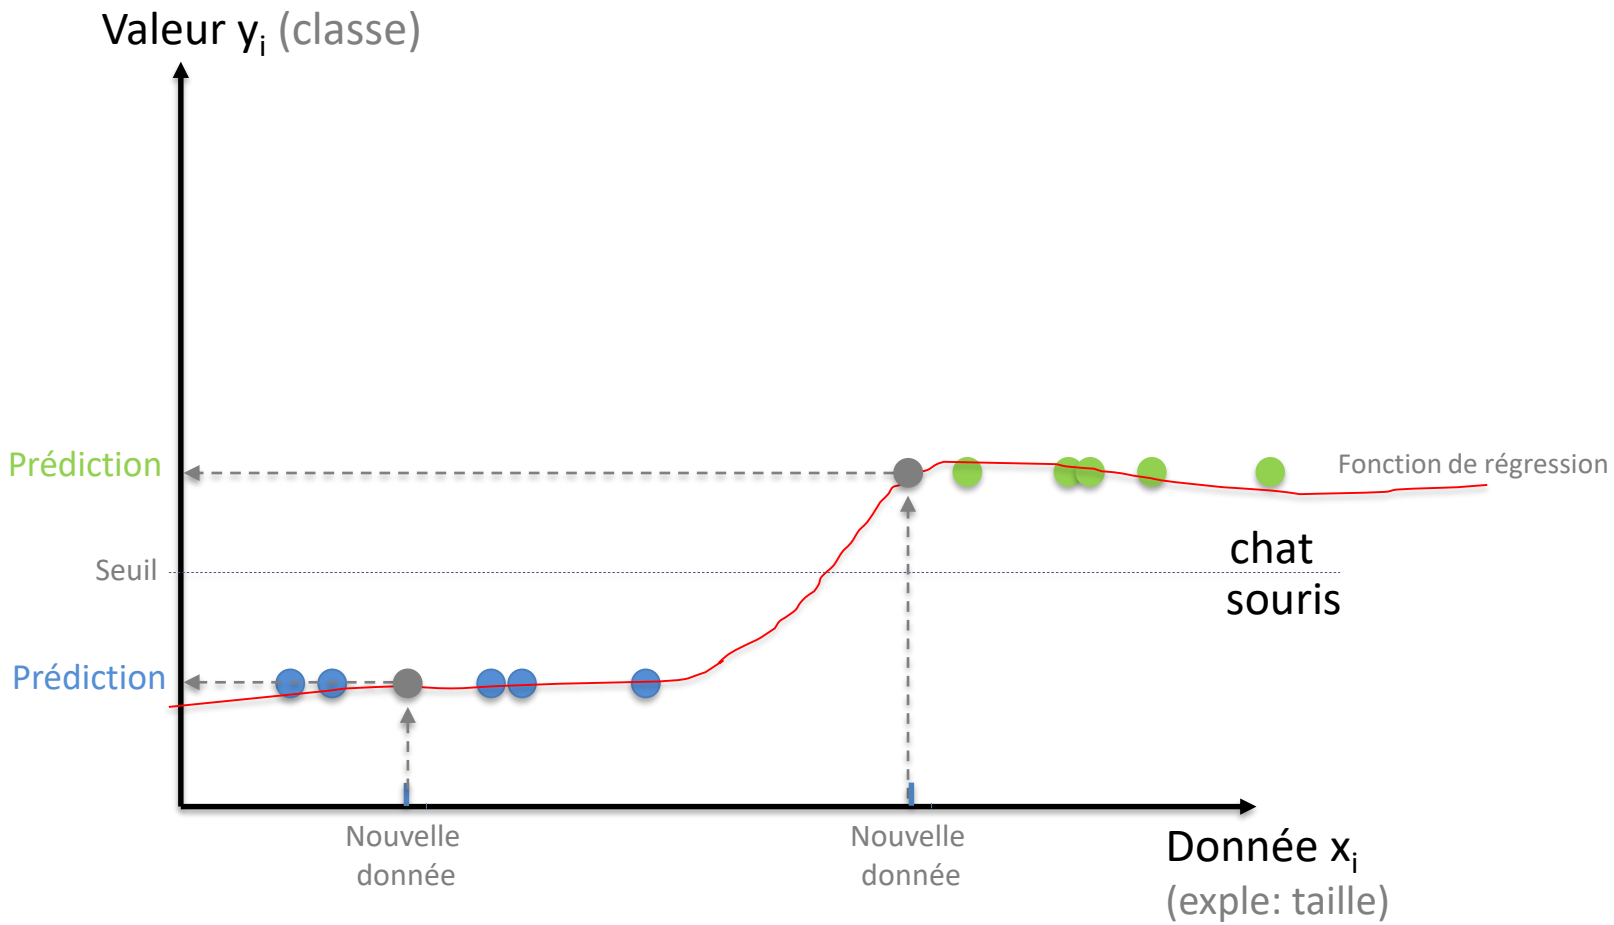

Dualité classification-régression

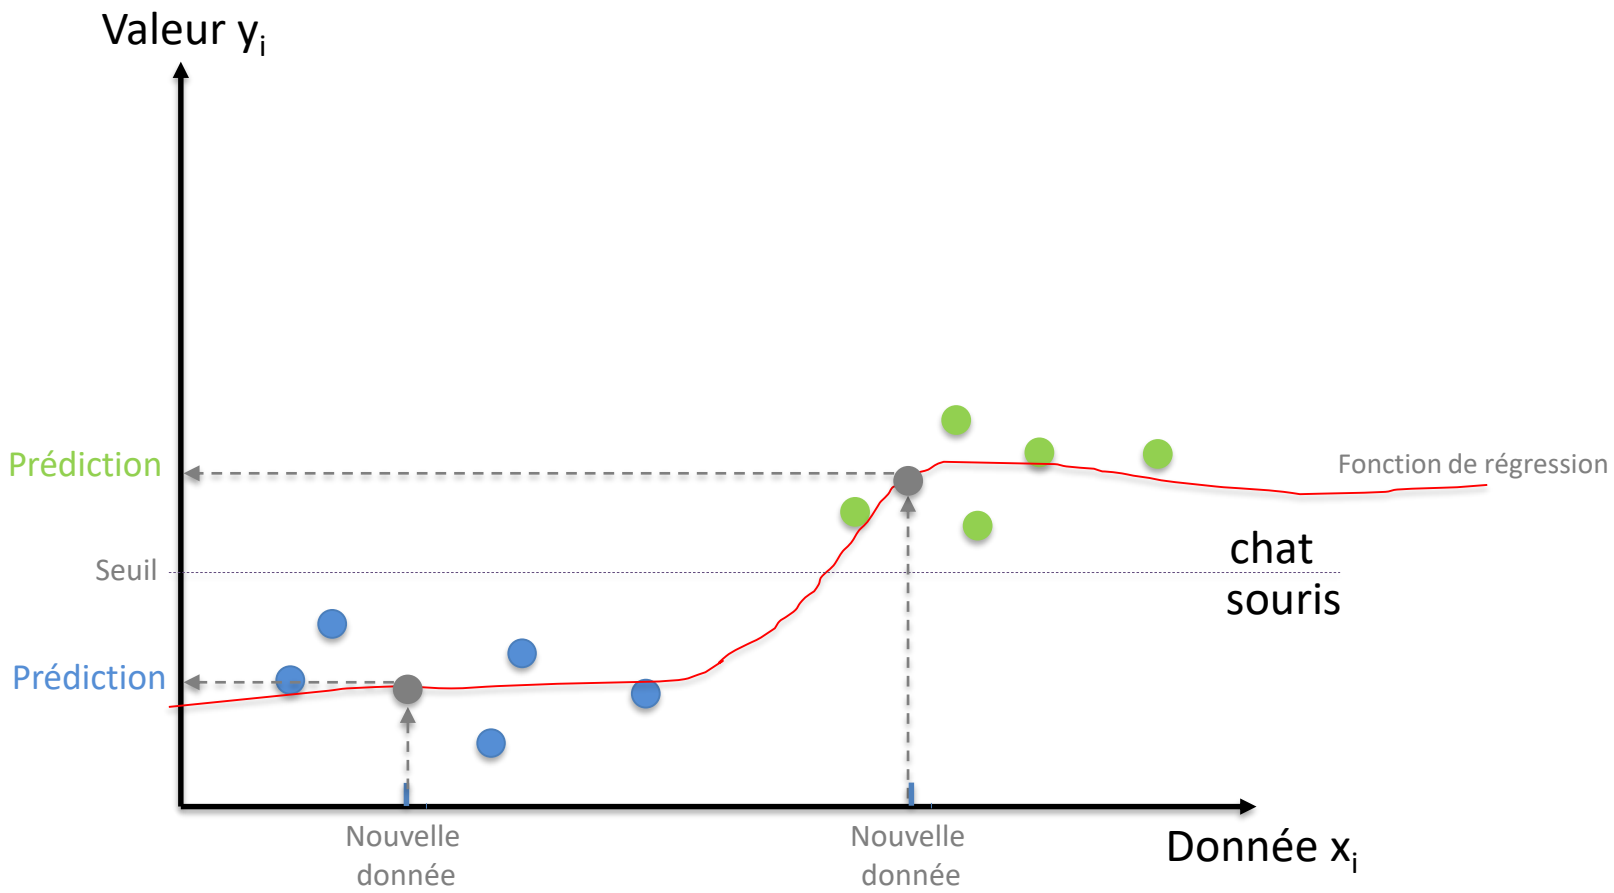

Apprentissage (semi-)supervisé

On vise l'association: *exemple* → *classe*

Exple: image → label (chien, chat, …)

Etant donnés un ensemble E={(x_i,y_i)} d'exemples associés à des *classes* (entrainement) et un ensemble T={x_i} (test) d'exemples pour lesquels on cherche la *classe* associé:

Types d'apprentissage:

- Inductif: on apprend un modèle (règles générales) sur l'ensemble E
  - Peut inclure une forme d'inférence
- Déductif: on utilise ces règles pour attribuer des classes sur T

- Transductif: On apprend sur E (et T) pour prédire des classes sur T
  - Lien avec l'apprentissage semi-supervisé et l'apprentissage "actif"
  - Capacité à apprendre une approximation des exemples (qui permet la gestion des exceptions aux règles)

Transductive learning

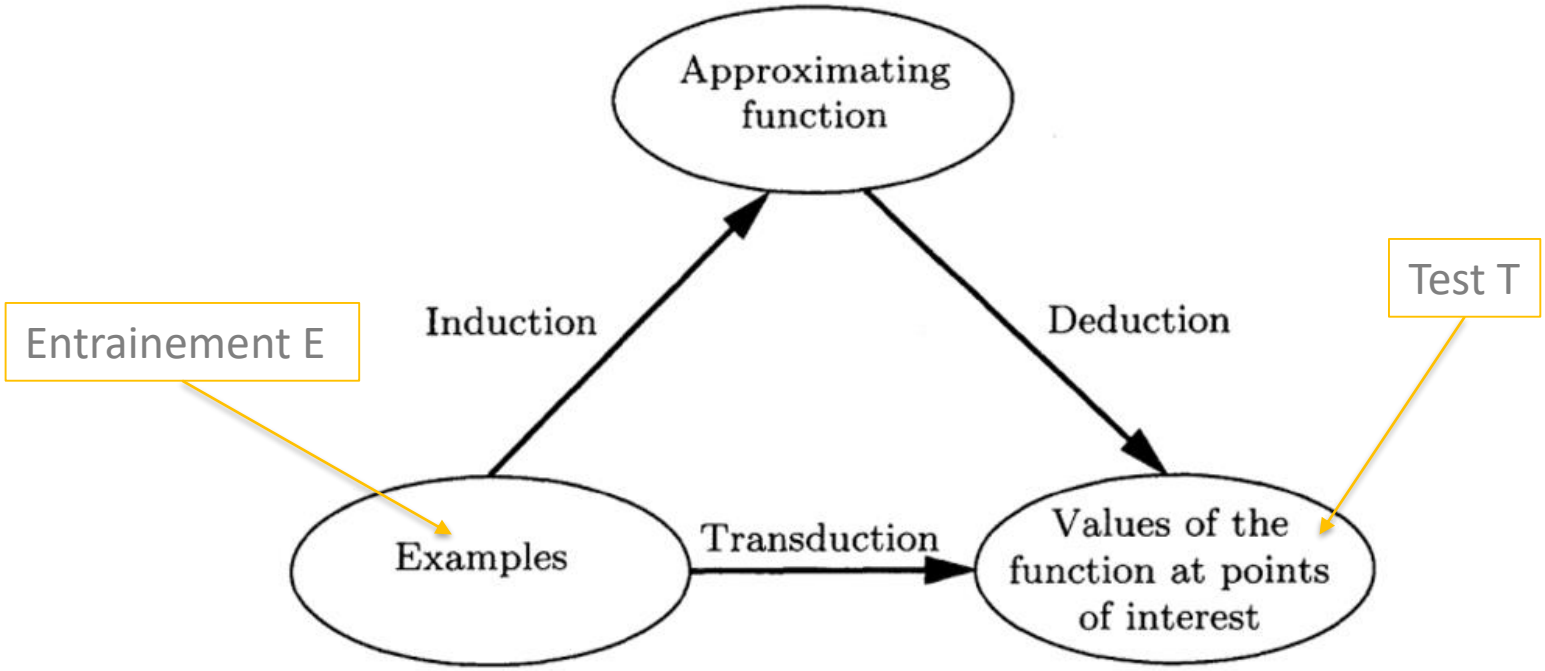

"When solving a given problem try to avoid solving a more general problem as an intermediate step."

From: The Nature of Statistical Learning Theory, Vapnik, Springer, 1998

Apprentissage

L'apprentissage dépend de la méthode utilisée:

- Hypothèses sous-jacentes
- Modèle de données
- Modèle d'apprentissage et critère d'optimalité

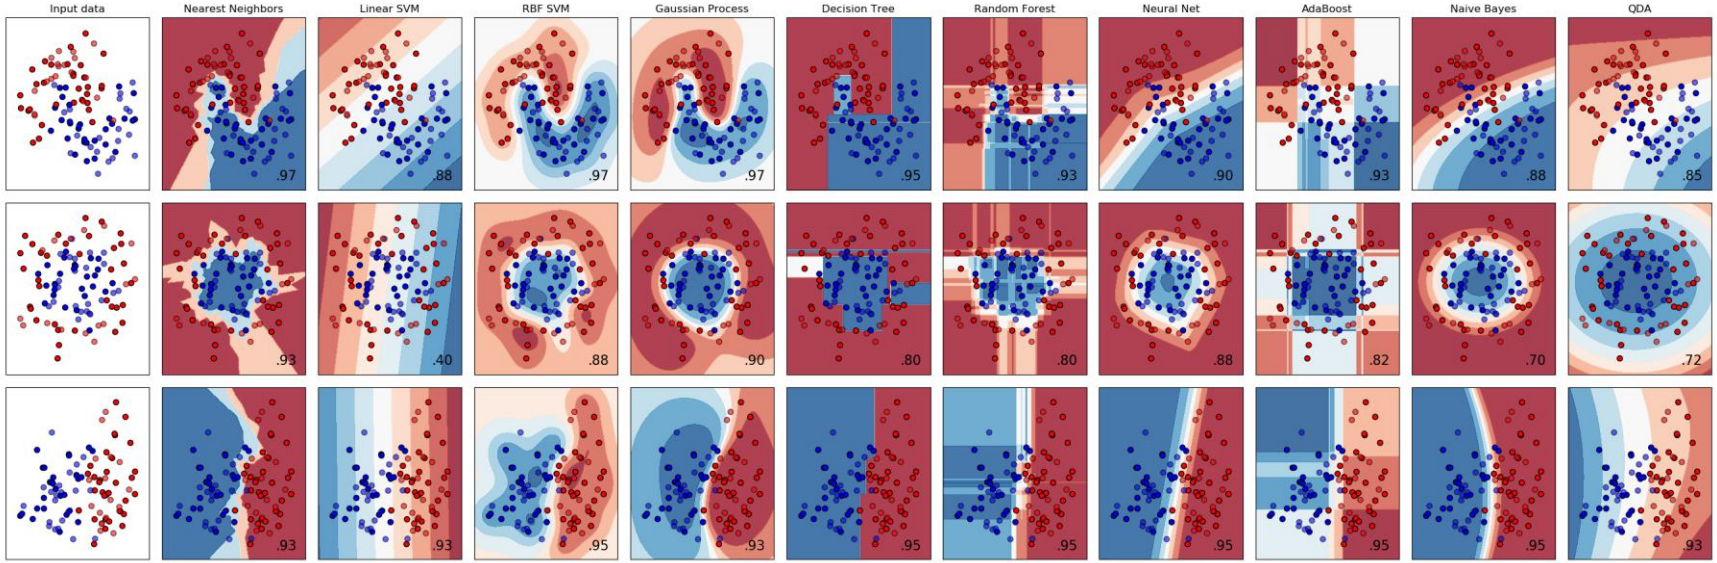

Voir: https://scikit-learn.org

Apprentissage

On choisit un modèle de fonction d'apprentissage ϕ_θ avec des paramètres θ et on cherche les paramètres optimaux grace aux données X

$$\theta^* = \underset{\theta}{\operatorname{argmin}}\, L(\phi_\theta\ (\mathrm{X}); \mathrm{X})$$

où L(X',X) est une mesure d'erreur

Exemple:

- Modèle de classification linéaire: θ = [a,b]
- L(.,.) mesure le taux de données mal classifiées par ϕ_θ

Composantes de l'apprentissage

- On doit définir un objectif:
  - Quelles sont les classes? Combien sont-elles?
  - Quelle prédiction veut-on?
- On fixe un modèle d'apprentissage:
  - Quels sont ses paramètres? Sa complexité? Sa capacité?
  - Quels sont ses hyper-paramètres?
  - Ai-je assez de données pour apprendre ce modèle?
- On rassemble des données:
  - Quelle est leur représentation?
  - Quel volume? Quelle diversité?

  Apprentissage → classes associées à un sous-ensemble?
- On fixe une mesure d'évaluation:
  - Quelle est la qualité de mon apprentissage?
  - Mes données sont-elles pertinentes (représentatives) pour évaluer?

Objectif de l'apprentissage

- Consiste à définir une abstraction du problème en question
- L'objectif doit être clair:
  - il définit l'évaluation
- L'objectif doit être aussi simple que possible:
  - Il conditionne la complexité du modèle
  - Il doit extraire la connaissance pertinente

C'est une étape largement arbitraire mais qui conditionne la suite:

→Les limites et hypothèses posées ici sont indépassables pour la suite

→Lien avec l'« Enveloppe du monde » (univers clos)

Modèle d'apprentissage

Le choix du modèle se base sur:

- Ses performances connues pour le type de problème
- Ses hypothèses sous-jacentes (connaissance *a priori*)
- Sa complexité, sa robustesse
- Le nombre de ses (hyper-)paramètres
- Le volume de données disponible
- Le volume de données requis pour l'apprendre
- La connaissance qu'on a du problème
- …
- *La mode du moment*

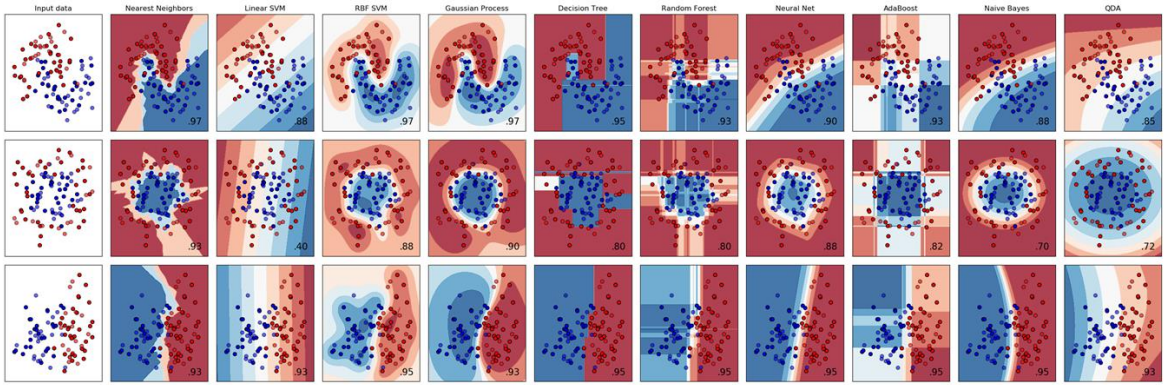

Exemple de modèles:

- Réseaux de Neurones
- Arbres de décisions
- Classifieurs à Noyaux
- …

Données

Une (grande) partie de la connaissance de notre monde (en plus des hypothèses du modèle)

Les questions liées sont:

- Leur représentation
  - Extraction de caractéristiques (coût, dimension)
  - Qualité de la représentation (pertinence, discrimination)
- La qualité
  - Bruit associé aux mesures
- Le volume, la diversité
  - Relation à la complexité du modèle et du problème
  - Lien avec la théorie de l'estimation statistique
- La labélisation
  - Qualité versus quantité
  - Proportion label/sans-label, entre classes

Evaluation

On doit être capable de quantifier la qualité de l'apprentissage:

→On définit des mesures d'évaluation

		Prédiction	
		Positif	Négatif
Réalité	Pertinent	Vrai Positif (TP)	Faux Négatif (FN)
	Non-pertinent	Faux Positif (FP)	Vrai Négatif (TN)

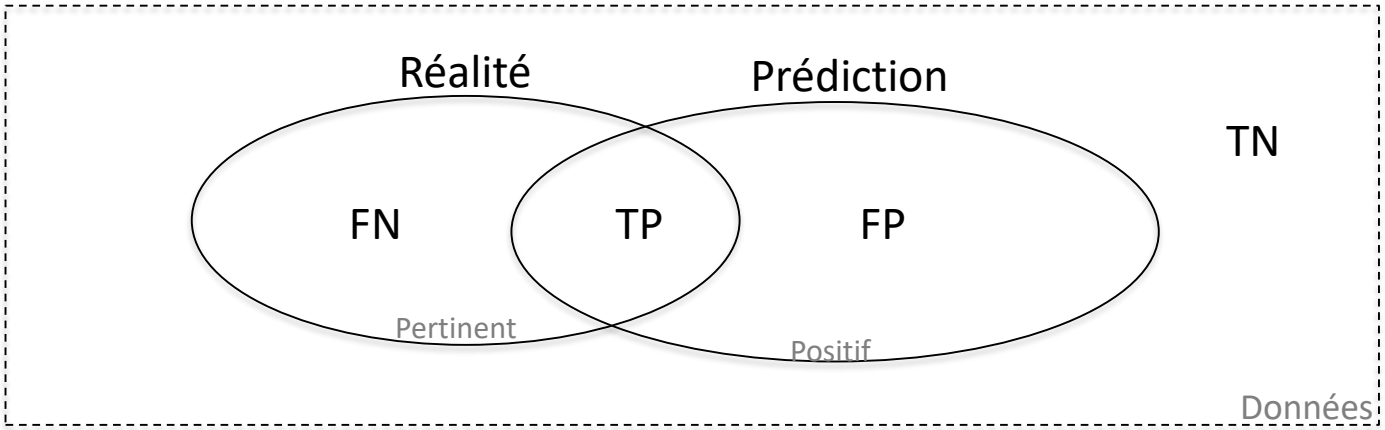

Evaluation

Exemple: ROC curve

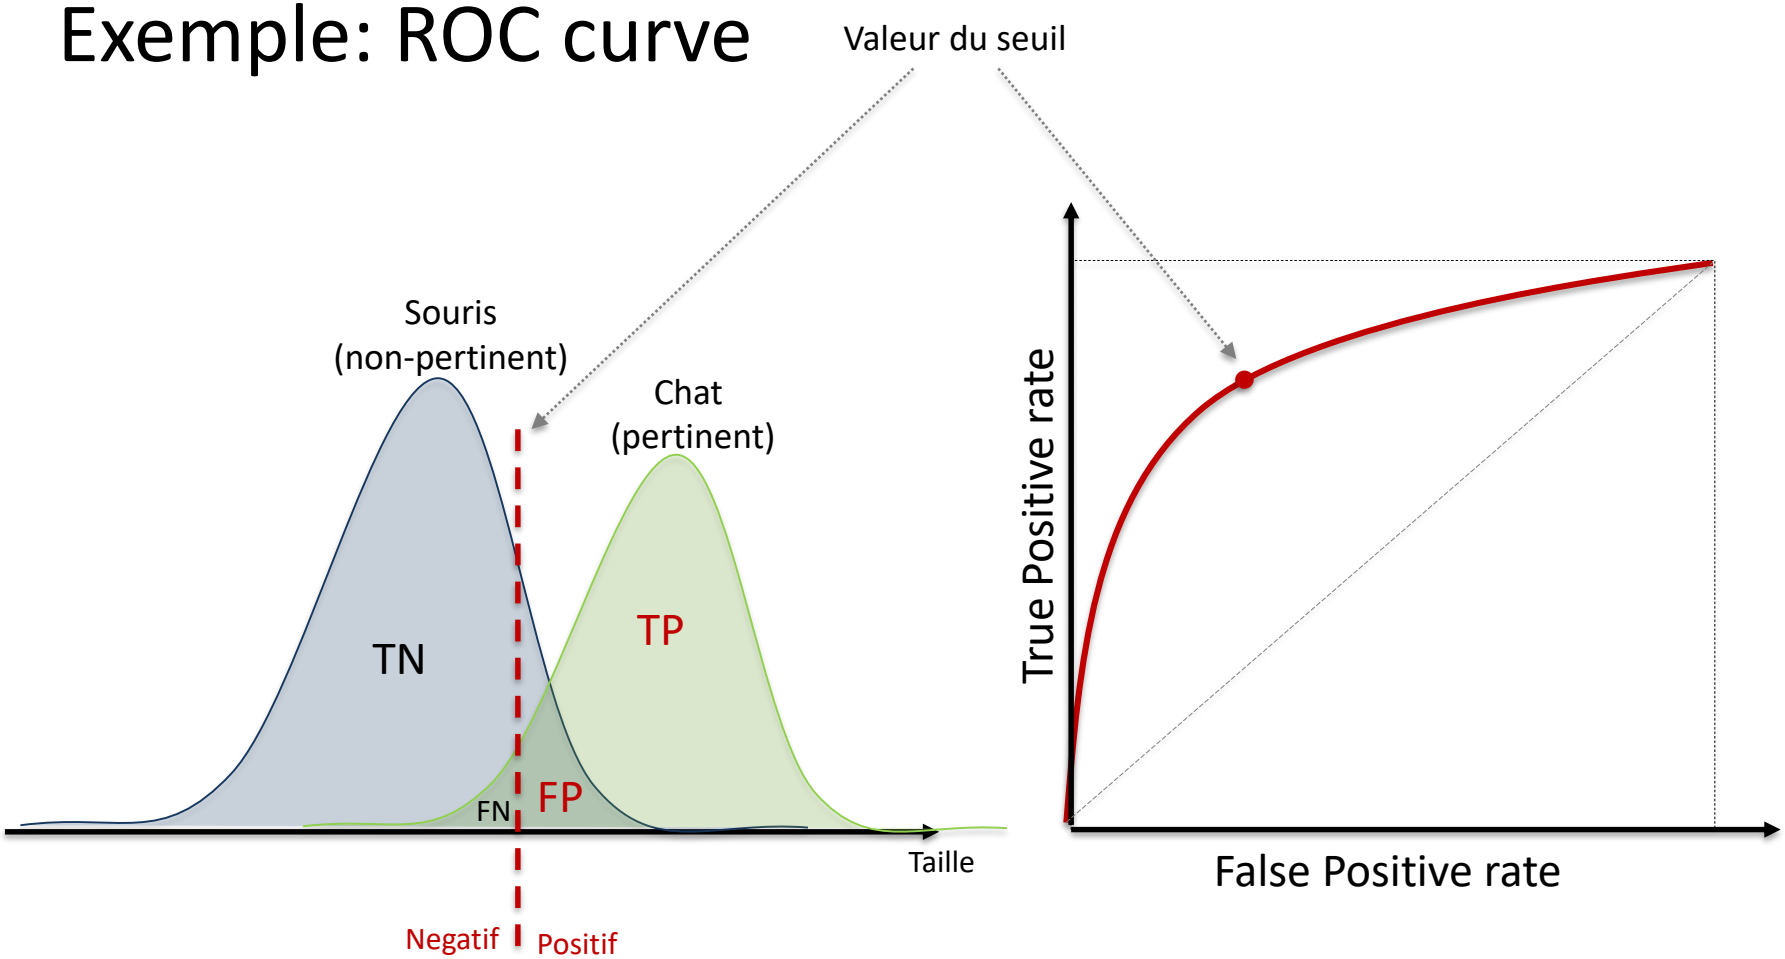

Evaluation

Exemple: ROC curve

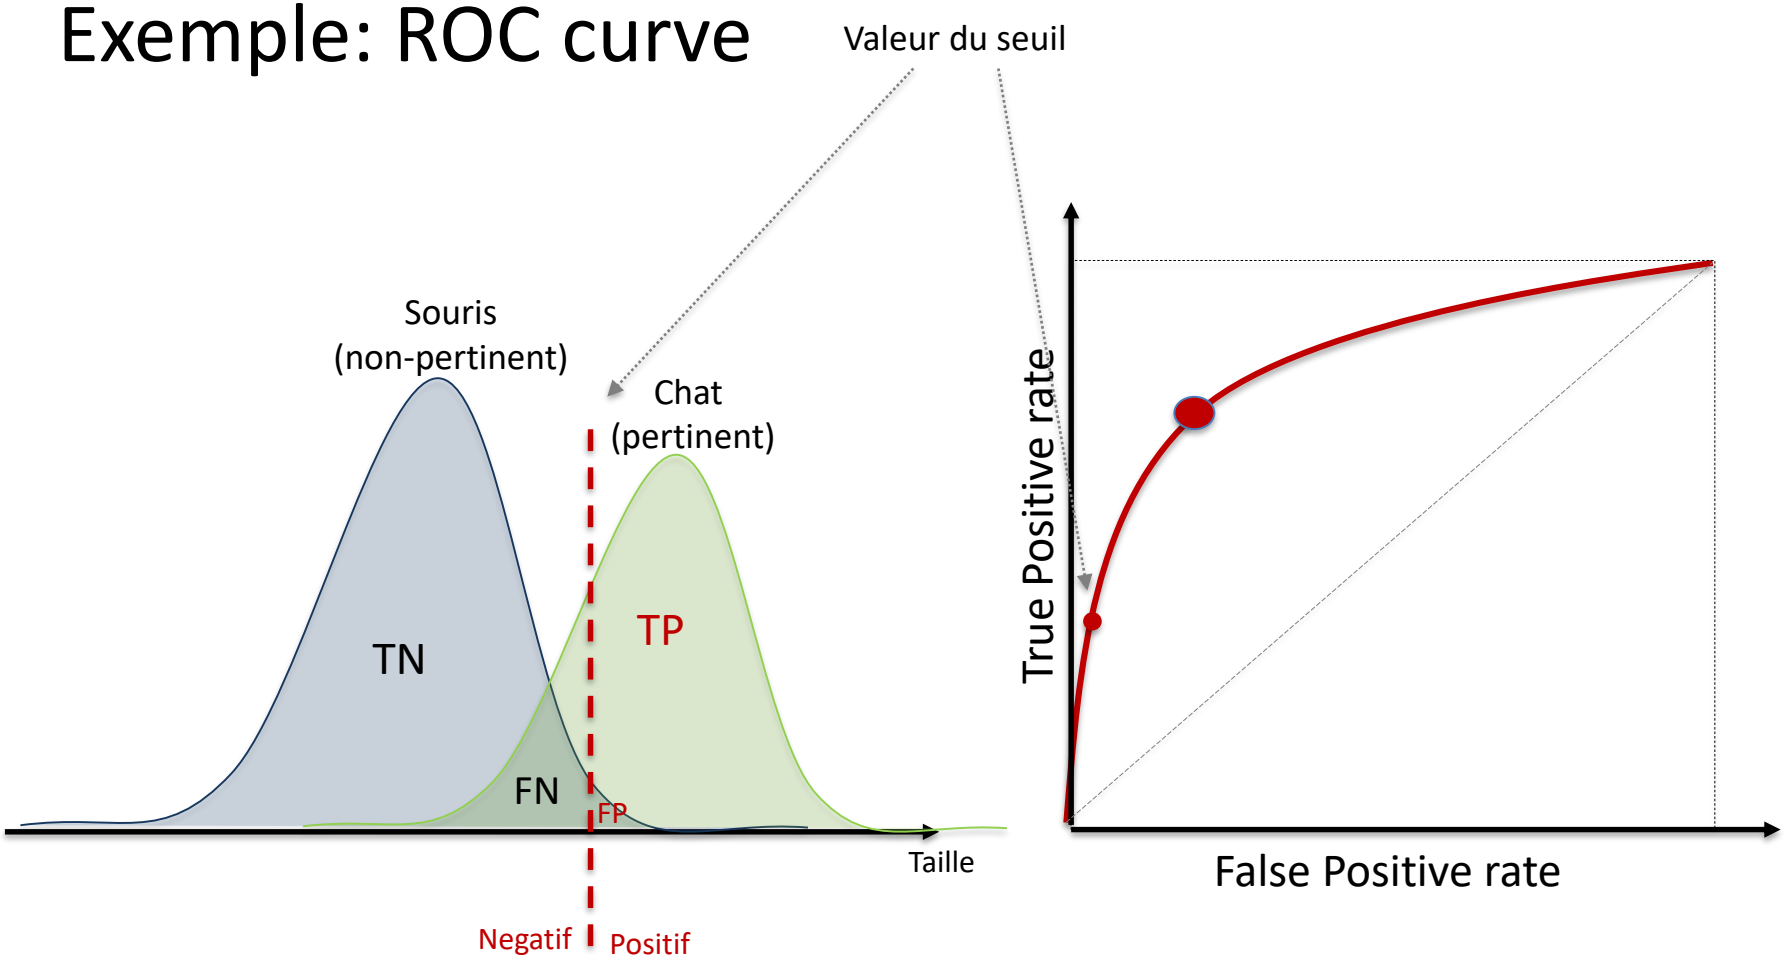

Evaluation

- Error rate: $ER=\frac{FP+FN}{TP+TN+FP+FN}$
  - Potentiellement normalisé par la taille des classes

  → P(erreur|paramètres θ)

- Précision/Rappel (*information retrieval*)

$$P=\frac{TP}{TP+FP} \qquad R=\frac{TP}{TP+FN}$$

  → mAP: *mean Average Precision*

- F_1 score: $F_1 = \frac{2PR}{P+R}$

Protocole supervisé

$$\theta^* = \underset{\theta}{\operatorname{argmin}}\, L(\phi_\theta\,(\mathrm{X}); \mathrm{X})$$

Entrainement: On utilise les données pour estimer θ^*:

- On utilise les données d'entrainement labelisées pour minimiser L(.,.)

→ On obtient pour une certaine erreur d'entrainement (*training error*)

Test: On évalue les performances du modèle ϕ_{θ^*} avec des données inconnues jusque la:

- On teste le modèle appris ϕ_{θ^*} avec des données de test labelisées (indépendantes de l'entrainement) dont on cache le label

→On obtient l'erreur de test (*test error*). C'est celle qui définit les performances du modèle

Validation

Le modèle contient en général des hyper-paramètres (paramètres d'architecture)

Exemples:

- Degré d'une fonction de régression
- Nombre de neurones

On rajoute une étape de validation dans l'entrainement pour tester plusieurs valeurs d'hyper-paramètres. On utilise (et teste) le modèle donnant l'erreur d'entrainement la plus basse.

Entrainement:

Pour chaque valeur d'hyper-paramètre:

Entrainer le modèle sur l'ensemble E

Valider sur l'ensemble V

Choisir les paramètres θ^* qui minimisent l'erreur d'entrainement

Test:

Utiliser l'ensemble de données T pour tester le modèle (*test error*)

Protocole d apprentissage

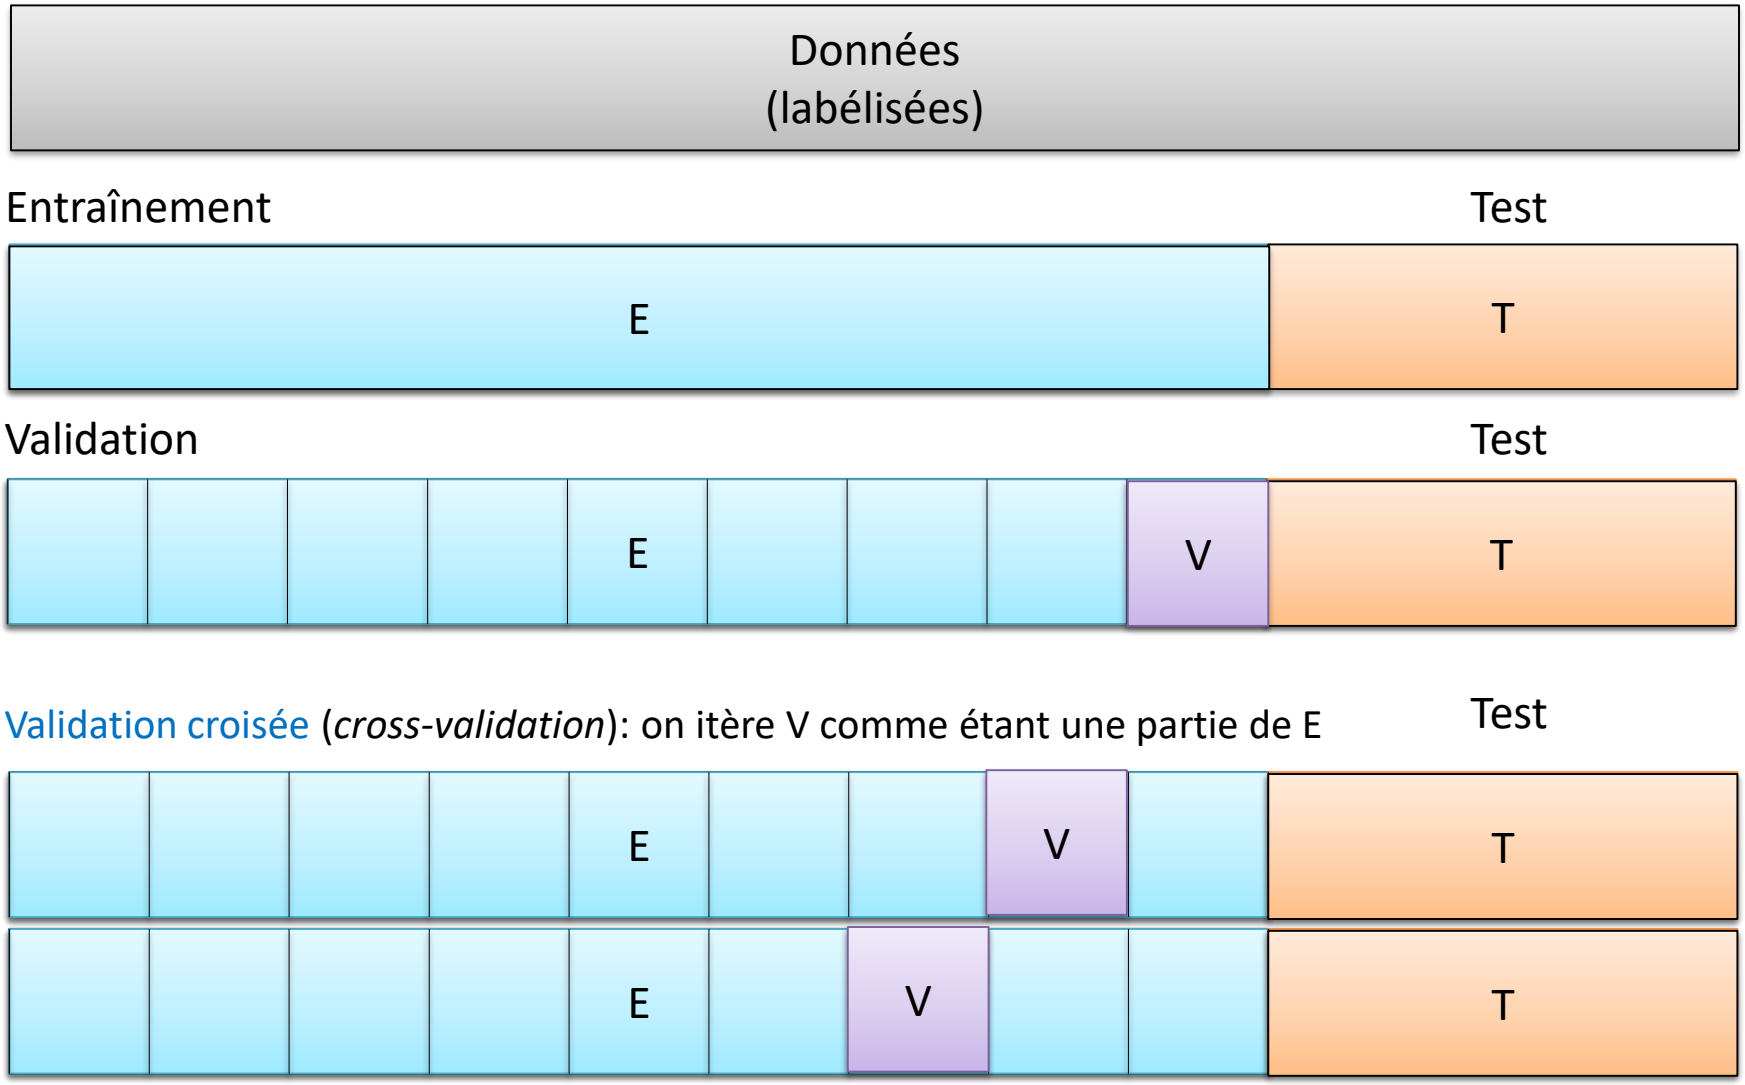

Propriétés

Simplicité (parcimonie) des modèles:

- On cherche un compromis entre la simplicité du modèle et sa performance
- Principe de parcimonie (cf Rasoir d'Occam)
  - Cf critères « *Information Criterion* »: BIC, AIC, …

Simplicité:

- Moins de paramètres → meilleure estimation à volume de données constant
- Données bruitées → on ne veut pas apprendre les détails des données (sur-apprentissage)
- Complexité moindre (sémantique et computationnelle)

Sur-apprentissage

On apprend les détails (bruit dans les données)

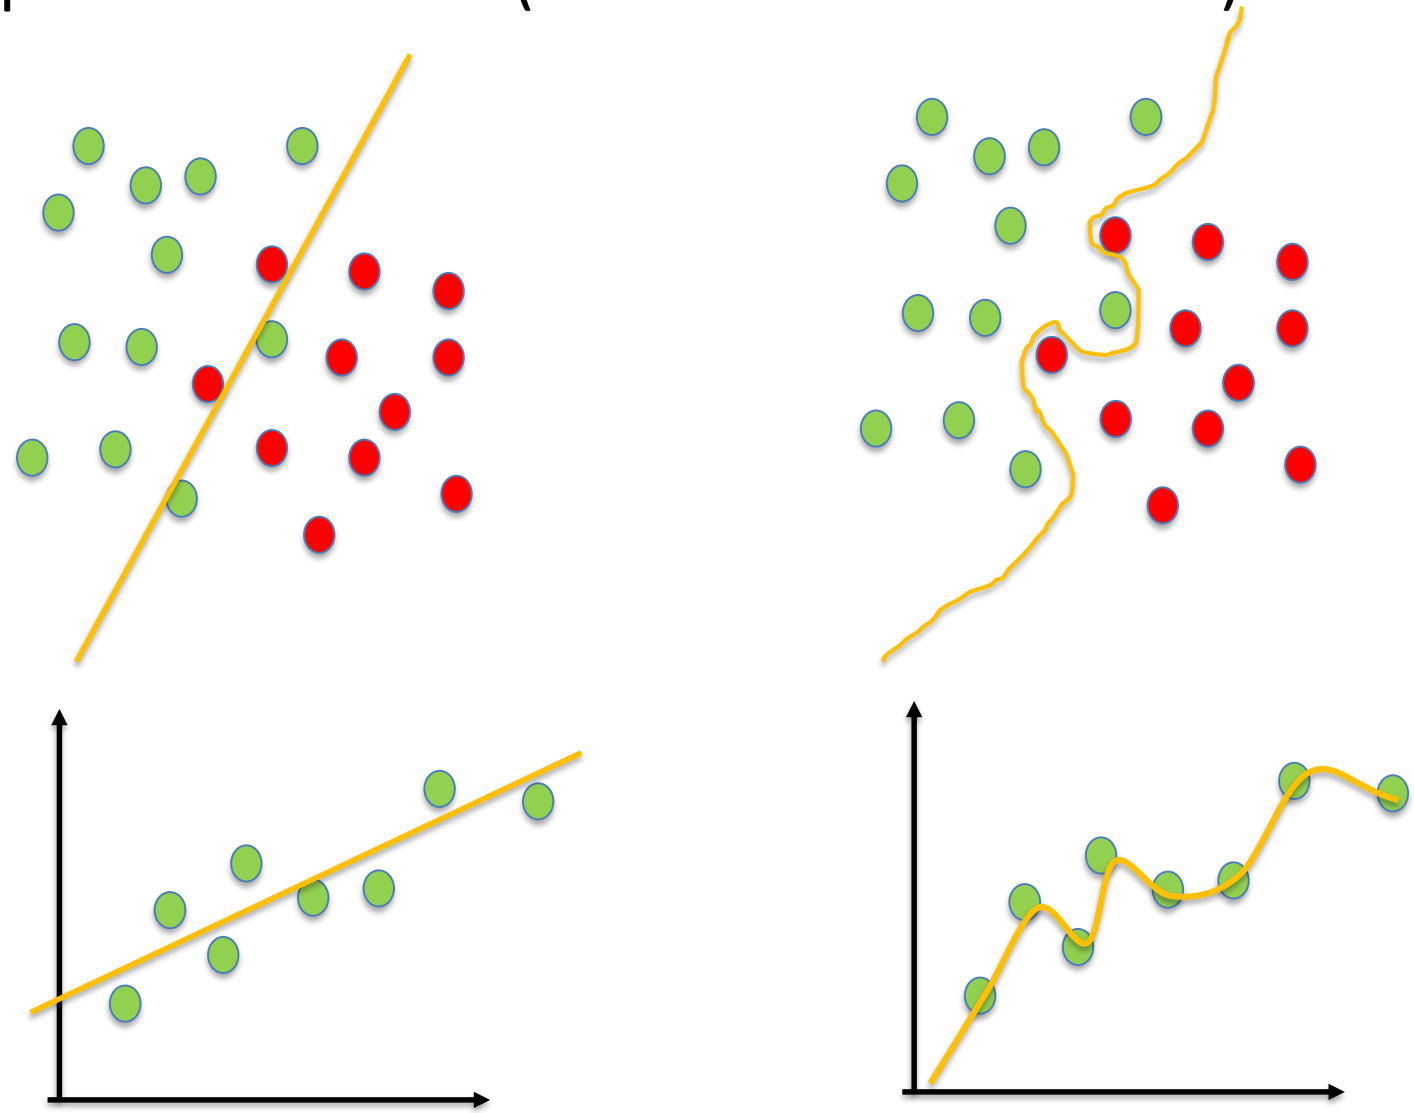

Généralisation

On cherche un modèle efficace hors des données d'entrainement:

- Trop simple: mauvaise prédiction
- Trop complexe: il apprend les données sans se préoccuper de l'espace entre les données

→On cherche une certain niveau de continuité de l'information

En général:

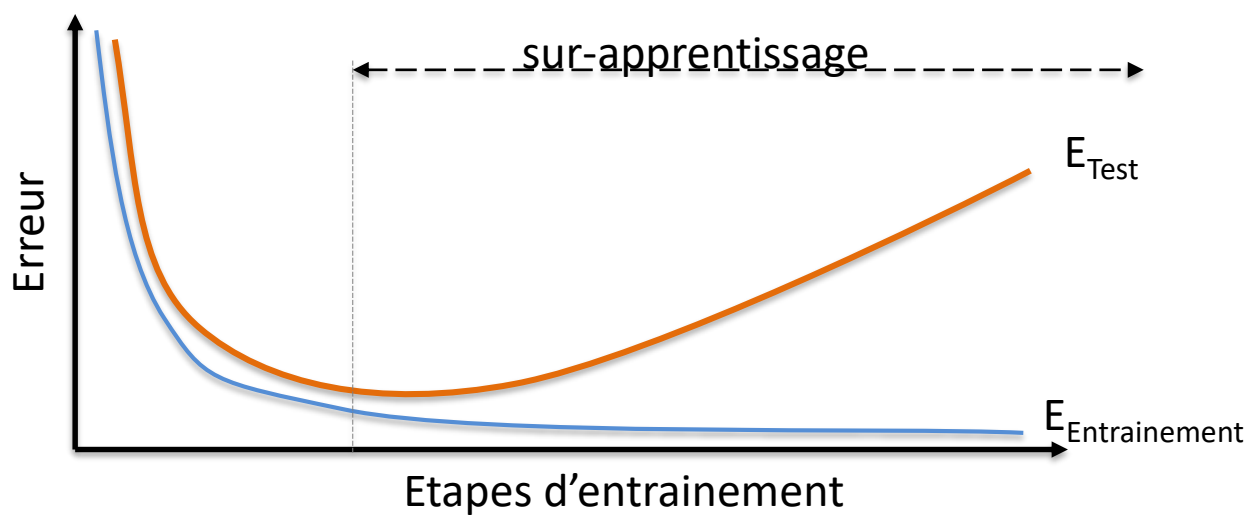

Résumé

- L'apprentissage se base sur les données pour estimer la réalité comme une «fonction» (dont on estime les paramètres)
- Le choix de représentation des données est important pour les performances
- Le protocole d'apprentissage inclut:
  - Un objectif, un modèle, des données labélisées et une mesure d'évaluation
- Les données sont la vue partielle du monde auquel le modèle a accès (en plus de ses propres hypothèses)
  - Leur choix (représentativité : volume, diversité) est important pour éviter les biais, le sur-apprentissage et le manque de généralisation
  - La validation croisée permet de diversifier les données et de fournir une statistique (variance) sur les résultats

Outlook

Dans ce cours nous verrons:
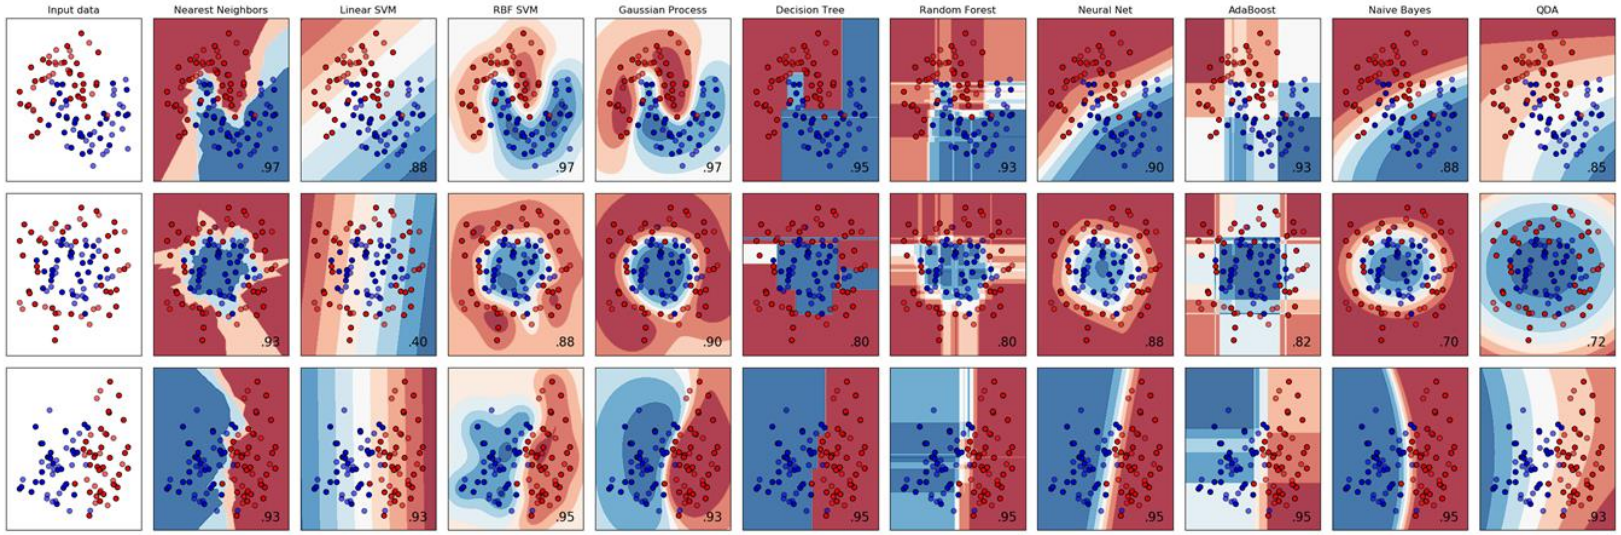
- Les arbres de décision
- Les réseaux Bayésiens
- Le classifieur « Naive Bayes »
- Les réseaux de Neurones