Intelligence Artificielle

Modèles de graphes pour les probabilités
Probabilistic Graphical Models

Stéphane Marchand-Maillet

Contenu

Rappel: notions fondamentales

Probabilistic Graphical Models (dirigés/discrets)

Indépendance conditionnelle

Flot d information

Rappel: Notions fondamentales

- Probabilité jointe: $P(A \cap B)=P(A,B)$
  $P((X=x) \wedge (Y=y))=P(x,y)$
- Probabilité conditionnelle: $P(B|A)=\frac{P(A,B)}{P(A)}$
  $P((X=r)|(Y=u_1))=P(r|u_1)$

- Règle de produit: $P(X,Y)=P(X|Y)P(Y)$
- Règle de la somme: $P(X)=\Sigma_y P(X,Y=y)$ (marginalisation)

- Indépendance: $P(A,B)=P(A)P(B)$
  $P((X=x) \wedge (Y=y)) = P(X=x)P(Y=y)$
  - On note $X \perp Y$ (en fait $X \perp\!\!\!\perp Y$)
  - Contre exemple: $P((X=r) \wedge (Y=u_1)) \neq P(X=r)P(Y=u_1)$

(*Probabilistic*) *Graphical Models*

Principe général: on utilise les graphes pour organiser les relations

Ici: on modélise les relations de dépendances (indépendance) probabiliste entre variables aléatoires

Exemple: soient 2 variables aléatoires X et Y non indépendantes:

temporalité →

$$P(X,Y)=P(Y)P(X|Y)$$

On notera:

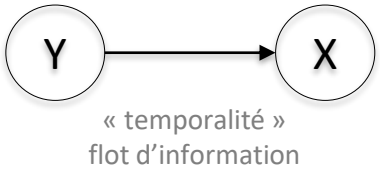

Note: on peut aussi avoir des relations non-dirigées (pas/peu abordé dans ce cours)

(*Probabilistic*) *Graphical Model*

Sur cette idée on peut définir un *Probabilistic Graph Model* (PGM):

Soit un ensemble de variables aléatoires $V=\{X_1,\ldots,X_N\}$

Soit $G=(V,\Gamma)$ un graphe construit sur V, où $\Gamma(X_i)\subseteq V$ contient les variables dépendantes de X_i

alors la probabilité jointe $P(X_1,\ldots,X_N)$ se factorise selon G si elle s'exprime selon le produit:

$$P(X_1 \ldots X_N) = \prod_{i=1}^{N} P\left(X_i \middle| X_{\gamma_i}\right) \qquad \forall X_i \in V$$

avec $X\gamma_i=\Gamma^{-1}(X_i)$, les parents de X_i dans G

Les termes $P\left(X_i \middle| X_{\gamma_i}\right)$ sont les modèles probabilistes « locaux » correspondant aux distributions de probabilités conditionnelles (*Conditional Probability Distribution*, CPD)

Exemple

$V=\{X_1,X_2\}$

X_1 = « Choix d'une urne (u1,u2) »

X_2 = « Tirage d'une balle (r,b) »

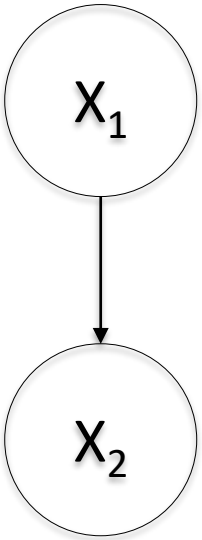

$\Gamma(X_1)= \{X_2\}$ $\quad$ $\Gamma^{-1}(X_1)= \emptyset = X\gamma_1$

$\Gamma(X_2)= \emptyset$ $\quad$ $\Gamma^{-1}(X_2)=\{X_1\}=X\gamma_2$

$$P(X_1,X_2) = \prod_{i=1}^{2} P\left(X_i \middle| X_{\gamma_i}\right)$$
$$= P\left(X_1 \middle| X_{\gamma_1}\right) P\left(X_2 \middle| X_{\gamma_2}\right)$$

$$\Rightarrow \quad P(X_1,X_2)= P(X_1)P(X_2|X_1)$$

Modèles locaux / *CPD*

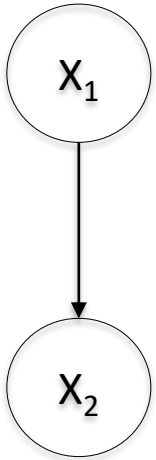

X_1	u1	u2
$P(X_1)$	0.6	0.4

ou

$P(X_2 \mid X_1)$	X_2=r	X_2=b
X_1=u1	0.6	0.4
X_1=u2	0.6	0.4

ou 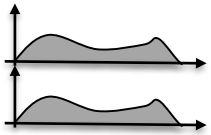

Variable binaires:
On a des tables de taille 2^{k+1} avec k le nombre de parents d'une variable

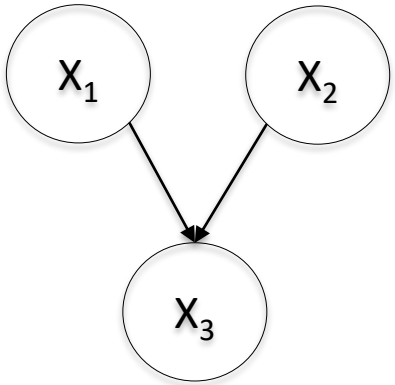

$P(X_3 \mid X_1, X_2)$		X_2=T	X_2=F
X_1=T	X_2=T	0.5	0.5
	X_2=F	0.6	0.4
X_1=F	X_2=T	0.7	0.3
	X_2=F	0.1	0.9

ou 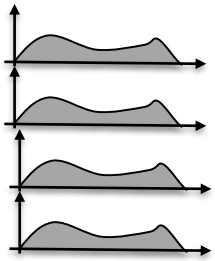

Notation complémentaire

- Si on observe une variable aléatoire (p.ex si elle fait partie de l'ensemble d'entrainement), elle devient fixe (déterministe)

→Noeud grisé

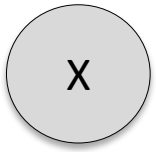

- Si une variable est composée de variables (composantes) indépendantes

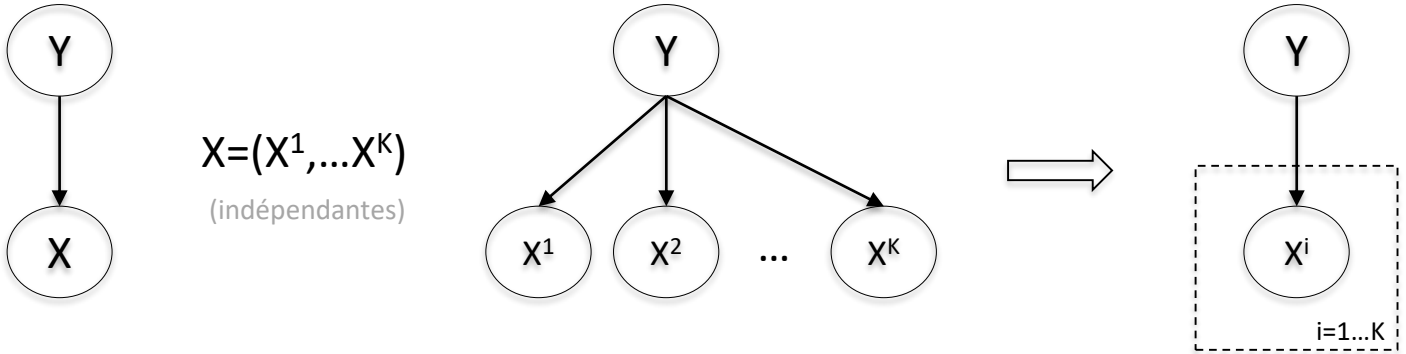

Plate Notation

(*Probabilistic*) *Graphical Model*

PGM:

- Si on détecte des indépendances entre les variables (ce qui est en général le cas), on réduit k (le degré maximal du graphe) et donc la complexité (volume) des calculs et représentations.
- Le PGM rend lisible le modèle en affichant les indépendances et une forme de temporalité (flot d'information) entre les variables (représentant les paramètres ou concepts du problème)

→ Le PGM introduit/capture une sémantique dans la modélisation et permet une meilleure abstraction/compréhension (voire simplification) de ces modèles

Exemple

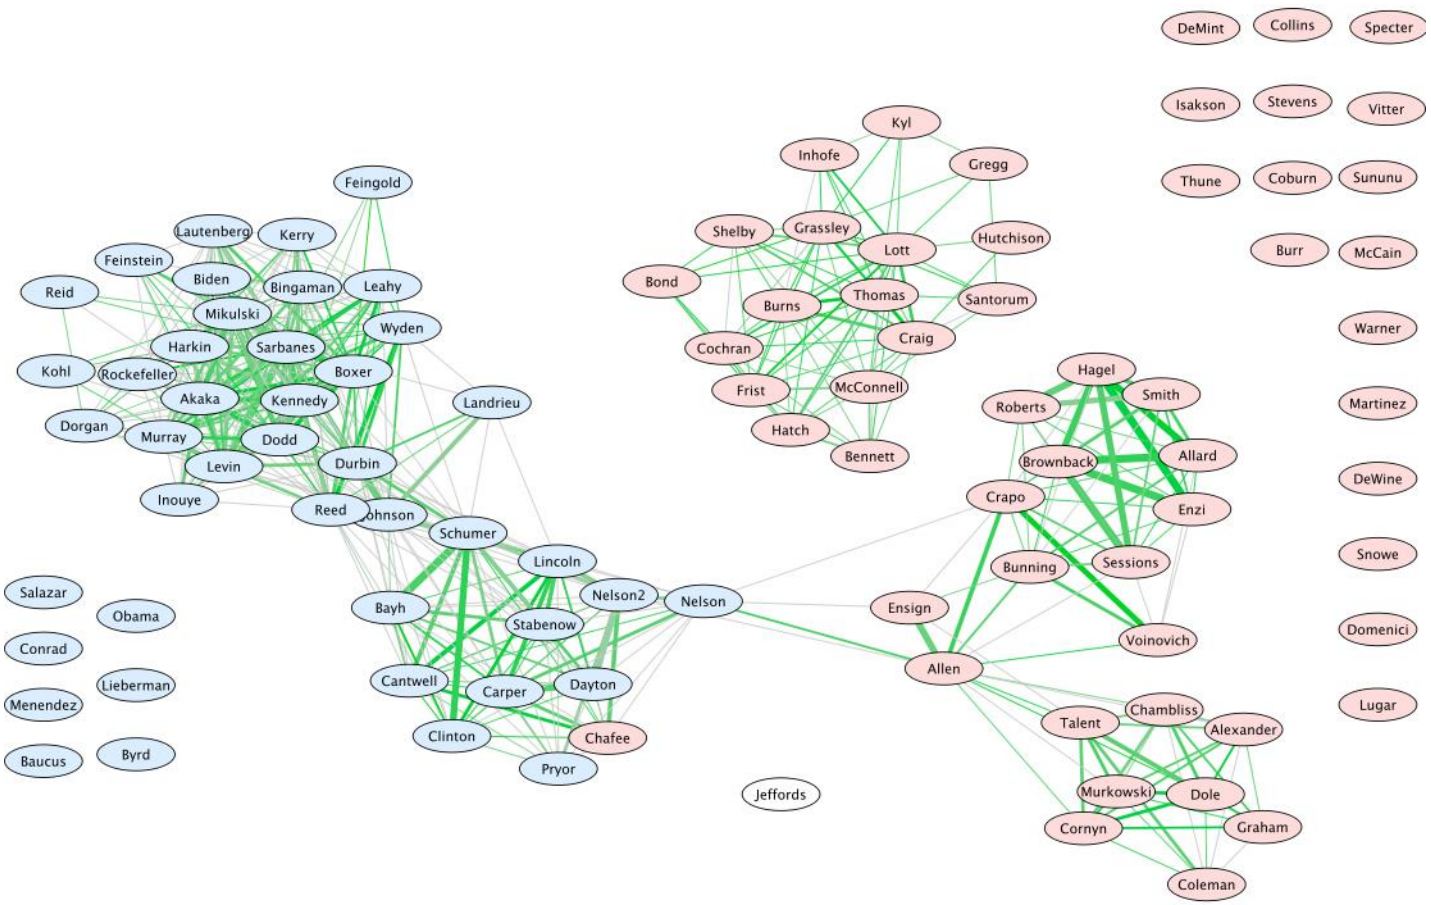

”Graphical model of Senate voting 2004-2006”

https://people.eecs.berkeley.edu/~elghaoui/StatNews/ex_senate.html

(non-orienté)

Exemple

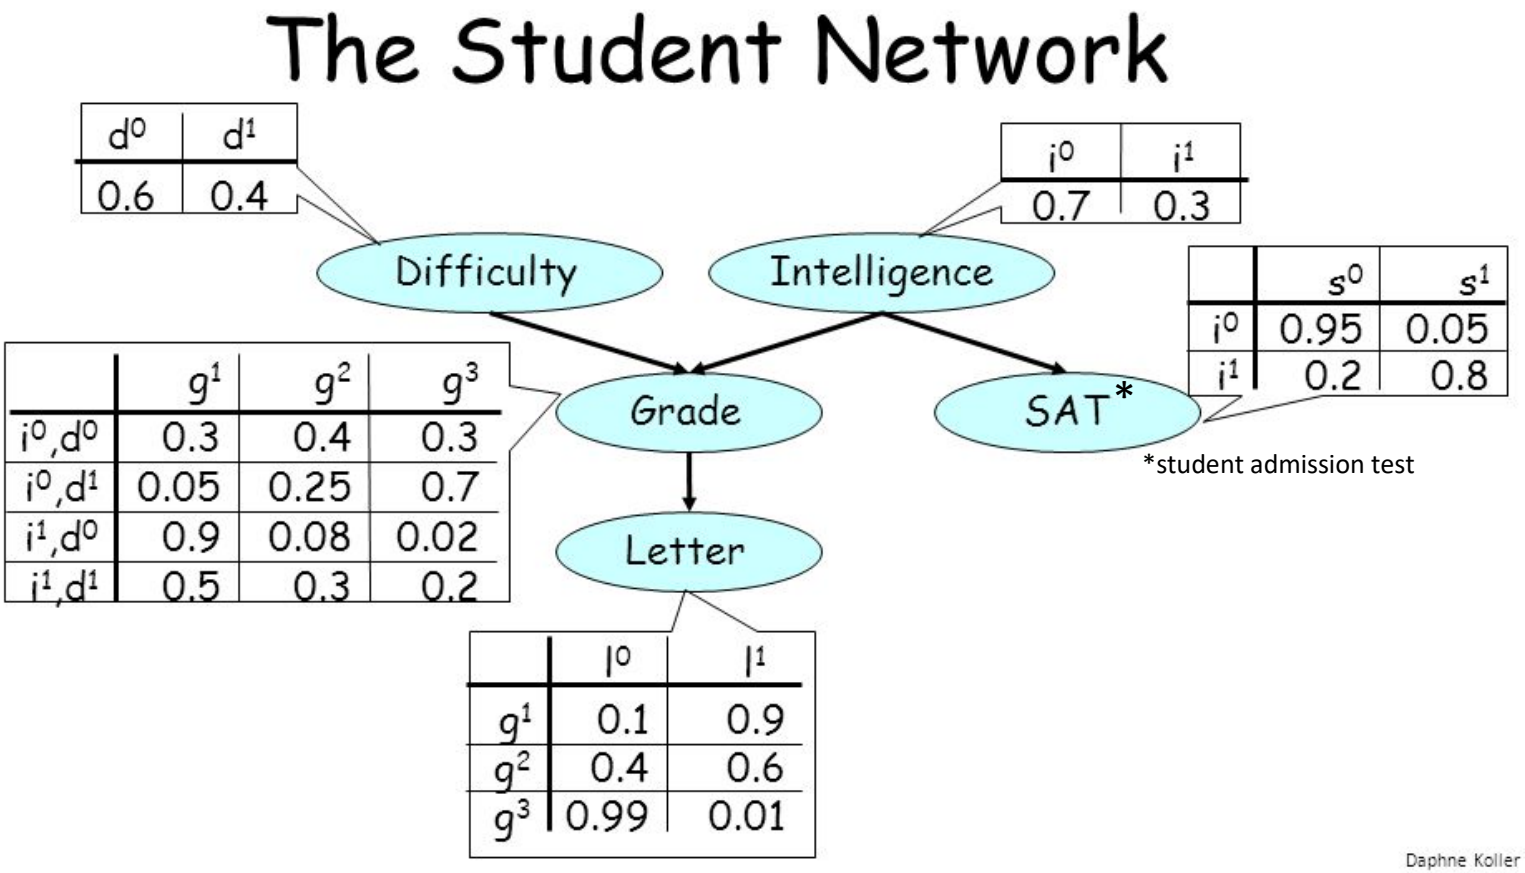

d^0	d^1
0.6	0.4

i^0	i^1
0.7	0.3

	s^0	s^1
i^0	0.95	0.05
i^1	0.2	0.8

	g^1	g^2	g^3
i^0,d^0	0.3	0.4	0.3
i^0,d^1	0.05	0.25	0.7
i^1,d^0	0.9	0.08	0.02
i^1,d^1	0.5	0.3	0.2

	l^0	l^1
g^1	0.1	0.9
g^2	0.4	0.6
g^3	0.99	0.01

(orienté, DAG = réseau Bayésien)

« Contre » exemple

Graphe complet:
Par l'application successive de la règle du produit on a:

$$P(W,X,Y,Z) = P(W).P(X,Y,Z|W) = P(W).P(X|W).P(Y,Z|X,W)$$

$$P(W,X,Y,Z)= P(W).P(X|W).P(Y|X,W).P(Z|W,X,Y)$$

Table $2^{(N-1)+1}=2^N$

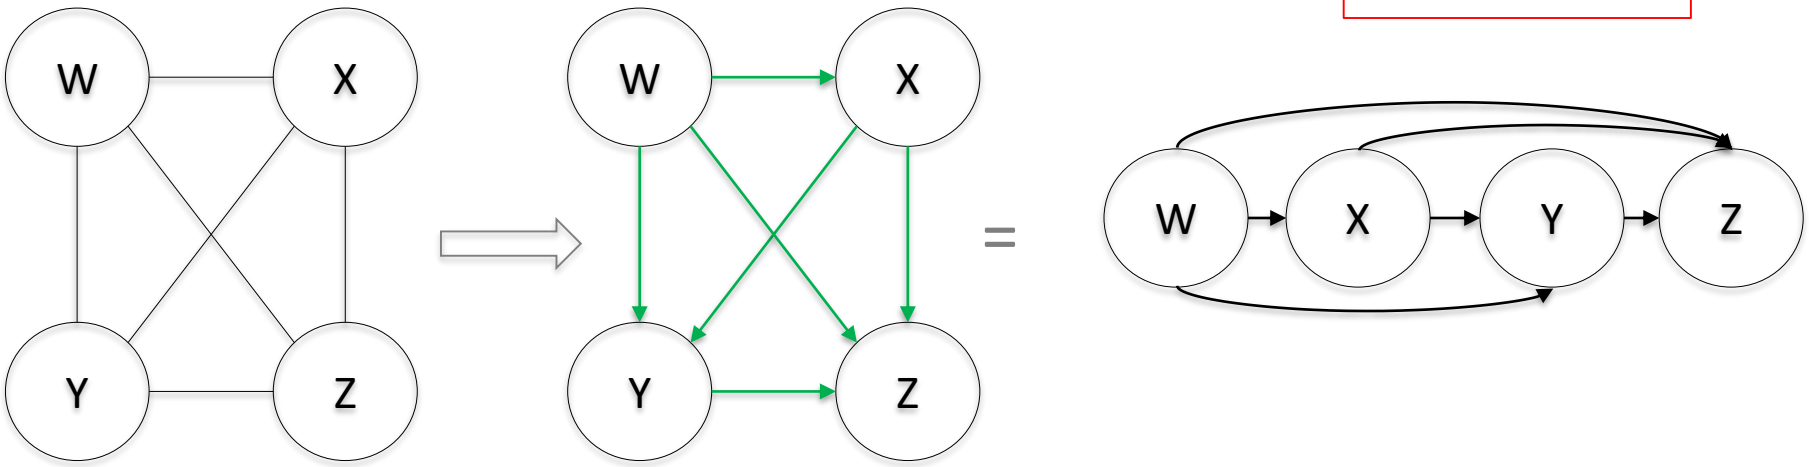

P(W,X,Y,Z)

P(W).P(X|W).P(Y|X,W).P(Z|W,X,Y)

Attention: Arbre de décision

Un arbre de décision représente une séquence de décisions et leurs branchements possibles

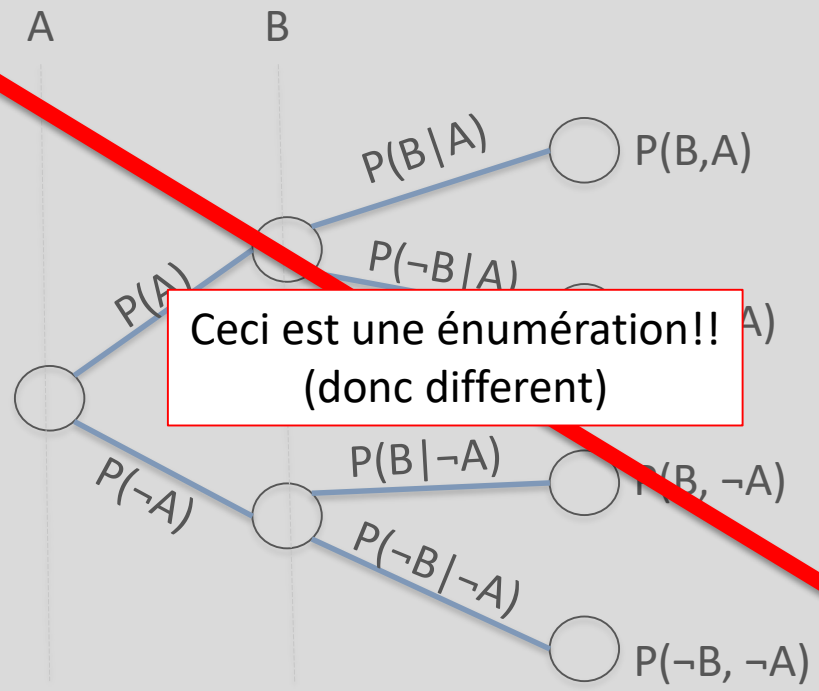

Ceci est une énumération!!
(donc different)

- La probabilité d'un nœud est le produit des probabilités le long du chemin
- L'arbre n'est pas forcément binaire

Configuration

Chaine de Markov (*head-to-tail*)

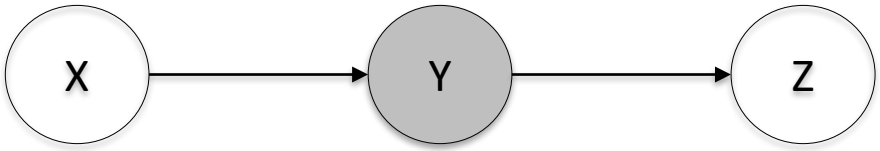

$$P(X,Y,Z)=P(X)P(Y|X)P(Z|Y)$$

$$\Longrightarrow P(Z|X,Y)=\frac{P(X,Y,Z)}{P(X,Y)}=\frac{\cancel{P(X)P(Y|X)}P(Z|Y)}{\cancel{P(X)P(Y|X)}}$$

$$P(Z|X,Y)=P(Z|Y)$$

→ Z est indépendant de X sachant Y

$(X \perp Z)|Y$ mais pas $\cancel{(X \perp Z)|\emptyset}$

→ indépendance conditionnelle

→ La variable observée «bloque» l'information entre X et Z

Independence conditionnelle

Dans le cas général:

$P(X,Y,Z)=P(X)P(Y|X)P(Z|X,Y)$

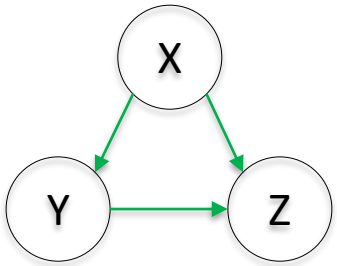

ou:

$P(X,Y,Z)=P(Y)P(X|Y)P(Z|X,Y)$

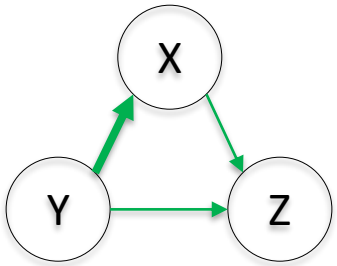

Si on observe X (par exemple)

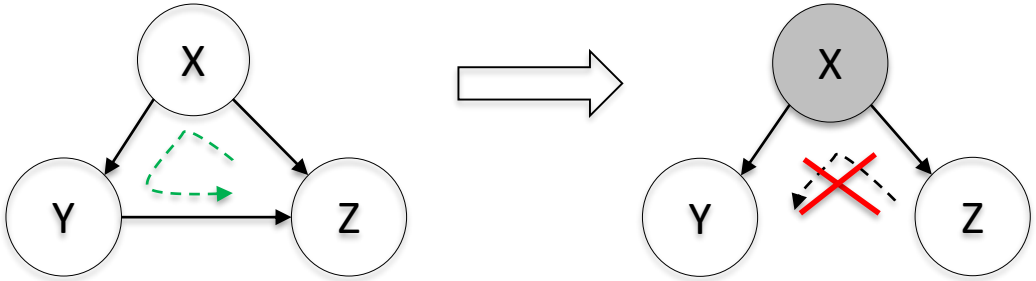

$P(X,Y,Z)=P(X)P(Y|X)P(Z|X)$

$(Y \perp Z)|X$

Configuration

Chaine de Markov (*head-to-tail*)

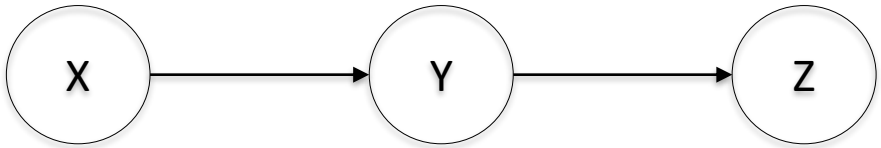

$$P(X,Y,Z)=P(X)P(Y|X)P(Z|Y)$$

$$P(X,Z)= \Sigma_y P(X,Y,Z) = \Sigma_y P(X)P(Y|X)P(Z|Y) \neq P(X)P(Z)$$

Rappel: $P(X,Z|Y) = P(X|Y)\ P(Z|Y)$

→ Z n'est indépendant de X en général (si Y n'est pas observé)

$(X \perp Z)|Y$ mais pas $\cancel{(X \perp Z)|\emptyset}$

(la présence d'un «chemin» indique une dépendance)

Configuration

« Cause commune » (*tail-to-tail*)

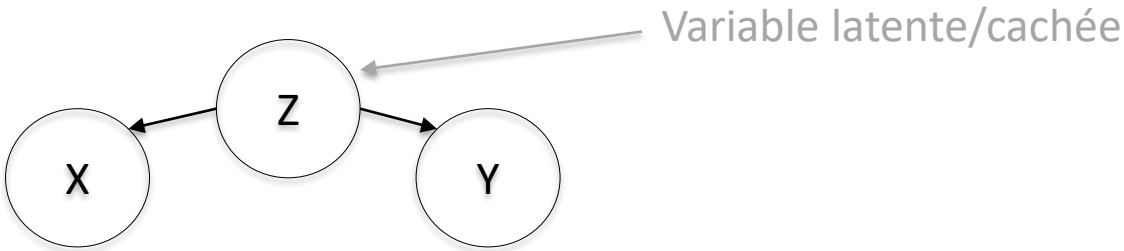

$$P(X,Y,Z)=P(Z)P(X|Z)P(Y|Z)$$

$$P(X,Y) = \Sigma_z P(X,Y,Z) = \Sigma_z P(Z)P(X|Z)P(Y|Z) \neq P(X)P(Y)$$

→ X n'est pas indépendant de Y en général

$$\cancel{(X \perp Y)|\emptyset}$$

(on trouve un «chemin» entre X et Y)

Configuration

« Cause commune » (*tail-to-tail*)

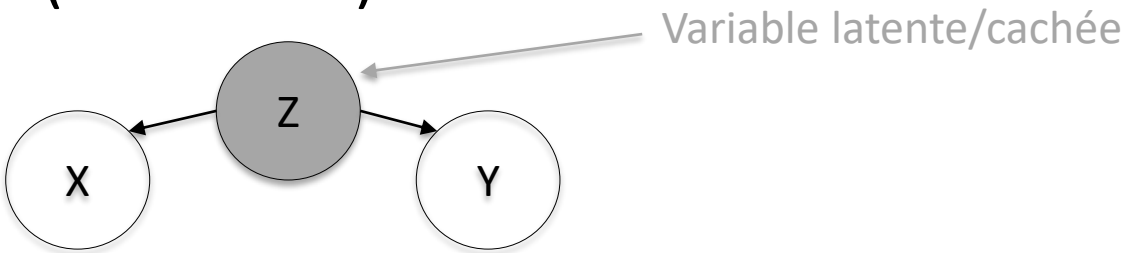

$$P(X,Y,Z)=P(X|Z)P(Y|Z)$$

$$\Longrightarrow P(X,Y|Z)=\frac{P(X,Y,Z)}{P(Z)}=\frac{\cancel{P(Z)}P(X|Z)P(Y|Z)}{\cancel{P(Z)}}$$

$$P(X,Y|Z)=P(X|Z)\,P(Y|Z)$$

→ X est indépendant de Y sachant Z

$(X \perp Y)|Z$ mais pas $\cancel{(X \perp Y)|\emptyset}$

→indépendance conditionnelle

Configuration

« Structure en V» (*head-to-head*)

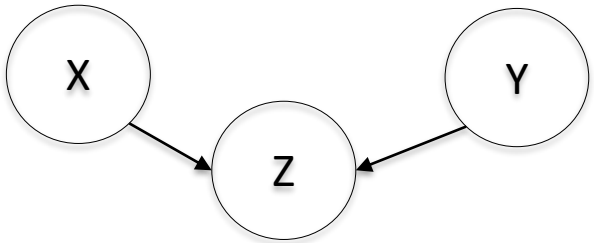

$$P(X,Y,Z)=P(X)P(Y)P(Z|X,Y)$$

$$\Longrightarrow P(X,Y)=\Sigma_z P(X)P(Y)P(Z|X,Y) = P(X)P(Y)\overbrace{\Sigma_z P(Z|X,Y)}^{=1}$$

$$\Longrightarrow P(X,Y)=P(X)P(Y)$$

→ X est indépendant de Y : $(X \perp Y)|\emptyset$

(malgré le «chemin» entre X et Y!!)

Configuration

« Structure en V» (*head-to-head*)

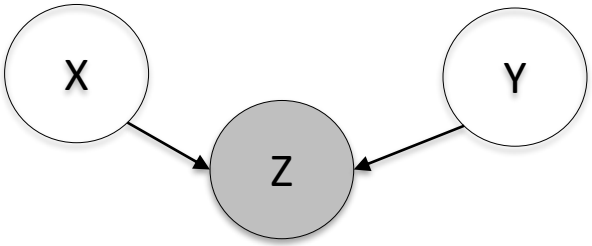

$$P(X,Y,Z)=P(X)P(Y)P(Z|X,Y)$$

$$\Longrightarrow P(X,Y|Z)=\frac{P(X,Y,Z)}{P(Z)}=\frac{P(X)P(Y)P(Z|X,Y)}{P(Z)}$$

$$\Rightarrow P(X,Y|Z) \neq P(X|Z)\,P(Y|Z)$$

→ X n'est pas indépendant de Y sachant Z : $\cancel{(X \perp Y)|Z}$
(idem si on observe un descendant de Z – à prouver)

→ Notion de couverture Markovienne (*Markov blanket*)

Exemple

X	p	f	p	f
Y	p	f	f	p
Z	V	F	F	F

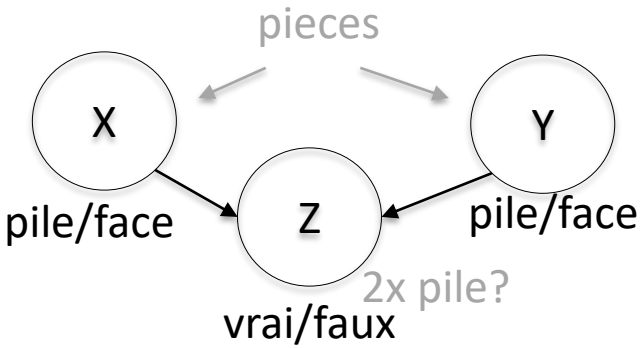

Les 2 pieces sont indépendantes (en general – en ignorant Z)

Supposons Z connu/observé (Z = Faux par exemple):

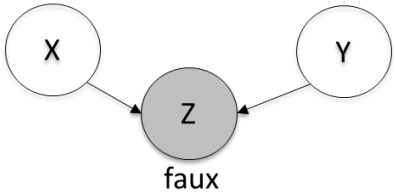

X	~~p~~	f	p	f
Y	~~p~~	f	f	p
Z	~~V~~	F	F	F

Z=F → P(X=p) = 1/3
P(Y=p) = 1/3

On observe X:

Z=F X=p → P(Y=p)=0
X=f → P(Y=p)=1/2

X a complètement expliqué Y
"X *explained away* Y"
→ Y devient inutile (déterministe)

Flot d'information (*D-separation*)

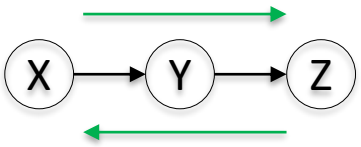

$\cancel{(X \perp Z) | \emptyset}$

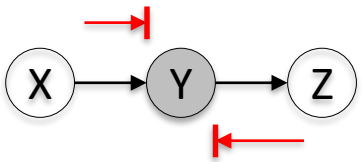

$(X \perp Z) | Y$

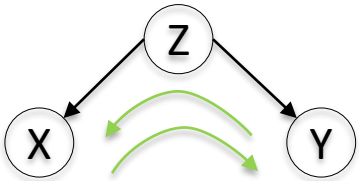

$\cancel{(X \perp Y) | \emptyset}$

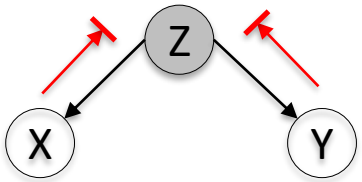

$(X \perp Y) | Z$

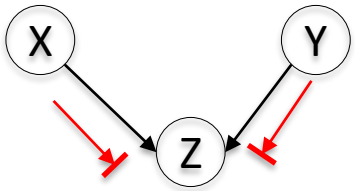

$(X \perp Y) | \emptyset$

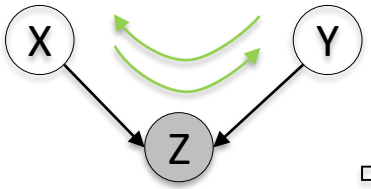

$\cancel{(X \perp Y) | Z}$

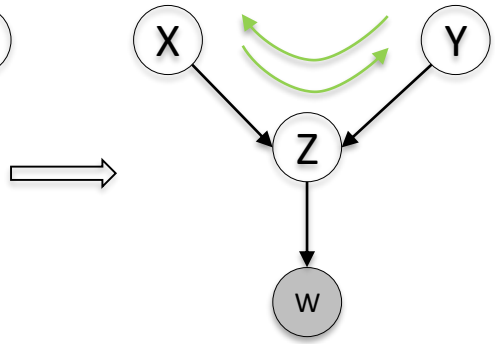

$\cancel{(X \perp Y) | W}$

→ Théorie de la D-separation (*direct separation*)

Markov blanket

Def: La couverture Markovienne de X est le plus petit sous-graphe contenant X tel que X est conditionnellement indépendant des autres variables si on observe les nœuds de ce sous-graphe

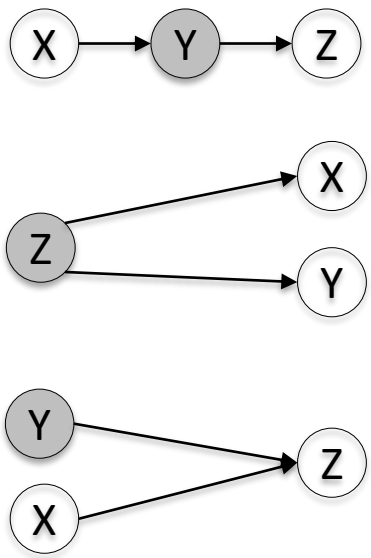

Enfants de X

Parents de X

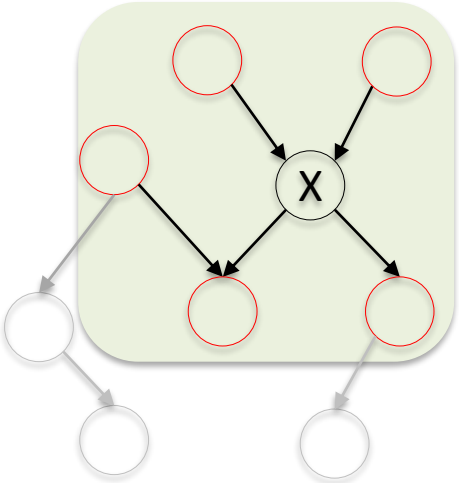

Autres parents des enfants de X

Moral graph (“fermeture probabiliste”)

C’est le graphe G=(V,E’) tel que:

$$(X,Y) \in E' \Leftrightarrow X \text{ est dans la couverture Markovienne de } Y$$

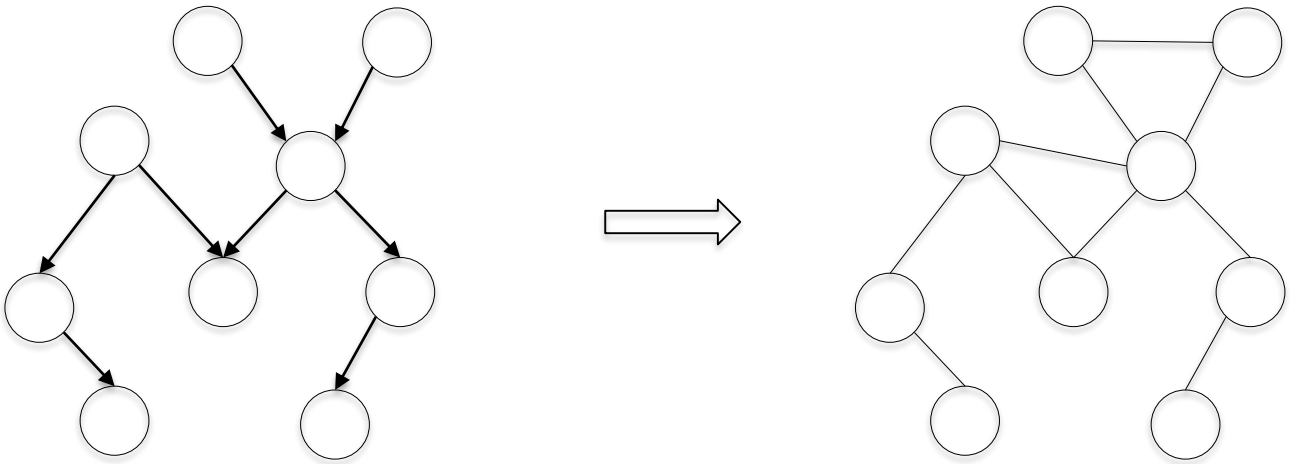

Le *moral graph* est utilisé pour l’inférence

Application: *Naive Bayes*

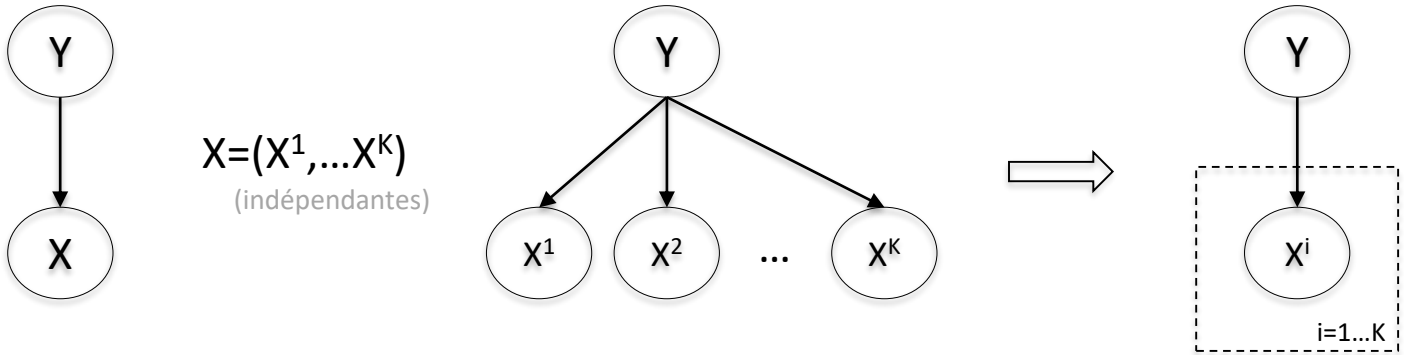

$$P(X,Y) = P(Y)P(X|Y) = P(Y)\,\Pi_k P(X^k|Y)$$

Résumé

Les modèles de graphes pour les probabilités permettent de modéliser l'indépendance

(C'est l'absence de relation qui donne l'indépendance – pas la réciproque)

L'indépendance conditionnelle n'est pas l'indépendance en général

L'indépendance conditionnelle est garantie pour tout nœud hors de la couverture Markovienne d'une autre nœud (par définition)

→ Simplifie les calculs d'inférence

→ Application (directe) aux Réseaux Bayésiens

Les GPM peuvent ne pas être orientés (HMM, CRF,…)