Intelligence Artificielle

Naive Bayes
Régression Logistique

Stephane Marchand-Maillet

Contenu

- *Naive Bayes*
- Régression logistique

Rappel: Protocole d apprentissage

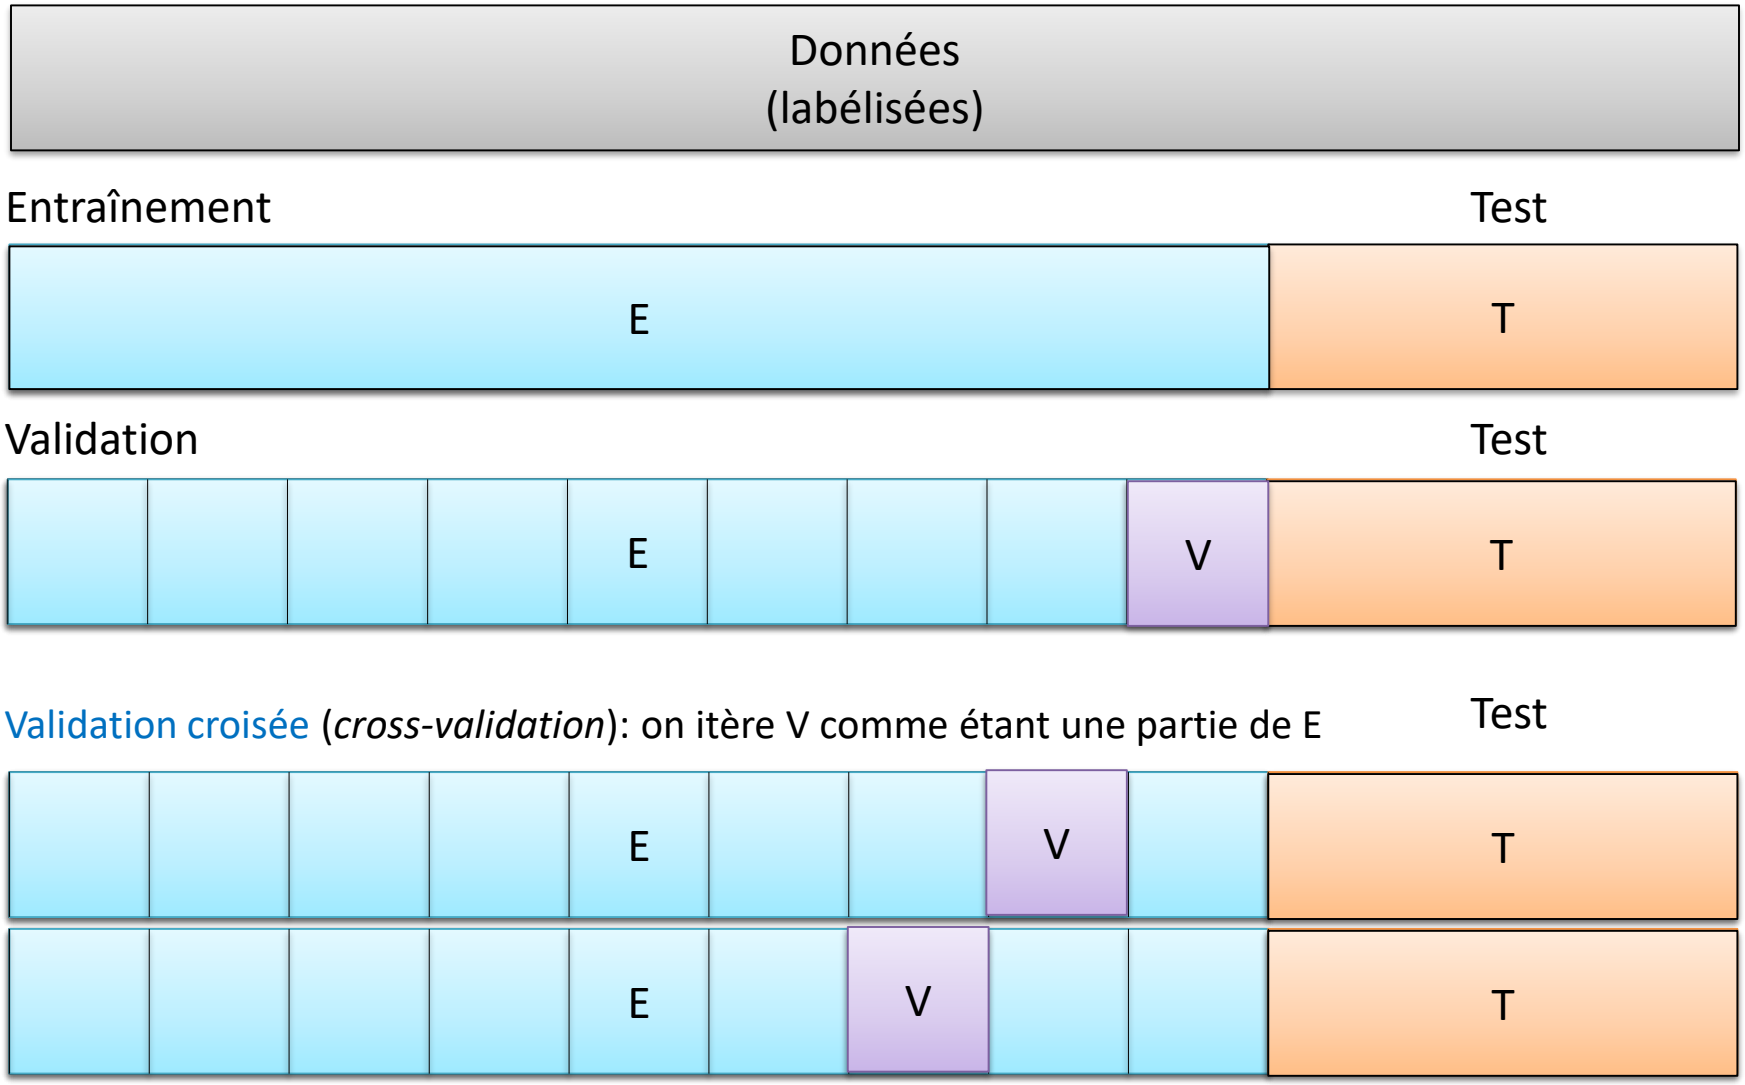

Formellement

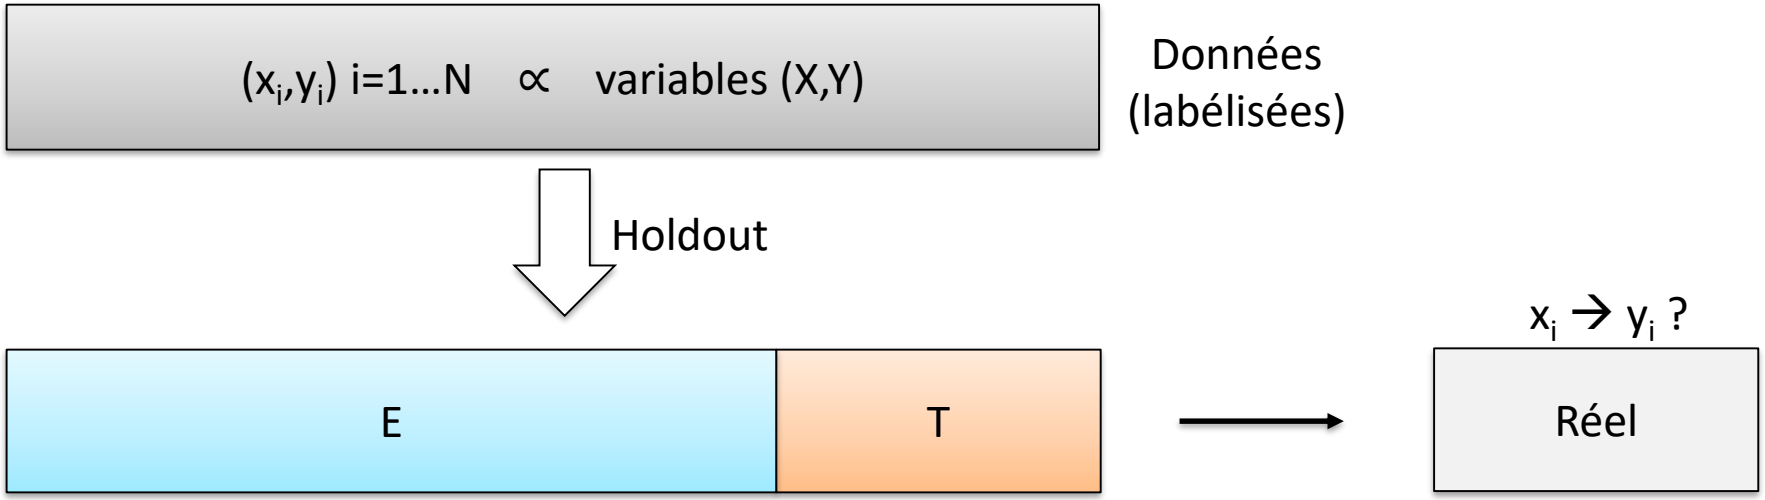

$x_i = [x_i^k] \in \mathcal{X} \subseteq \mathbb{R}^K$: Attributs des données de dimension K

$y_i \in \mathcal{Y} = \{1 \dots C\}$: Label (classe)

Classification

Etant donné un ensemble de données (X) labellisées (Y), on cherche à définir un classifieur:

$$\phi_\theta : \mathcal{X} \longrightarrow \mathcal{Y}$$

$$x_i \longrightarrow \phi_\theta(x_i) = y_i$$

(θ : paramètres)

Exemple: Classification de fruits

- Attributs continus: diamètre, poids
- Attributs discrets: nombre de feuilles, couleur, forme

Rappel: Théorème de Bayes

likelihood *prior*

$$P(B|A)=\frac{P(A|B)P(B)}{P(A)}$$

posterior *evidence*

On place nos observations
sous l'hypothèse de la cause…

…tout en ayant un apriori
sur la présence de la cause
(indépendamment de l'effet)…

$$P(\text{cause}|\text{effet})=\frac{P(\text{effet}|\text{cause})P(\text{cause})}{P(\text{effet})}$$

On cherche à savoir si la cause
est probable étant données nos observations

…et un apriori
sur la présence de l'effet
(indépendamment de la cause)

Exemples: $P(\text{maladie}|\text{sympôme}) = \frac{P(\text{symptôme}|\text{maladie})P(\text{maladie})}{P(\text{symptôme})}$ $P(\text{magic in the air}|\text{joie}) = \frac{P(\text{joie}|\text{magic})P(\text{magic})}{P(\text{joie})}$

Classification Bayésienne

likelihood *prior*

$$P(B|A)=\frac{P(A|B)P(B)}{P(A)}$$

posterior *evidence*

On cherche à transformer la vraisemblance d'une donnée dans une classe (observée)…

… normalisée par la vraisemblance de la classe…

$$P(\text{classe}|\text{donnée})=\frac{P(\text{donnée}|\text{classe})P(\text{classe})}{P(\text{donnée})}$$

… en la vraisemblance de la classe indiquée par la donnée

…tout en ayant un apriori sur la vraisemblance de la donnée (indépendamment de toute classe)

Classification Bayesienne

La classe estimée y~ est la plus vraisemblable:

→On calcule P(classe|donnée) = P(y~|x) pour toutes les classes et on choisit celle qui réalise le max

→Formellement:

$$\tilde{y} = \underset{y \in \mathcal{Y}}{\operatorname{argmax}}\, P(y|x)$$

→ C est un classifieur optimal au sens où on ne peut pas réduire l'erreur de classification

Classification Bayesienne

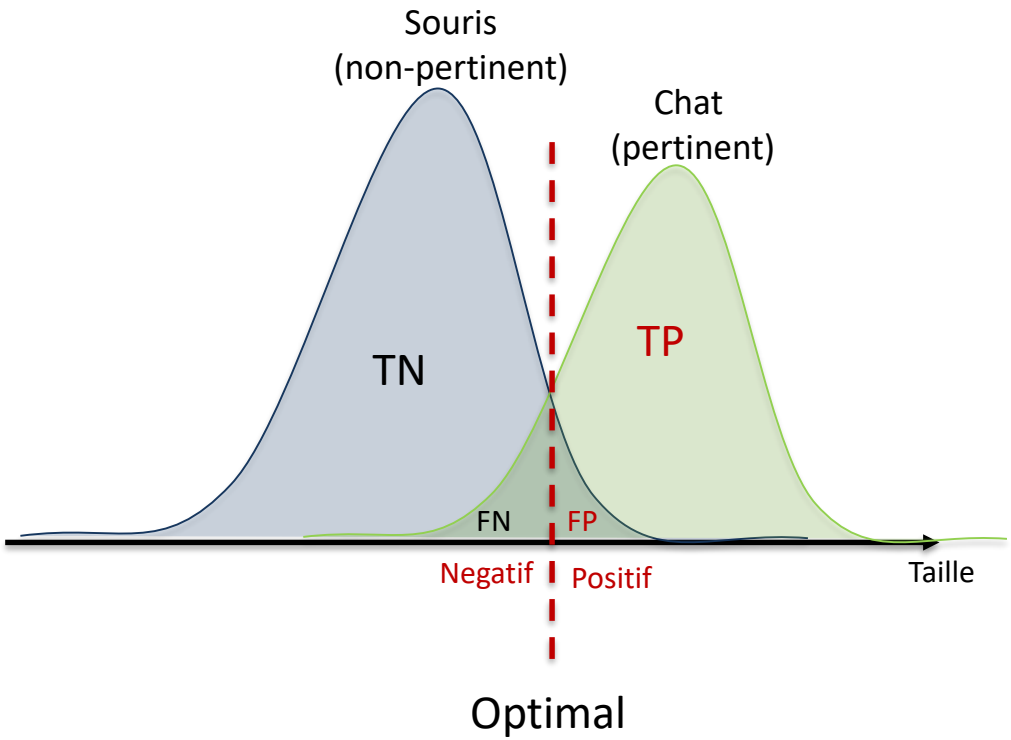

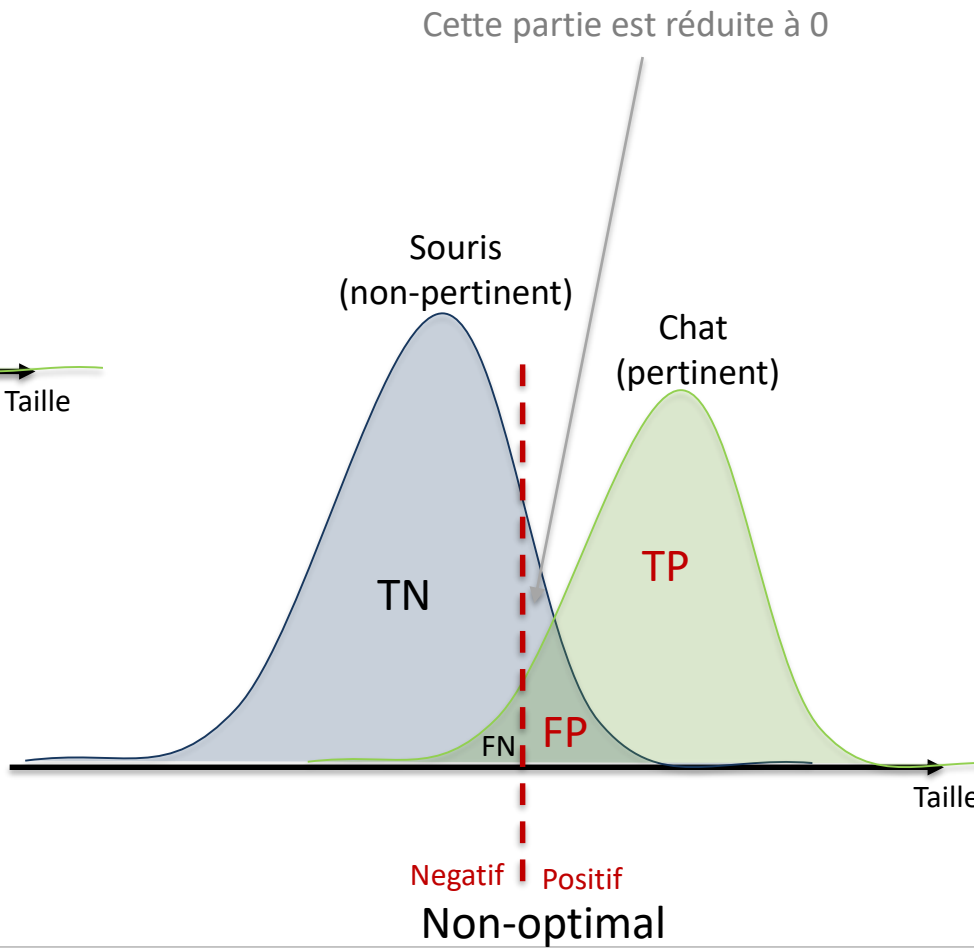

Classification Bayesienne

$$\tilde{y} = \underset{y \in \mathcal{Y}}{\operatorname{argmax}}\, P(y|x)$$

Etant donné x on cherche P(y|x)

Idéalement, grâce à l'ensemble d'entrainement on a une LUT: x → y

Mais x est complexe (multidimensionnel $x \in \mathbb{R}^K$) on ne l'a probablement jamais observé

Exemple: x=pixels d'une image de chat, on doit avoir déjà vu EXACTEMENT cette image (impossible)

→ On doit trouver un moyen de généraliser

Approche Bayésienne

Par le théorème de Bayes:

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}$$

La probabilité P(x) de chaque donnée est indépendante de la classe , de plus on cherche l'argmax, pas la valeur

→On ignore le dénominateur dans la maximisation

$$P(y|x) \propto P(x|y)P(y)$$

$$\tilde{y} = \underset{y \in \mathcal{Y}}{\operatorname{argmax}}\, P(x|y)P(y)$$

Remarque: données équiprobables

On considère souvent que chaque échantillon x_i est unique et « échantillonable » équitablement. Ce n'est pas forcément le cas..

Contre exemples:

- Urne avec des balles de matériaux différents: Les plus légères sont favorisées dans un tirage par le haut
- Population: on néglige le fait de personnes « identiques » (jumeaux, triplés,…)

Classifieur *Naive Bayes*

$$P(y|x) \propto P(x|y)P(y)$$

et $$P(x|y) = P(x^1, x^2, \ldots, x^K|y)$$

Telle que, P(x|y) serait trop complexe à estimer. On a besoin d'estimer toutes les relations entre les caractéristiques

Par la règle produit:

$$\begin{aligned} P(x|y) &= P(x^1, x^2, \ldots, x^K|y) \\ &= P(x^2, \ldots, x^K|x^1,y)\, P(x^1|y) \\ &= P(x^K|x^{K-1},\ldots,x^1,y) \ldots P(x^1|y) \\ &= \prod_k P(x^k|x^{k-1,\ldots,}x^1,y).\, P(x^1|y) \end{aligned}$$

Classifieur *Naive Bayes*

On accepte l'indépendance conditionnelle des attributs

Hypothèse: $P(x^k|x^{k-1,\dots,}x^1,y) = P(x^k|y)$

→Les attributs sont conditionnellement (à y) indépendants entre eux, alors:

$$P(x|y) = \prod_k P(x^k|x^{k-1,\dots,}x^1,y).\ P(x^1|y)$$

$$\rightarrow \quad P(x|y) = \prod_{k=1}^{K} P(x^k|y)$$

Classifieur *Naive Bayes*

On a donc:

$$\tilde{y} = \underset{y \in \mathcal{Y}}{\operatorname{argmax}} \; P(y) \prod_{k=1}^{K} P(x^k | y)$$

L'appartenance à la classe P(y|x) est une agrégation (produit) d'indications d'appartenance à la classe par les attributs P(xk|y)

Chaque classe porte sa signature par l'importance de chaque attribut dans les données de cette classe

→ Chaque attribut apporte son information (indépendante – complémentaire) sur la décision d'appartenance à une classe

→ On estime la distribution de chaque attribut. On ne cherche pas à séparer les attributs de chaque donnée

Rappel: *Naive Bayes* comme *PGM*

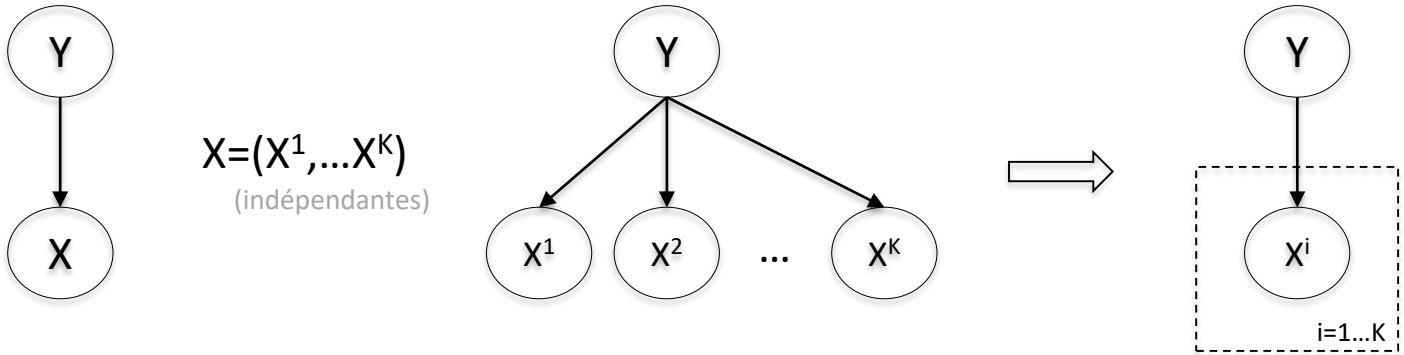

$$P(X,Y) = P(Y)P(X|Y) = P(Y)\,\Pi_k P(X^k|Y)$$

Estimation: Probabilité conditionelle

$$P(X|Y) = \frac{P(X,Y)}{P(Y)}$$

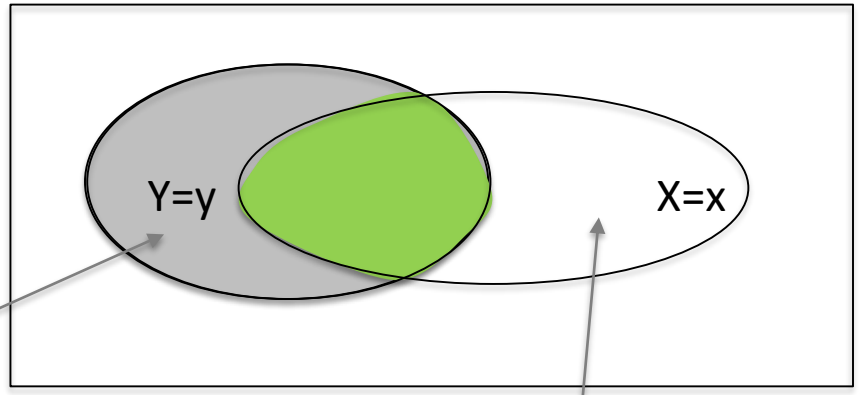

Données avec le label y

Données avec la caractéristique x

$$P_{est}(X|Y) = \frac{\#(X=x \wedge Y=y)}{\#(Y=y)}$$

Classifieur *Naive Bayes* (estimation)

Attributs discrets:

On peut estimer sur le *Training set* E par une approche fréquentiste:

$$P(y) = \frac{|\{x_i \text{ t.q } y_i = y\}|}{|\{x_i\}|}$$

Exemple:

P(Y=pomme) = proportion de pommes dans E

$$P(x^k|y) = \frac{|\{x_i \text{ t.q } x_i^k = xk \text{ et } y_i = y\}|}{|\{x_i \text{ t.q } y_i = y\}|}$$

Exemple:

P(jaune|pomme) = proportion de fruits jaunes parmi les pommes dans E

Classification par *Naive Bayes*

Exemple:

10 fruits:

P(Pomme)=?

P(Citron)=?

P(Vert|Citron)=?

Couleur	Taille	Fruit
Jaune	Moyen	Pomme
Rouge	Moyen	Pomme
Jaune	Moyen	Citron
Vert	Moyen	pomme
Vert	Petit	citron
Jaune	Moyen	Pomme
Vert	Gros	Pomme
Rouge	Petit	Pomme
Jaune	Moyen	Citron
Vert	Moyen	pomme

Naive Bayes: Modèle Gaussien

Attributs continus:

Au lieu de quantifier les attributs, on considère un modèle gaussien pour la valeur de chaque attribut x^k dans la classe y

$$P(x^k|y) = \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{(x^k-\mu_k)^2}{2\sigma_k^2}}$$

→ On estime les paramètres (moyenne, variance) de chaque attribut dans sa classe

Classification par *Naive Bayes*

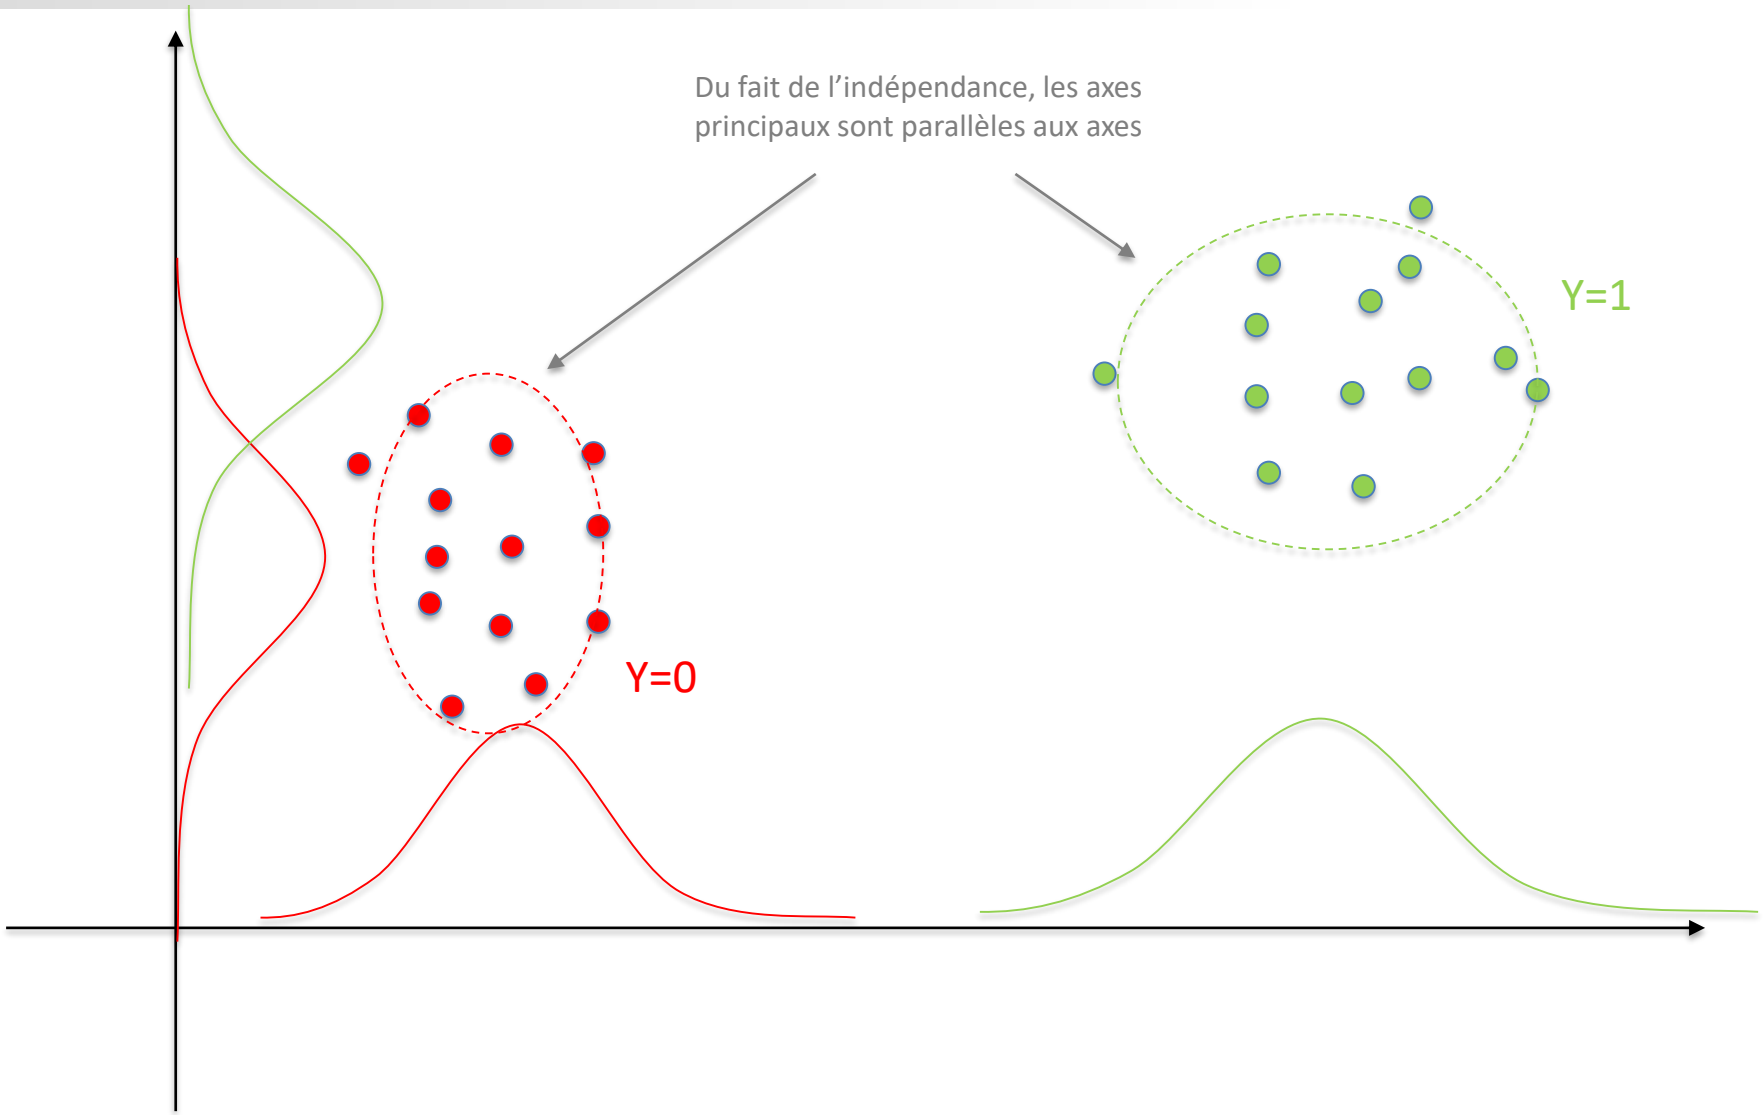

Classification par *Naive Bayes*

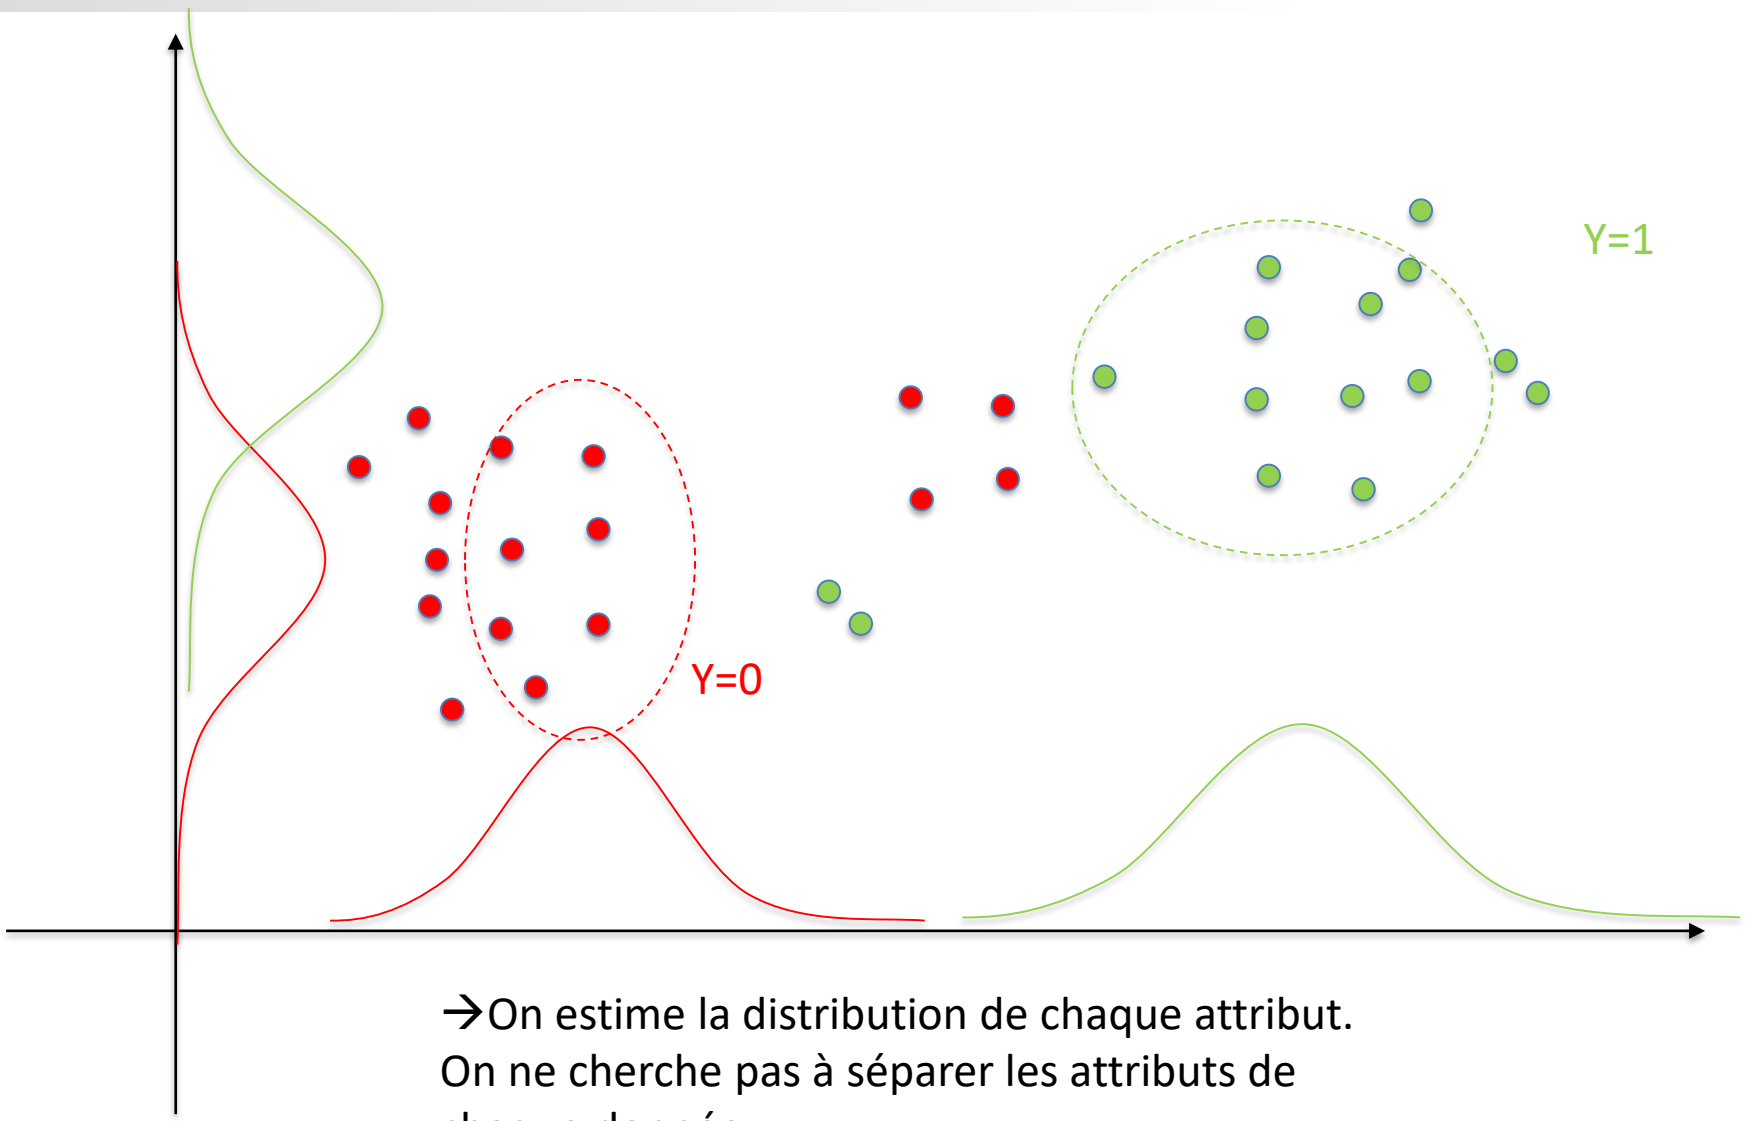

→On estime la distribution de chaque attribut.
On ne cherche pas à séparer les attributs de chaque donnée

Classification par *Naive Bayes*

On cherche à classifier un objet $x=[x^k]$ dont on connait (observe) les attributs.

On peut calculer $P(x^k|y)$ selon la valeur (ou la présence binaire) de chaque attribut grâce au modèle entrainé sur les données

→On estime

$$y\tilde{} = \underset{y \in \mathcal{Y}}{\operatorname{argmax}}\, P(y) \prod_{k=1}^{K} P\left(x^k \middle| y\right)$$

En pratique on ne multiplie pas les probabilités:

$$y\tilde{} = \underset{y \in \mathcal{Y}}{\operatorname{argmax}}\, \log P(y) + \sum_{k=1}^{K} \log P\left(x^k \middle| y\right)$$

Classification par *Naive Bayes*

D autres modèles sont possibles pour les densités de probabilités des attributs selon leurs caractéristiques (histogramme, multimomiale,…)

Chaque modèle donne des propriétés particulières au classifieur *Naive Bayes*

- Exemple: le classifieur est linéaire si les distributions sont de la famille exponentielle (par ex. Gaussiennes) – *cf plus loin*

Régression Logistique

Régression Logistique

Soit une variable binaire Y suivant une distribution de Bernoulli et soit X une caractéristique de prediction pour la variable Y,

$$P(Y=1|x) = p \qquad P(Y=0|x) = 1-p$$

on collecte les données (x_i,y_i)

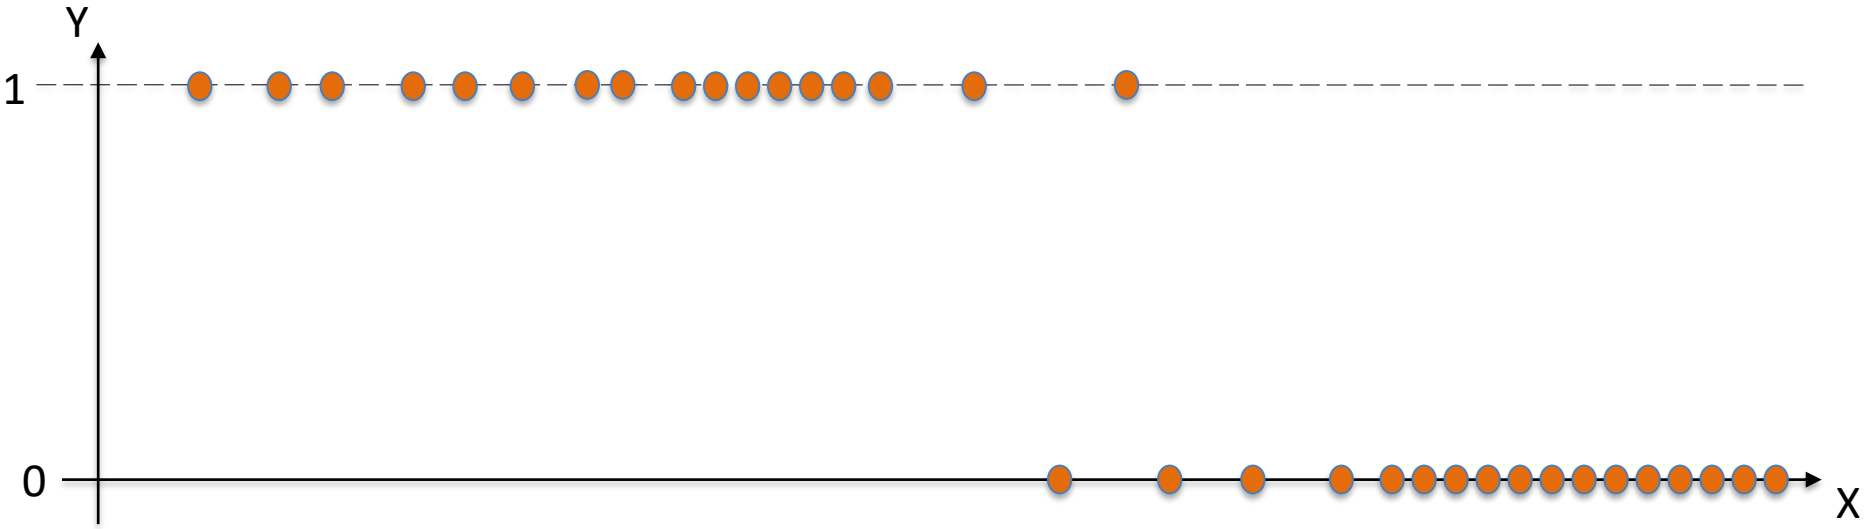

Régression Logistique

Si X est un bon prédicteur de Y on peut espérer "binariser" X avec le seuil x_0 (seuil de prédiction):

$$y_i = (x_i < x_0) \qquad Y = \mathbb{1}_{(X<x0)}$$

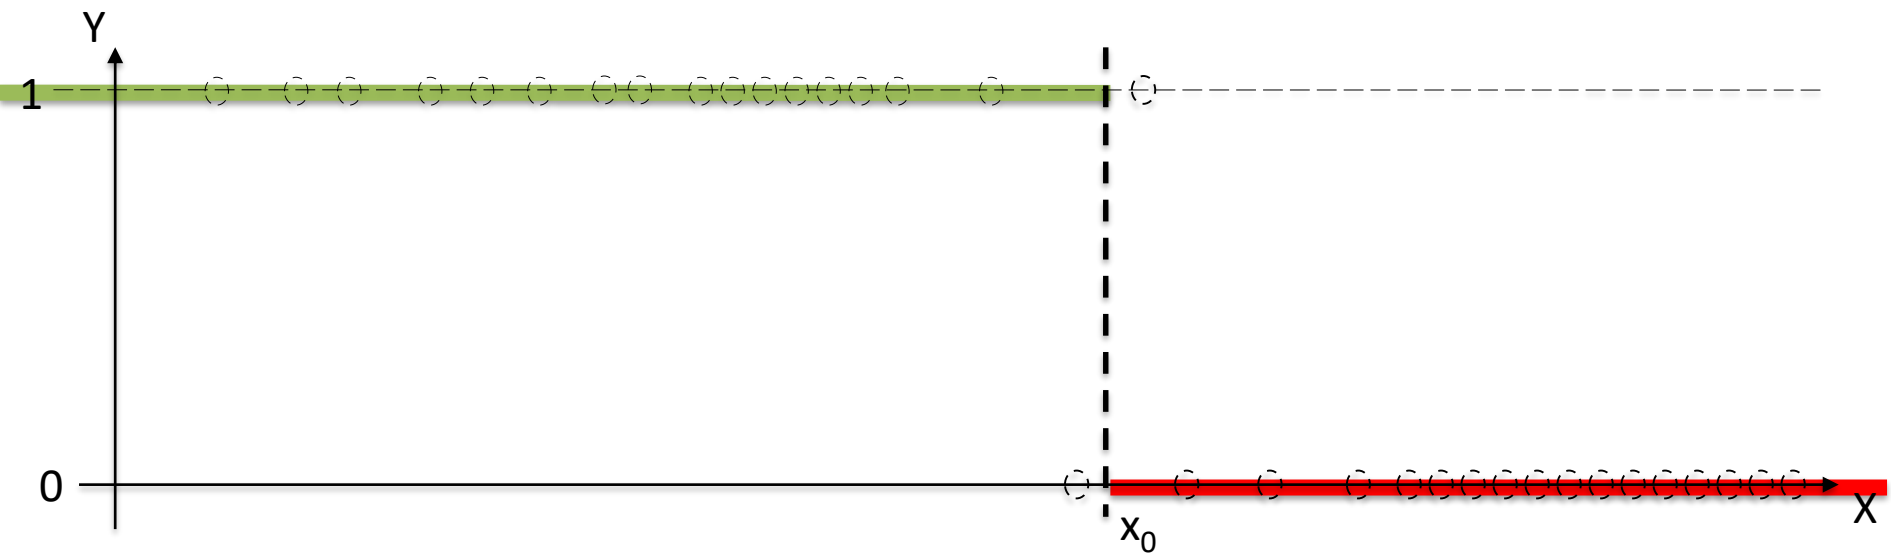

Régression Logistique

A cause du bruit (et de la qualité du prédicteur) on a une zone de recouvrement (plus ou moins importante) dans les labels des données

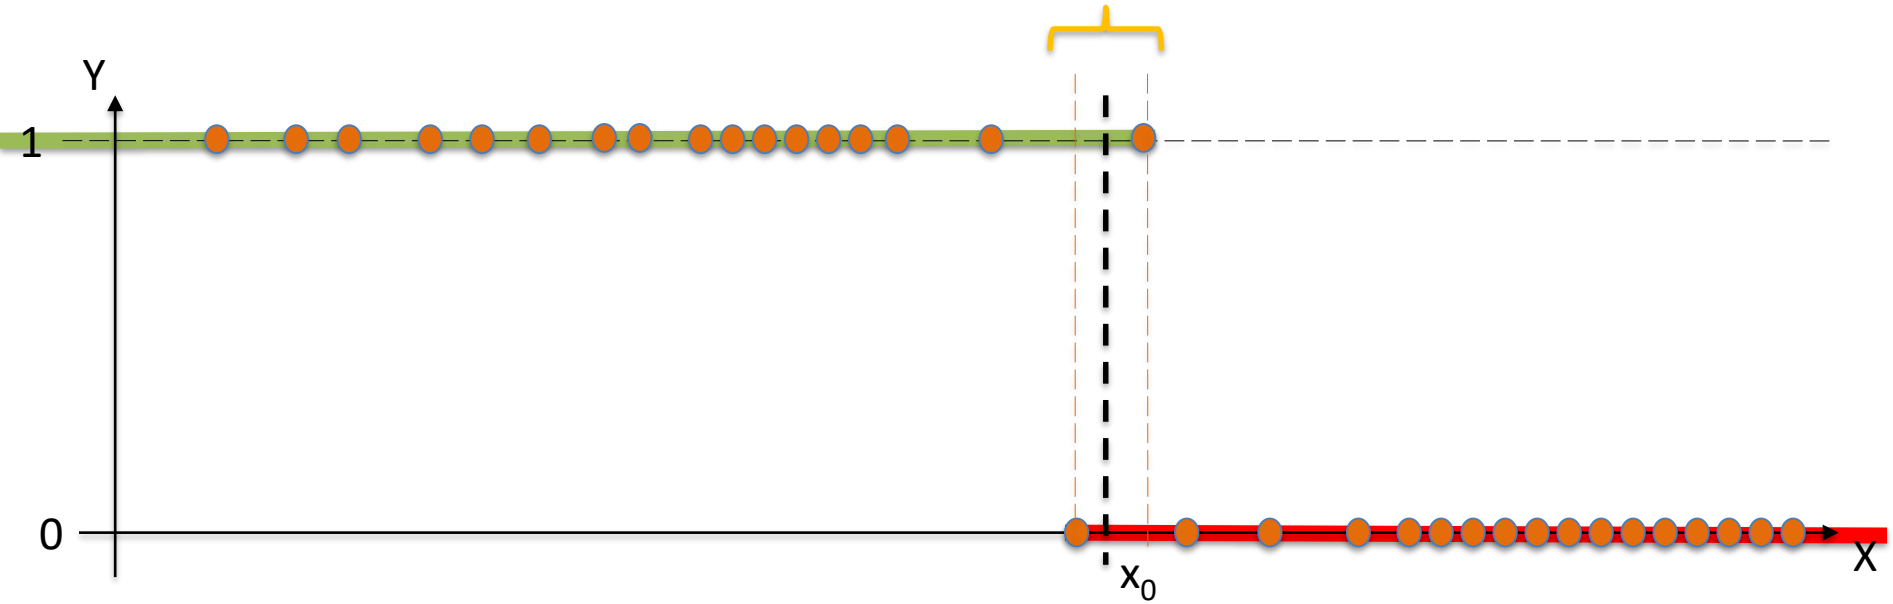

Régression Logistique

Avec suffisamment de données, on agrège les statistiques

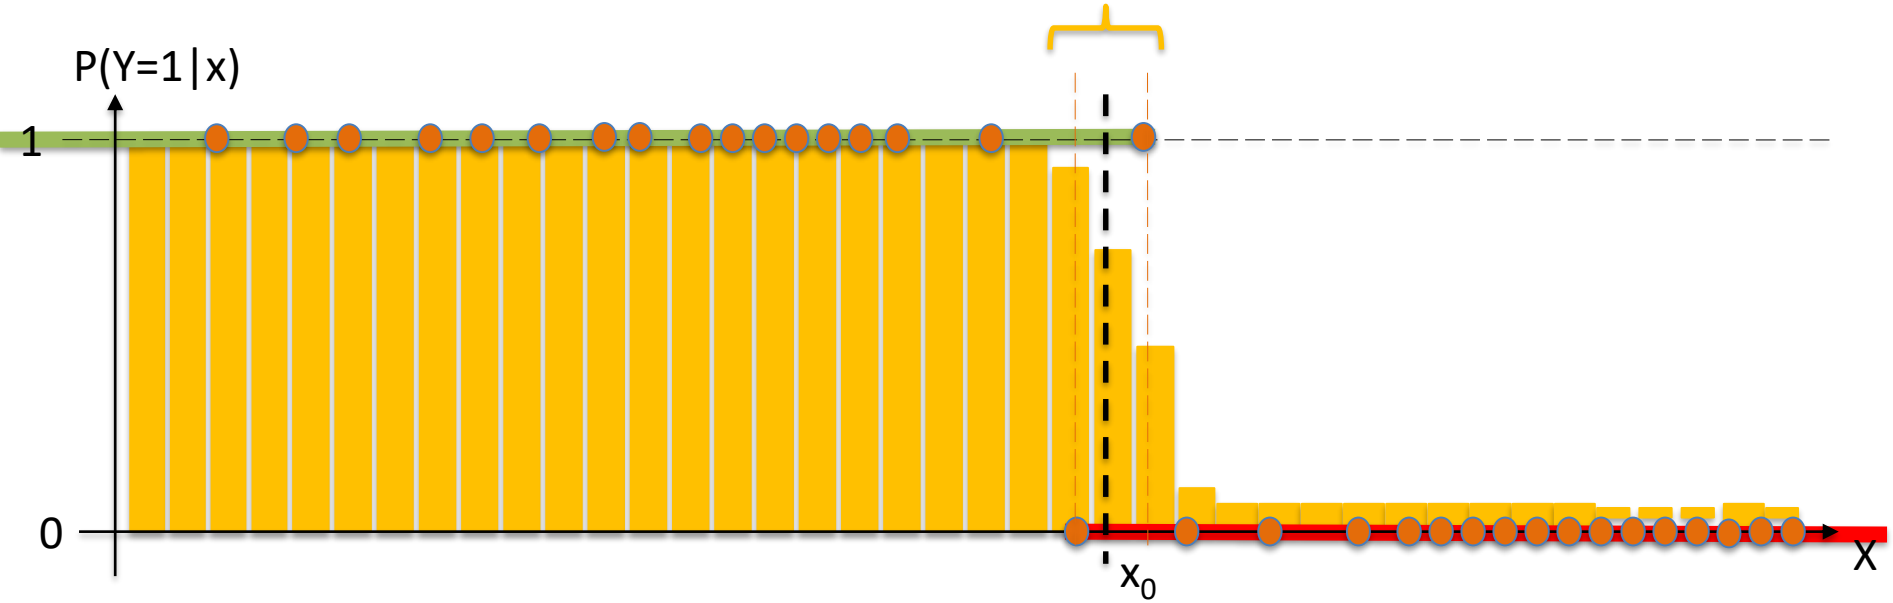

Régression Logistique

On fait une régression avec une version lissée de la fonction indicatrice: la fonction logistique

$$P(Y=1|x) = \phi_\theta(x) = \frac{1}{1+e^{-a(x-x_0)}}$$

$\theta=[a,x_0]$

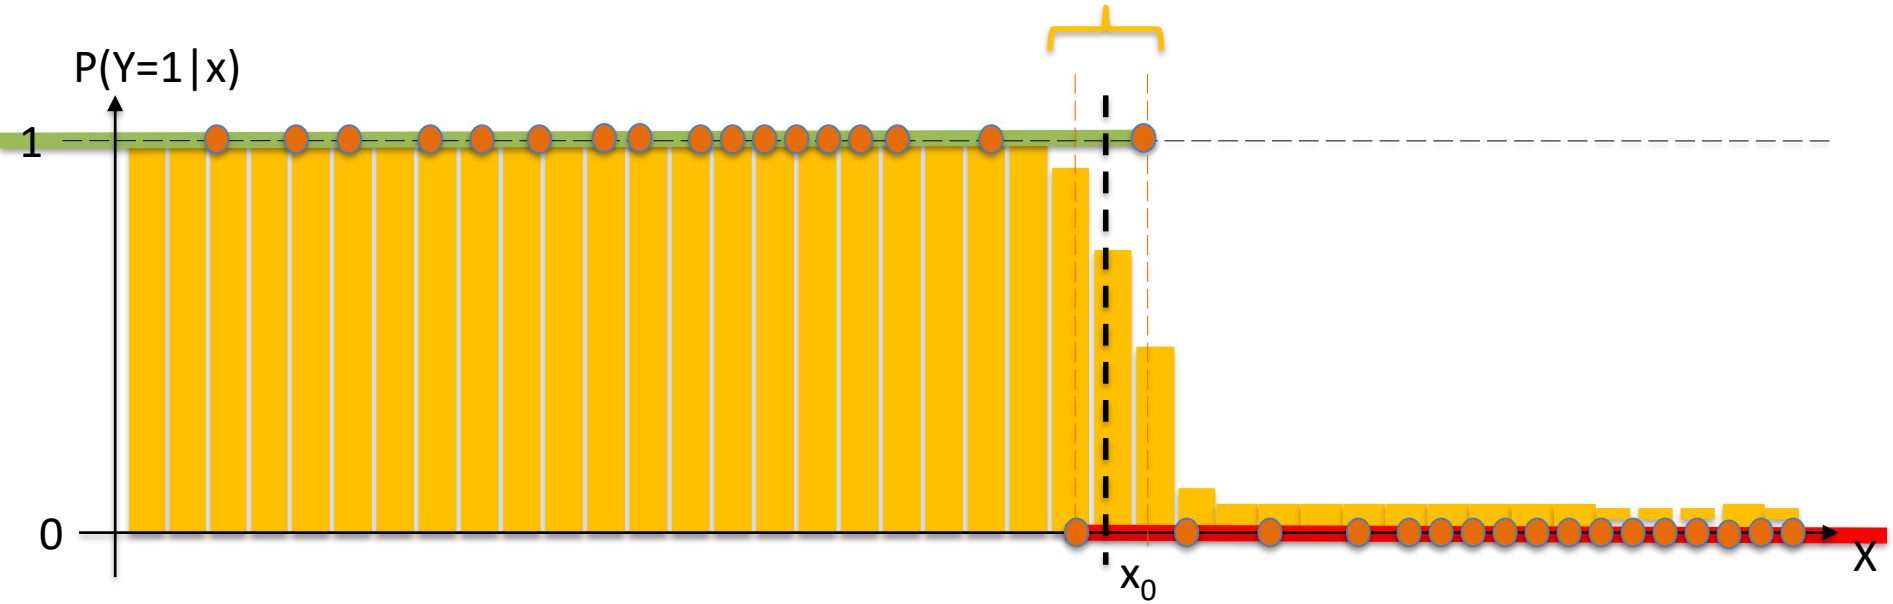

Fonction logistique

$$\phi_\theta(x) = \frac{1}{1+e^{-a(x-x_0)}}$$

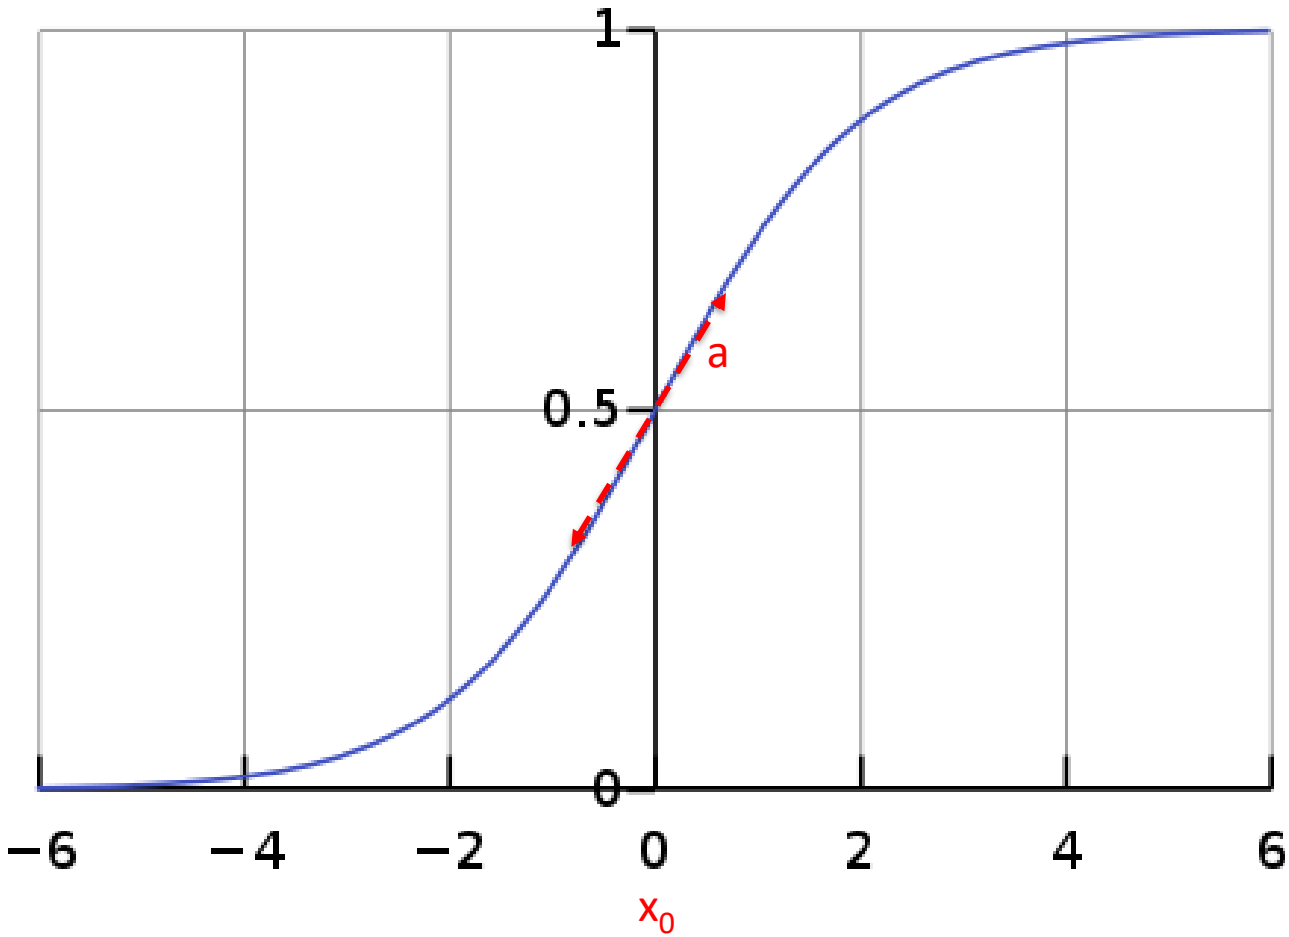

Régression Logistique

On fait une régression avec une version lissée de la fonction indicatrice: la fonction logistique

$$P(Y=1|x) = \phi_\theta(x) = \frac{1}{1+e^{-a(x-x_0)}}$$

$\theta=[a,x_0]$

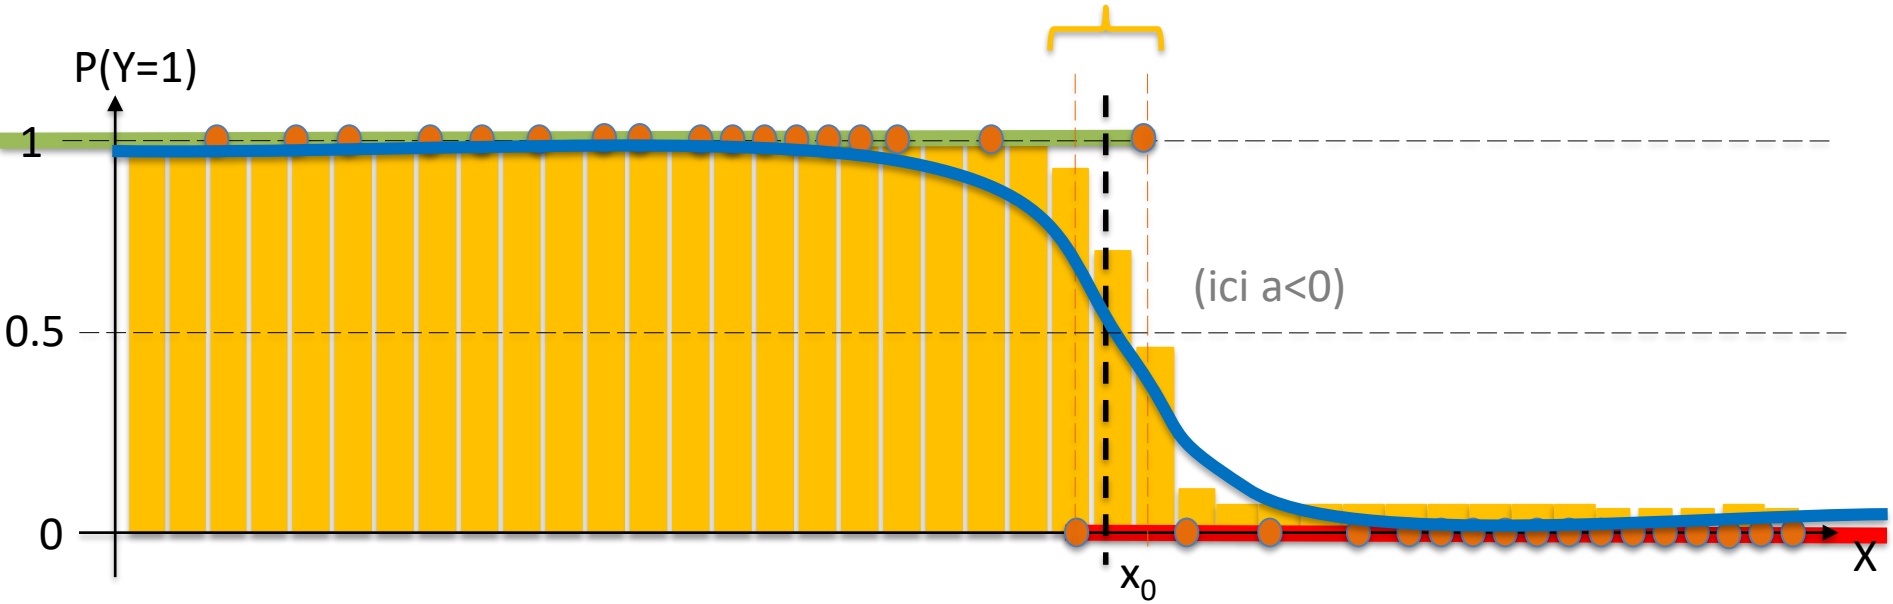

Régression logistique

$$\phi_\theta(x) = \frac{1}{1 + e^{-a(x-x_0)}}$$

$$P(Y = 1|x) = \phi_\theta(x) = \frac{1}{1 + e^{-a(x-x_0)}}$$

$$\Rightarrow \log \frac{P(Y = 1|x)}{P(Y = 0|x)} = a(x - x_0)$$

Preuve:

$$p = \frac{1}{1 + e^{-a(x-x_0)}} \quad \Rightarrow \quad p = \frac{e^{a(x-x_0)}}{e^{a(x-x_0)} + 1}$$

$$\Rightarrow \frac{p}{1-p} = e^{a(x-x_0)} \Rightarrow \log \frac{p}{1-p} = a(x - x_0)$$

Soit une variable binaire Y suivant une distribution de Bernoulli et soit X une caractéristique de prediction pour la variable Y,

$$P(Y=1|x) = p \qquad P(Y=0|x) = 1-p$$

On appellee rapport de vraisemblance (*odds ratio*) le rapport:

$$O(Y = 1|x) = \frac{P(Y=1|x)}{P(Y=0|x)} = \frac{p}{1-p}$$

Régression logistique

$$\phi_\theta(x) = \frac{1}{1 + e^{-a(x-x_0)}}$$

- $\log \frac{p}{1-p} = a(x - x_0)$
- $O(Y = 1|x) = \frac{P(Y=1|x)}{P(Y=0|x)} = \frac{p}{1-p}$

On a donc:

$$\text{Log } O(Y=1|x)=a(x-x_0)$$

Pour la regression on part donc de l'hypothèse que le rapport de vraisemblance du label (Y) a une relation log-linéaire avec la variable de prédiction (X)

C'est le principe "le plus, le mieux"

La régression cherche à estimer $\theta=[a,x_0]$

Analyse multidimensionnelle

$$\phi_\theta(\mathbf{x}) = \frac{1}{1+e^{-\mathbf{a}^T(\mathbf{x}-\mathbf{x}_0)}}$$

$$P(Y=1|\mathbf{x})=\phi_\theta(\mathbf{x}) \quad \Rightarrow \quad \log O(Y=1|\mathbf{x})=b+\sum_{k=1}^{K} a_k x^k$$

Rappel en 1D

Log $O(Y=1|x)=a(x-x_0)$

$\theta=[b,(a_k)]$

(x^k_0)

Exemple:

Tache réussie = ϕ_θ(age, durée d'apprentissage)

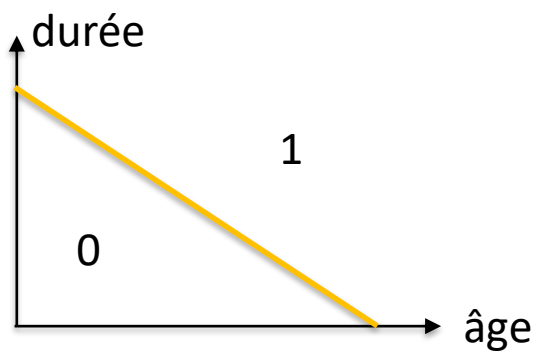

Analyse multidimensionnelle

$$\phi_\theta(\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{a}^T(\mathbf{x}-\mathbf{x}_0)}}$$

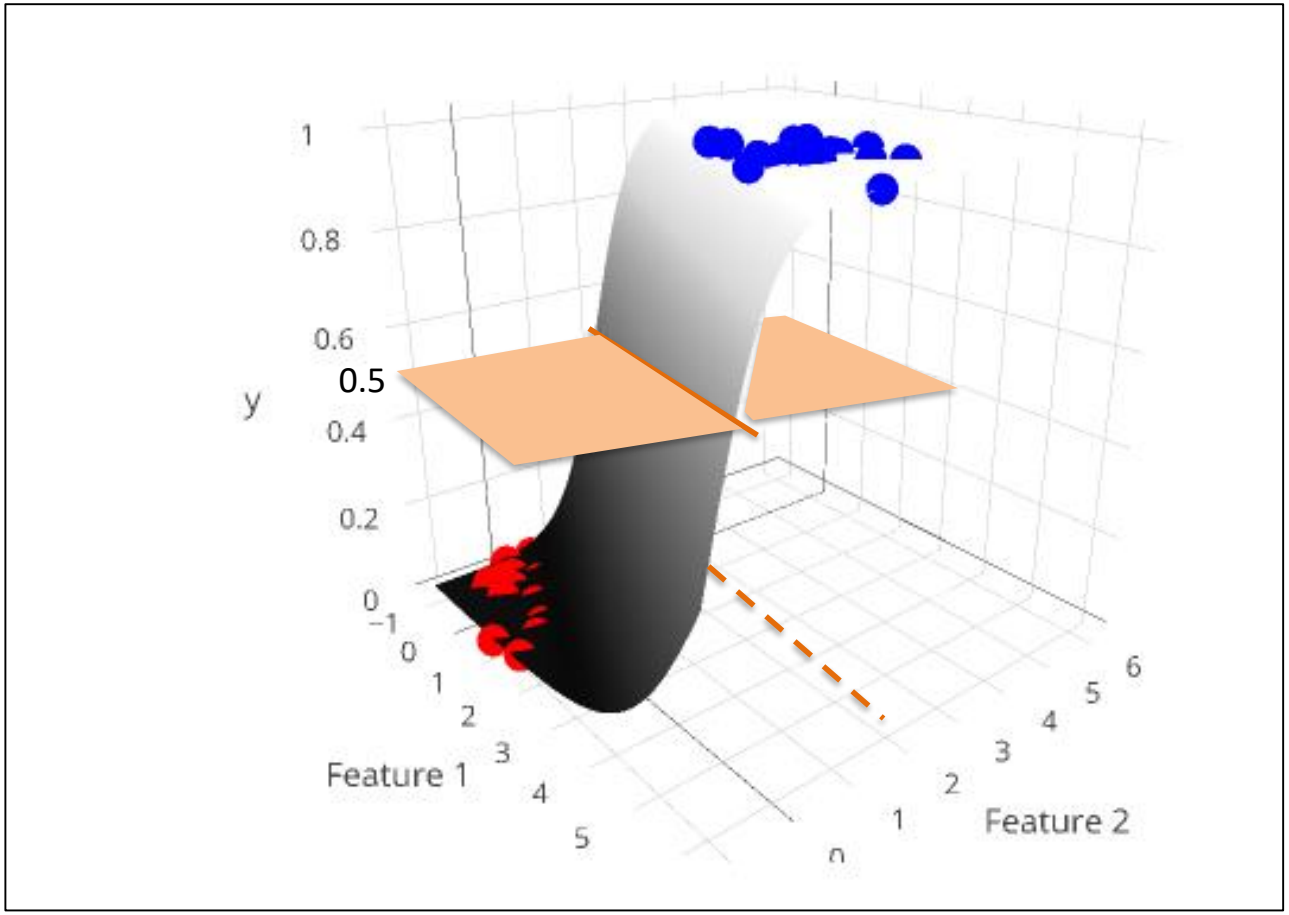

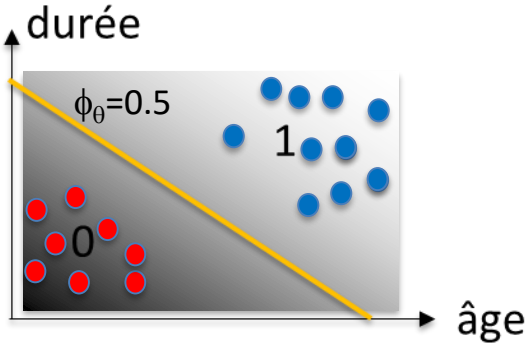

Equivalent à une classification linéaire multidimensionnelle

Rappel: Classification linéaire

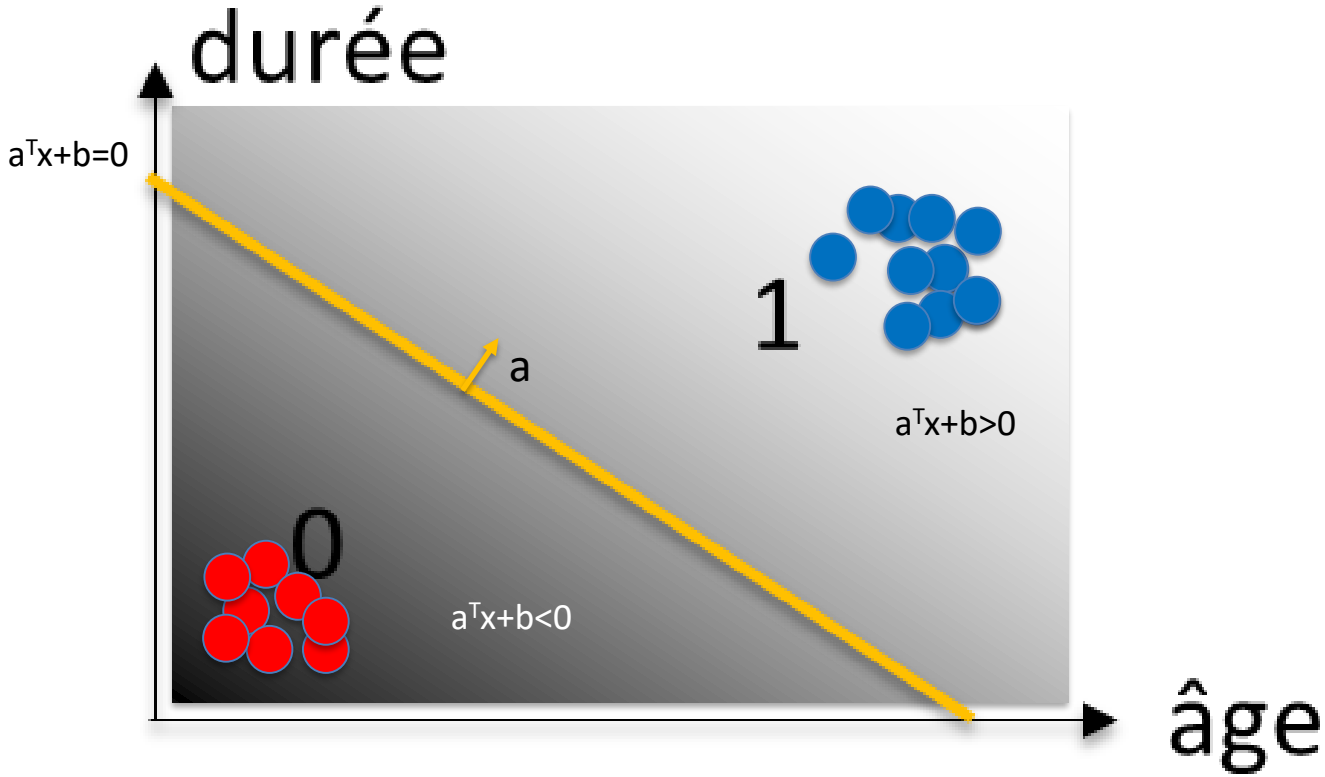

Regression logistique et *Naive Bayes*

Naive Bayes: $$P(Y=1|x)=\frac{P(x|Y=1)P(Y=1)}{P(x|Y=1)P(Y=1)+P(x|Y=0)P(Y=0)}$$

$$=\frac{1}{1+\frac{P(x|Y=0)P(Y=0)}{P(x|Y=1)P(Y=1)}} = \frac{1}{1+e^{-\log\frac{P(x|Y=1)P(Y=1)}{P(x|Y=0)P(Y=0)}}}$$

or $$\log\frac{P(x|Y=1)P(Y=1)}{P(x|Y=0)P(Y=0)} = \sum_{k=1}^{K}\log\frac{P(x^k|Y=1)}{P(x^k|Y=0)}+\log\frac{P(Y=1)}{P(Y=0)}$$

indépendance

- $P(x|y) = \prod_{k=1}^{K} P(x^k|y)$

Si de plus le modèle est Gaussien $P(x^k|Y) = \frac{1}{Z}e^{-\frac{(x^k-\mu)^2}{2\sigma^2}}$ pour chaque caractéristique alors on peut trouver θ=[a,b] tels que:

$$P(Y=1|x)=\phi_\theta(\boldsymbol{x})$$

Soit:

$$\log O(Y=1|x)=b+\sum_{k=1}^{K} a_k x^k = a^T x + b$$

Naive Bayes avec modèle Gaussien est un classifieur linéaire (aussi vrai pour d'autres modèles de la famille exponentielle)

Estimation de paramètres

Essentiellement formulée comme une minimisation d'erreur puis descente en gradient

Par exemple:

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

et aussi: https://scikit-learn.org/stable/modules/naive_bayes.html

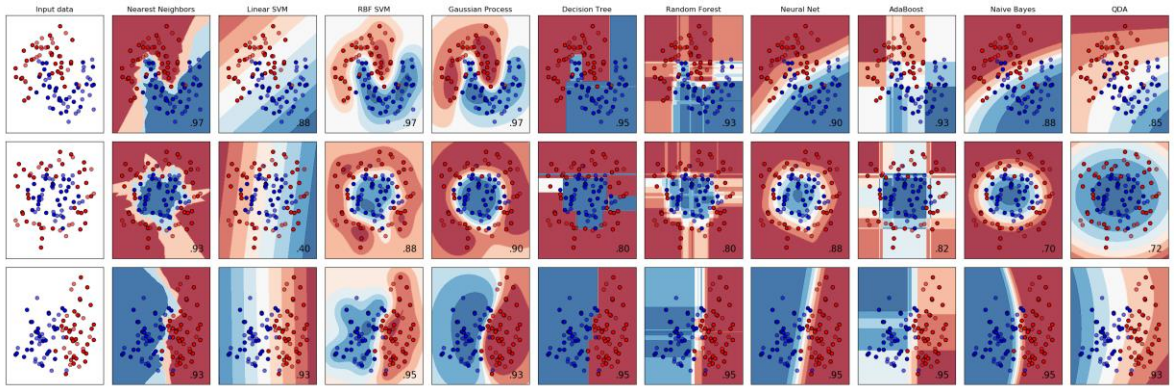

Résumé

- La classification Bayésienne choisit le label de plus forte probabilité étant la donnée
- Le classifieur *Naive Bayes* diminue la complexité en faisant l'hypothèse d'indépendance conditionnelle des caractéristiques
- Un modèle est place sur chaque caractéristique et appris en fonction des caractéristiques des données d'entrainement

- La régression logistique cherche une fonction logistique qui se colle au mieux aux données
- La régression logistique est équivalente à une classification linéaire

- *Naive Bayes* correspond à une régression logistique si le modèle des caractéristique est Gaussien (ou multinomial, famille exponentielle…)

→ La régression logistique permet d'estimer un classifieur Bayésien sans estimer le modèle des caractéristiques explicitement