Intelligence Artificielle

Biais et équité

Stephane Marchand-Maillet

Contenu

- Définition de l’équité
- Correspondance probabiliste
- Etudes de cas

Protection contre la discrimination

Des textes légaux:

Déclaration des Droits de l'Homme et du Citoyen de 1789

Article 1er https://www.conseil-constitutionnel.fr/le-bloc-de-constitutionnalite/declaration-des-droits-de-l-homme-et-du-citoyen-de-1789

Les hommes naissent et demeurent libres et égaux en droits. Les distinctions sociales ne peuvent être fondées que sur l'utilité commune.

RÈGLEMENT (UE) 2016/679 DU PARLEMENT EUROPÉEN ET DU CONSEIL

du 27 avril 2016

relatif à la protection des personnes physiques à l'égard du traitement des données à caractère personnel et à la libre circulation de ces données, et abrogeant la directive 95/46/CE (règlement général sur la protection des données)

GDPR: https://eur-lex.europa.eu/legal-content/FR/TXT/HTML/?uri=CELEX:32016R0679&from=FR#d1e1874-1-1

Article 9 - Traitement portant sur des catégories particulières de données à caractère personnel

1. Le traitement des données à caractère personnel qui révèle l'origine raciale ou ethnique, les opinions politiques, les convictions religieuses ou philosophiques ou l'appartenance syndicale, ainsi que le traitement des données génétiques, des données biométriques aux fins d'identifier une personne physique de manière unique, des données concernant la santé ou des données concernant la vie sexuelle ou l'orientation sexuelle d'une personne physique sont interdits.

https://www.cnil.fr/fr/reglement-europeen-protection-donnees/chapitre2#Article9

Protected caracteristics

A **protected group** or **protected class** is a group of people qualified for special protection by a law, policy, or similar authority. In the United States, the term is frequently used in connection with employees and employment.

Where discrimination on the basis of protected group status is concerned, a single act of discrimination may be based on membership in more than one protected group. For example, discrimination based on antisemitism may relate to religion, national origin, or both; discrimination against a pregnant woman might be based on sex, marital status, or both.[1]

United States [edit]

U.S. federal law protects individuals from discrimination or harassment based on the following nine protected classes: sex, race, age, disability, color, creed, national origin, religion, or genetic information (added in 2008). Many state laws also give certain protected groups special protection against harassment and discrimination, as do many employer policies. Although it is not required by federal law, employer policies may also protect employees from harassment or discrimination based on marital status or sexual orientation.[1] The following characteristics are "protected" by United States federal anti-discrimination law:

- Race – Civil Rights Act of 1964
- Religion – Civil Rights Act of 1964
- National origin – Civil Rights Act of 1964
- Age (40 and over) – Age Discrimination in Employment Act of 1967
- Sex – Equal Pay Act of 1963 and Civil Rights Act of 1964
  - The Equal Employment Opportunity Commission interprets 'sex' to include discrimination based on sexual orientation and gender identity[2]
- Pregnancy – Pregnancy Discrimination Act
- Familial status – Civil Rights Act of 1968 Title VIII: Prohibits discrimination for having children, with an exception for senior housing. Also prohibits making a preference for those with children.
- Disability status – Rehabilitation Act of 1973 and Americans with Disabilities Act of 1990
- Veteran status – Vietnam Era Veterans' Readjustment Assistance Act of 1974 and Uniformed Services Employment and Reemployment Rights Act
- Genetic information – Genetic Information Nondiscrimination Act

Individual states can and do create other classes for protection under state law.

Presidents have also issued executive orders which prohibit consideration of particular attributes in employment decisions of the United States government and its contractors. These have included Executive Order 11246 (1965), Executive Order 11478 (1969), Executive Order 13087 (1998), Executive Order 13279 (2003), and Executive Order 13672 (2014).

https://en.wikipedia.org/wiki/Protected_group

protected characteristic

Definition from Nolo's Plain-English Law Dictionary

In employment law, a trait that may not be the basis of employment decisions. Under federal law, protected characteristics include race, color, national origin, religion, gender (including pregnancy), disability, age (if the employee is at least 40 years old), and citizenship status.

Un sujet d’importance

NewScientist

Biased policing is made worse by errors in pre-crime algorithms

4 October 2017 , updated 27 April 2018

CNBC

MARKETS BUSINESS INVESTING TECH POLITICS CNBC TV

TECH

Facebook and YouTube should have learned from Microsoft's racist chatbot

PUBLISHED SAT, MAR 17 2018 • 4:03 PM EDT

Ingrid Angulo
@INGRID__ANGULO

KEY POINTS

- Facebook and YouTube have recently come under fire for offensive search suggestions.
- Microsoft made a Twitter chatbot in 2016 that was trained to say outrageous things by users, but Facebook and YouTube don't seem to have learned from the mistake.
- Psychological studies have shown that people are drawn to negative and offensive content, so engagement maximization drives the popularity of this content.

PRO PUBLICA

How We Analyzed the COMPAS Recidivism Algorithm

by Jeff Larson, Surya Mattu, Lauren Kirchner and Julia Angwin

May 23, 2016

← Read the story

Across the nation, judges, probation and parole officers are increasingly using algorithms to assess a criminal defendant's likelihood of becoming a recidivist – a term used to describe criminals who re-offend. There are dozens of these risk assessment algorithms in use. Many states have built their own assessments, and several academics have written tools. There are also two leading nationwide tools offered by commercial vendors.

We set out to assess one of the commercial tools made by Northpointe, Inc. to discover the underlying accuracy of their recidivism algorithm and to test whether

NewScientist

Discriminating algorithms: 5 times AI showed prejudice

Artificial intelligence is supposed to make life easier for us all – but it is also prone to amplify sexist and racist biases from the real world

TECHNOLOGY 12 April 2018 , updated 27 April 2018

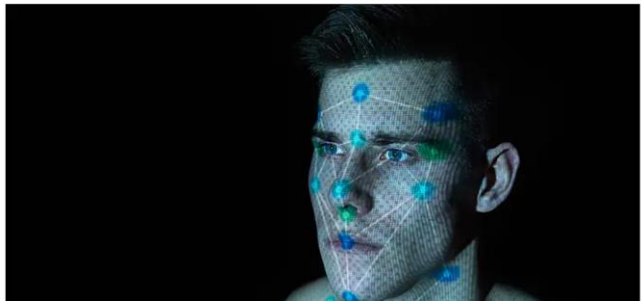

Une conscience technologique

Le développement de la conscience des conséquences sociales et sociétales potentielles de la création ou de l'utilisation d'une technologie fait partie intégrante des programmes d'éducation visant à former les créateurs, promoteurs ou utilisateurs de cette technologie.

C'est en particulier vrai pour l'Intelligence Artificielle qui vise à s'intégrer au plus profond des nos processus sociaux (savoir, communication, comportement, échanges,…)

→ Besoin de développer des critères objectifs pour maintenir un regard bienveillant mais critique envers toute proposition

Classification équitable

Constat: L'apprentissage (classification) est par définition un problème de discrimination (entre classes)

→ posterior: $\text{argmax}_{\text{classe}}\ P(\text{classe}|\text{donnée})$

Le problème de l'équité consiste à (inclut le fait de) ne pas faire cette "discrimination" sur des caractéristiques protégées

On doit éviter les biais de classification et donc des dissymétries corrélées aux caractéristiques protégées

Vision Bayesienne (conditionnelle)

Formulation:

- $x_i = [x_i^k] \in \mathcal{X} \subseteq \mathbb{R}^K$: Attributs des données

  $x_i = [x_i^A, x_i^P]$ avec:

  A = caractéristiques acceptées

  P = caractéristiques protégées

- $y_i \in \mathcal{Y} = \{1 \dots C\}$: Label (classe)

On cherche:

$$\phi_\theta : \mathcal{X} \longrightarrow \mathcal{Y}$$

$$x_i \longrightarrow \phi_\theta(x_i) = y_i$$

Ignorance (*unawareness*)

La première solution consiste simplement à ignorer les caractéristiques protégées.

On veut:

$$\phi_\theta (x) = \phi_\theta (x^A)$$

Le classifieur est entrainé seulement avec les caractéristiques acceptées

Faiblesse: On ignore les corrélations entre x^A et x^P dans les données. La suppression de x^P n'est pas une garantie d'équité

Exemple: corrélation entre profession (x^A) et genre (x^P) dans l'attribution de prêts bancaires

→ Insuffisant

Parité de groupe (*Group parity*)

On impose équivalence du classifieur conditionné aux caractéristiques protégées

$$P(\phi_\theta(x), X^P = x^P) = P(\phi_\theta(x), X^P \neq x^P)$$

Exemple: La prédiction d'un engagement pour un travail ($\phi_\theta(X)$=oui/non) doit rester la même quelque soit le genre (x^P) de la personne

Faiblesse: On ignore les corrélations initiales entre x et y. Si les statistiques de base sont différentes on encourage implicitement le groupe le moins représenté (discrimination positive)

→ Peut être discutable

Egalité des chances (*Equal opportunity*)

On obtient l'égalité des chances si on s'assure que le taux de vrais positifs est constant:

$$P(\phi_\theta(x)=1, X^P=x^P \mid Y=1) = P(\phi_\theta(x)=1, X^P \neq x^P \mid Y=1)$$

Plus généralement, la parité d'erreur (*accuracy parity*):

$$P(\phi_\theta(x) \neq y, X^P=x^P) = P(\phi_\theta(x) \neq y, X^P \neq x^P)$$

ou encore, egalité de cotes (*normalized odds*):

$$P(\phi_\theta(x), X^P=x^P \mid Y) = P(\phi_\theta(x), X^P \neq x^P \mid Y)$$

Exemple: On veut engager la même proportion de genres à compétences égales

Faiblesse: On maintient le biais des données qui lui-même a tendance à s'aggraver (cf plus tard)

Parité de prédiction (*Prediction parity*)

La décision réelle (Y) devient indépendante des caractéristiques protégées sachant la prédiction:

$$P(Y,X^P=x^P|\phi_\theta(x)) = P(Y,X^P\neq x^P|\phi_\theta(x))$$

Exemple: La décision d'embauche doit être liée à la capacité réelle d'une personne à faire une tâche (indépendamment de son genre)

Faiblesse: Conserve les biais initiaux qui peuvent eux-mêmes s'aggraver

Compromis équité/performance

En biaisant la décision vers un comportement autre que celui intrinsèque aux données, on dégrade mécaniquement la performance ($E_{Entrainement}$ et E_{Test})

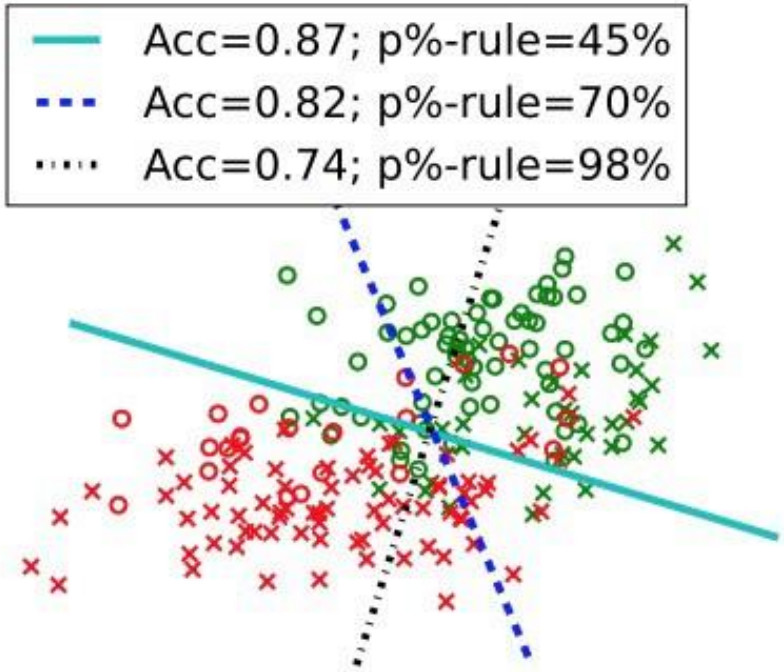

Effet d'aggravation (*compounding*)

Si un système préserve une dissymétrie (sociale) dans les données, les résultats de prédiction vont décourager la minorité qui aura tendance à se sous-représenter… etc

Exemple: Si un algorithme d'embauche prédit (comme il le lit dans les données) que la corrélation "Médecin-Homme" est plus forte que "Médecin-Femme" alors il aura tendance à ne recommander que des hommes pour l'embauche sur un poste de médecin. Ce qui diminuera d'autant le taux de femmes dans cette profession et ainsi de suite…

Effet d'aggravation intrinsèque

L'itération de déséquilibres tend à polariser les phénomènes:

Soient a > b

Normalisation :

$a/\max(a,b) = 1$

$b/\max(a,b)<1$

Itération:

$a^n=1$

$b^n \rightarrow 0$

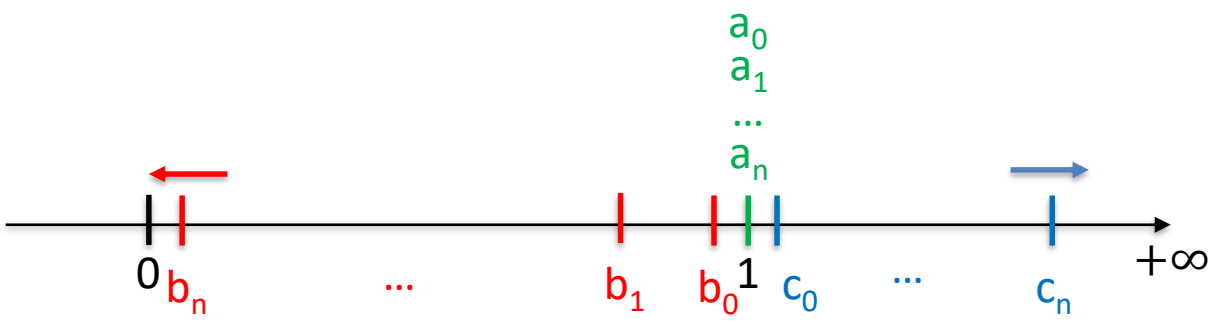

C'est ce qui se passe implicitement dans beaucoup d'algorithmes itératifs

- Exagération des caractéristiques dominantes
- Polarisation des limites

Biais dans les recrutements

Setup: Résumés (bios) collectés sur le Web (eg Wikipedia)

Bias in Bios: A Case Study of Semantic Representation Bias in a High-Stakes Setting. Maria De-Arteaga, Alexey Romanov, Hanna Wallach, Jennifer Chayes, Christian Borgs, Alexandra Chouldechova, Sahin Geyik, Krishnaram Kenthapadi, Adam Tauman Kalai. CoRR abs/arXiv:1901.09451, 2019

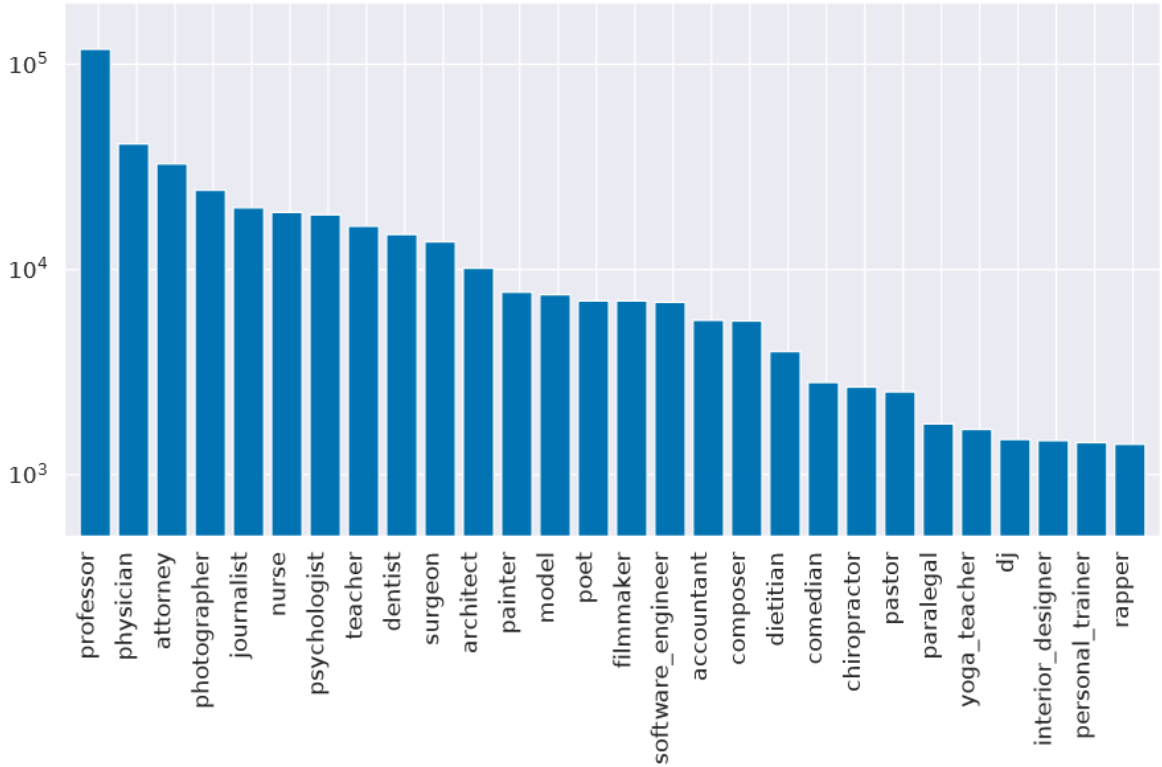

Figure 1: Distribution of the number of biographies for the twenty-eight different occupations, shown on a log scale.

Biais dans les recrutements

Setup: Association bio-profession par *Word Embeddings* (type GloVe)

On constate des biais dans ces représentations:

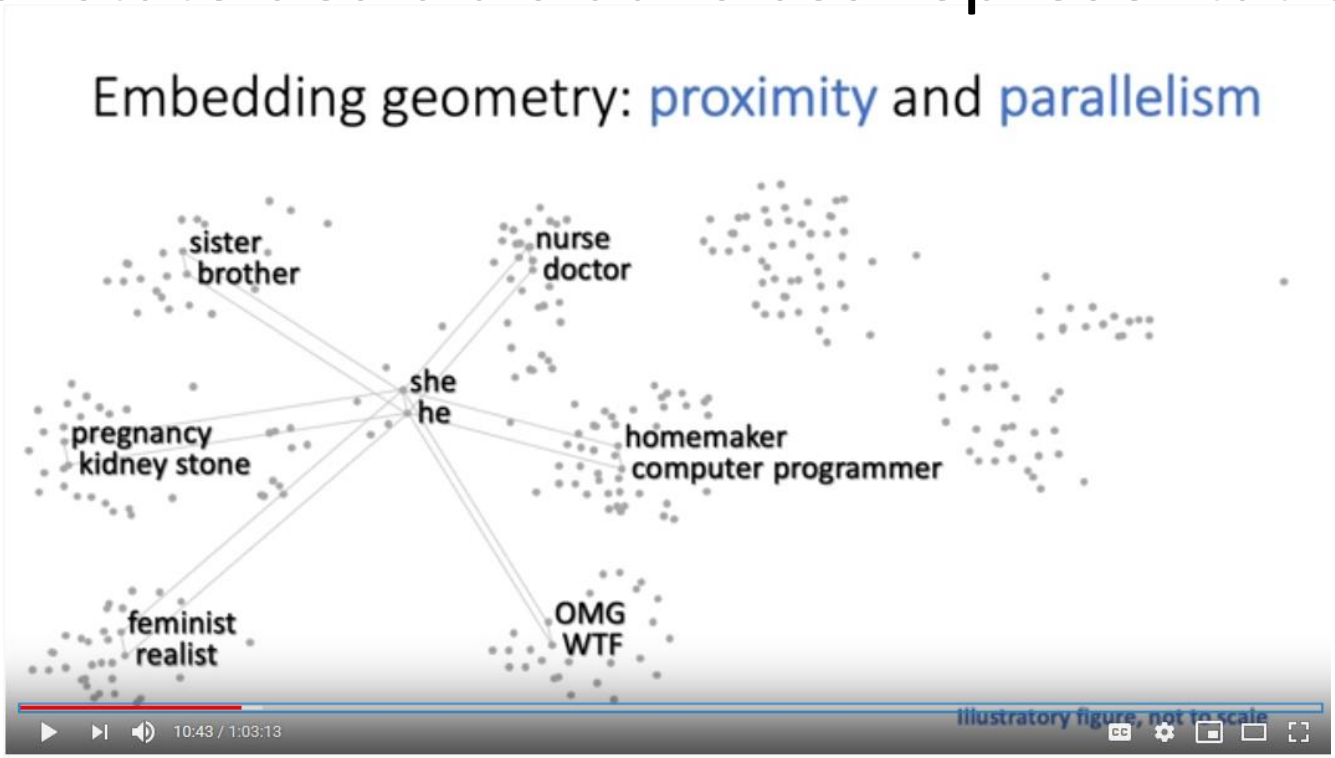

An ICERM Public Lecture - Bias in bios: fairness in a high-stakes machine-learning setting

Parenthèse: causalité dans les séquences

Exemple: texte

Les mots ne sont pas equiprobables

- Give me a word
- Give me the next word
  - I am a …. → “man”, “woman”, “teacher” / “car” is unlikely
- Give me the missing word
  - The sun is … today → “shinning”, “hiding” / “running” is unlikely

Cette causalité peut être apprise

Word Embedding

Idée principale: apprend un vecteur par mot

$$\phi_\theta(w_i)=v_i$$

Le vecteur est une représentation du contexte dans lequel le mot est utilisé

Illustration: vecteur v_i = probabilités d'occurrence de chaque mot comme voisin de ce mot w_i

On crée une géométrie grâce à ces vecteurs

«King» – «Male» ~ *dominant*

dominant + "Female" = "Queen"

Modèle Word2Vec

Word from context

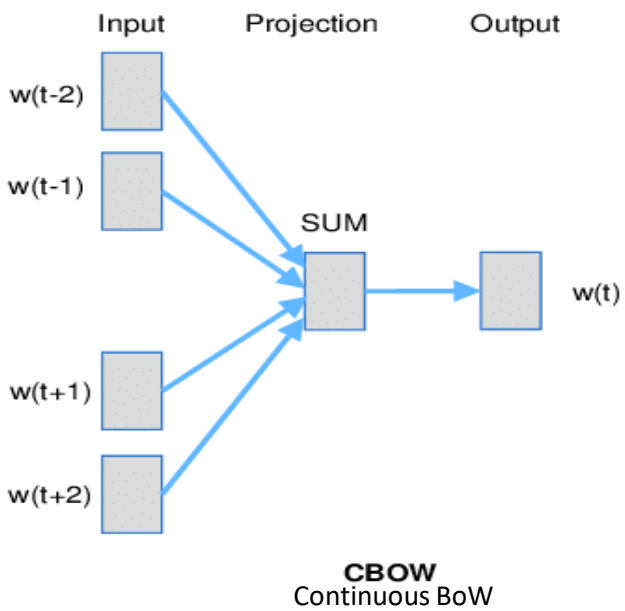

Context from word

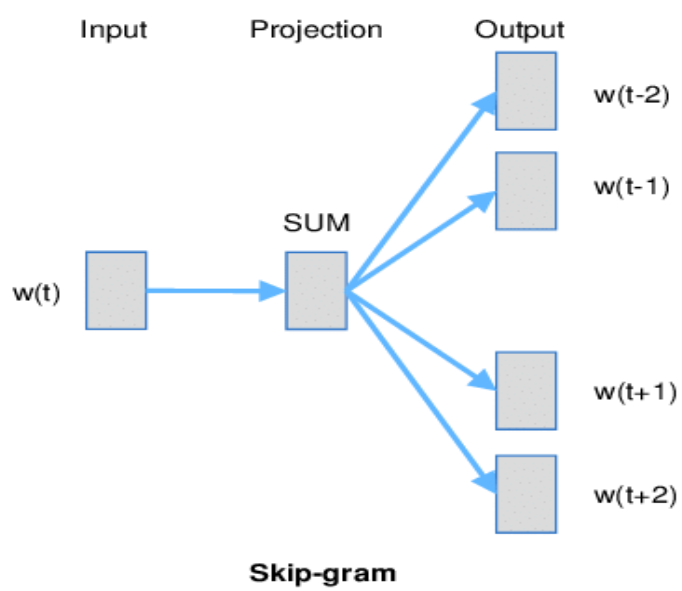

Ideas combined into the Glo(bal)Ve(ctors) idea (GloVe)

Picture from Landthaler, Joerg & Waltl, Bernhard & Huth, Dominik & Braun, Daniel & Matthes, Florian & Stocker, Christoph & Geiger, Thomas. (2017). Extending Thesauri Using Word Embeddings and the Intersection Method.

Géométrie de la sémantique

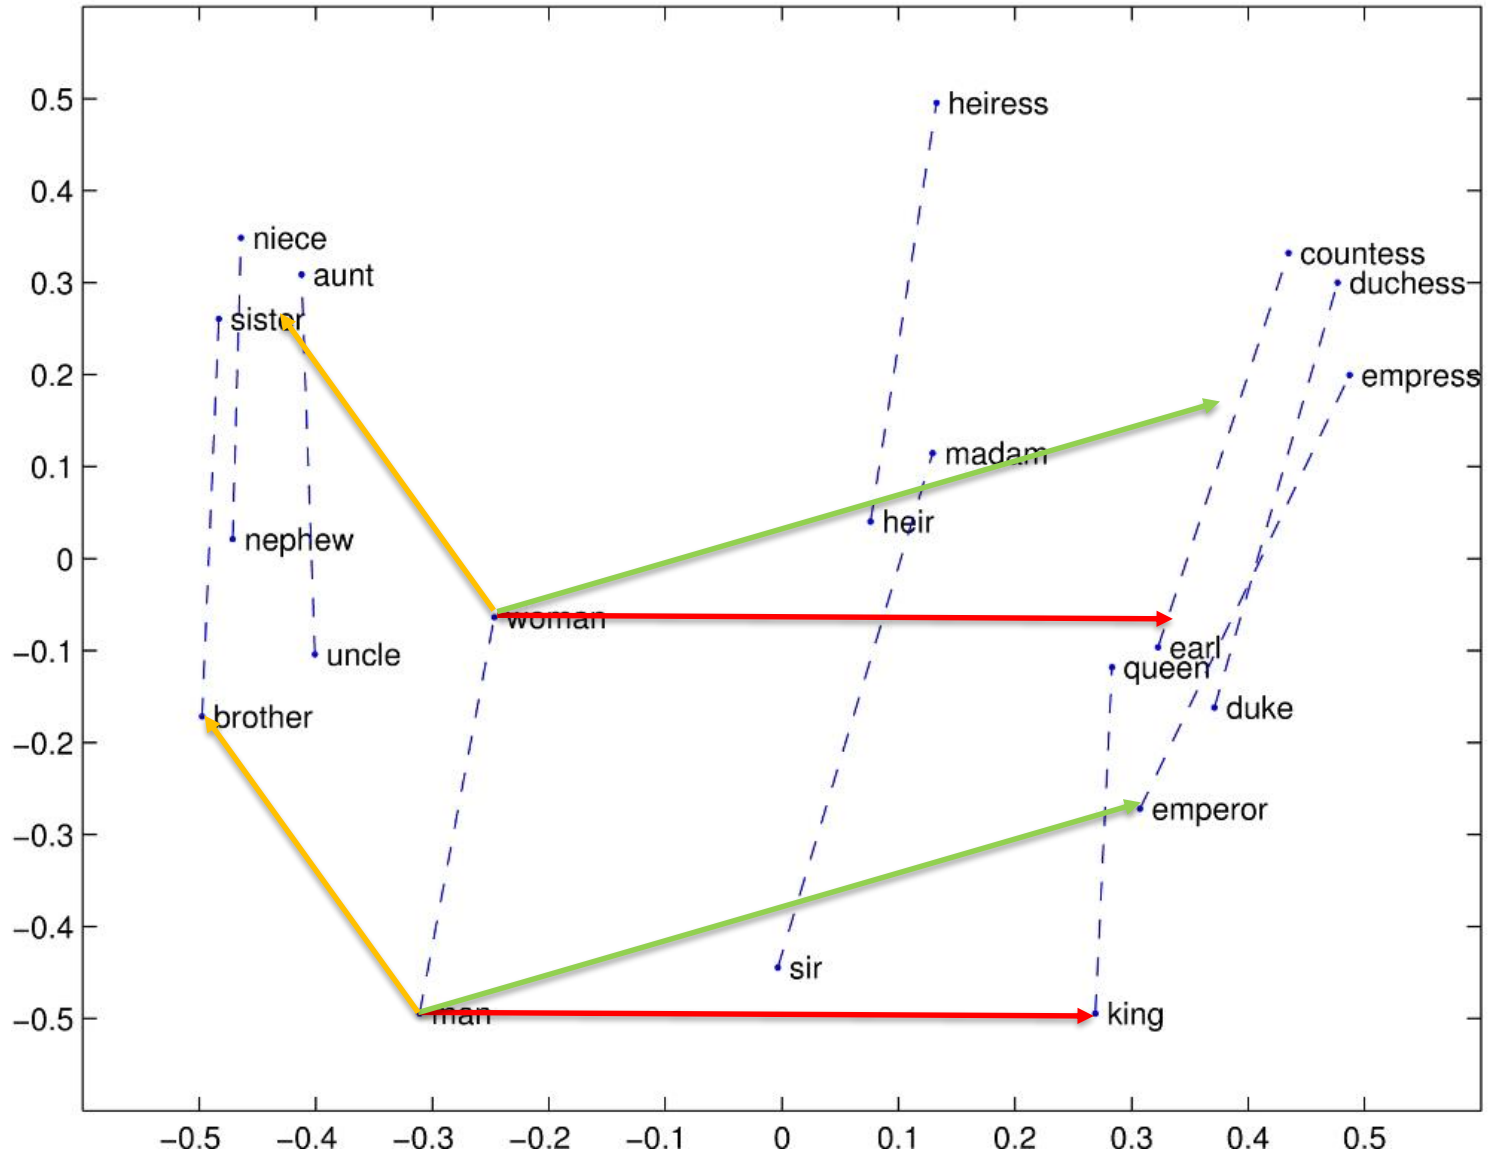

… pour des concepts divers

Superlatives

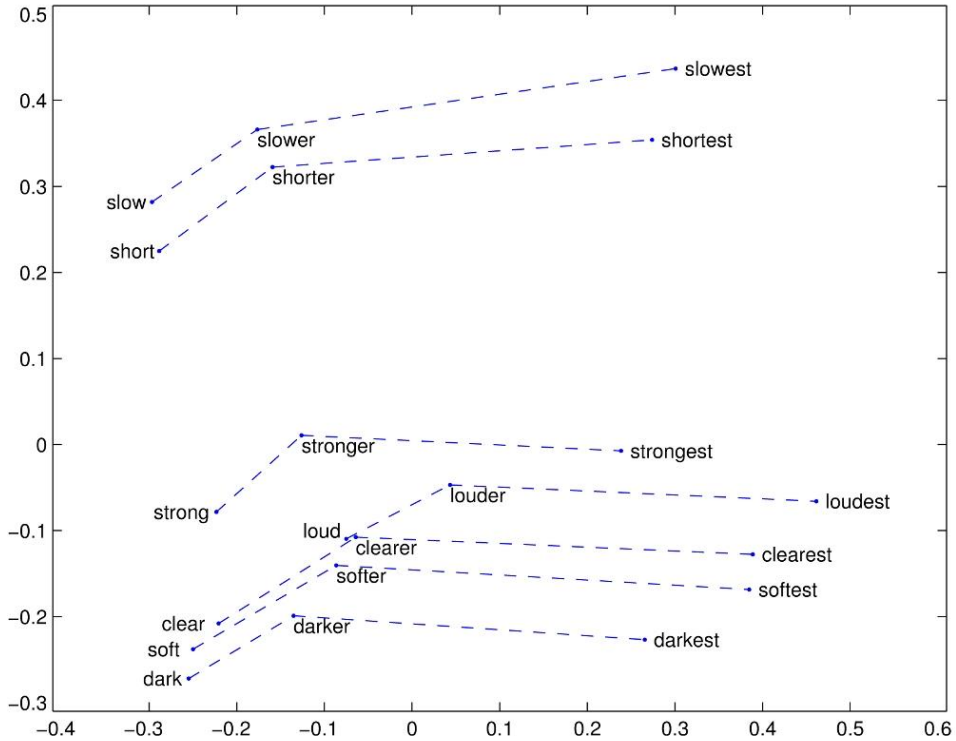

"CEO of"

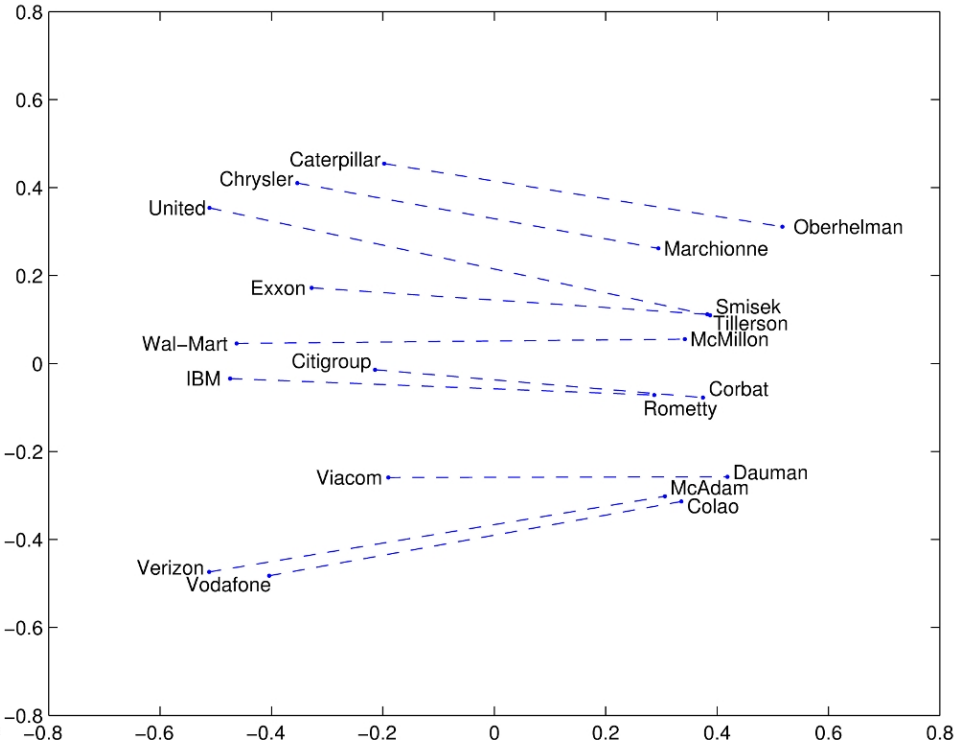

(Fin de la parenthèse)

Biais dans les recrutements

https://www.youtube.com/watch?v=IDNXZitcQng

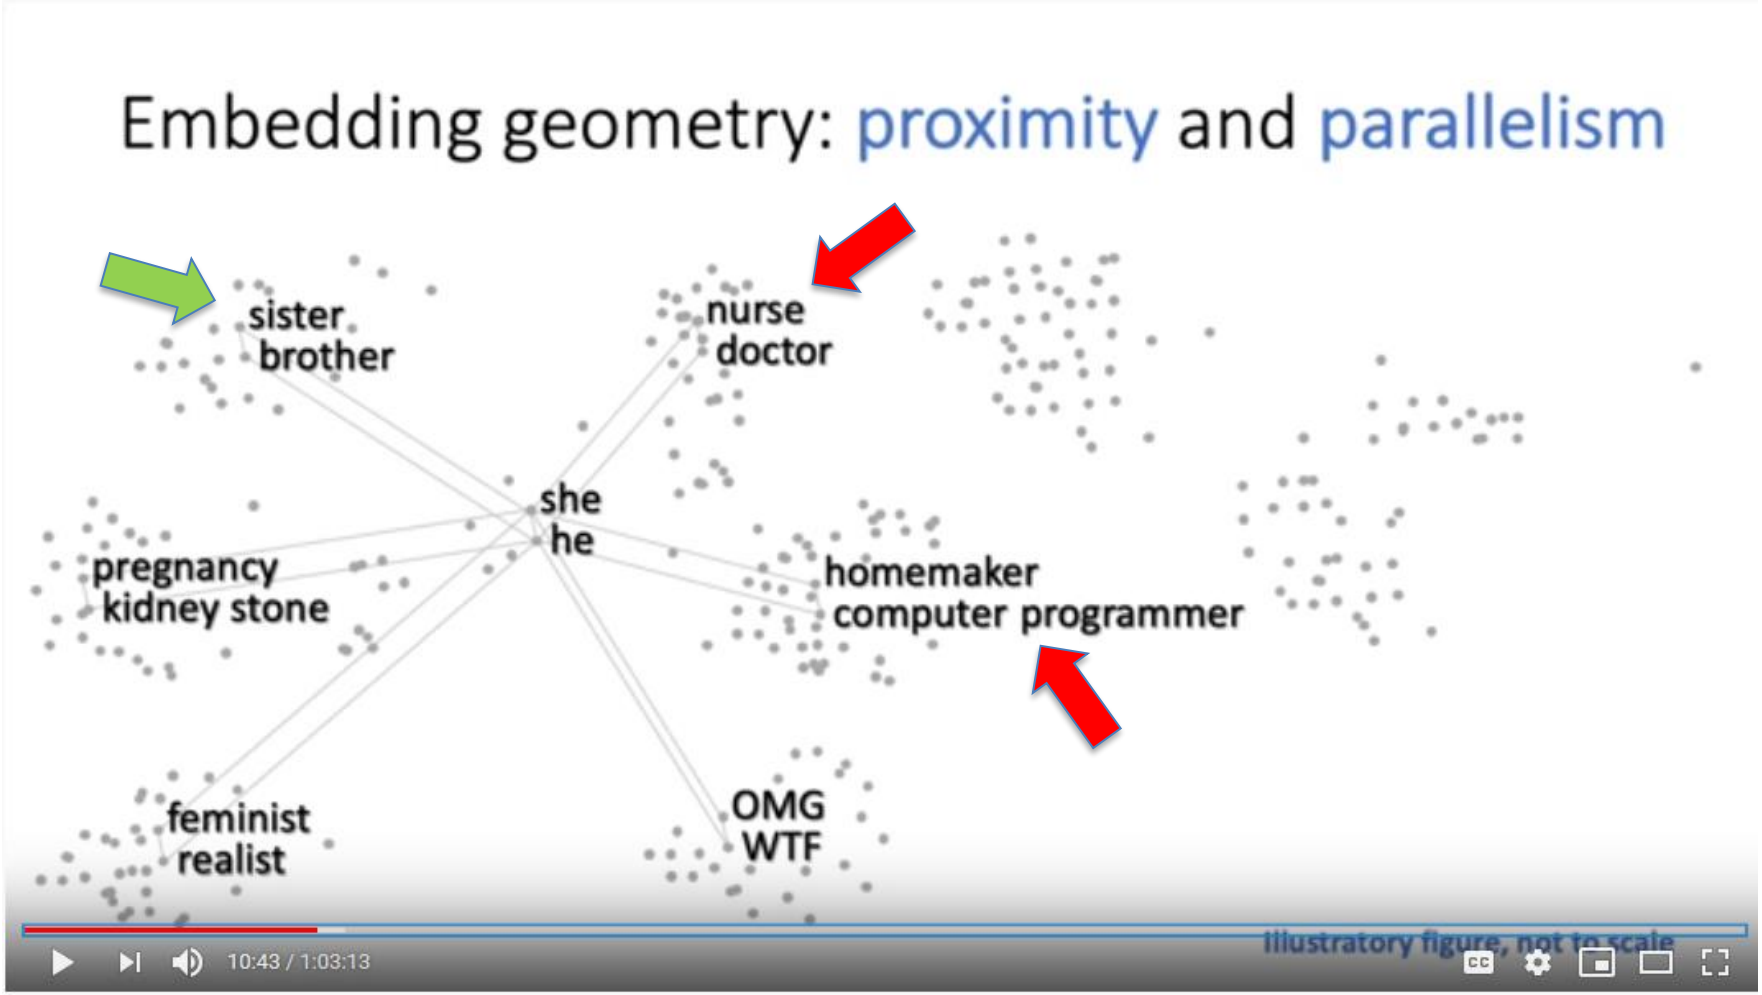

An ICERM Public Lecture - Bias in bios: fairness in a high-stakes machine-learning setting

Biais dans les recrutements

Figure 5: Scatterplot of log frequency versus correlation with G = female for each word type in the vocabulary.

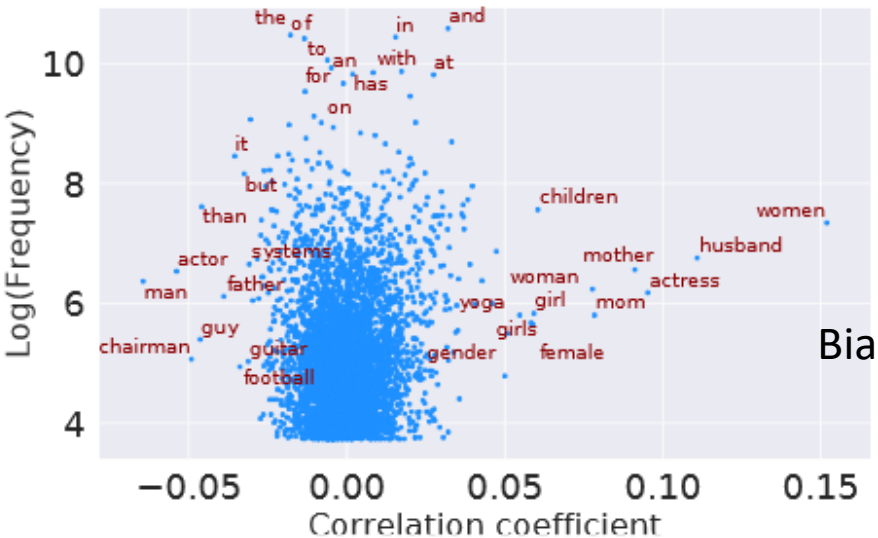

Bias in hiring

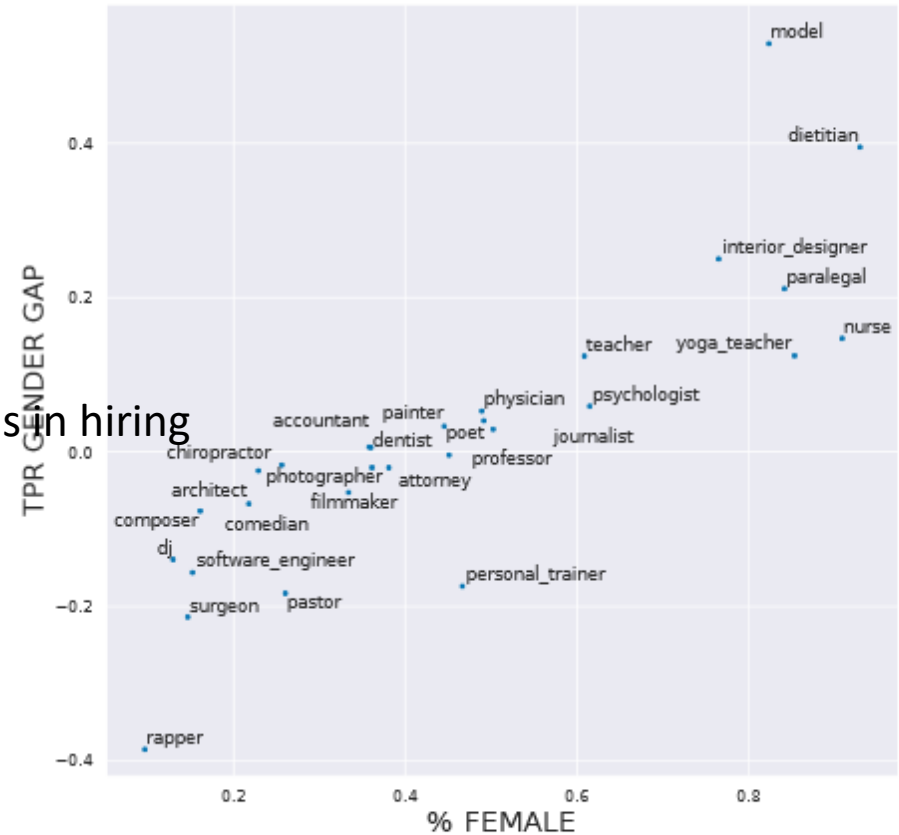

Bias in Bios: A Case Study of Semantic Representation Bias in a High-Stakes Setting. Maria De-Arteaga, Alexey Romanov, Hanna Wallach, Jennifer Chayes, Christian Borgs, Alexandra Chouldechova, Sahin Geyik, Krishnaram Kenthapadi, Adam Tauman Kalai. CoRR abs/arXiv:1901.09451, 2019

Figure 3: $\mathrm{Gap}_{\mathrm{female},y}$ versus $\pi_{\mathrm{female},y}$ for each occupation y for the BOW representation with explicit gender indicators.

On doit trouver des voies d'améliorations

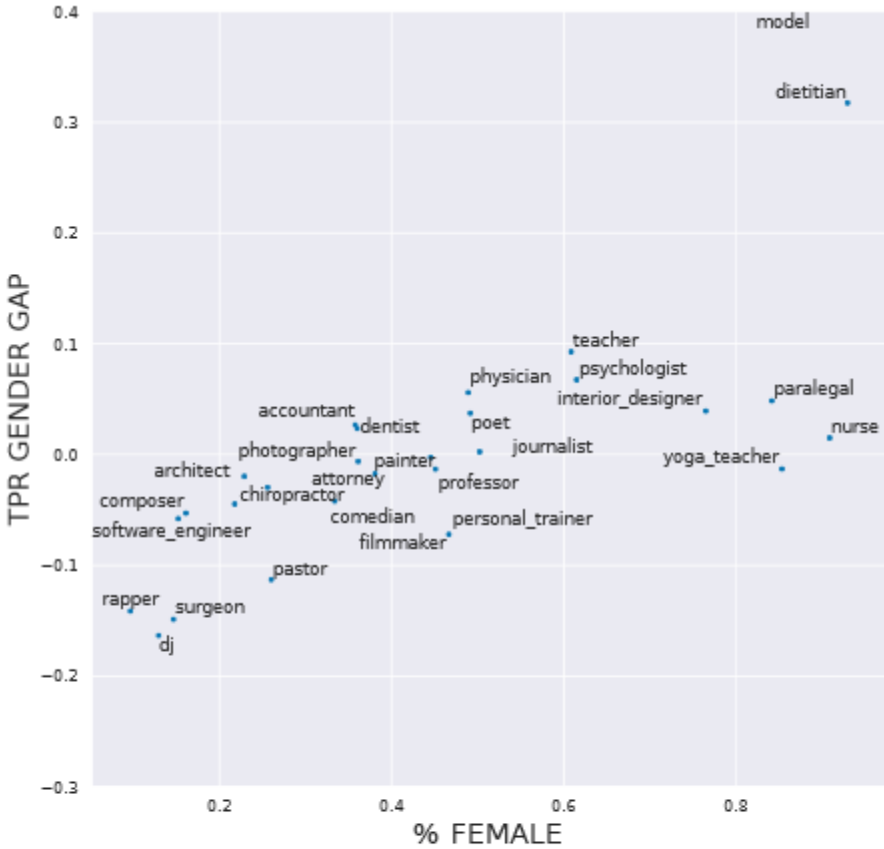

Figure 11: Gender gap per occupation vs. % females in occupation for WE trained without gender indicators.

Un sujet d'importance

NewScientist

Biased policing is made worse by errors in pre-crime algorithms

4 October 2017 , updated 27 April 2018

CNBC

MARKETS BUSINESS INVESTING TECH POLITICS CNBC TV

TECH

Facebook and YouTube should have learned from Microsoft's racist chatbot

PUBLISHED SAT, MAR 17 2018 • 4:03 PM EDT

Ingrid Angulo
@INGRID__ANGULO

KEY POINTS

- Facebook and YouTube have recently come under fire for offensive search suggestions.
- Microsoft made a Twitter chatbot in 2016 that was trained to say outrageous things by users, but Facebook and YouTube don't seem to have learned from the mistake.
- Psychological studies have shown that people are drawn to negative and offensive content, so engagement maximization drives the popularity of this content.

PRO PUBLICA

How We Analyzed the COMPAS Recidivism Algorithm

by Jeff Larson, Surya Mattu, Lauren Kirchner and Julia Angwin

May 23, 2016

← Read the story

Across the nation, judges, probation and parole officers are increasingly using algorithms to assess a criminal defendant's likelihood of becoming a recidivist – a term used to describe criminals who re-offend. There are dozens of these risk assessment algorithms in use. Many states have built their own assessments, and several academics have written tools. There are also two leading nationwide tools offered by commercial vendors.

We set out to assess one of the commercial tools made by Northpointe, Inc. to discover the underlying accuracy of their recidivism algorithm and to test whether

NewScientist

Discriminating algorithms: 5 times AI showed prejudice

Artificial intelligence is supposed to make life easier for us all – but it is also prone to amplify sexist and racist biases from the real world

TECHNOLOGY 12 April 2018 , updated 27 April 2018

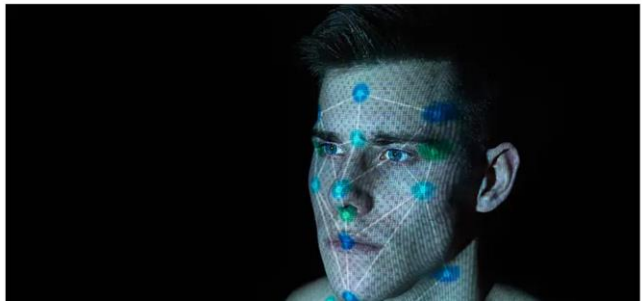

https://fatconference.org/

Track 1: Computer Science

1. Fairness, equity and justice by design
2. Methods to audit, measure, and evaluate fairness
3. Methods involving human factors and humans-in-the-loop
4. Accountability, transparency and interpretability by design
5. Methods to assess explainability, transparency and interpretability

Track 2: Law

1. Data protection law and fundamental rights and freedoms
2. Non-discrimination law, justice and fairness

Track 3: Social Sciences and Humanities

1. Sociology, and Science and Technology Studies (STS)
2. Philosophy, Political Philosophy, and Digital Ethics

Track 4: Practice and Experience

1. Deployed applications, systems and software
2. Algorithmic audits, evaluations, benchmarks of real-world systems
3. Experiences in governance: standardization, activism and communication

Track 5: Education

1. Educating at the intersection of Law, Social Sciences, Humanities, and Computer Science

Résumé

- L'équité (*fairness*) est un objectif important dans le développement d'un technologie
- C'est un sujet qui doit faire partie intégrante de la conception de la technologie
  - Pas un correctif
- La définition de l'équité comporte beaucoup de facettes souvent contradictoire
  - Exemple: paradoxe de Simpson
- Son implémentation peut être liée à la notion d'indépendance probabiliste
- Les effets d'aggravation peuvent être inhérents aux algorithmes (exemple: par polarisation), pas seulement aux données

- L'équité est en lien avec l'éthique mais n'est en pas la seule composante (voir Techno-Ethics)

→ La recherche a beaucoup de progrès à faire sur le sujet

Quelques references

- Tolga Bolukbasi,Kai-Wei Chang,James Zou,Venkatesh Saligrama,Adam Kalai. Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings, ArXiv 1607.06520, 2016
- Solon Barocas, Andrew D. Selbst. Big Data's Disparate Impact. 104 CALIF.Law REV.671(2016). DOI: http://dx.doi.org/10.15779/Z38BG31
- Pratik Gajane, Mykola Pechenizkiy. On Formalizing Fairness in Prediction with Machine Learning. ArXiv 1710.03184, 2017
- Sahil Verma, Julia Rubin. Fairness Definitions Explained. 2018 ACM/IEEE International Workshop on Software Fairness
- L. Hu, Y Chen. A Short-term Intervention for Long-termFairness in the Labor Market. ArXiv 1712.00064, 2017
- Michael P. Kim,Omer Reingold, Guy N. Rothblum. Fairness Through Computationally-Bounded Awareness. arXiv 1803.03239, 2018
- Alexandra Chouldechova. Fair prediction with disparate impact:A study of bias in recidivism prediction instruments. ArXiv 1610.07524, 2016
- Richard Zemel, Yu Wu, Kevin Swersky, Toniann Pitassi, Learning Fair Representations. ICML 2013.
- Muhammad Bilal Zafar, Isabel Valera, Manuel Gomez Rodriguez, Krishna P. Gummadi. Fairness Constraints: Mechanisms for Fair Classification. AISTATS 2017.

Liens

Videos:

- Bias in bios: fairness in a high-stakes machine-learning setting https://www.youtube.com/watch?v=IDNXZitcQng (ArXiv 1901.09451, 2019)
- CNBC report: https://www.youtube.com/watch?v=ZMsSc_utZ40
- Demo interactive: http://research.google.com/bigpicture/attacking-discrimination-in-ml/
- Techno-ethics: https://en.wikipedia.org/wiki/Ethics_of_technology