Intelligence Artificielle

Gestion de l’aléatoire

Stephane Marchand-Maillet

Contenu

- Notion de probabilité
- Les outils probabilistes pour l'IA
- Variations sur le théorème de Bayes
- Notion d'entropie

Evénements

La sémantique des probabilités peut être ambiguë:

- Probabilité qu'un événement *A* se réalise

→ Probabilité que la proposition « *A* se réalise » *soit vraie*

→ *A* est vu comme une proposition logique

→ On parle de « non A » (¬A)

→ C'est la vision de A comme *variable aléatoire*

Mais *A* est aussi vu comme un ensemble de réalisations valides (évènement élémentaires): Exple: {1,3,5} pour les faces impaires d'un dé

→ Version ensembliste on écrit « $A \cap B$ » et « A^c »

→ Définition d'un univers Ω ($A \subseteq \Omega$)

→ C'est la version proche du formalisme de la *théorie de la mesure* ou de l'approche *fréquentiste*

Définition

La probabilité P(A) d'un évènement A de l'univers Ω est telle que (axiomes de Kolmogorov):

1. $0 \leq P(A) \leq 1$

   La probabilité est une mesure positive

2. $P(\Omega)=1$

   La mesure de l'univers est 1

   La probabilité qu'au moins un évènement élémentaire se réalise est 1

3. $P(A \cup B)=P(A)+P(B)$ si $A \cap B = \emptyset$

   Les mesures s'additionnent si l'intersection est vide

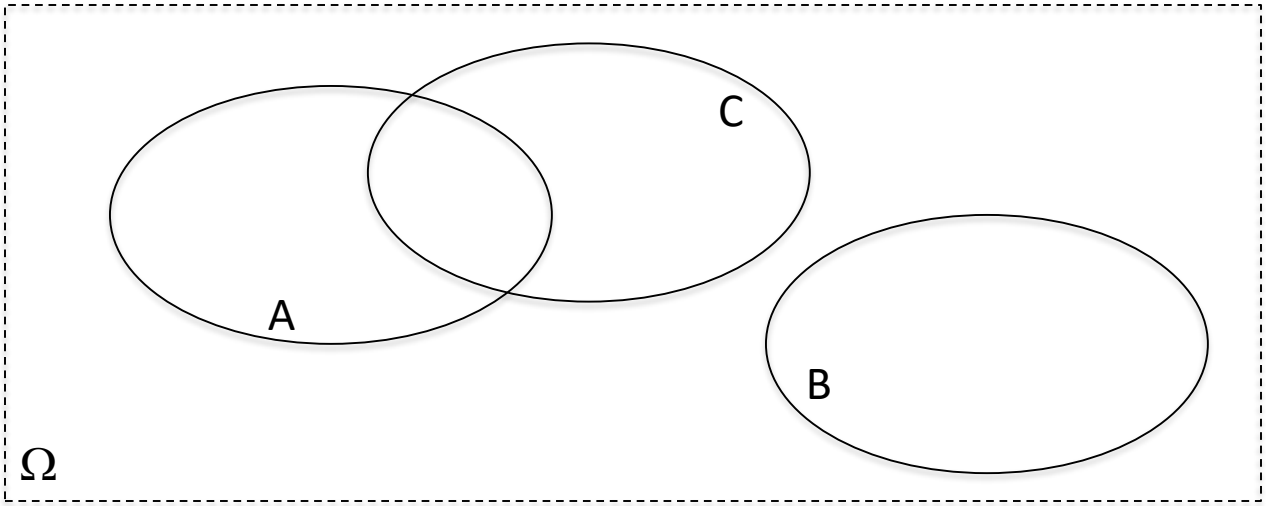

Attention: cette représentation a ses limites (cf plus tard)

Propriétés

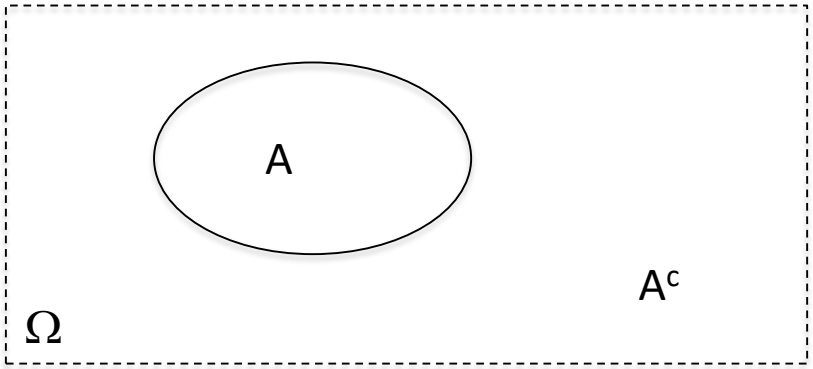

Etant donné A on a:

$$\Omega = A^c \cup A \quad \text{et} \quad A \cap A^c = \emptyset$$

$\rightarrow P(\Omega) = P(A^c \cup A) = P(A^c) + P(A) = 1$

$\rightarrow P(A^c) = 1 - P(A)$

Exercice: Prouvez que $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ (cf lois de De Morgan)

Calcul effectif

Pour des probabilités discrètes (Ω dénombrable et fini):

$$A \subseteq \Omega \qquad P(A) = \frac{|A|}{|\Omega|}$$

Si A est composé d'événements (a) élémentaires disjoints et équiprobables:

Mesure d'un événement élémentaire (« |a| »)

$$P(A) = \sum_{a \in A} P(a) \quad \text{et} \quad P(a) = \frac{1}{|\Omega|}$$

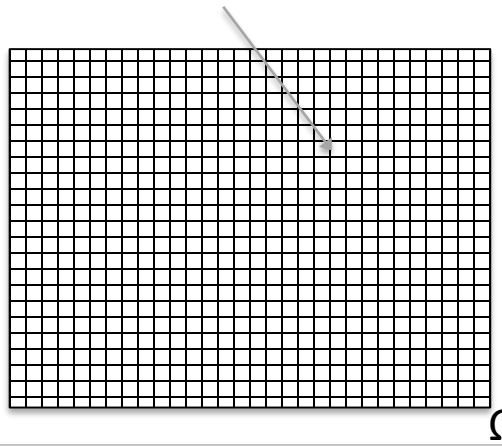

Décompte des événements élémentaires a

$$\text{donc } |\Omega| = \sum_{a \in \Omega} 1 \qquad (\text{car } P(\Omega)=1)$$

Exemple

Dé équilibré à 6 faces:

- $\Omega=\{1,2,3,4,5,6\}$
- Un évènement $A=\{2,4,6\}$

- $|\Omega| = \sum_{a\in\Omega} 1 = 6$

- $P(a) = \frac{1}{|\Omega|} = \frac{1}{6} \qquad a\in\Omega$

- $P(\{2\}) = \frac{1}{6}$

- $P(A)=P(\{2,4,6\})=P(\{2\})+P(\{4\})+P(\{6\}) = \frac{3}{6} = \frac{1}{2}$

Variable aléatoire (définition informelle)

Une variable aléatoire X peut être vue comme une proposition pouvant être vraie avec la probabilité $p \in (0,1)$ et fausse avec la probabilité $1-p$

Exemple (dé à 6 faces):

- Univers: $\Omega=\{1,2,3,4,5,6\}$
- Un évènement $A=\{2,4,6\}$
- On déclare la variable aléatoire X (résultat)
- $P(A) = P(\{2,4,6\})$ est traduit en $P(X \in \{2,4,6\})$
- Ou $P(\{5\}) = P(X=5)$ (Note: $P(X \neq 5) = 1 - P(X=5)$)

ensembliste logique

Probabilité conditionnelle

Définition:

$$P(A|B)=\frac{P(A\cap B)}{P(B)}$$

"Probabilité de A sachant (la probabilité de) B"

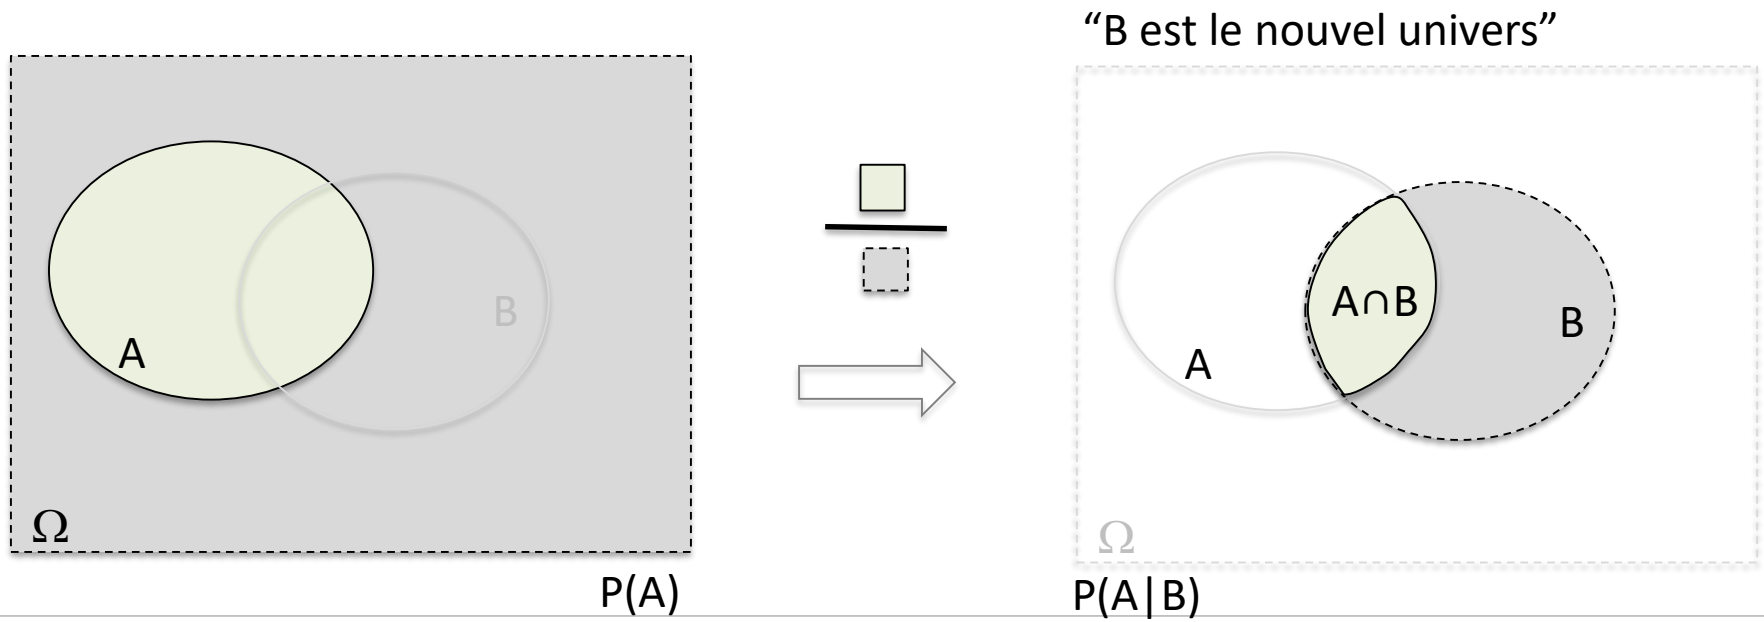

Probabilité conditionnelle

On a donc:

$$P(A) = P(A \cap \Omega)/1 = \frac{P(A \cap \Omega)}{P(\Omega)} = P(A|\Omega)$$

→ Toute probabilité est conditionnée à son univers

P(A) en connaissance de (sachant)… B, Ω, …

P(A) en ignorant ce qui n'est pas dans.. B, Ω,…

Cas particuliers

- $B \subset A$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B)}{P(B)} = 1$$

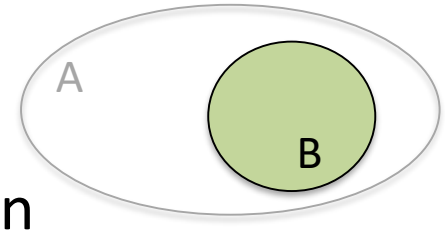

→ si on sait que B est réalisé alors A est certain
(B est le nouvel univers, seule la partie B de A est visible)

- $A \subset B$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)}{P(B)}$$

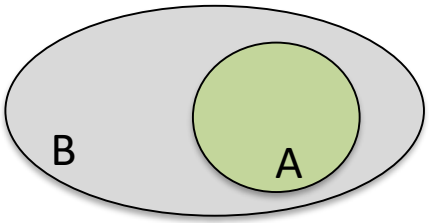

→ A est mesuré complètement en fonction de B
(B est le nouvel univers)

- $A \cap B = \emptyset$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(\emptyset)}{P(B)} = 0$$

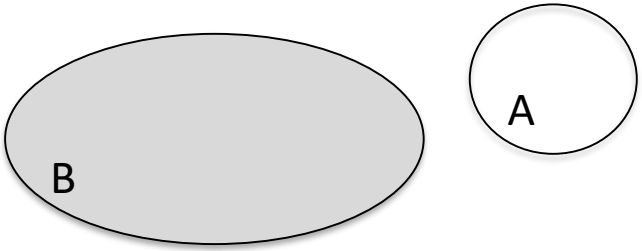

→ A n'est pas visible dans le nouvel univers (B)

Loi des probabilités totales

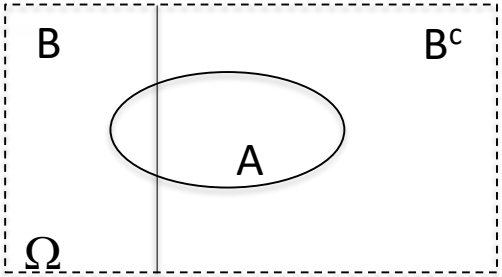

On a:

$$P(A) = P(A \cap \Omega)$$

et $A \cap \Omega = A \cap (B \cup B^c) = (A \cap B) \cup (A \cap B^c)$

et $(A \cap B) \cap (A \cap B^c) = \emptyset$

Donc (axiome 3):

$P(A) = P((A \cap B) \cup (A \cap B^c)) = P(A \cap B) + P(A \cap B^c)$

Soit:

$$P(A) = P(A|B).P(B) + P(A|B^c).P(B^c)$$

Plus généralement:

$$P(A) = \sum_{i=1}^{N} P(A|B_i).P(B_i)$$

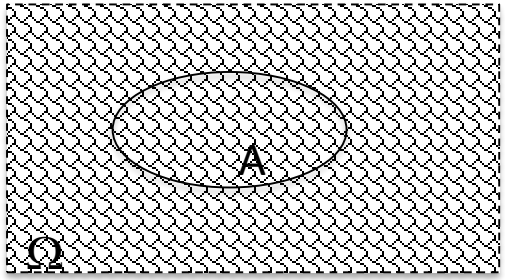

si la famille B_i est une partition de Ω
(couvre Ω et sont disjoints 2 à 2)

Probabilité jointe

Si $P(A|B)=\dfrac{P(A\cap B)}{P(B)}$

alors $P(A\cap B) = P(A|B).P(B)$

$P(A\cap B) = P(A,B)$ est la probabilité jointe des évènements A et B

temporalité

$$P(A\cap B) = P(A|B).P(B)$$

Proba jointe,
Proba des 2 evenements

Proba de l'un (B)…
…proba de l'autre (A)
sachant le premier (B)

temporalité

A et B se réalisent (ou non) ← A se réalise (ou non) sachant B ← B se réalise (ou non)

Exemple

Une urne contient des objets (balles et cubes) de couleur (rouges ou blancs)

Evenement A="l'objet est rouge"
Evenement B="l'objet est un cube"

	Rouge	Blanc
Cube	12	2
Balle	4	8

- P(A) = proportion d'objets rouges = 16/26 ~ 0.61
- P(B) = proportion de cubes = 14/26 ~ 0.53

- P(A,B)=proportion de cubes rouges = 12/26 ~ 0.46

- P(A|B)=chance d'avoir un objet rouge sachant la probabilite de tenir un cube = 12/14 ~ 0.85

- $P(A^c|B)$=chance d'avoir un objet blanc sachant la probabilite de tenir un cube = 2/14 ~ 0.19

- $P(A|B^c)$=chance d'avoir un objet rouge sachant la probabilite de tenir une balle = 4/12 ~ 0.33

Exercice: refaire les calculs avec une plus forte proportion de balles que de cubes

Indépendance

Définition:

On dit que deux évènements A et B sont indépendants ssi:

$$P(A \cap B) = P(A,B) = P(A).P(B)$$

$$\rightarrow P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A)$$

→B n'apporte pas de connaissance pour A

→Et A n'apporte pas de connaissance pour B

Attention: l'indépendance n'implique pas $A \cap B = \emptyset$

Sinon: $P(A \cap B) = P(\emptyset) = 1 - P(\Omega) = 0 \neq P(A).P(B)$

Attention aux illustrations

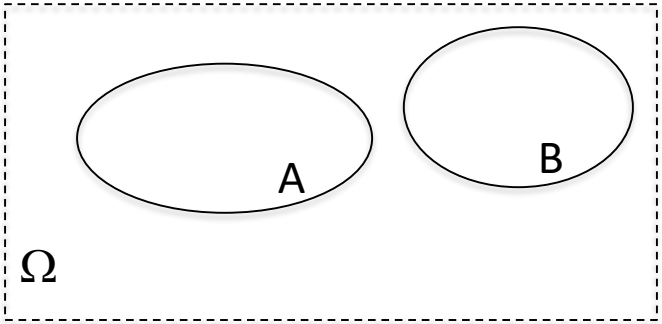

A et B sont disjoints: $A \cap B = \emptyset$

$P(A \cap B) = P(\emptyset) = 1 - P(\Omega) = 0$

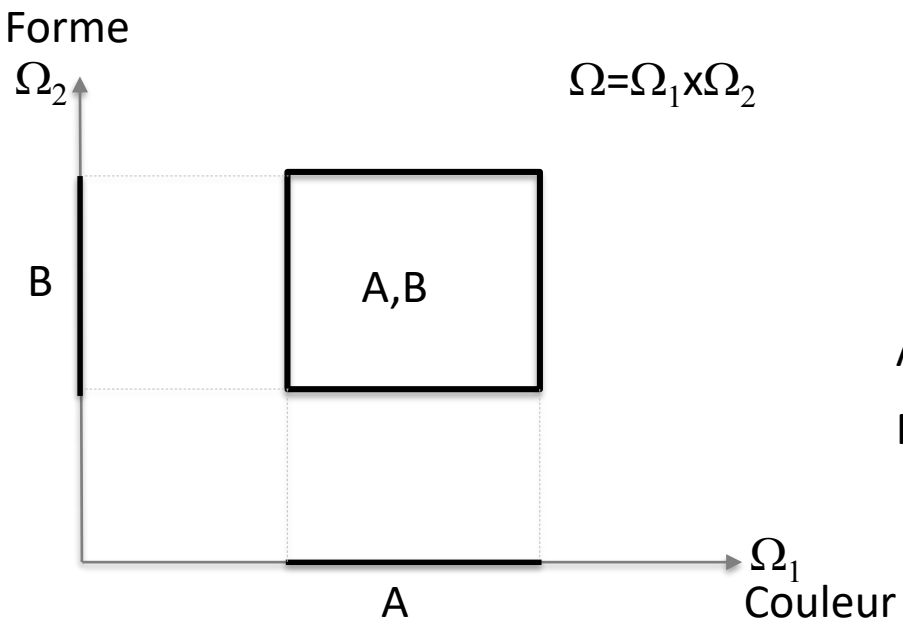

A et B sont indépendants ("orthogonaux")

$P(A,B) = P(A)P(B)$

Théorème de Bayes

Si A et B sont deux évènements alors:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

Preuve:

Directe à partir de la définition de la probabilité conditionnelle

Facettes du Théorème de Bayes

Interprétation:

La probabilité conditionnelle introduit une temporalité. On peut donc étudier les effets (observable) d'une cause (supposée)

A = Observation de l'effet (symptôme)

B = présence de la cause (cachée)

Je peux observer les effets sous l'hypothèse de la cause: c'est P(A|B) = P(effet|cause)

J'ai une idée a priori sur la présence de la cause: c est P(B) = P(cause)

J ai une idée sur la présence de l'effet: c est P(A)=P(effet)

→ Je peux estimer la présence de la cause (sans l'observer directement) sachant que j'ai observé l'effet:

c'est P(B|A) que je peux calculer par le théorème de Bayes

Interprétation opérationnelle

likelihood *prior*

$$P(B|A)=\frac{P(A|B)P(B)}{P(A)}$$

posterior *evidence*

On place nos observations
sous l'hypothèse de la cause…

…tout en ayant un apriori
sur la présence de la cause
(indépendamment de l'effet)…

$$P(\text{cause}|\text{effet})=\frac{P(\text{effet}|\text{cause})P(\text{cause})}{P(\text{effet})}$$

On cherche à savoir si la cause
est probable étant données nos observations

…et un apriori
sur la présence de l'effet
(indépendamment de la cause)

Exemples: $P(\text{maladie}|\text{sympôme}) = \frac{P(\text{symptôme}|\text{maladie})P(\text{maladie})}{P(\text{symptôme})}$ $P(\text{magic in the air}|\text{joie}) = \frac{P(\text{joie}|\text{magic})P(\text{magic})}{P(\text{joie})}$

Interprétation

Modification de connaissance
apportée par l'observation
(observation de l'effet normalisée
par notre apriori sur la présence de l'effet)

$$P(\text{cause}|\text{effet}) = \left(\frac{P(\text{effet}|\text{cause})}{P(\text{effet})}\right) P(\text{cause})$$

Notre certitude sur la présence de la cause après avoir observé l'effet

Notre certitude sur la présence de la cause avant d'avoir observé l'effet

$$P(\text{maladie}|\text{sympôme}) = \frac{P(\text{symptôme}|\text{maladie})}{P(\text{symptôme})} P(\text{maladie})$$

Exercice

Je veux savoir si il fait soleil en écoutant les oiseaux

J'observe que :

- Les oiseaux chantent 9 fois sur 10 quand le soleil est la
- 7 fois sur 10 quand je tends l'oreille j'entends les oiseaux chanter
- Il fait soleil 1 jour sur 4

Avant d'ouvrir mes volets, j'entends les oiseaux. Quelle est la probabilité qu'il y ait du soleil?

$$P(\text{soleil}|\text{chant}) = \frac{P(\text{chant}|\text{soleil})P(\text{soleil})}{P(\text{chant})} = \frac{0.9*0.25}{0.7} \cong 0.32$$

Exercice

$P(\text{soleil}|\text{chant}) \cong 0.32$

Je veux savoir si il fait soleil en écoutant les oiseaux
J'observe que :

- Les oiseaux chantent 9 fois sur 10 quand le soleil est la
- 7 fois sur 10 quand je tends l'oreille j'entends les oiseaux chanter
- Il fait soleil 1 jour sur 4

→ Les oiseaux chantent très souvent quand le soleil est la (90%)
→ Mais les oiseaux chantent souvent EN GENERAL (70%)
→ L'information du chant des oiseaux ne modifie pas beaucoup ma connaissance sur la présence du soleil (32% au lieu de mon apriori de 25%)

posterior = 1.28 * prior $\quad P(\text{soleil}|\text{chant}) = \frac{P(\text{chant}|\text{soleil})}{P(\text{chant})} P(\text{soleil})$

Ce serait différent si:

- Les oiseaux chantaient moins souvent (30%) en général: $P(\text{soleil}|\text{chant})=?$
- Le soleil brillait plus souvent (75%): $P(\text{soleil}|\text{chant})=?$

- Que se passe t il si les oiseaux chantent 9 fois sur 10 quand je tends l'oreille?

Exercice

Comment exprimer que les oiseaux chantent toujours et seulement quand il y a du soleil?

$P(chant|soleil) = 1$ et $P(chant)=P(soleil)$

Dans ce cas:

$$P(chant,soleil) = P(chant|soleil)P(soleil) = P(soleil)$$
$$= P(soleil|chant)P(chant) =$$
$$\frac{P(chant|soleil)P(soleil)}{P(chant)} P(chant) = P(chant)$$

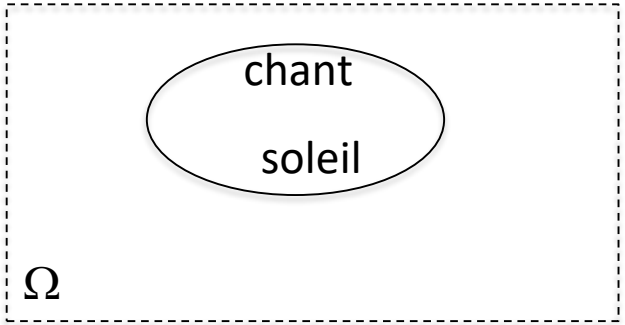

Suffit-il de dire: $P(chant)=P(soleil)$?

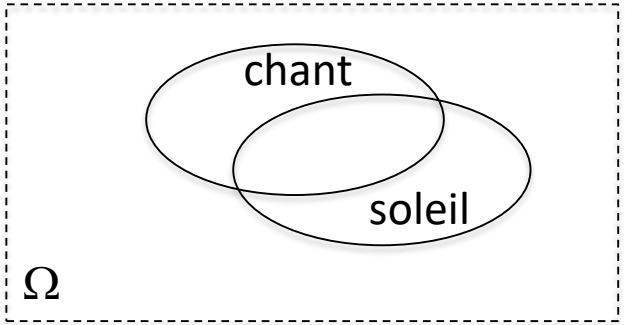

Non

Cas particulier

$$P(\text{cause}|\text{effet}) = \frac{\overset{=1}{P(\text{effet}|\text{cause})}P(\text{cause})}{P(\text{effet})}$$

Je veux savoir si il fait soleil en écoutant les oiseaux

et je sais que $P(\text{chant}|\text{soleil}) = 1$

→ Les oiseaux chantent à chaque fois qu'il y a du soleil (mais pas seulement)

→ $P(\text{chant}|\text{soleil}) = \dfrac{P(\text{chant} \cap \text{soleil})}{P(\text{soleil})} = 1$

→ On peut ne considérer que les chants car

$P(\text{soleil}|\text{non-chant})=0$

$$P(C|S) = \frac{P(S|C)P(C)}{P(S|C)P(C) + P(S|NC)P(NC)} = 1$$

$$\Rightarrow P(S|C)P(C) = P(S|C)P(C) + \underbrace{\cancel{P(S|NC)}P(NC)}_{=0}$$

$$\Rightarrow P(\text{soleil}|\text{chant}) = \frac{P(\text{soleil})}{P(\text{chant})}$$

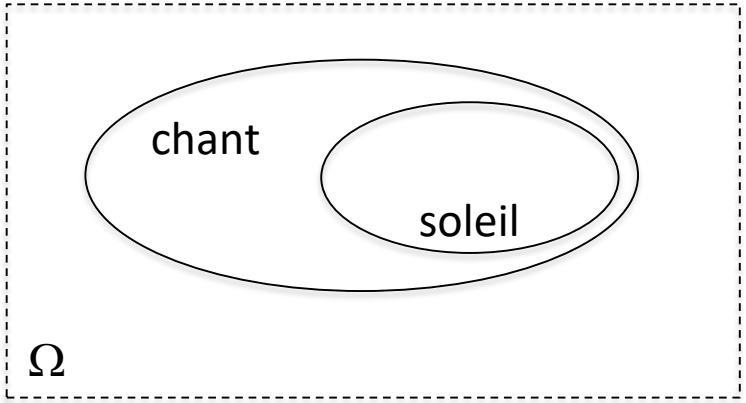

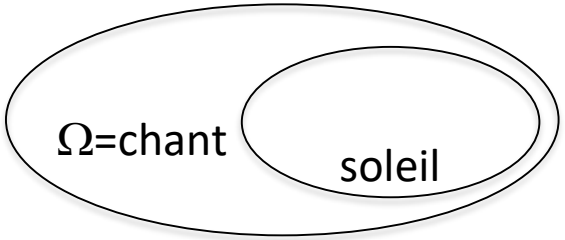

Je n'ai plus d'information pour décider

Autre écriture

On sait que $P(A) = P(A|B).P(B) + P(A|B^c).P(B^c)$
Donc:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A|B).P(B) + P(A|Bc).P(Bc)}$$

$$P(B|A) = \left(1 + \left(\frac{P(A|Bc).P(Bc)}{P(A|B)P(B)}\right)\right)^{-1}$$

La certitude que la cause est présente (P(cause|effet)=1) est altérée par le fait d'observer le même effet en l'absence de la cause

$$P(\text{cause}|\text{effet}) = \left(1 + \left(\frac{P(\text{effet}|\text{non-cause}).P(\text{non-cause})}{P(\text{effet}|\text{cause}).P(\text{cause})}\right)\right)^{-1}$$

Contexte de test

On a une hypothèse (H, « cause ») qu'on cherche a verifier à travers des observations (O, « effets »)

$$P(H|O)=\frac{P(O|H)P(H)}{P(O|H).P(H)+P(O|H^c).P(H^c)}$$

Hypothèse (cause)

(effet) Observation

	Hypothèse vraie	Hypothèse fausse
Observé	Vrai positif P(O,H)	Faux positif P(O,H^c)
Pas observé	Faux négatif	Vrai négatif

La probabilité que l'observation soutienne l'hypothèse (P(H|O)) est la proportion de vrais positifs parmi tous les positifs

Arbre de décision

Un arbre de décision représente une séquence de décisions et leurs branchements possibles

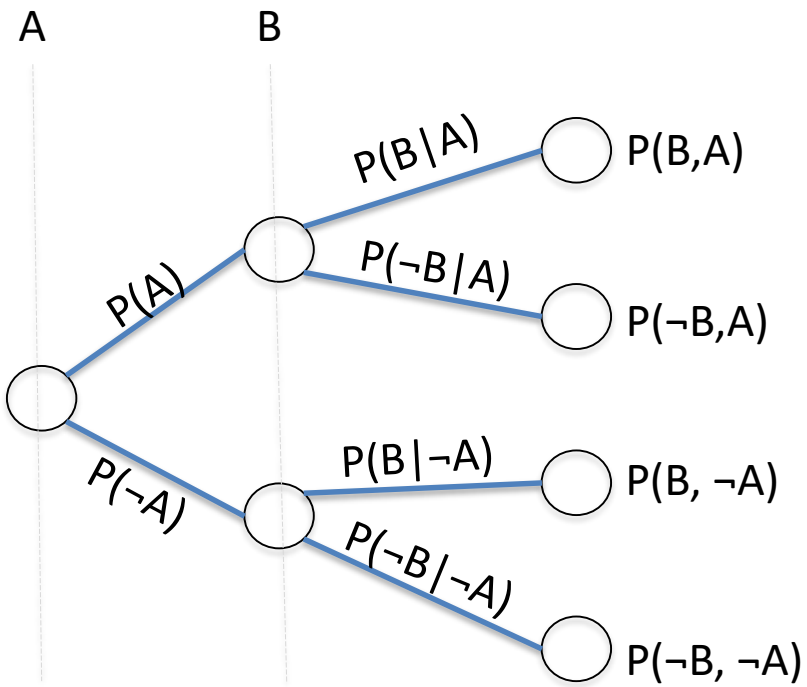

- La probabilité d'un nœud est le produit des probabilités le long du chemin
- L'arbre n'est pas forcément binaire

Arbre de décision

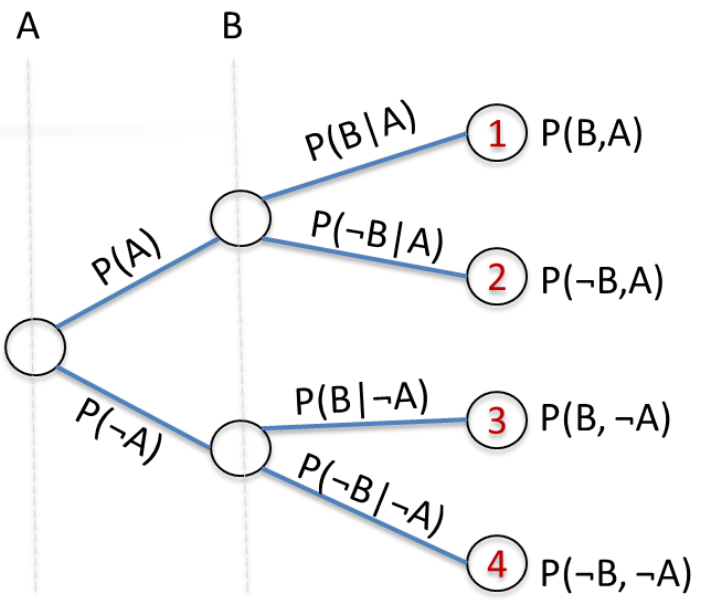

On peut faire de l'inférence:

$$P(A|B)=\frac{P(B|A)P(A)}{P(B)}$$

P(B)?

Probabilités totales →

$$P(A|B)=\frac{P(B|A)P(A)}{P(B|A)P(A)+P(B|\neg A)P(\neg A)}$$

Exercice: calculez P(¬ A|B)

$$P(A|B)=\frac{P(A,B)}{P(A,B)+P(\neg A,B)}=\frac{(1)}{(1)+(3)}$$

On va étudier la construction d'arbres de décision dans la suite du cours

Exemple 1

2 urnes contenant des balles rouges et blanches

	Rouge	Blanc
Urne 1	12	2
Urne 2	4	8

Je tire une balle rouge d'une des urnes. Quelle est la probabilité que ce soit l'urne 1?

Exemple 1

On veut calculer P(Urne 1|Rouge)

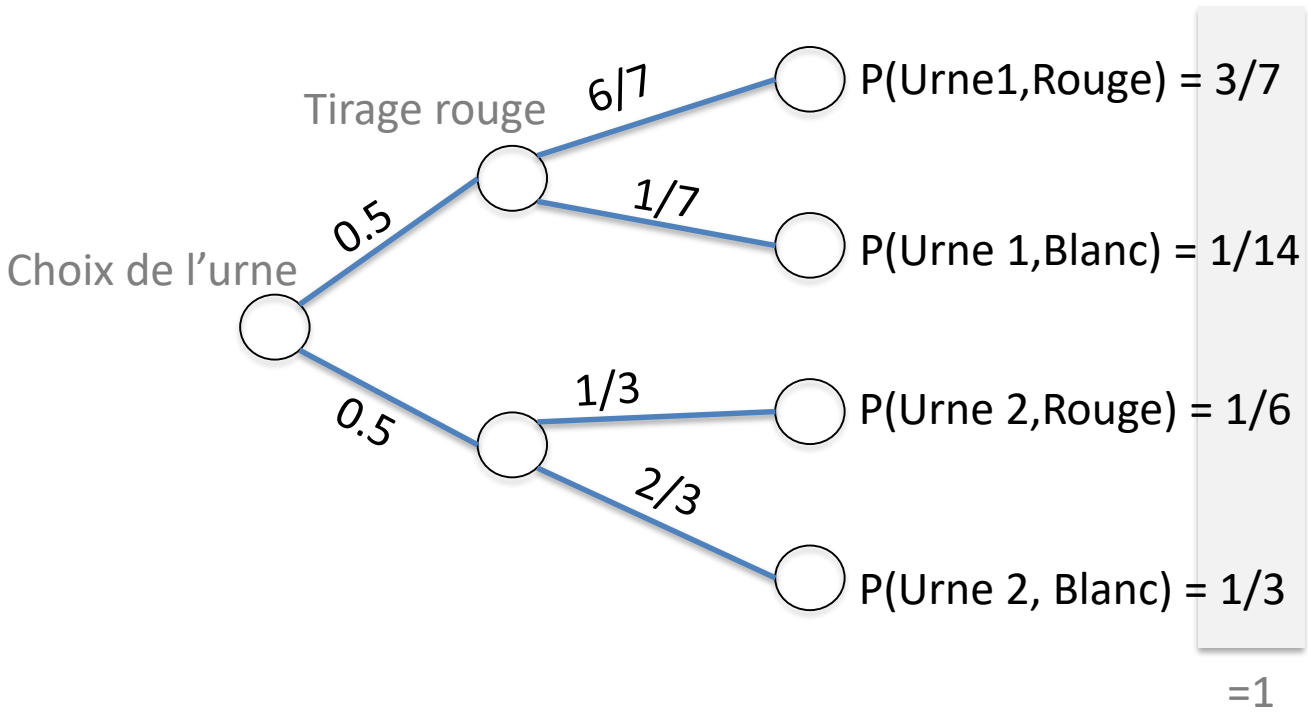

P(Urne 1|Rouge) = P(Urne1,Rouge) / (P(Urne1,Rouge)+ P(Urne 2,Rouge))

= (3/7) / ((3/7)+(1/6)) = 0.72 → 72%

Exemple 2

- Je sais que 80% des champignons sont comestibles
- Un spécialiste sait reconnaitre à 95% un champignon comestible
- Par contre, il surestime 3% des champignons

Je trouve un champignon et il le classe comme comestible: quelles sont mes chances de me régaler?

Exemple 2

On veut calculer P(comestible|oui) :

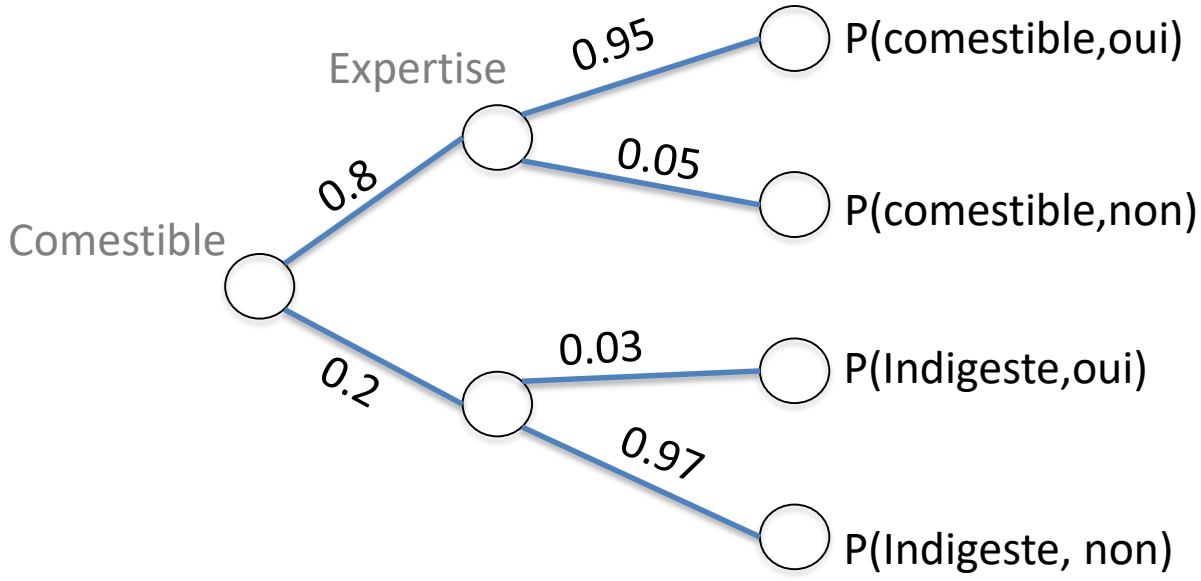

Réponse = (0.8*0.95)/((0.8*0.95)+(0.2*0.03)) = 99,2%

Mesurer l'incertitude: notion d'entropie

Etant donné un ensemble Ω d'éléments équiprobables, on cherche à distinguer chaque élément avec des questions binaires (Vrai/Faux)

Combien de questions au minimum faut-il pour identifier un objet?

La réponse est la profondeur de l'arbre (de décision) binaire équilibré dont les feuilles sont les éléments de Ω, soit $\log_2(|\Omega|)$. C'est une mesure (en bits) de l'incertitude du système (son contenu d'information).

Exemple: Dé équilibré à 8 faces:

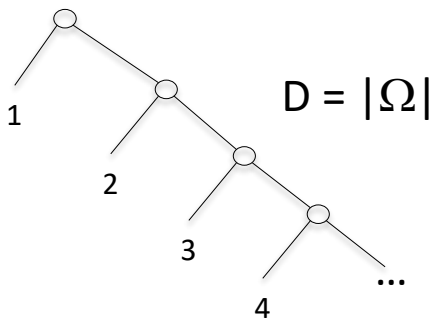

$D = |\Omega|$

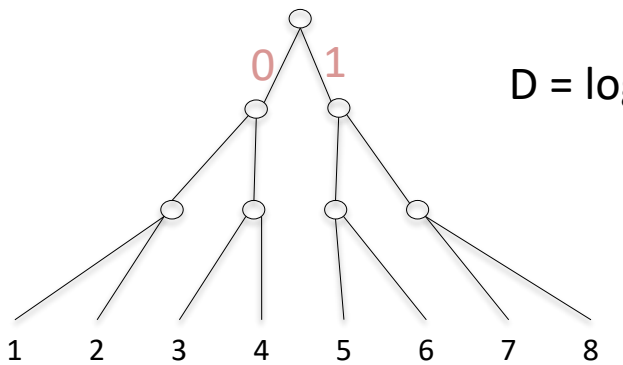

$D = \log_2(|\Omega|) = 3$

Note: l'arbre représente le codage binaire d'un label pour chaque élément

Entropie (construction informelle)

Pour le tirage d'un dé équilibré à 8 faces, on a pour chaque face a:
$P(a) = 1/|\Omega|$ soit $D = -\log_2(P(a))$

On généralise en distribuant l'incertitude du système sur chaque événement a.
On définit donc l'entropie d'une variable aléatoire X représentant le résultat d'un tirage sur Ω par la somme (moyenne) pondérée:

$$H(X) = -\sum_{a \in \Omega} P(a) \log_2 P(a)$$

Note:

Pour des événements a équiprobables on a $P(a) = 1/|\Omega|$

donc

$$H(X) = -\sum_{a \in \Omega} P(a) \log_2 P(a) = \log_2 |\Omega|$$

Autre construction (informelle)

Soit une variable aléatoire X séparant Ω en Ω_1 et Ω_2 avec la probabilité p_1 ($X=x_1$) et $p_2 = 1-p_1$ ($\neg X$, $X=x_2$) respectivement

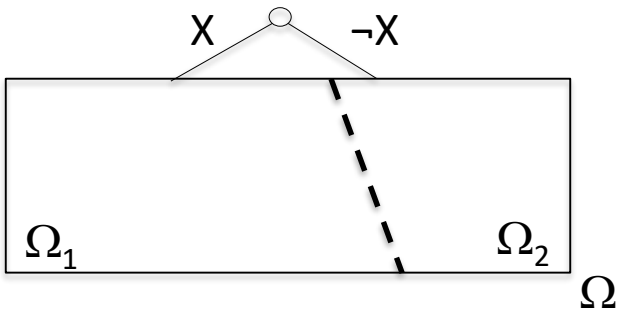

Pour $a \in \Omega$ on a

$$P(a) = P(a|X)P(X)+P(a|\neg X)P(\neg X) = P(a|X)\, p_1+P(a|\neg X)\, p_2$$

Dans Ω_1 et Ω_2 les événements sont équiprobables donc pour "coder" Ω_1 il faut $-\log_2 p_1$ bits et pour "coder" Ω_2 il faut $-\log_2 p_2$ bits

Soit en moyenne

$$H(X) = - p_1 \log_2 p_1 - p_2 \log_2 p_2$$

bits d'incertitude sur le système complet

En généralisant le raisonnement on arrive à

$$H(X) = -\sum_{a\in\Omega} P(a)\log_2 P(a)$$

Exemple

Documents pertinents pour une requête:

- Soit une collection de documents Ω séparée en 2 sous ensembles Ω_1 et Ω_2 (pertinents et non-pertinents respectivement).

L'entropie de la requête est une mesure de l'incertitude:

- Une requête séparant les documents équitablement apportera une incertitude plus grande ($\log_2(2) = 1$) qu'une requête définissant un petit ensemble de documents pertinents.

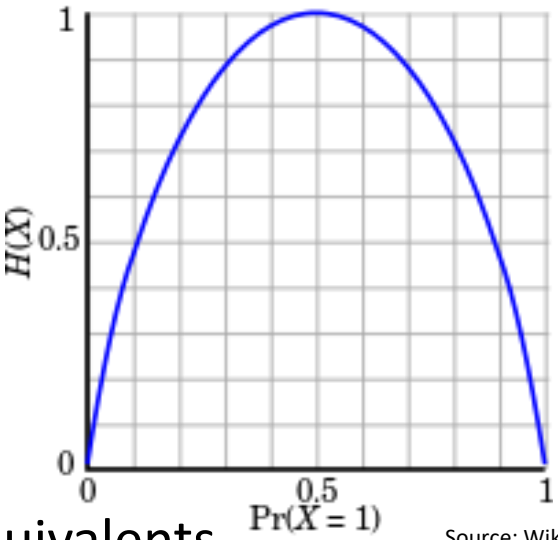

Source: Wikipedia

Note: Dans Ω_1 et Ω_2 les documents deviennent équivalents (équiprobables)

Autre exemple: pièce biaisée

Entropie conditionnelle

L'entropie H(X) est une mesure de l'information contenue dans une variable aléatoire X. Quid de l'information contenue dans X dans le contexte de la connaissance de Y?

Exemple: X=« Les oiseaux chantent », Y=« C'est l'été »

C'est l'entropie conditionnelle (par énumération) :

$$H(X|Y) = -\sum_{y \in \Omega_Y} P(Y=y) \sum_{x \in \Omega_X} P(X=x|Y=y) \log_2 P(X=x|Y=y)$$

Note (avec probabilités jointes):

$$H(X|Y) = -\sum_{x \in \Omega_X} \sum_{y \in \Omega_Y} P(X=x,Y=y) \log_2 \frac{P(X=x,Y=y)}{P(Y=y)}$$

Information mutuelle / Gain

Le gain d'information de la connaissance de Y sur X (et inversement) définit l'information mutuelle entre X et Y:

$$I(X;Y) = H(X)-H(X|Y) = H(Y)-H(Y|X)$$

On peut représenter graphiquement l'information par les diagrammes de Venn:

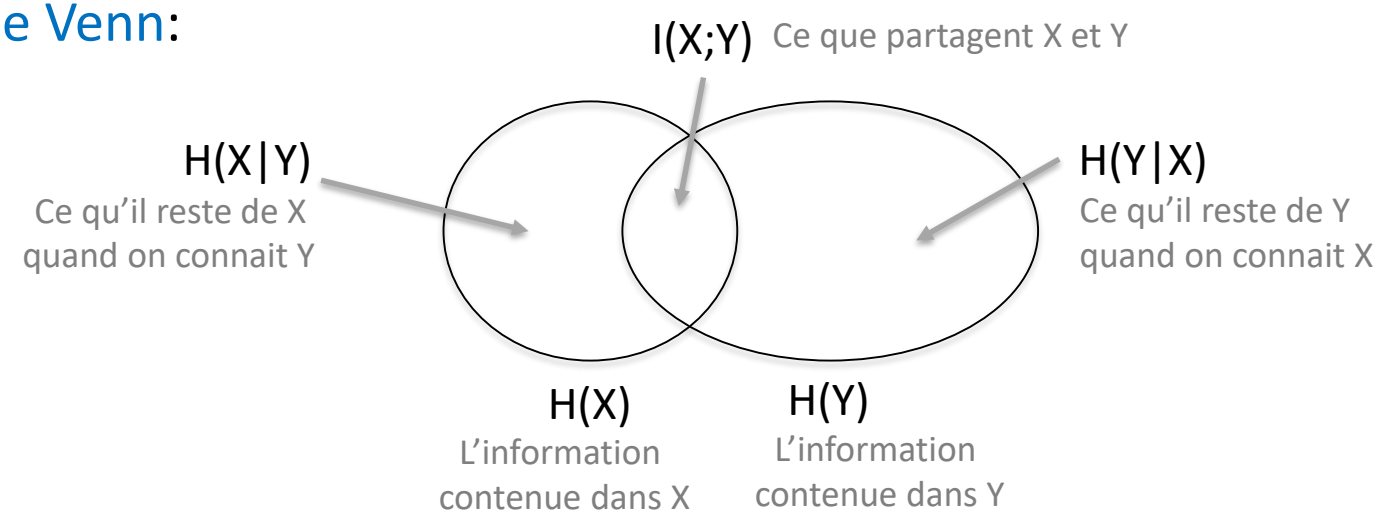

Un cercle représente un conteneur d'information. Si les variables ne sont pas indépendantes (elle partagent de l'information mutuelle), leurs cercles se recouvrent d'autant. Sinon I(X;Y)=0

Résumé

- Les probabilités discrètes se calculent de façon ensembliste (par énumération – approche fréquentiste)
- On raisonne en général sur des variables aléatoires (propositions logiques)

- La notion de probabilité conditionnelle permet de faire de l'inférence: on exploite l'information donnée par nos observations dans le contexte de nos hypothèses (approche épistémologique – basée sur le *belief* (croyance, certitude))

- La notion d'entropie permet de quantifier l'information et donc donne un critère d'optimisation pour l'inférence

→ On va exploiter ces constructions dans les prochains chapitres