Intelligence Artificielle

Arbres de Décision

Stephane Marchand-Maillet

Contenu

- Partition et arbre de décision
- Algorithmes d'apprentissage (ID3, CART)
- *Regression Tree*
- *Random Forest*

Partition et arbre de décision

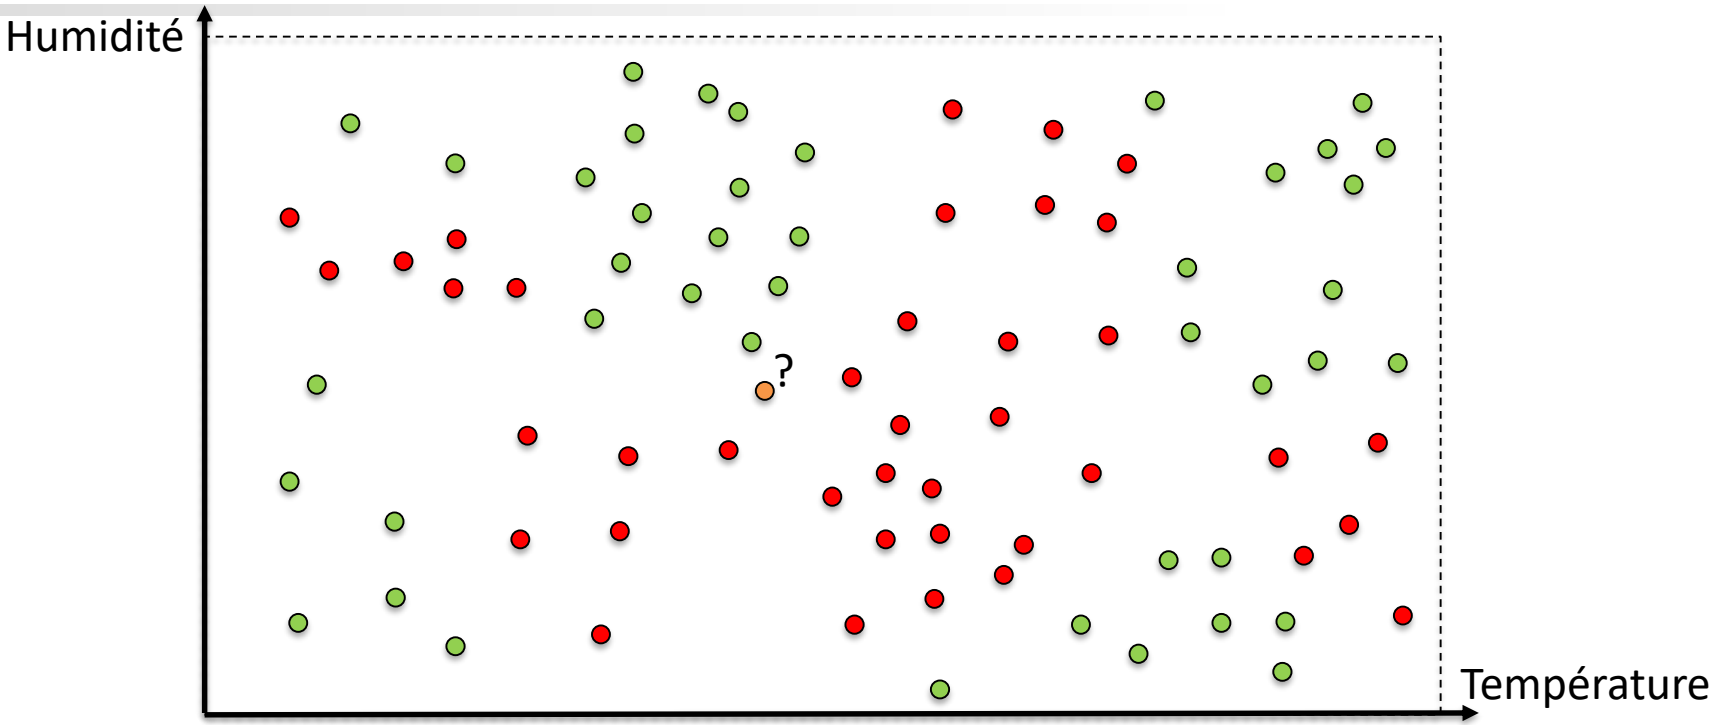

Données annotées (Décision: vert/rouge)

→ Contexte supervise (données+label)

→ On veut prédire le résultat en fonction de conditions

Exemple:

- Temperature
- Humidité

→ J'observe ce specimen d'oiseau (oui/non)

Partition et arbre de décision

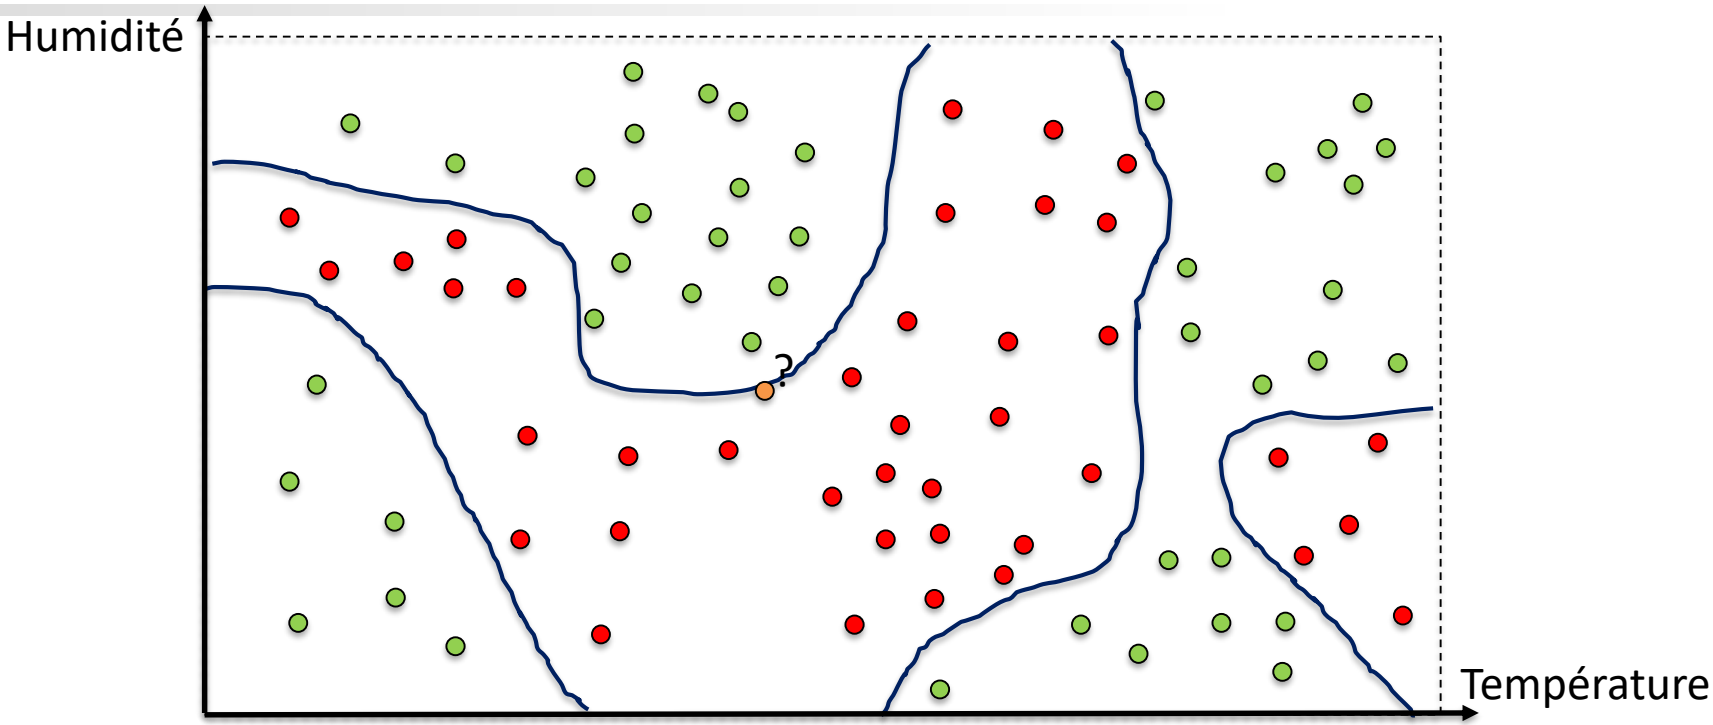

Données annotées (Décision: vert/rouge)

→ Contexte supervise (données+label)

→ On veut prédire le résultat en fonction de conditions

Exemple:

- Temperature
- Humidité

→ J'observe ce specimen d'oiseau (oui/non)

Partition et arbre de décision

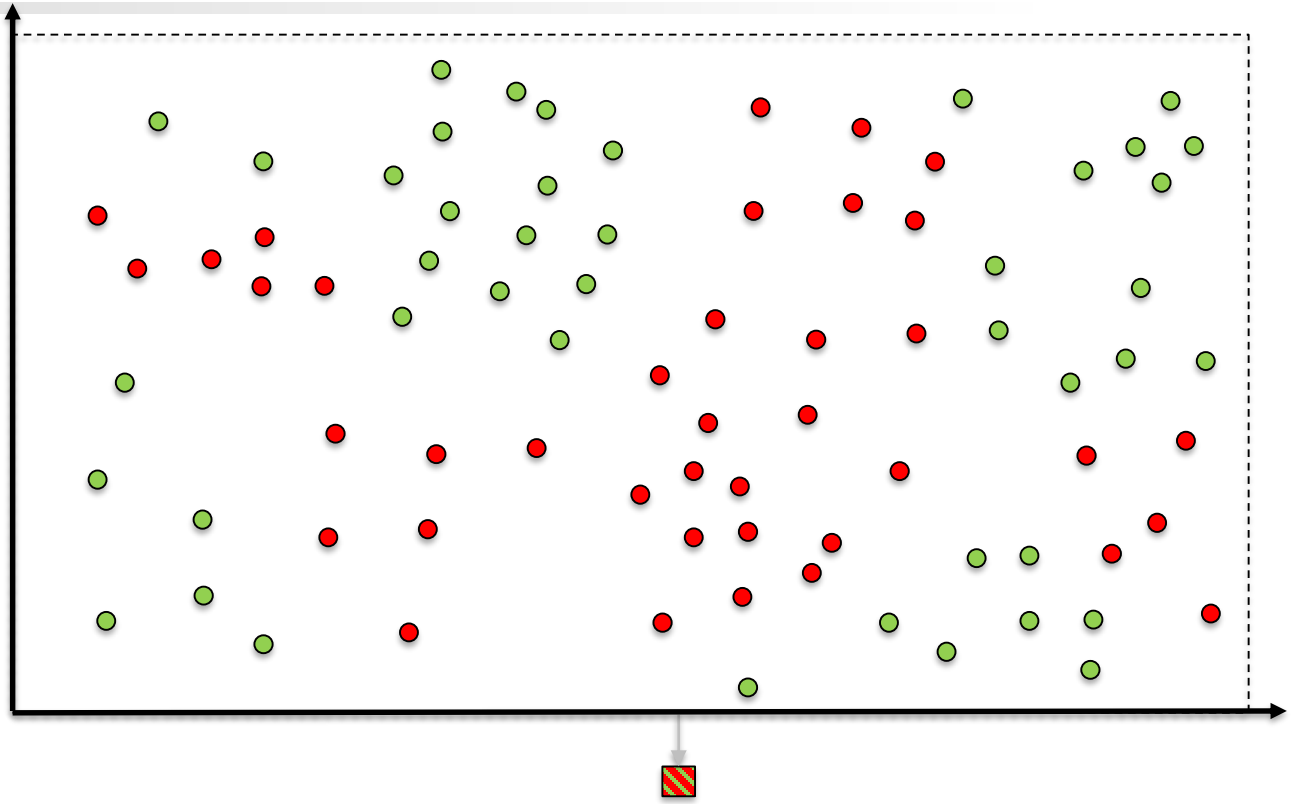

Partition et arbre de décision

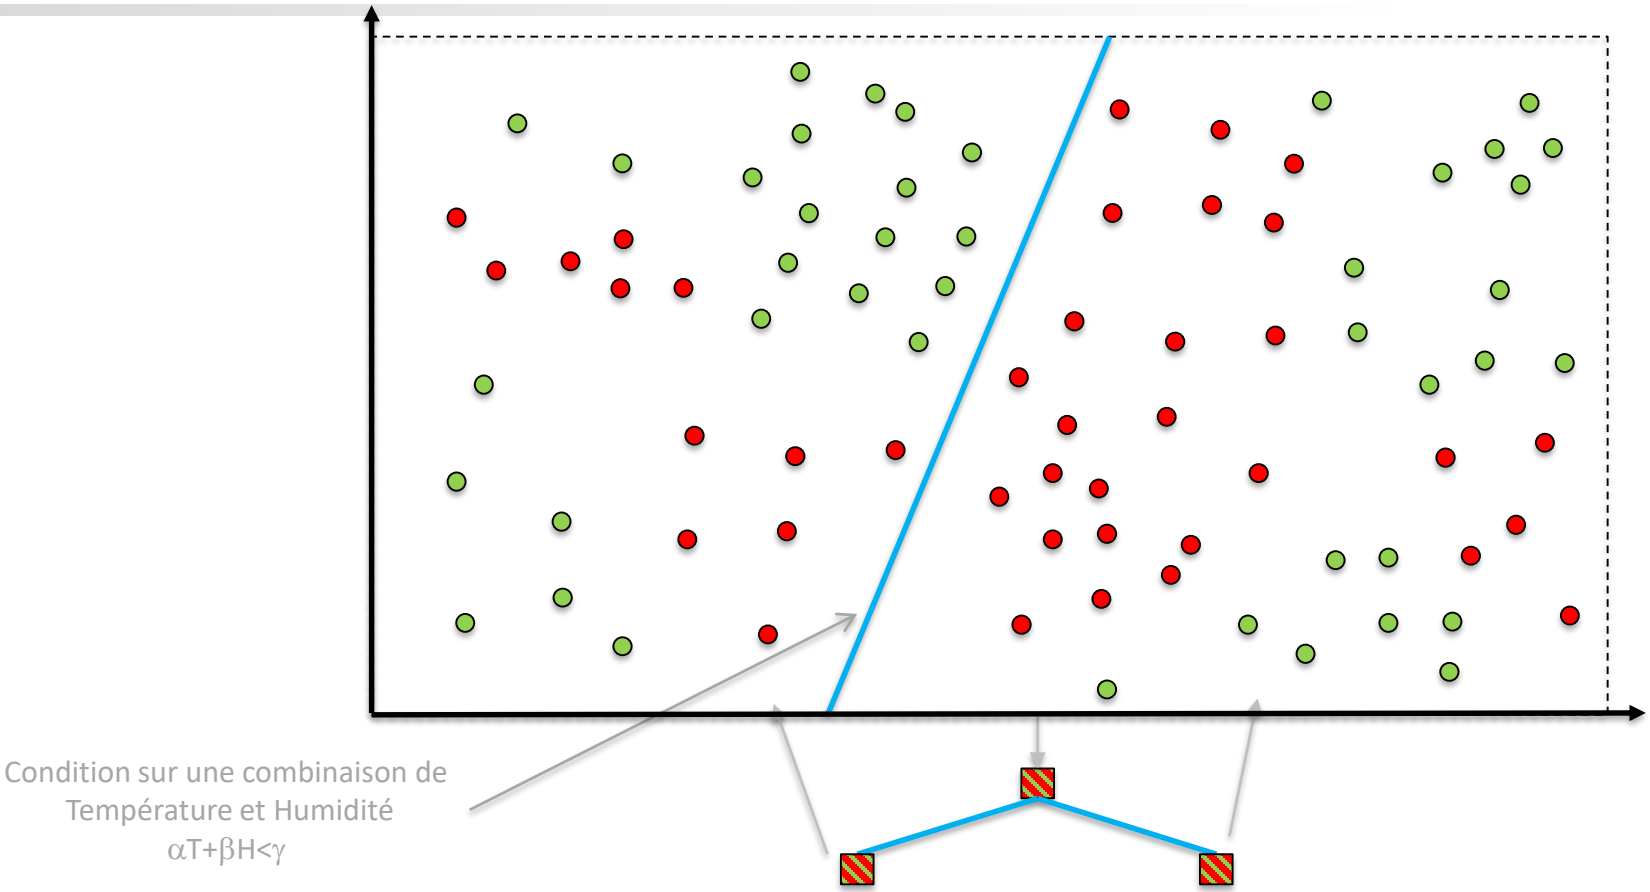

Une division binaire correspond à un choix de branche dans un arbre binaire

Partition et arbre de décision

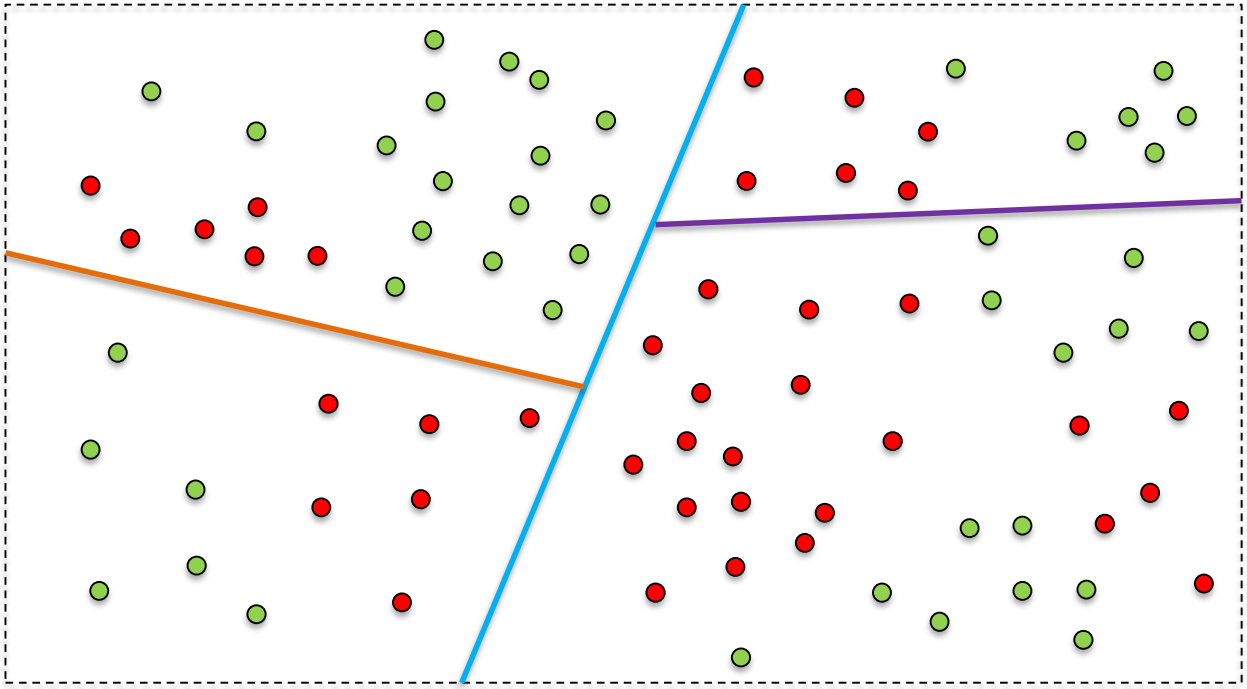

Partition et arbre de décision

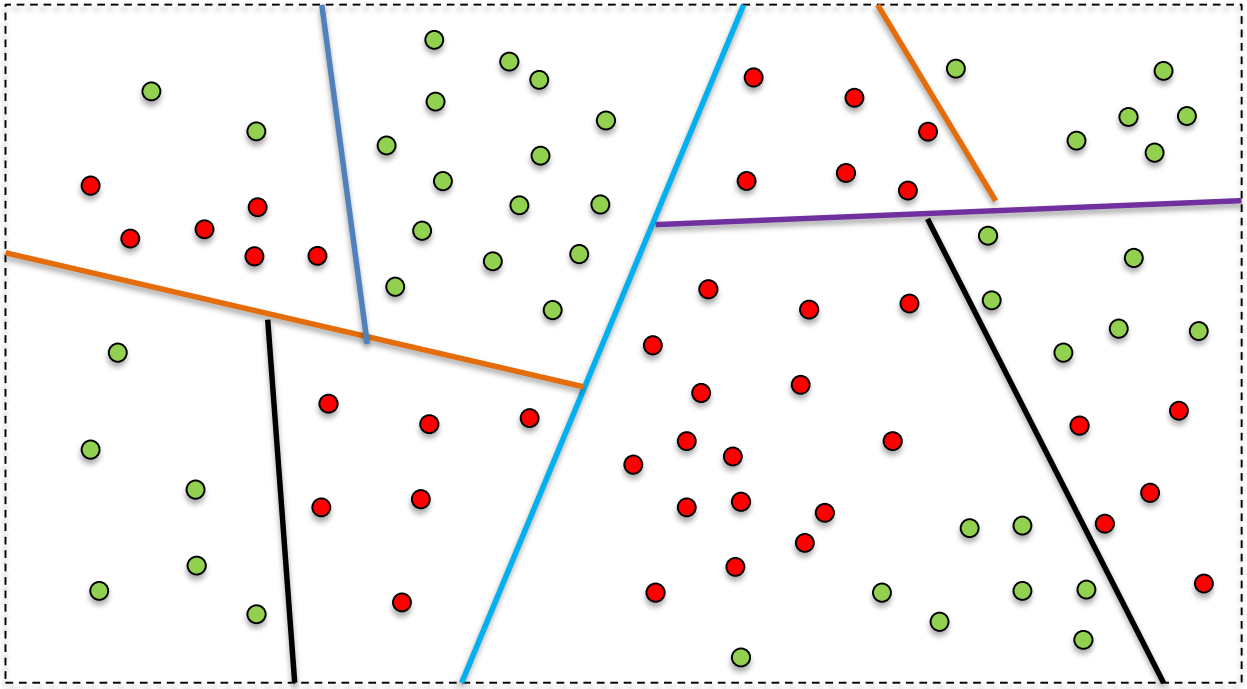

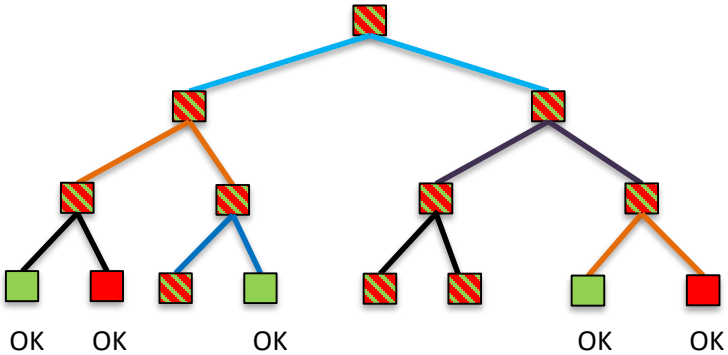

Partition et arbre de décision

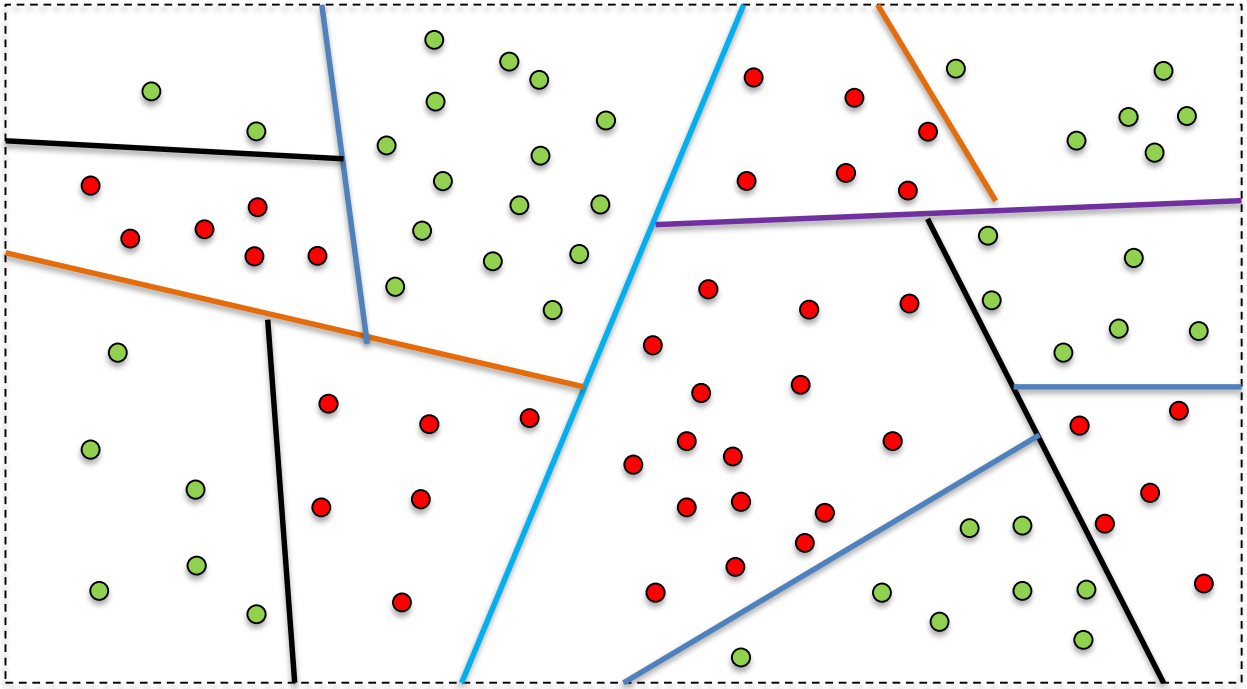

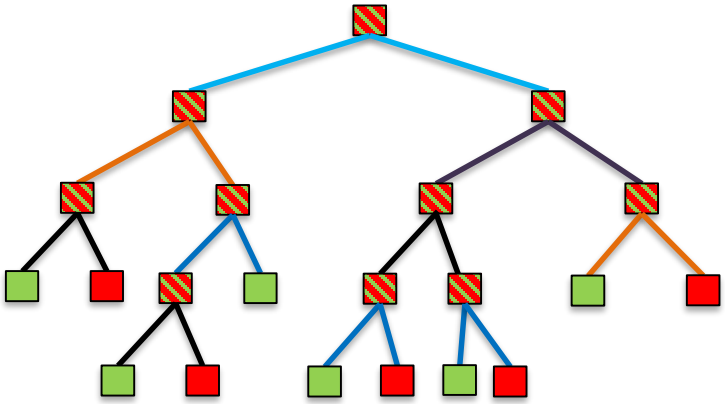

Partition et arbre de décision

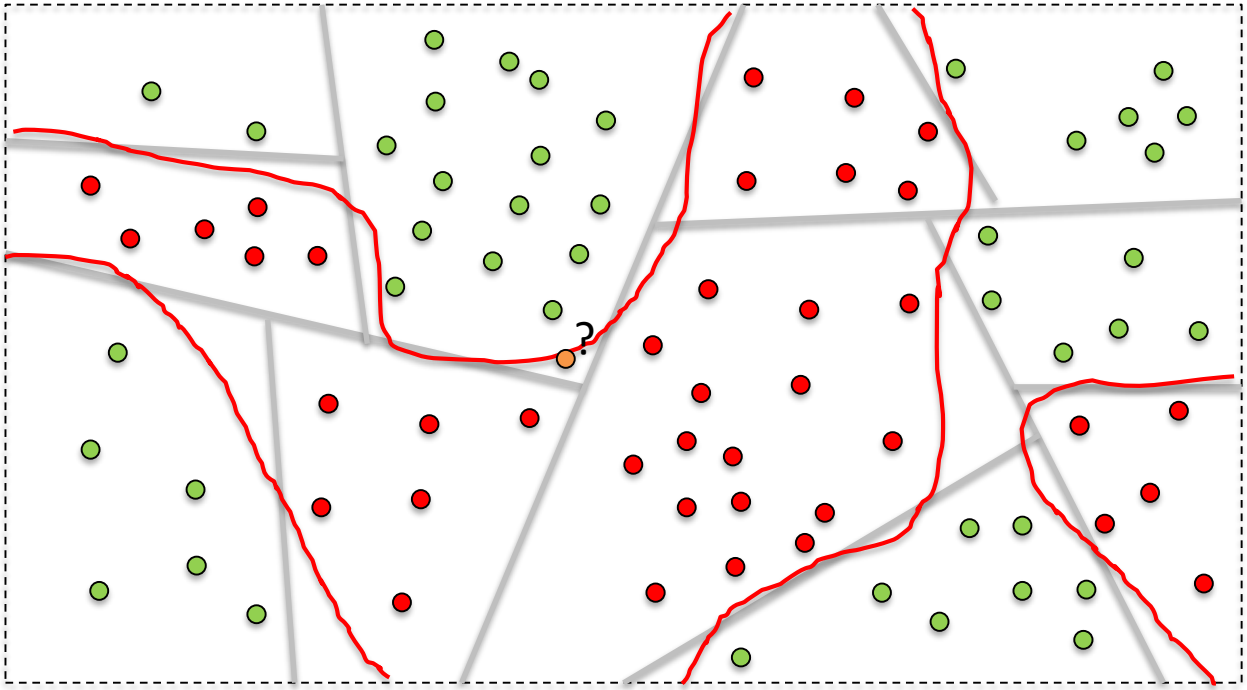

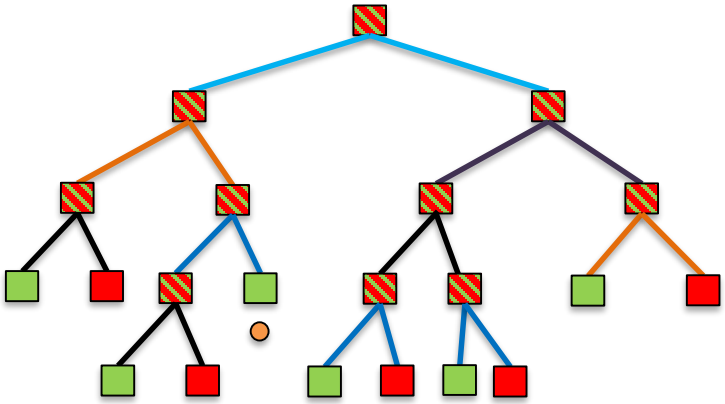

Partition et arbre de décision

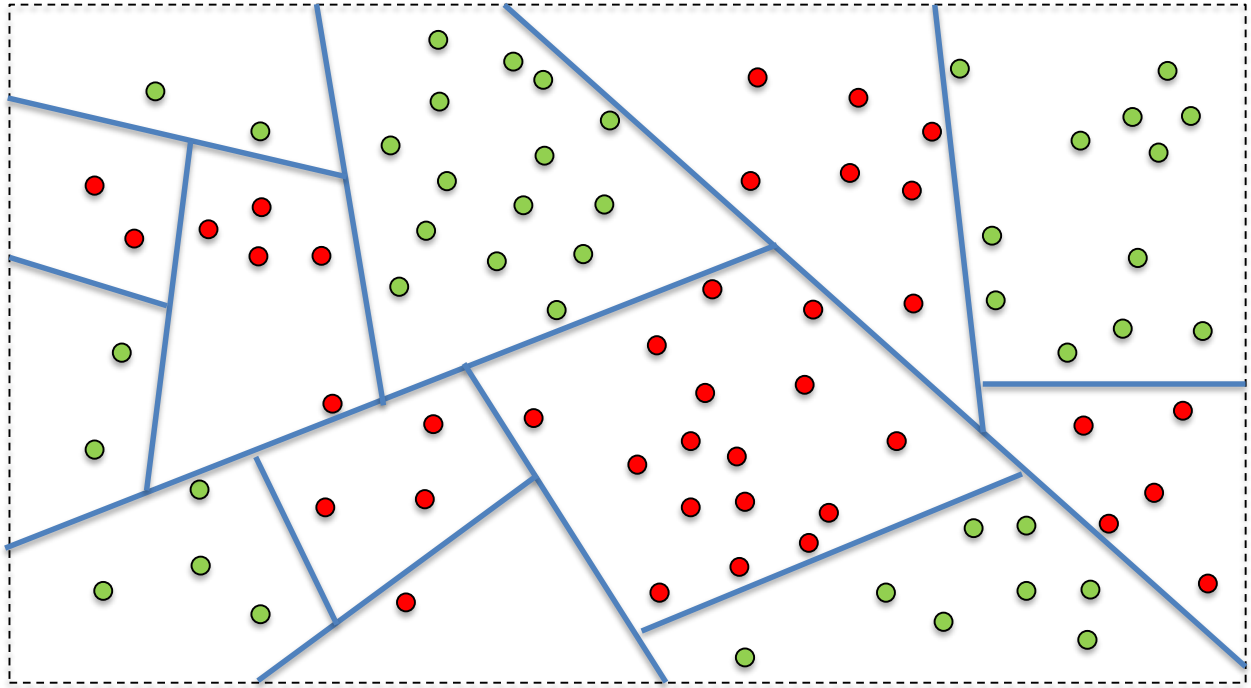

Exercice: Créez l'arbre de décision correspondant

Partition et arbre de décision

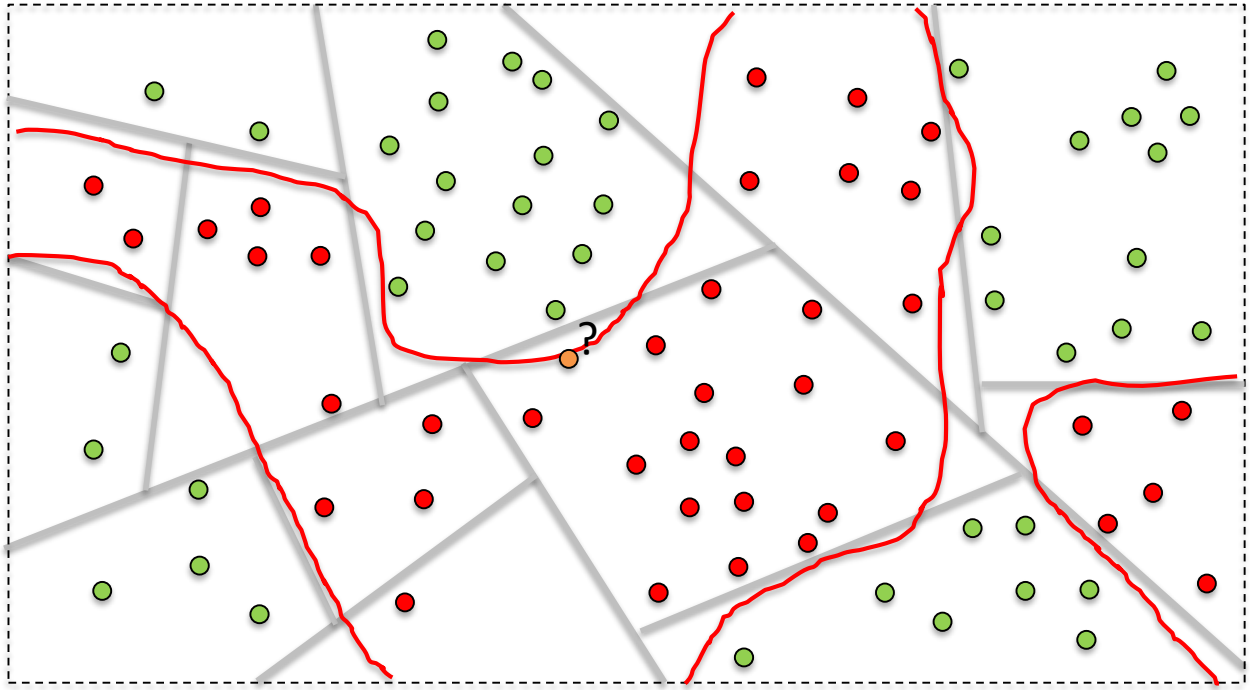

Toujours une approximation de notre fonction de décision

Arbre de décision et propositions

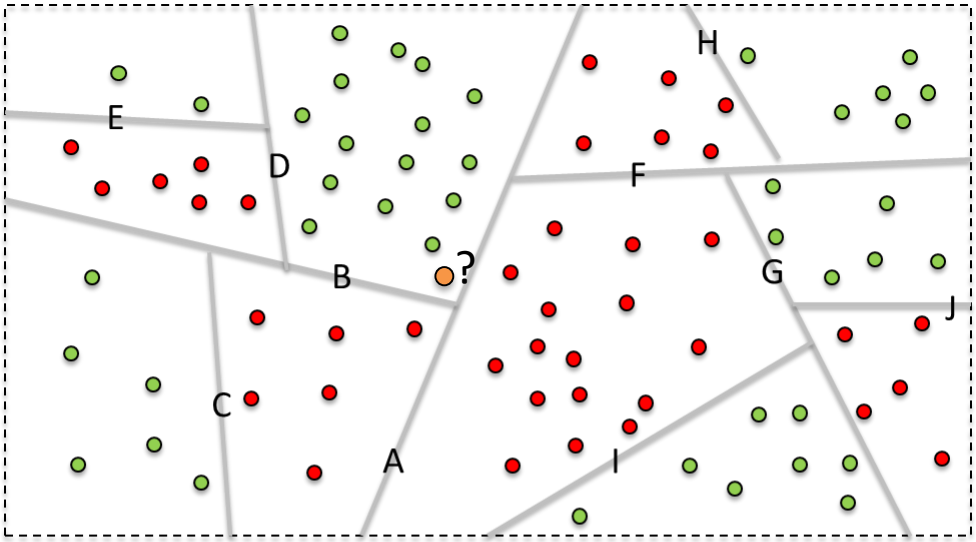

Exercices:

- Factoriser l'expression en vous aidant de l'arbre
- Ecrire l'expression pour non

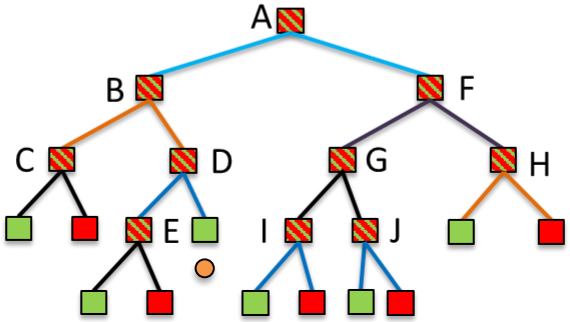

Oui = (A∧B∧C)V(A∧¬B∧D∧E)V(A∧¬B∧¬D)V(¬A∧F∧G∧I)V(¬A∧F∧¬G∧J)V(¬A∧¬F∧H)

→ Construire un arbre = construire des expressions logiques (décisions)
→ Défi: réduire la longueur des propositions (en moyenne) → profondeur de l'arbre

Rappel: Mesurer l'information

Entropie d'une variable X à valeurs (discretes) dans Ω:

$$H(X) = -\sum_{X \in \Omega} P(X=x)\log_2 P(X=x)$$

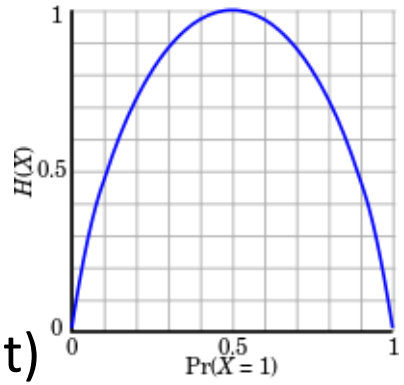

- Maximum quand les évenements sont equiprobables
- Minimum si le choix est deterministe (1 seul évènement)

→ Mesure d'information (en bits de surprise)

Entropie conditionnelle:

$$H(X|Y) = -\sum_{y \in \Omega Y} P(Y=y) \sum_{x \in \Omega X} P(X=x|Y=y)\log_2 P(X=x|Y=y)$$

→ On énumère les combinaisons

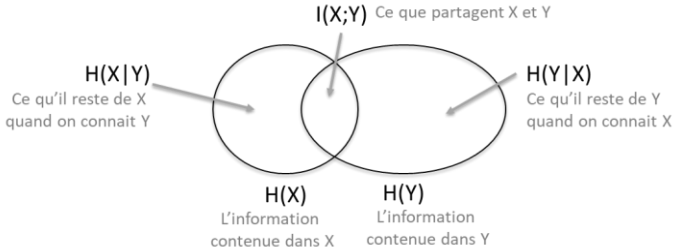

Gain d'information:

$$I(X;Y) = H(X)-H(X|Y) = H(Y)-H(Y|X)$$

Construction d'un arbre de décision

Etant données des données représentées par leurs caractéristiques et la decision induite…

…on cherche à partitionner l'ensemble de données par des decisions sur les caractéristiques…

…de telle façon que les sous-ensembles soient d'entropie minimale.

Le but est de construire un arbre pour décider sur une situation à venir

Exemple:

Jour	Température	Humidité	Oiseau visible?
J1	Moyenne	Forte	Oui
J2	Elevée	Faible	Oui
J3	Basse	Forte	Non
J4	Gel	Faible	Oui
J5	Basse	Moyenne	Non
J6	Elevée	Forte	Oui
J7	Moyenne	Moyenne	Non

Température Moyenne, Humidité Faible → oui/non?

Contexte d'apprentissage

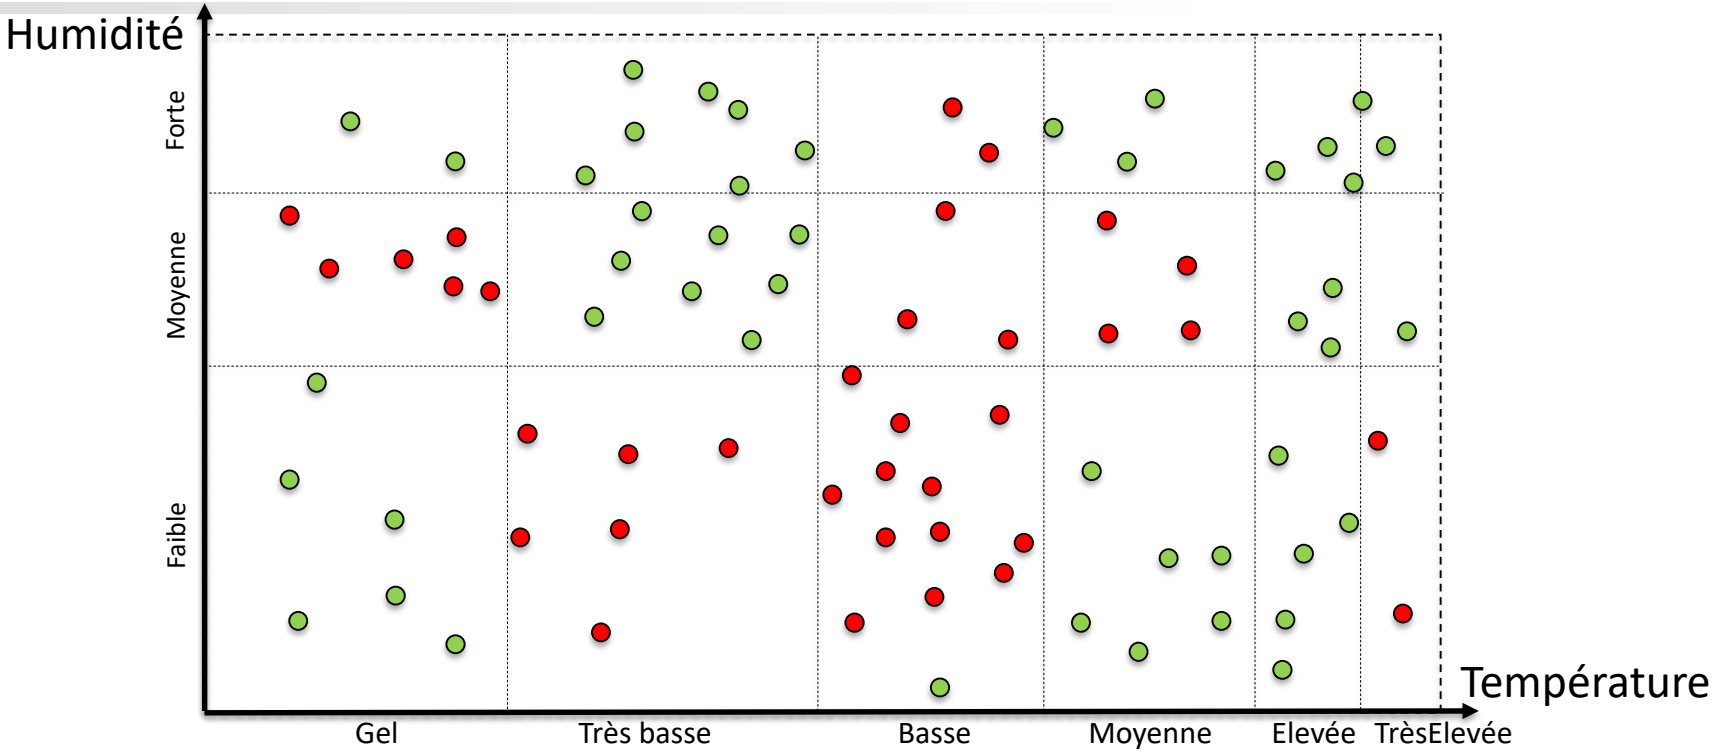

Jour	Température	Humidité	Oiseau visible?
J1	Moyenne	Forte	Oui
J2	Elevée	Faible	Oui
J3	Basse	Forte	Non
J4	Gel	Faible	Oui
J5	Basse	Moyenne	Non
J6	Elevée	Forte	Oui
J7	Moyenne	Moyenne	Non

Contexte d'apprentissage:

- Données quantifiées

Partition et arbre de décision

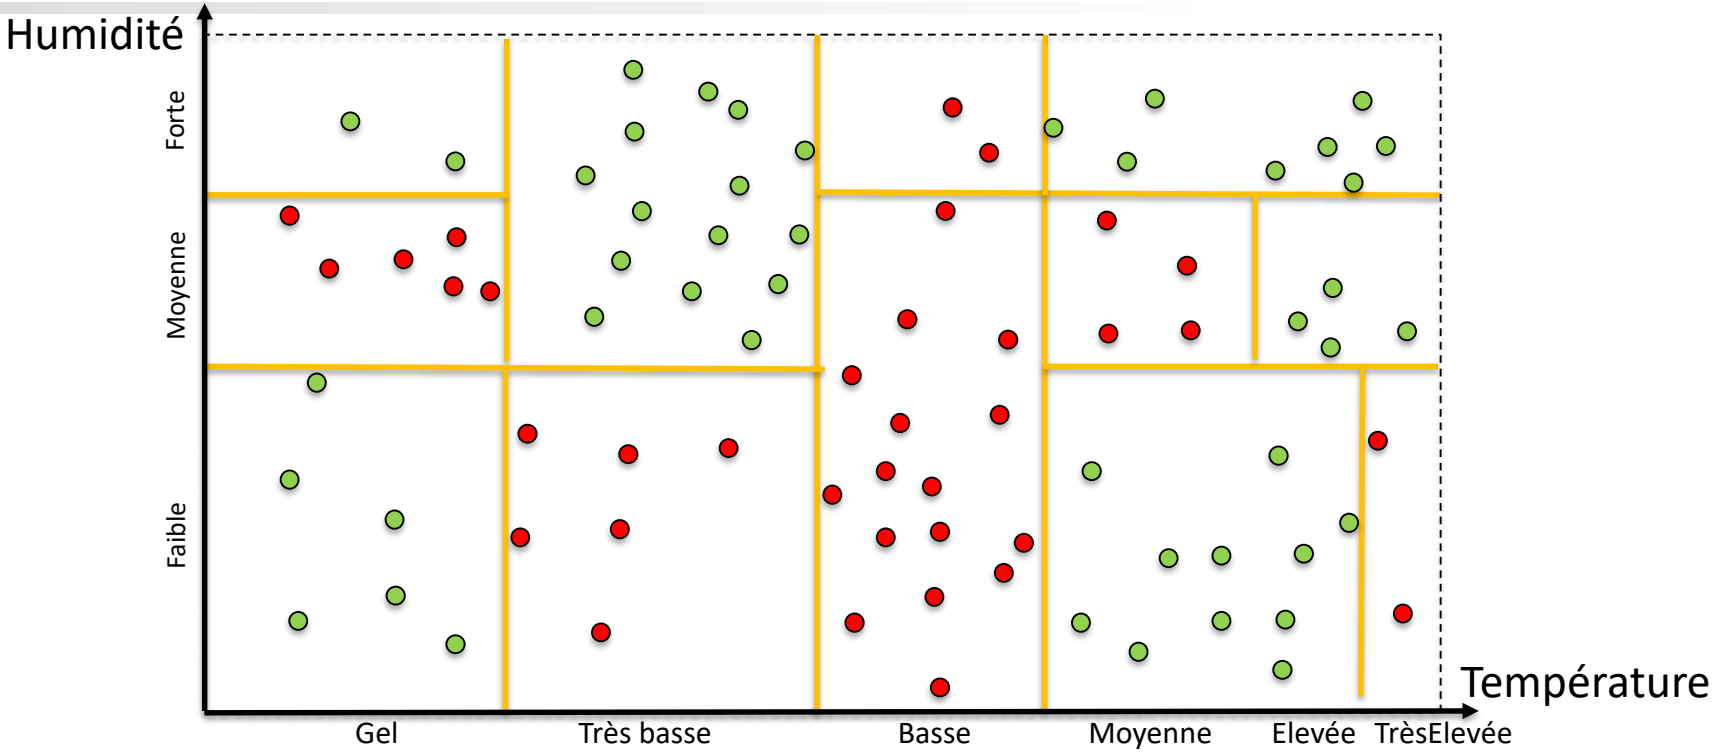

Jour	Température	Humidité	Oiseau visible?
J1	Moyenne	Forte	Oui
J2	Elevée	Faible	Oui
J3	Basse	Forte	Non
J4	Gel	Faible	Oui
J5	Basse	Moyenne	Non
J6	Elevée	Forte	Oui
J7	Moyenne	Moyenne	Non

Contexte d'apprentissage:

- Données quantifiées
- Décisions univariées (par paramètre) type:
  si Température = "élevée" alors …
- → Partition parallèle aux axes

Partition et arbre de décision

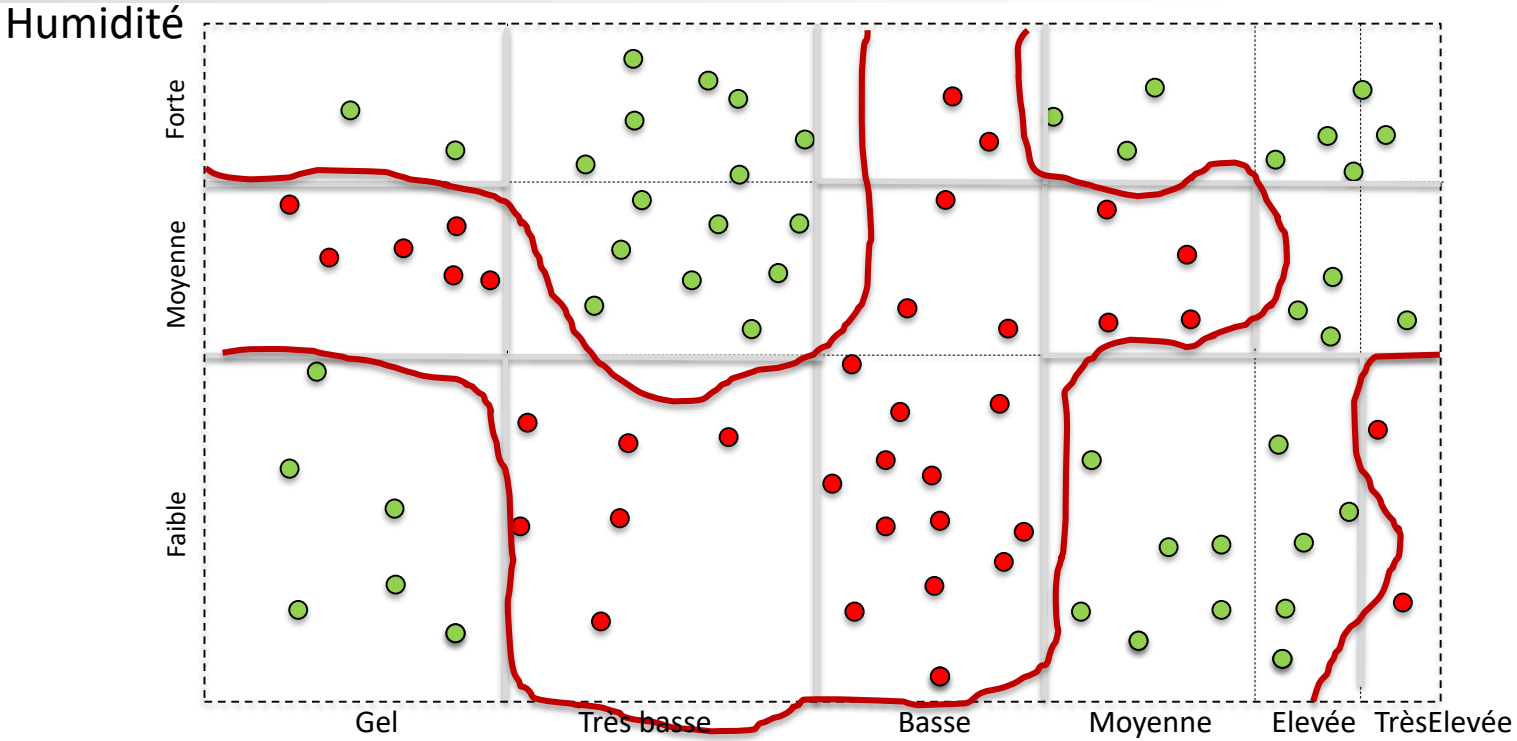

Toujours une approximation de notre fonction de décision

Algorithme ID3 (*Iterative Dichotomiser 3*, Quinlan 1986)

- Algorithme type glouton (*greedy*) pour la construction d'arbres de décision
- Utilise un critère récursif de partition basé sur le gain d'information maximum

ID3(Ω)

1. Soit Ω les données et H(X) l'entropie de la variable associée
2. Partitionner $\Omega = \Omega_1 U \Omega_2$ (créer les sous-arbres) selon la caractéristique C telle que le gain d'information I(X;C) soit maximum
3. Soient X_i les restrictions de Ω à Ω_i
   a. Si $H(X_i)>0$ alors ID3(Ω_i)

Exemple $(h(x)= -x\log_2 x)$

	T	H	O
Jour	**Température**	**Humidité**	**Oiseau visible?**
J1	Moyenne	Forte	Oui
J2	Elevée	Faible	Oui
J3	Basse	Forte	Non
J4	Gel	Faible	Oui
J5	Basse	Moyenne	Non
J6	Elevée	Forte	Oui
J7	Moyenne	Moyenne	Non

$H(O)=h\left(\frac{4}{7}\right)+h\left(\frac{3}{7}\right)\sim 0.98$

$H(O|?)=\Sigma P(?)\Sigma P(O|?)\log_2 P(O|?)$

Gain: $I(O;?) = H(O)-H(O|?)$

1ère décision:

Température: ([J4];-)(-;[J3,J5])([J1];[J7])([J2,J6];-)(-;-)

$H(O|T)=\frac{1}{7}h\left(\frac{1}{1}\right)+\frac{2}{7}h\left(\frac{2}{2}\right)+\frac{2}{7}\left(h(\frac{1}{2})+h(\frac{1}{2})\right)+\frac{2}{7}h(\frac{2}{2})$

~ 0.28

Humidité: ([J2,j4];-)(-;[J5;J7])([J1,J6];[J3])

$H(O|H)=\frac{2}{7}h\left(\frac{2}{2}\right)+\frac{2}{7}h\left(\frac{2}{2}\right)+\frac{3}{7}\left(h(\frac{2}{3})+h(\frac{1}{3})\right)$

~ 0.39

→ Gain: $I(O;T) > I(O;H)$

→ Température réduit le plus l'entropie…

→ 2ème décision: Humidité…

Exercices:

- Créez les arbres de decision
- Implémentez l'algorithme

Exemple 2: Données

Day	Outlook	Temperature	Humidity	Wind	Play?
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Premières itérations

Données H(X) = 0.940

	Sunny	Overcast	Rain	Gain
Outlook	0.971	0	0.971	0.247

	Weak	Strong	Gain
Wind	0.811	1.0	0.048

	Hot	Mild	Cold	Gain
Temp.	1.0	0.911	0.811	0.029

	High	Normal	Gain
Humidity	0.985	0.592	0.15

→ Racine = “Outlook”

→ Branche Sunny:

	High	Normal	Gain
Humidity	0	0	0.971

	Weak	Strong	Gain
Wind	0.918	1.0	0.019

	Hot	Mild	Cold	Gain
Temp.	0	1	0	0.57

Exercice: Faire les calculs restants

Arbre correspondant

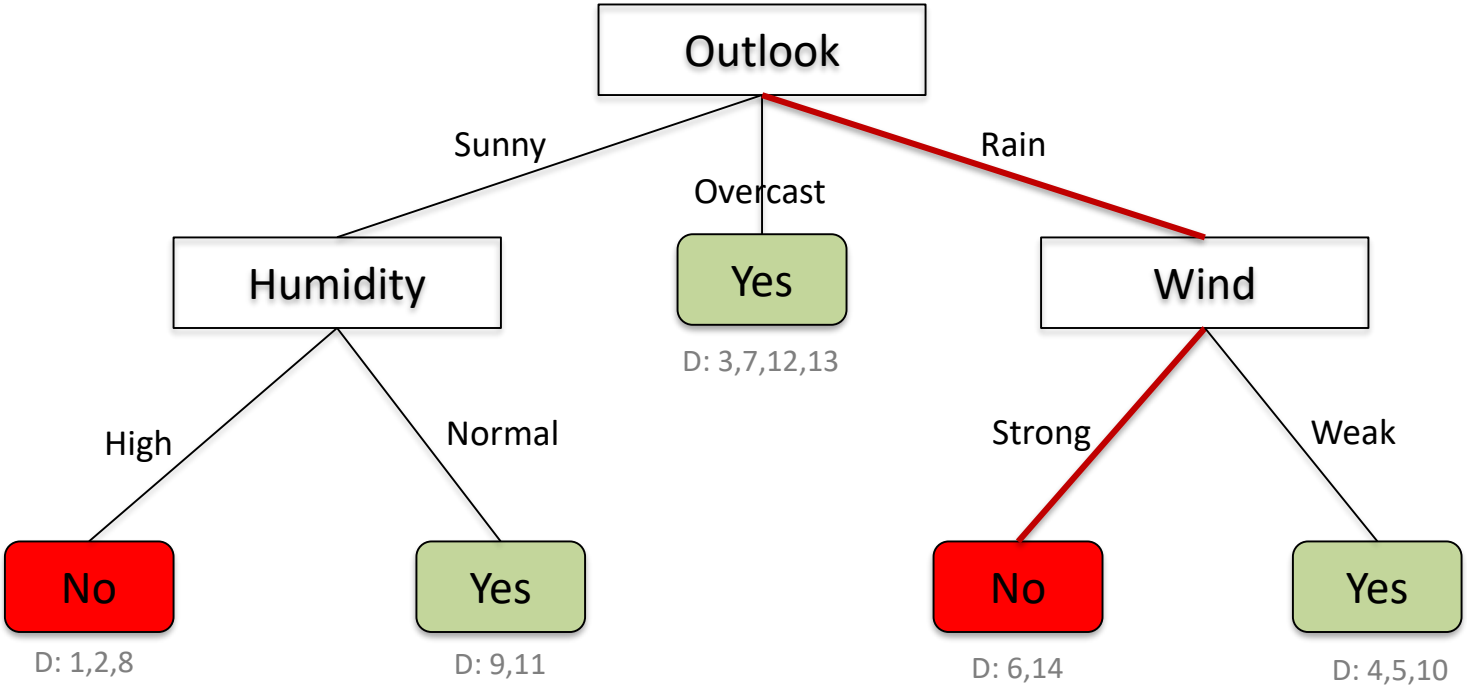

Exercice:

- Ecrire l'expression logique pour Yes

Outlook= Rain, Humidity=High, Temperature=Cool, Wind=Strong → No

Algorithmes C4.5 et C5.0 (Quinlan)

C4.5 modifie ID3 pour:

- Gérer des valeurs continues

→ Un seuil adaptatif est créé pour diviser les données à chaque pas.

Exemple: Température et Humidité non quantifiées

- Autres propriétés: élagage, mesures manquantes, mesures avec pondérations

→ C'est celui généralement utilisé

C5.0 modifie C4.5 pour l'efficacité:

- Rapidité, consommation mémoire
- Arbres plus réduits
- Autres propriétés (Boosting, etc)

→ Produit commercial

Rappel: Evaluation

On doit être capable de quantifier la qualité de l'apprentissage:

→On définit des mesures d'évaluation

		Prédiction	
		Positif	Négatif
Réalité	Pertinent	Vrai Positif (TP)	Faux Négatif (FN)
	Non-pertinent	Faux Positif (FP)	Vrai Négatif (TN)

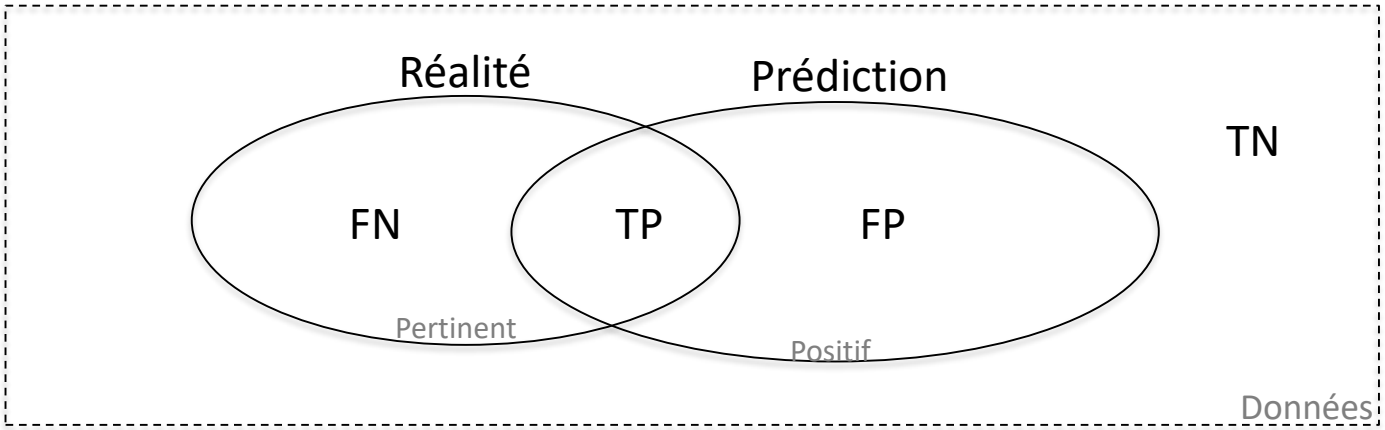

Rappel: Evaluation

- Taux d'erreur (*Error Rate*): $ER=\frac{FP+FN}{TP+TN+FP+FN}$
  - Potentiellement normalisé par la taille des classes

  → P(erreur|paramètres θ)

- Précision/Rappel (*information retrieval*)

$$P=\frac{TP}{TP+FP} \qquad R=\frac{TP}{TP+FN}$$

  → mAP: *mean Average Precision*

- F_1 score: $F_1 = \frac{2PR}{P+R}$

Evaluation

Si on atteint le niveau de l'arbre ou le critère de partition est 0 (et que les données d'entrainement sont cohérentes), l'erreur d'entrainement est nulle (par définition)

Si les données de test sont cohérentes avec l'entrainement on aura une erreur de test nulle aussi

Par contre:

- Complexité élevée
- Risque de sur-apprentissage

→ On peut utiliser les données et l'évaluation pour introduire formellement une tolérance (dans l'erreur d'entrainement) pour garantir une simplicité de l'arbre (principe de parcimonie du modèle) – cf *pruning*

Algorithme CART

CART (*Classification And Regression Tree*)

- Proposé indépendamment de ID3 pour des tâches de classification et régression

Classification Tree: Les feuilles sont des valeurs quantifiées

- Utilise l'index d'impureté Gini [rappel: ID3 → Entropie]

Regression Tree: Les feuilles sont des valeurs approximées (p.ex moyenne)

- Au lieu d'une prédiction binaire (oui/non), permettent de prédire une valeur
- Critère d'homogénéité: p.ex: écart-type

→Exemples:

  – prix d'un objet en fonction de ses caractéristiques (immobilier, assurance,…)

  →Approxime une fonction en fonction de ses valeurs d'entrée

Index Gini

Pour chacun des sous-ensembles Ω_k calcul de la probabilité d'erreur ($P(E_k) = 1-P(\Omega_k)$) en proportion de la présence du label ($P(\Omega_k)$)

→ Mesure l'"impureté" d'un ensemble partitionné en K classes Ω_k:

$$G(\Omega)=\sum_k P\left(x\in\Omega_k\right)\left(1-P\left(x\in\Omega_k\right)\right) = 1-\sum_k\left(P\left(x\in\Omega_k\right)\right)^2$$

→ Encourage des ensembles homogènes

- Min $G(\Omega_k) = 0$ si Ω_k est déterministe (1 seul label)
- Max $G(\Omega_k)$ si $P(\Omega_k)=1/K$ (répartition uniforme)

→ Approximation de l'entropie*

Peut être utilisé comme critère de partitionnement itératif (comme (H(X))

*de Shannon, cf Entropie de Tsallis

Données (classification)

Day	Outlook	Temperature	Humidity	Wind	Play?
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

CART: Index Gini pour la racine

G("Sunny")= 1- $(2/5)^2$- $(3/5)^2$ = 0.48
G("Overcast")= 1- $(4/4)^2$ = 0
G("Rain")= 1- $(3/5)^2$- $(2/5)^2$ = 0.48

I_G("outlook") = (5/14)*0.48+(4/14)*0+(5/14)*0.48
= **0.342**

Outlook	Yes	No	N (14)
Sunny	2	3	5
Overcast	4	0	4
Rain	3	2	5

	Outlook	Temperature	Humidity	Wind
I_G	0.342	0.439	0.367	0.428

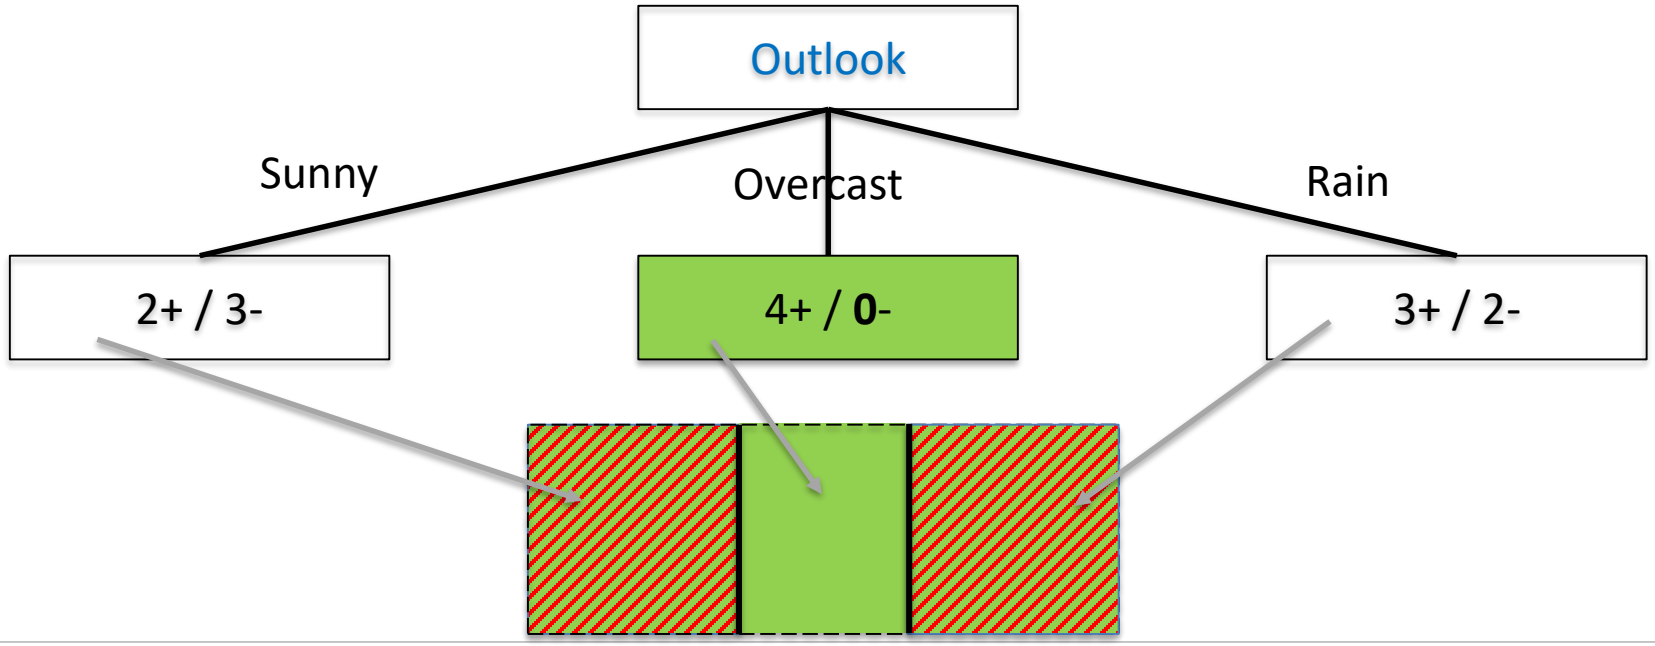

CART: Recursion

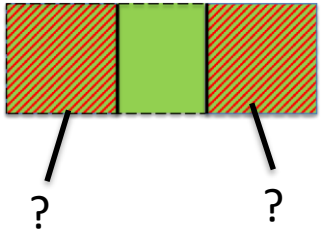

Outlook

Day	Temp.	Humidity	Wind	Play
D3	Hot	High	Weak	Yes
D7	Cool	Normal	Strong	Yes
D12	Mild	Mild	Strong	Yes
D13	Hot	Hot	Weak	Yes

Outlook = Overcast

Day	Temp.	Humidity	Wind	Play
D1	Hot	High	Weak	No
D2	Hot	High	Strong	No
D8	Mild	High	Weak	No
D9	Cool	Normal	Weak	Yes
D11	Mild	Normal	Strong	Yes

Outlook = Sunny

Outlook est fixe dans chacune des branches

Day	Temp.	Humidity	Wind	Play
D4	Mild	High	Weak	No
D5	Cool	Normal	Weak	No
D6	Cool	Normal	Strong	No
D10	Mild	Normal	Weak	Yes
D14	High	High	Strong	Yes

Outlook = Rain

CART: *Regression Tree*

Principe de Régression:

- On approxime des données (x,y) par une fonction f
- On minimise l'erreur d'approximation

Exemple: Régression linéaire

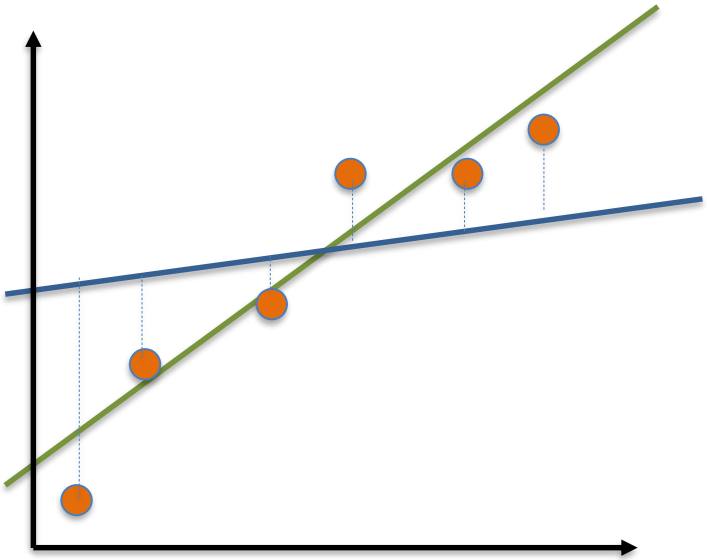

$$\text{Erreur} = \sum_i (y_i - f(x_i))^2$$

Regression Tree

Les données sont des valeurs en fonction de caracteristiques

Exemple: Appréciation (%) du dessert *vs* sucre (g)

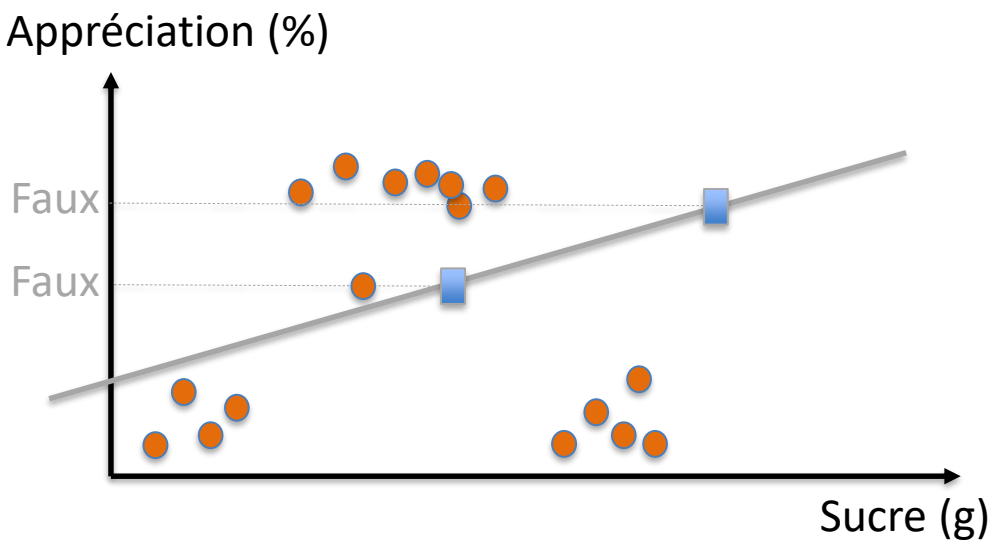

Une régression linéaire (même optimale) donnerait de mauvaises prédictions
→ Besoin d'une fonction plus complexe

CART: Regression

On teste tous les seuils (pour chaque donnée) et on regarde la qualité de l'approximation par une fonction choisissant la moyenne pour chaque sous-ensemble

→Choix de la racine

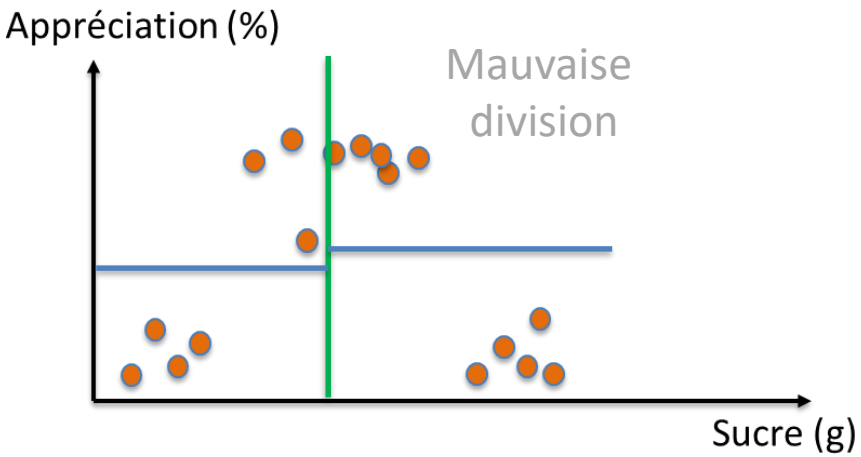

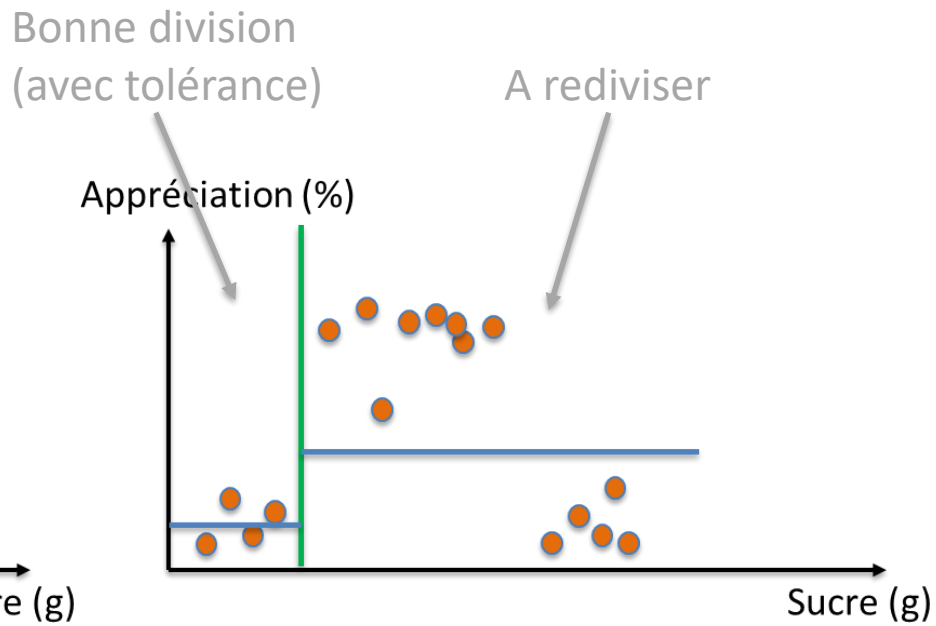

→Récursion sur les sous ensembles

CART: *Regression Tree*

- Divise les données récursivement en testant les attributs et choisit de meilleur seuil global (par énumération par attribut et pour tous les attributs) pour les valeurs de moindres carrés (*Sum of Square Residuals*)
- Les feuilles prennent la valeur moyenne (max,min,médiane) des observations qu'ils contiennent
- Le critère d'arrêt est une tolérance basée sur
  - La profondeur de l'arbre
  - La valeur de l'erreur
  - Le nombre de données par feuille

  →Rapport à la qualité de l'estimation (qualité vs complexité)

  →Rapport Biais/Variance

  →Compromis sur-apprentissage/généralisation

Regression: Exemple de données

Day	Outlook	Temp.	Humidity	Wind	Golf Players
1	Sunny	Hot	High	Weak	25
2	Sunny	Hot	High	Strong	30
3	Overcast	Hot	High	Weak	46
4	Rain	Mild	High	Weak	45
5	Rain	Cool	Normal	Weak	52
6	Rain	Cool	Normal	Strong	23
7	Overcast	Cool	Normal	Strong	43
8	Sunny	Mild	High	Weak	35
9	Sunny	Cool	Normal	Weak	38
10	Rain	Mild	Normal	Weak	46
11	Sunny	Mild	Normal	Strong	48
12	Overcast	Mild	High	Strong	52
13	Overcast	Hot	Normal	Weak	44
14	Rain	Mild	High	Strong	30

Elagage (*Decision Tree pruning*)

- La construction d'un arbre cherche à minimiser l'entropie des sous-ensembles (entropie des feuilles à 0)
- Les données d'entrainement sont un échantillon de la réalité → risque de sur-apprentissage

→On réduit la taille (profondeur) de l'arbre par élagage des feuilles

→Augmente la généralisation

→Accélère le calcul de décisions

→Gagne de la place mémoire

→Compromis performance (erreur) *vs* complexité

Random Forests

SK.Learn RandomForest XXX:
Exemple: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html#

Principe: La construction d'un arbre est biaisé vers les données d'entrainement

→ On veut construire plusieurs arbres et moyenner leurs résultats

→ On diversifie les données par échantillonnage de l'ensemble de départ

Bagging (*bootstrap aggregation*) consiste à échantillonner (avec remise) l'ensemble de départ:

- Une donnée peut etre présente plusieurs fois
- On devient robuste aux outliers

Random feature selection : On sélectionne un sous ensemble de caractéristique par sous-ensemble

- On filtre les caractéristiques inutiles/puissantes
- $\sqrt{d}$ pour la classification, d/3 pour la régression

On crée des ensembles et on construit un arbre sur chaque ensemble

→ La classification est faite par vote (majorité)

→ La régression est faite par moyennage

Exemple

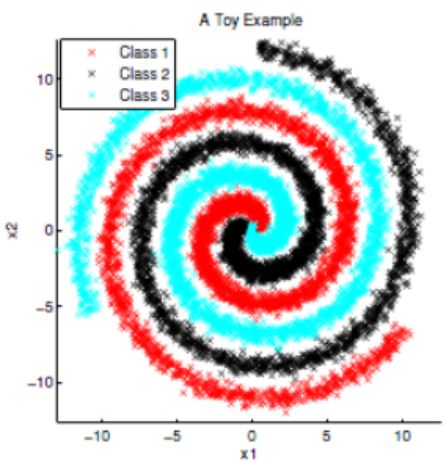

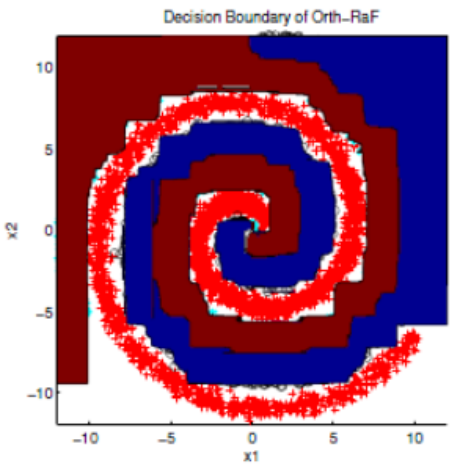

Du fait du moyennage, les frontières de décision sont plus lisses

Résumé

Illustration ludique:
http://www.r2d3.us/visual-intro-to-machine-learning-part-1

On se place dans un contexte supervisé
→ On cherche à approximer une fonction de décision

Les arbres représentent une partition récursive de l'ensemble d'entrainement
→ Prédicat logique sur les caractéristiques
→ Suite de décisions basiques à appliquer
→ Potentielle bonne interprétation des décisions

L'optimalité est décidée sur les critères (entropie, Gini) et propriétés de l'arbre (profondeur, complexité)

La régression généralise la classification en fournissant une information non quantifiée

Les *Random Forest* permettent de réduire le biais des données