Intelligence Artificielle

Réseaux Bayésiens

Stephane Marchand-Maillet

Contenu

Réseaux Bayésiens

Inférence exacte

Inférence approximée

Réseau Bayésien

Def: Un réseau Bayésien (*Bayes(ian) Network*) est un modèle de graphe de probabilités (*PGM*) ayant une structure de graphe dirigé acyclique (*DAG*)

Exemple: *Student Network*

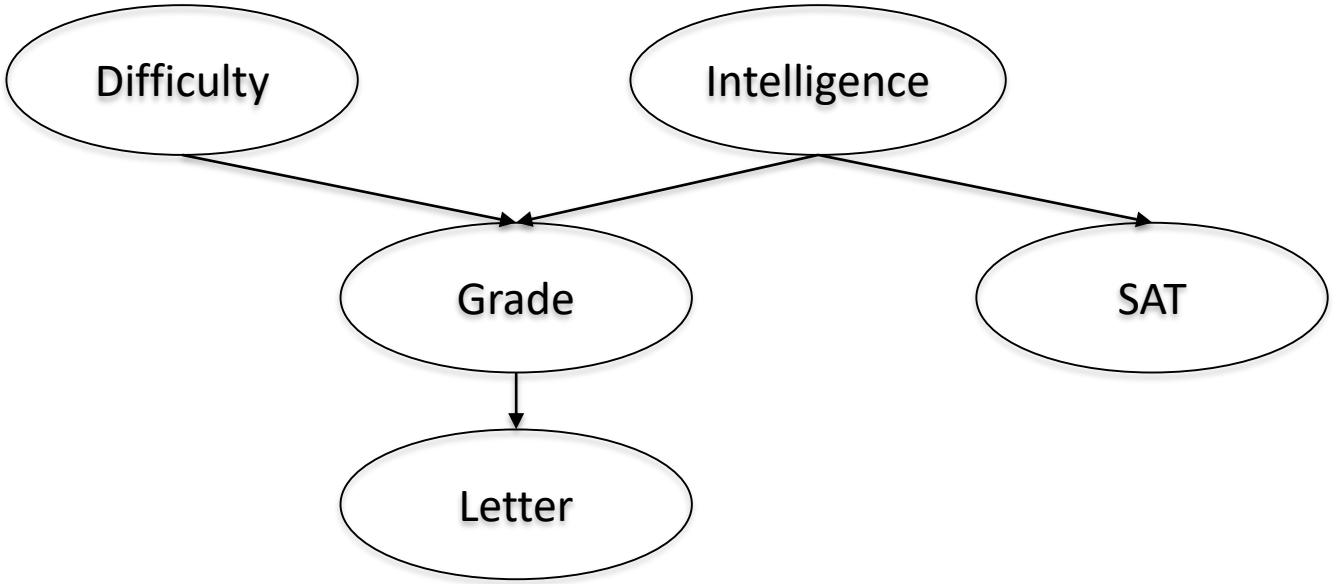

(de: Daphne Koller and Nir Friedman, *Probabilistic Graphical Models*, 2009)

Exemple: Propagation de risques

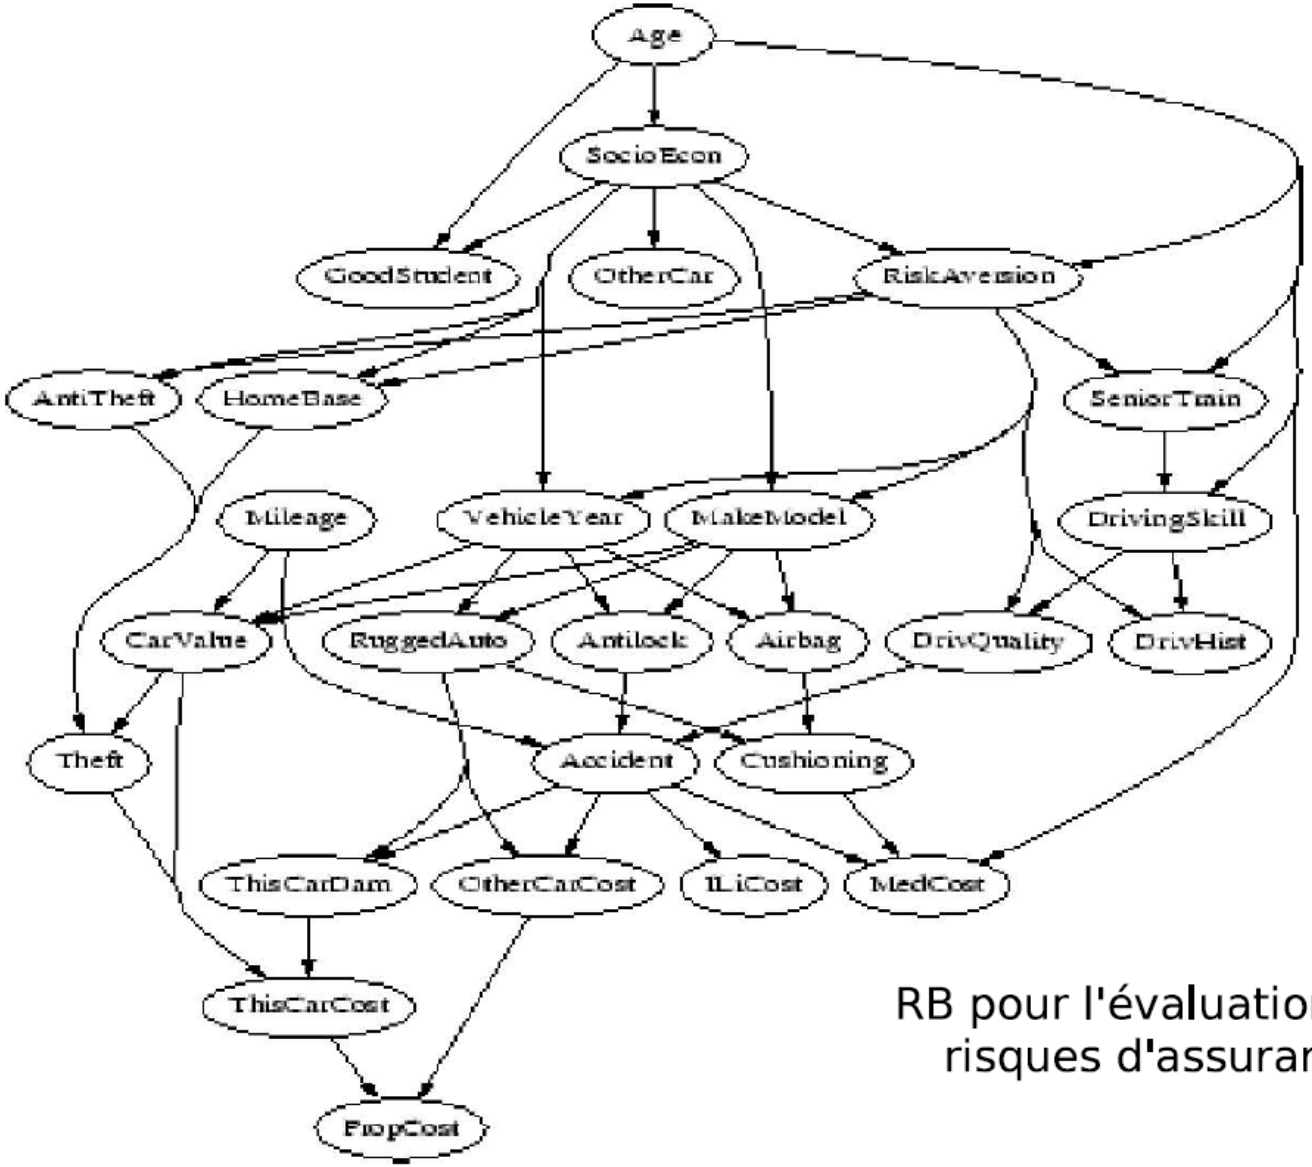

RB pour l'évaluation des risques d'assurance

Exemple: Le réseau *"Asia"*

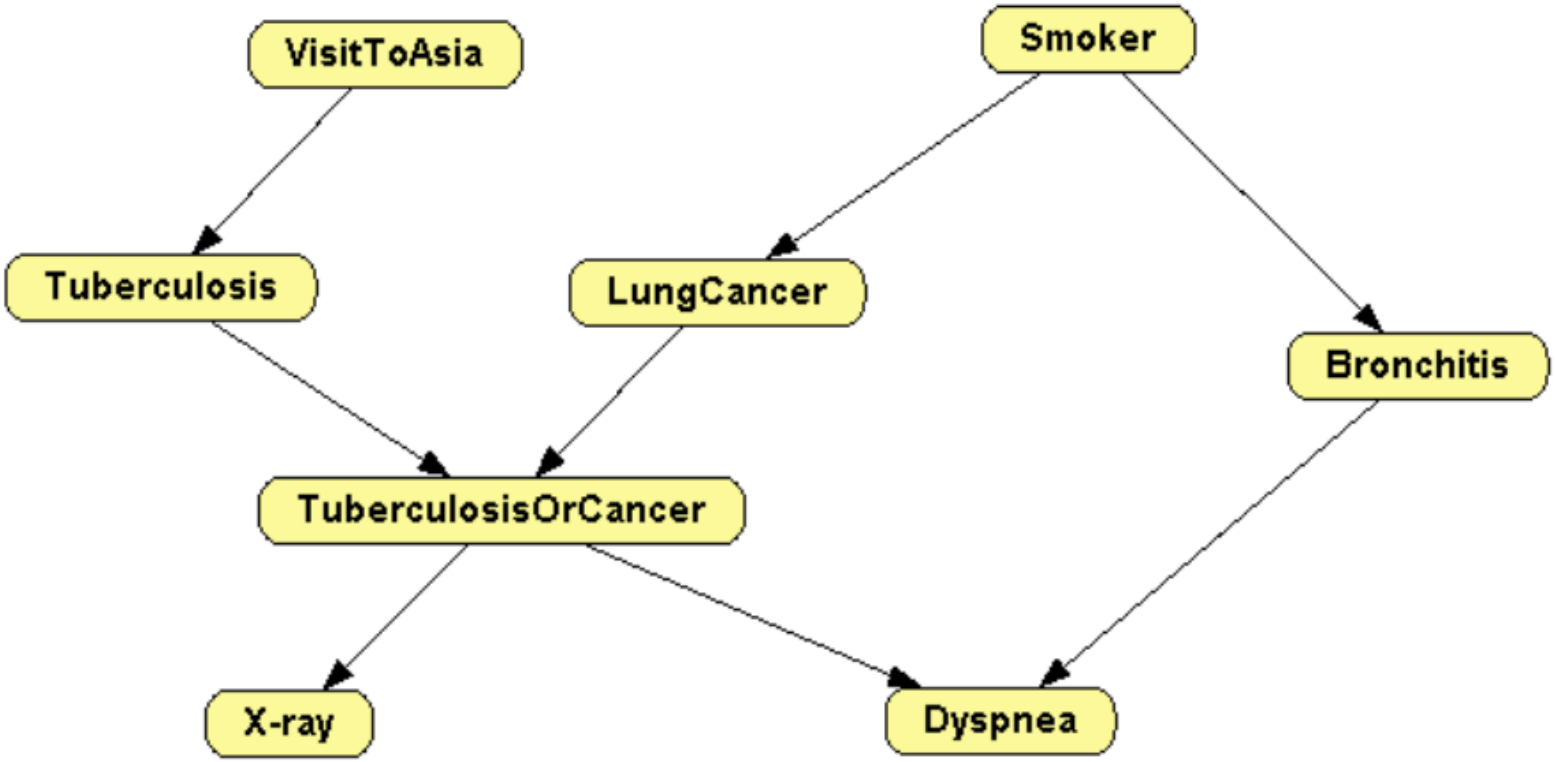

Lauritzen, S. L. and Spiegelhalter, D. J. (1988). Local computations with probabilities on graphical structures and their application to expert systems.Journal of the Royal StatisticalSociety, Series B, 50:157–224.

Réseau Bayésien

On représente une connaissance à l'aide du réseau Bayésien et on peut ensuite l'interroger (pour faire une inférence)

- On considère la probabilité jointe de toutes les variables
- On développe selon le réseau (factorisation PGM)
- On utilise la règle de la somme (marginalisation) pour éliminer les variables qui ne nous intéressent pas

→On peut faire une inférence exacte

… ou approximée

Rappel: Notions fondamentales

- Probabilité jointe: $P(A \cap B)=P(A,B)$
  $P((X=x) \wedge (Y=y))=P(x,y)$
- Probabilité conditionnelle: $P(B|A)=\frac{P(A,B)}{P(A)}$
  $P((X=r)|(Y=u_1))=P(r|u_1)$

- Règle de produit: $P(X,Y)=P(X|Y)P(Y)$
- Règle de la somme: $P(X)=\Sigma_y P(X,Y=y)$ (marginalisation)

- Indépendance: $P(A,B)=P(A)P(B)$
  $P((X=x) \wedge (Y=y)) = P(X=x)P(Y=y)$
  - On note $X \perp Y$ (en fait $X \perp\!\!\!\perp Y$)
  - Contre exemple: $P((X=r) \wedge (Y=u_1)) \neq P(X=r)P(Y=u_1)$

Un exemple de réseau

Connaissance:

- On sait que les champignons poussent sous les sapins
- On sait que les déjections d'oiseaux favorisent les champignons
- Si il y a des champignons et que je les trouve, je peux m'en faire une poêlée
- Il peut y avoir des écureuils dans ces bois

Question: Quelle est la probabilité de me faire une poêlée quand je vois un sapin?

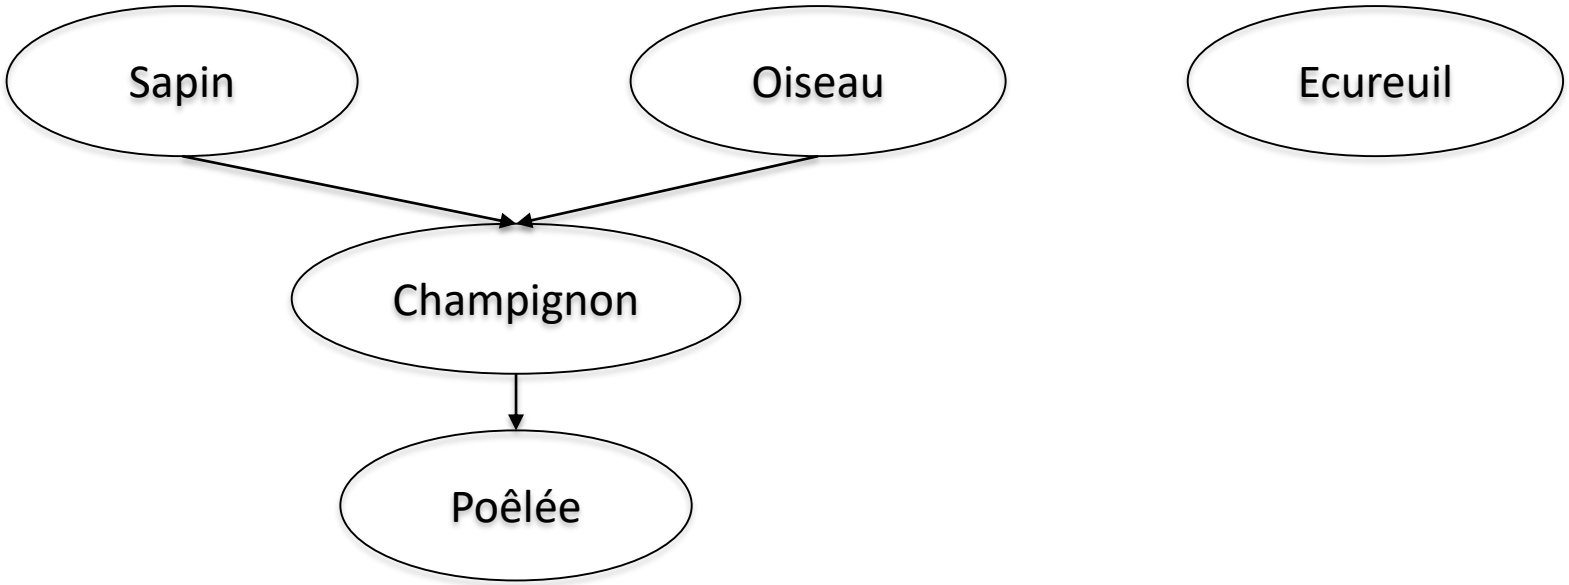

Inférence

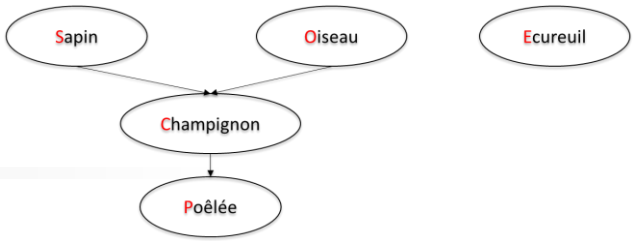

La probabilité jointe est:

$$P(S,O,C,P,E)=P(E)P(S)P(O)P(C|S,O)P(P|C)$$

On cherche à estimer (inférer):

$$P(P=p|S=s) = P(p|s)= \frac{P(p,s)}{P(s)} = \frac{P(p,s)}{P(p,s)+P(\neg p,s)} \propto P(p,s)$$

→ on infère les 2 cas P(p,s) et P(¬p,s) pour éviter de calculer le dénominateur

En marginalisant (règle de la somme):

$$P(p,s)=\Sigma_e\Sigma_o\Sigma_c P(s,o,c,p,e)$$
$$=\Sigma_e\Sigma_o\Sigma_c P(e)P(s)P(o)P(c|s,o)P(p|c)$$

On note que (on factorise):

$$P(p,s)= P(s)\Sigma_o P(o)\Sigma_c P(c|s,o)P(p|c)\Sigma_e P(e)$$

Or: $\Sigma_e P(e)=1$

→ Constat 1: chaque composante connexe du graphe peut être traitée indépendamment (les écureuils n'influent pas la poêlée)

Inférence

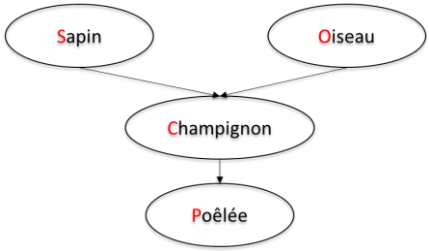

$$P(p|s) = \alpha\, P(s) \Sigma_o P(o) \Sigma_c P(c|s,o) P(p|c)$$

2^n facteurs
n: nombre de variables à marginaliser

Méthode directe: énumération:

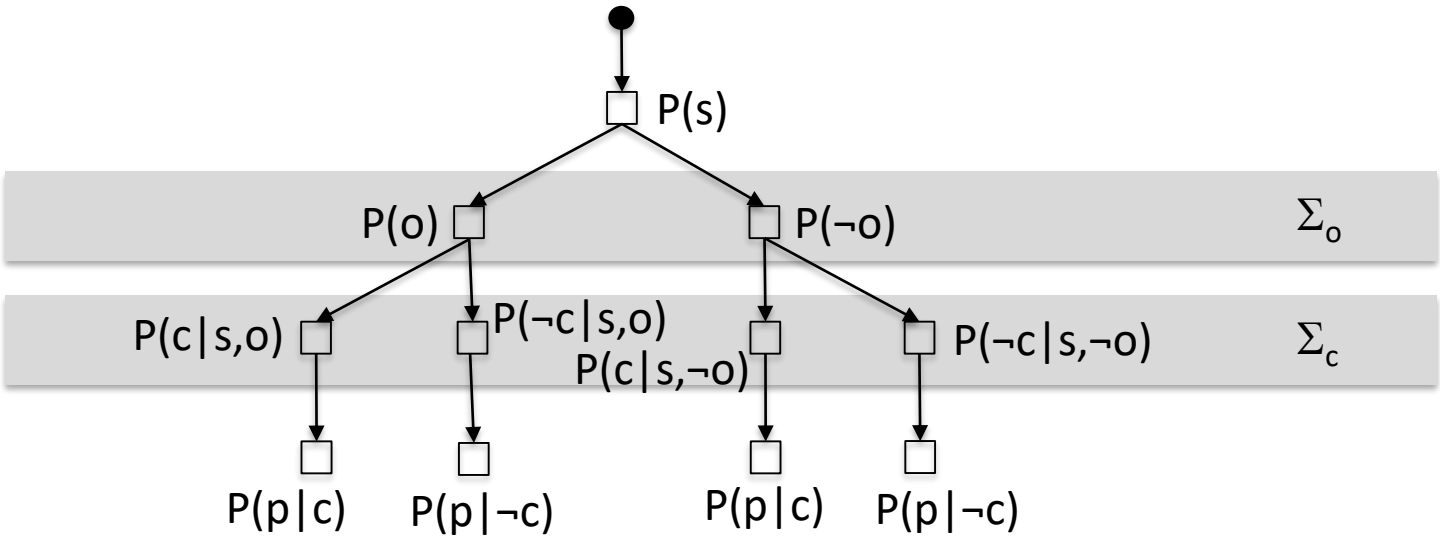

Elimination de variables

$$P(p|s)= \alpha\ P(s)\ \Sigma_o P(o)\ \underbrace{\Sigma_c P(c|s,o)P(p|c)}$$

Dépend de s (fixe), p(fixe), o et c (marginalisé)

On crée le facteur $f_C(o)$:

$$f_C(o)=\Sigma_c P(c|s,o)P(p|c)$$

et on réécrit:

$$P(p|s)= \alpha\ P(s)\Sigma_o P(o)\ f_C(o)$$

On recommence:

$$f_O() = \Sigma_o P(o)\ f_C(o)$$

Ainsi:

$$P(p|s)= \alpha\ P(s)\ f_O()$$

→ On organise les calculs en facteurs réutilisables pour minimiser la redondance (visible sur les grands réseaux)

Exercice: factorisez un PGM plus complexe

Elimination de variables

Algorithme général:

Répéter:

- Choisir une variable X à factoriser
- f_X(*vars restantes*)= Σ_x P(… X=x …)

jusqu'à épuisement des variables

→ l'inférence exacte est toujours #P-Hard (énumération)

→ Dans une structure d'arbre, l'inférence est linéaire (en nombre d'entrées dans les tables de conjonction)

Note:

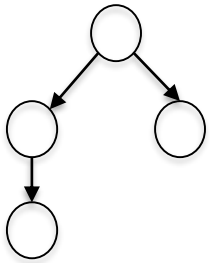

Arbre
Une seule racine

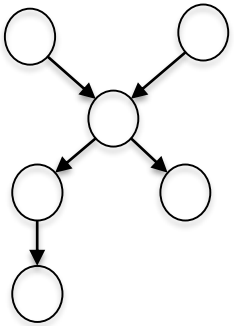

Poly-arbre (*polytree*)
chaque nœud a un seul chemin vers un autre

Inférence approximée

Au lieu de calculer formellement le résultat, on utilise le réseau pour générer des échantillons

	Vrai	Faux
Sapin	0.7	0.3

	Vrai	Faux
Oiseau	0.6	0.4

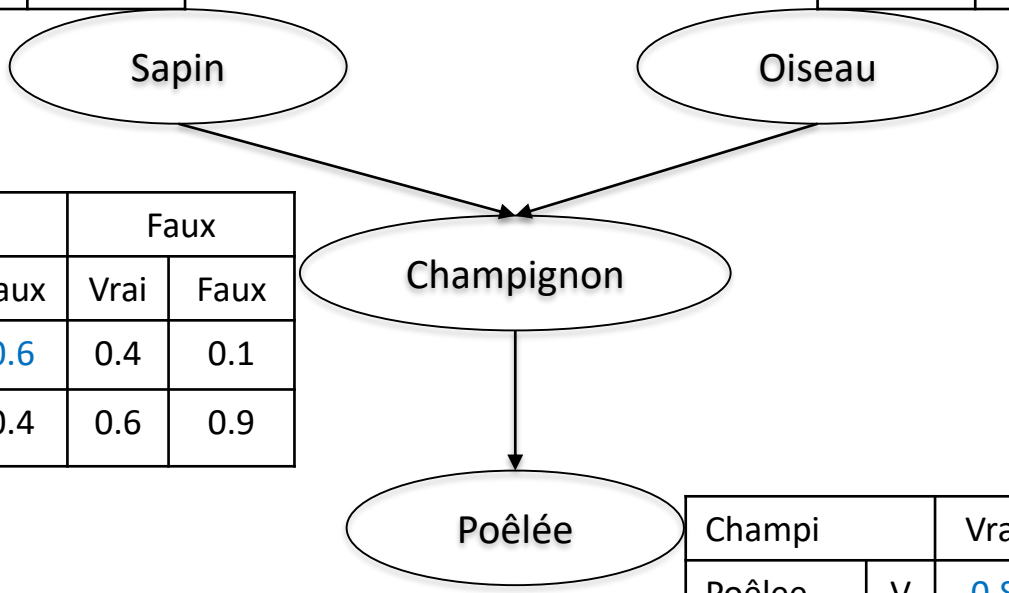

Sapin		Vrai		Faux	
Oiseau		Vrai	Faux	Vrai	Faux
Champi	V	0.7	0.6	0.4	0.1
	F	0.3	0.4	0.6	0.9

Champi		Vrai	Faux
Poêlee	V	0.8	0.0
	F	0.2	1.0

Inférence approximée

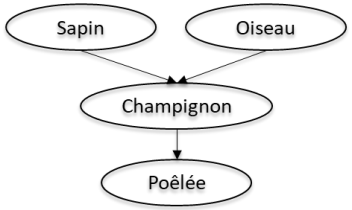

Principe: On utilise le réseau comme un modèle génératif et on échantillonne P(S,O,C,P) selon les distributions

Exemple:

- On sait que P(S)=0.7, on tire V/F selon cette probabilité → V (par exemple)
- On sait que P(O)=0.6, on tire V/F selon cette probabilité → F (par exemple)
- On sait que P(C|S=V,O=F)=0.6. On tire → V (par exemple)
- On sait que P(P|C=V)=0.8 → F (par exemple)

→ On obtient un échantillon de la probabilité jointe P(S,O,C,P)

	Sapin	Oiseau	Champi	Poêlée
Tirage 1	V	F	V	F
Tirage 2	V	V	F	F
…	…	…	…	…
Tirage N	F	V	V	V

→ On peut calculer une estimation

$P(S,O,C,P,E)=P(E)P(S)P(O)P(C|S,O)P(P|C)$

Exemple académique

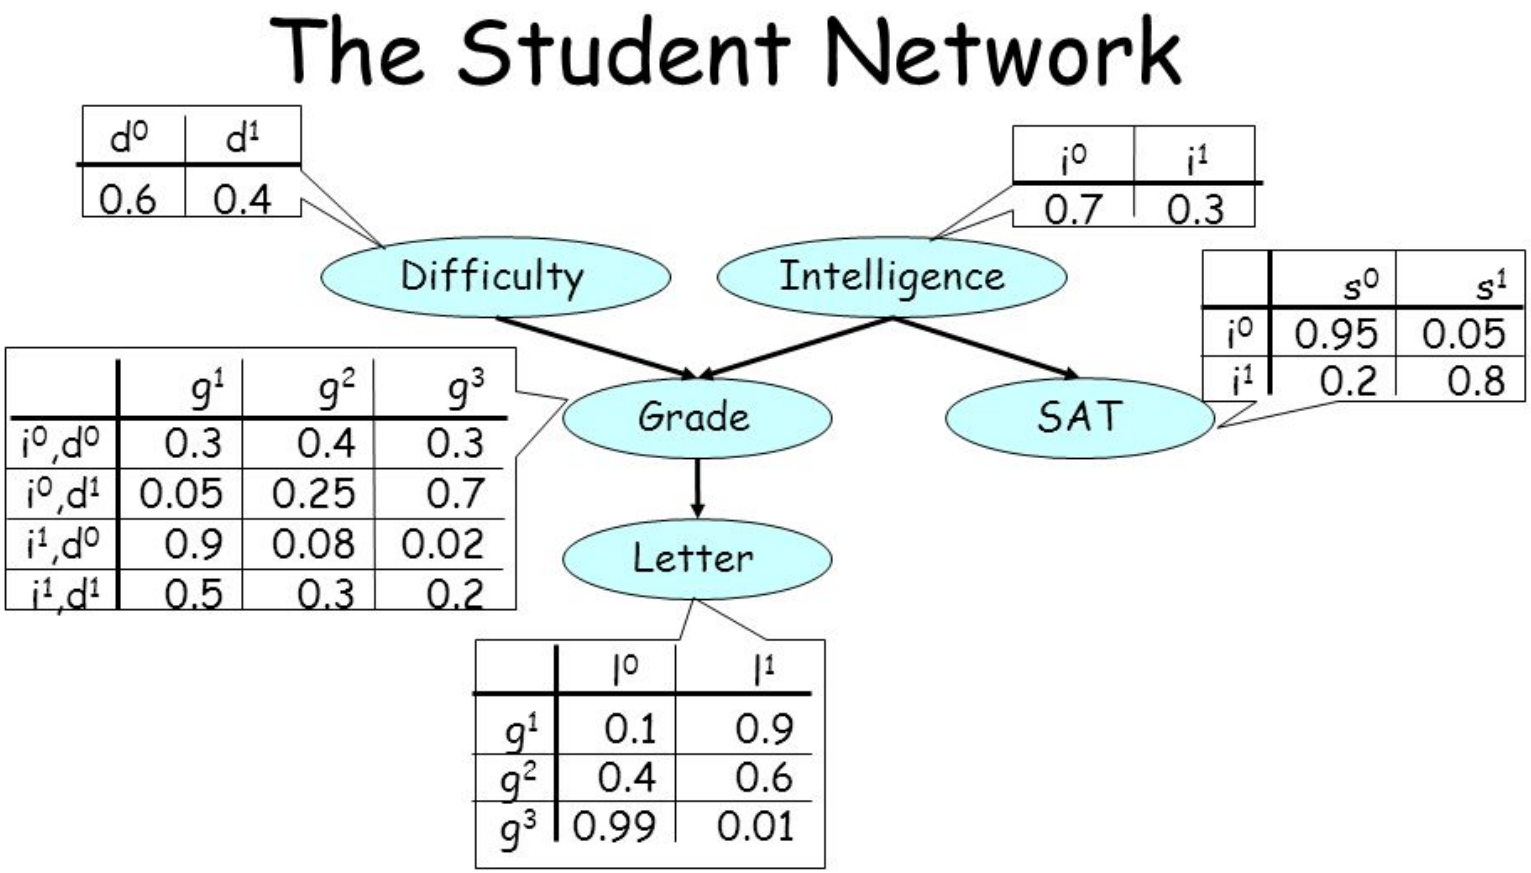

d^0	d^1
0.6	0.4

i^0	i^1
0.7	0.3

	s^0	s^1
i^0	0.95	0.05
i^1	0.2	0.8

	g^1	g^2	g^3
i^0,d^0	0.3	0.4	0.3
i^0,d^1	0.05	0.25	0.7
i^1,d^0	0.9	0.08	0.02
i^1,d^1	0.5	0.3	0.2

	l^0	l^1
g^1	0.1	0.9
g^2	0.4	0.6
g^3	0.99	0.01

(de: Daphne Koller and Nir Friedman, *Probabilistic Graphical Models*, 2009)

Inférence

- Pour inférer des distributions plus complexes on doit échantillonner avec des procédés du type Monte-Carlo (MCMC – pas traités ici)
- On peut utiliser la factorisation en fonctions potentielles $\Psi(X,Y,Z,W)$ de cliques
- Pour découvrir les cliques dans un réseau orienté, on doit “moraliser” le graphe

Estimation de paramètres

- Si on connait la structure de G=(V,Γ)
- Soit θ_i les paramètres de $P(X_i|X_{\gamma_i})$
  $X\gamma_i=\Gamma^{-1}(X_i)$, les parents de X_i dans G

- Étant donné un échantillon on cherche à optimiser les paramètres par maximum de vraisemblance (*maximum likelihood*)

$$\theta^* = \underset{\theta}{\operatorname{argmax}} \frac{1}{M} \sum_m \log P(x^m, \theta)$$

- En utilisant la factorisation dans le réseau Bayésien on a:

$$\theta^* = \underset{\theta}{\operatorname{argmax}} \frac{1}{M} \sum_m \sum_i \log P(x_i^m | x_{\gamma_i}^m, \theta_i)$$

- Comme chaque facteur est indépendant (par définition), on peut dissocier les problèmes en M problèmes indépendants et le résoudre analytiquement
  - par exemple si $P(X_i|X_{\gamma_i})$ est Gaussien, on utilise la moyenne et la variance pour estimer θ_i

Implémentation / simulation

On peut utiliser un simulateur:

Par exemple: http://www.openmarkov.org/

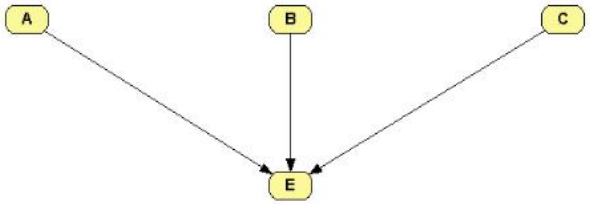

Figure 1.7: A network containing four nodes. The probability of E will be specified using a noisy OR model.

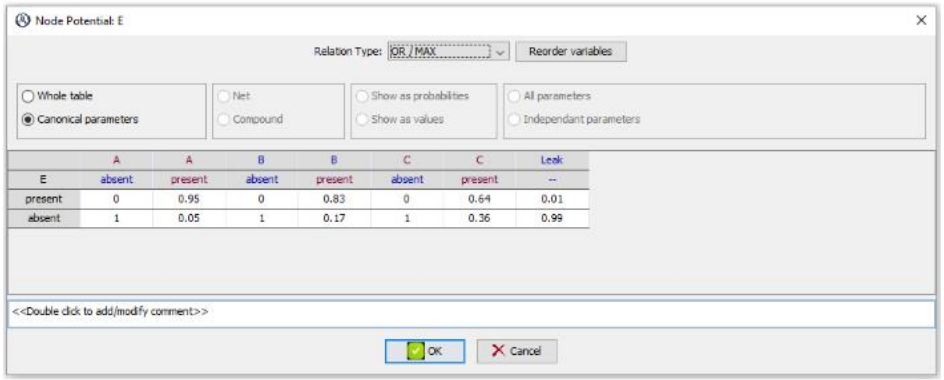

	A	A	B	B	C	C	Leak
E	absent	present	absent	present	absent	present	--
present	0	0.95	0	0.83	0	0.64	0.01
absent	1	0.05	1	0.17	1	0.36	0.99

Figure 1.8: Canonical parameters of a noisy OR model.

http://www.openmarkov.org/docs/tutorial/openmarkov-tutorial.pdf

Résumé

- Les réseaux Bayésiens sont des PGM dirigés acycliques
- Ils sont le support à la factorisation de probabilité jointe
- Ils permettent de répondre à des requêtes par inférence

- L'inférence exacte est prohibitive sauf dans le cas des réseaux en arbre
- On peut utiliser l'échantillonnage pour faire de l'inférence approximée

→ *MCMC, Gibbs sampling, Variational Inference*

Details:

Christopher M. Bishop, *Pattern Recognition and Machine Learning*, 2006

Daphne Koller and Nir Friedman, *Probabilistic Graphical Models*, 2009