Graphes Computationnels Différentiation automatique Rétropropagation

Chapitre

Réseaux de Neurones Artificiels (*Artificial Neural Networks – ANN*)

Stephane Marchand-Maillet

Intelligence Artificielle

Graphes Computationnels
Différentiation automatique
Rétropropagation

Chapitre
Réseaux de Neurones Artificiels (*Artificial Neural Networks – ANN*)

Stephane Marchand-Maillet

Rappel: *Backpropagation*

On a:

$$\frac{\partial \mathcal{L}}{\partial a_j^l} = \frac{\partial \phi_j^l}{\partial a_j^l}\frac{\partial \mathcal{L}}{\partial \phi_j^l} = \phi_j^l(1-\phi_j^l)\frac{\partial \mathcal{L}}{\partial \phi_j^l} \qquad (1)$$

De plus:

$$\frac{\partial \mathcal{L}}{\partial \phi_k^{l-1}} = \sum_{j=1}^{N_l} \frac{\partial a_j^l}{\partial \phi_k^{l-1}}\frac{\partial \mathcal{L}}{\partial a_j^l} = \sum_{j=1}^{N_l} w_{kj}^{l-1}\frac{\partial \mathcal{L}}{\partial a_j^l} \qquad (2)$$

Finalement:

$$\frac{\partial \mathcal{L}}{\partial w_{kj}^{l-1}} = \frac{\partial a_j^l}{\partial w_{kj}^{l-1}}\frac{\partial \mathcal{L}}{\partial a_j^l} = \phi_k^{l-1}\frac{\partial \mathcal{L}}{\partial a_j^l} \qquad (3)$$

→ On utilise l'itération de (1) et (2) (en partant de l'erreur à la couche L: $\mathcal{L}([\phi_j^L(x_i)], y_i)$ pour inférer toutes les valeurs de $\frac{\partial \mathcal{L}}{\partial \phi_j^l}$ et $\frac{\partial \mathcal{L}}{\partial a_j^l}$

→ On peut calculer les gradients: $\frac{\partial \mathcal{L}}{\partial w_{kj}^{l-1}}$ pour toutes les couches (3)

On a:

$$\frac{\partial \mathcal{L}}{\partial a_j^l} = \frac{\partial \phi_j^l}{\partial a_j^l}\frac{\partial \mathcal{L}}{\partial \phi_j^l} = \phi_j^l(1-\phi_j^l)\frac{\partial \mathcal{L}}{\partial \phi_j^l}$$

De plus:

$$\frac{\partial \mathcal{L}}{\partial \phi_k^{l-1}} = \sum_{j=1}^{N_l} \frac{\partial a_j^l}{\partial \phi_k^{l-1}}\frac{\partial \mathcal{L}}{\partial a_j^l} = \sum_{j=1}^{N_l} w_{kj}^{l-1}\frac{\partial \mathcal{L}}{\partial a_j^l}$$

Finalement:

$$\frac{\partial \mathcal{L}}{\partial w_{kj}^{l-1}} = \frac{\partial a_j^l}{\partial w_{kj}^{l-1}}\frac{\partial \mathcal{L}}{\partial a_j^l} = \phi_k^{l-1}\frac{\partial \mathcal{L}}{\partial a_j^l}$$

→ On utilise l'itération de (1) et (2) (en partant de l'erreur à la couche L: $\mathcal{L}([\phi_j^L(x_i)], y_i)$ pour inférer toutes les valeurs de $\frac{\partial \mathcal{L}}{\partial \phi_j^l}$ et $\frac{\partial \mathcal{L}}{\partial a_j^l}$

→ On peut calculer les gradients: $\frac{\partial \mathcal{L}}{\partial w_{kj}^{l-1}}$ pour toutes les couches (3)

Outil 1: Graphe computationnel

Représente le calcul d'une fonction

Nœuds: variables et operateurs (résultats intermédiaires)

Arcs: dépendances dans le calcul

[idée similaire à celle d'un arbre syntaxique]

Exemple simple:

$\phi(x,y,z) = x^2(x+y-z)$ on veut $\frac{\partial\phi}{\partial x}, \frac{\partial\phi}{\partial y}, \frac{\partial\phi}{\partial z}$

$\phi(x,y,z) = x^2(x+y-z)$ on veut $\frac{\partial\phi}{\partial x}, \frac{\partial\phi}{\partial y}, \frac{\partial\phi}{\partial z}$

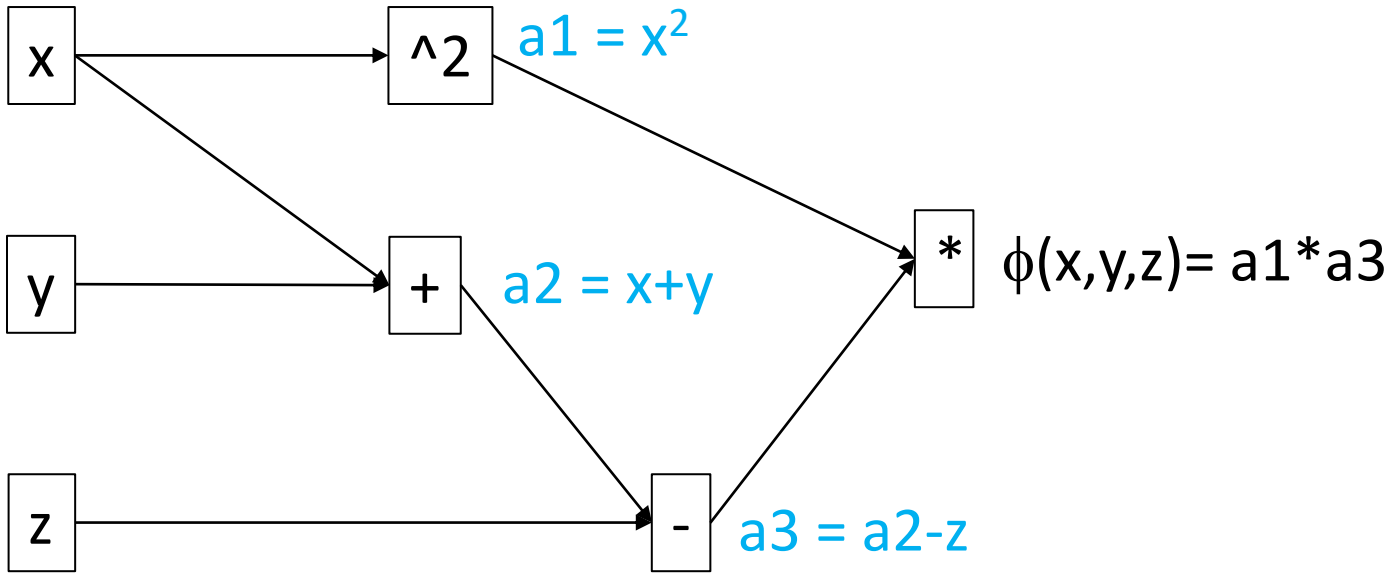

On construit le graphe en définissant des variables intermédiaires (ici a1, a2, a3)
A chaque niveau (couche), la fonction ne s'exprime qu'en fonction des résultats de la couche précédente

<u>NB:</u> cette étape correspondrait à la transcription de notre équation de réseau en un graphe.

Exercice écrivez le graphe d'un neurone:

$\phi_\theta(x_i) = \varphi(a_i)$ (au lieu de $\phi_\theta(x_i) = (a_i>0)$)

avec

- activation : $a_i = \sum_{k=0}^{K} w_k x_i^k$
- $\varphi(z) = \frac{1}{1+e^{-z}}$

$\phi(x,y,z) = x^2(x+y-z)$ on veut $\frac{\partial\phi}{\partial x}, \frac{\partial\phi}{\partial y}, \frac{\partial\phi}{\partial z}$

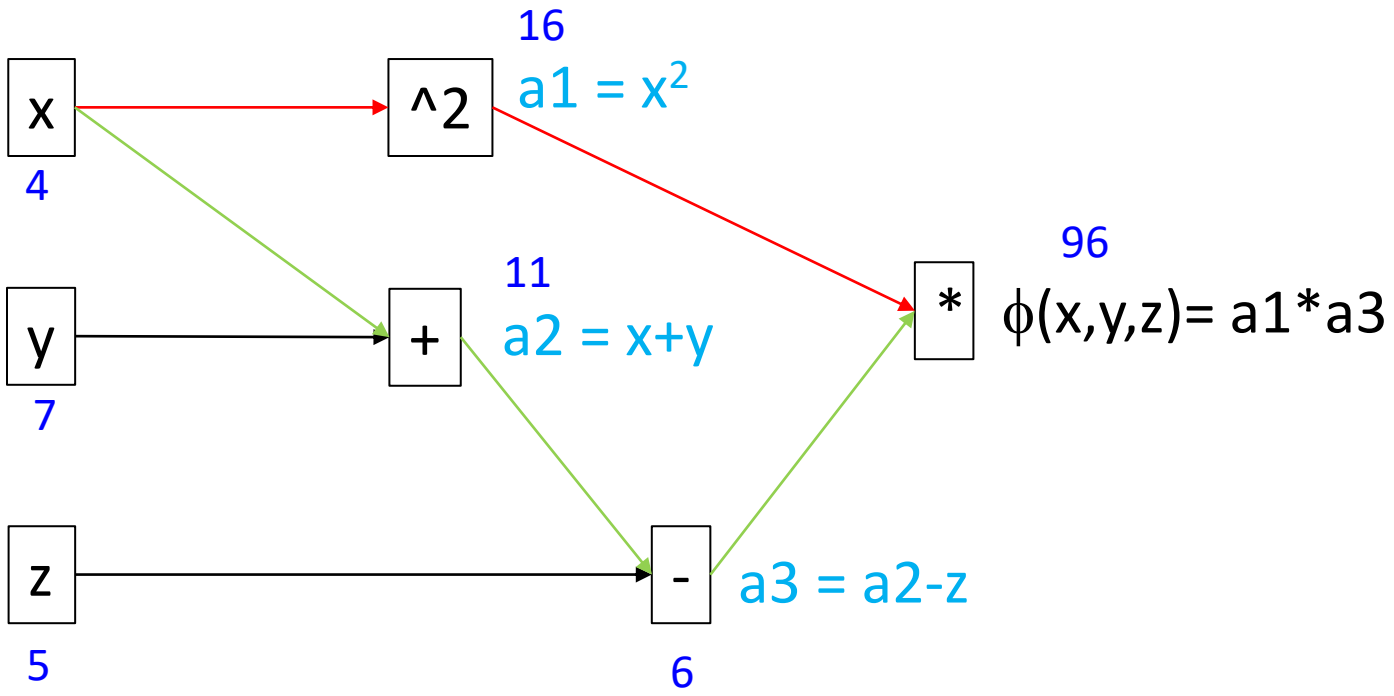

<u>Propagation:</u> On peut se servir du graphe pour calculer la valeur de la fonction pour certaines valeurs des paramètres (ici on donne des valeurs à x,y,z)

<u>NB:</u> cette étape correspondrait à activer le réseau pour une ou plusieurs données d'entrée ($x_i = [x^k_i]$)

$\phi(x,y,z) = x^2(x+y-z)$ on veut $\frac{\partial\phi}{\partial x}, \frac{\partial\phi}{\partial y}, \frac{\partial\phi}{\partial z}$

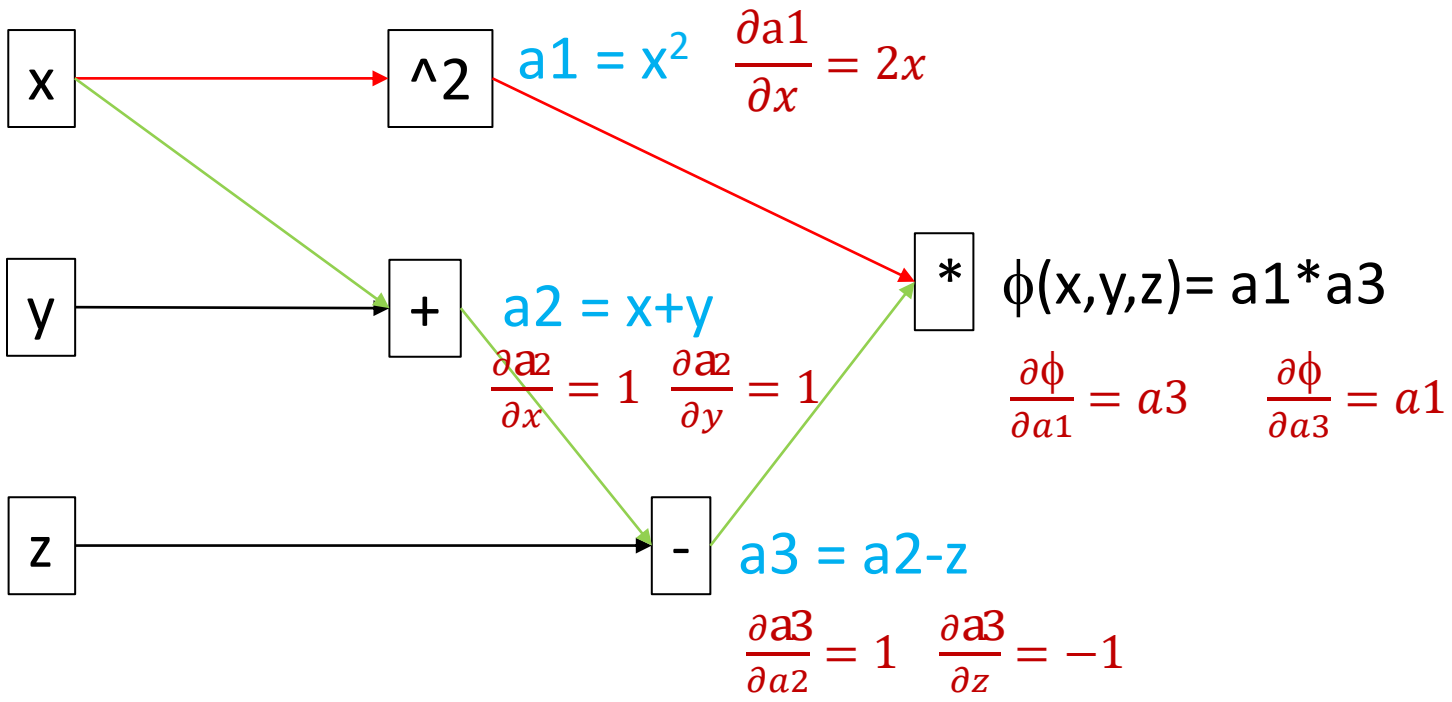

On peut aussi calculer toutes les dérivées "locales" (en rouge) de la fonction à chaque noeud en fonction des variables intermédiaires dont elle dépend (couche précédente)

<u>Note</u>: les termes n'ayant pas de chemin entre eux sont = 0 (exple: $\frac{\partial a3}{\partial a1} = 0$)

$\phi(x,y,z) = x^2(x+y-z)$ on veut $\frac{\partial\phi}{\partial x}, \frac{\partial\phi}{\partial y}, \frac{\partial\phi}{\partial z}$

$$\frac{\partial\phi}{\partial x} = \frac{\partial\phi}{\partial a1}\frac{\partial a1}{\partial x} + \frac{\partial\phi}{\partial a3}\frac{\partial a3}{\partial a2}\frac{\partial a2}{\partial x}$$

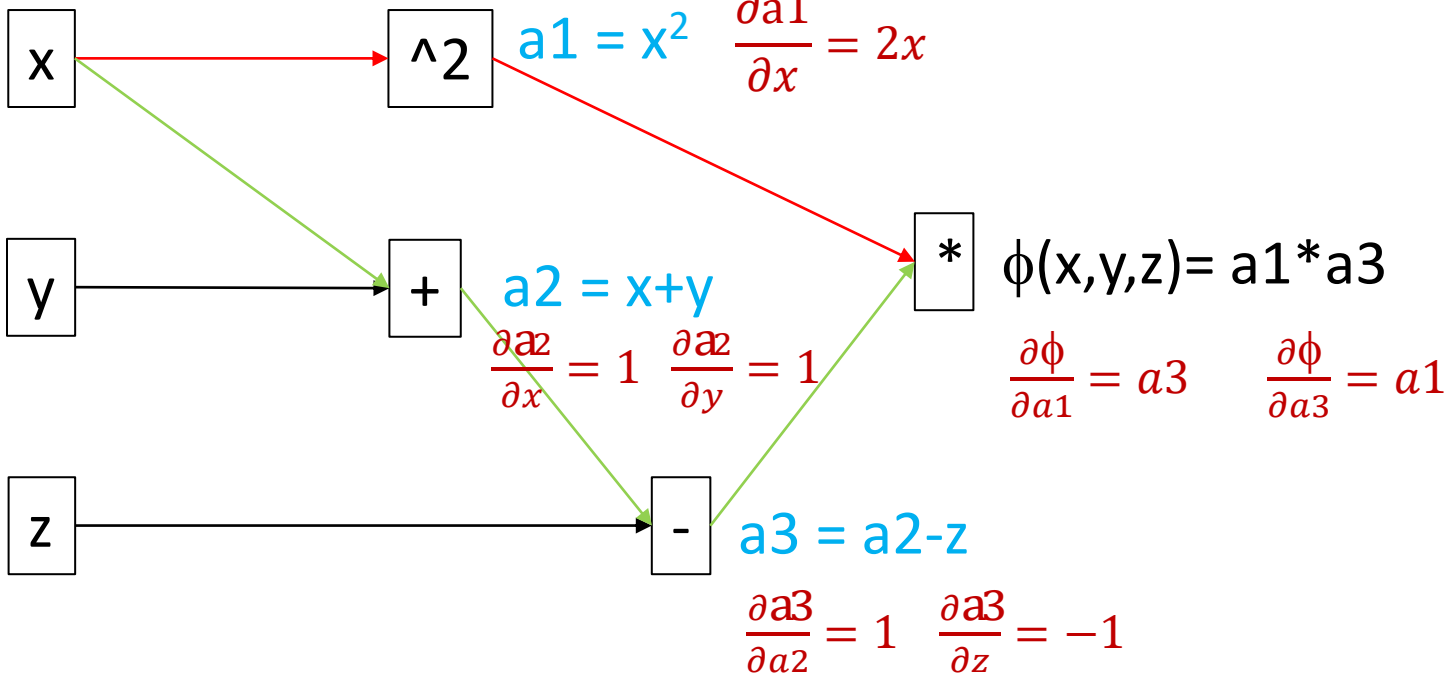

De cette façon, on retrouve bien la procédure (formule) de dérivation composée:

- On part du niveau le plus profond et on remonte (rétropropage) en suivant chaque chemin (ici vert et rouge) en
  - multipliant a chaque noeud traversé
  - ajoutant à chaque jonction

$$\frac{\partial\phi}{\partial x} = \frac{\partial\phi}{\partial a1}\frac{\partial a1}{\partial x} + \frac{\partial\phi}{\partial a3}\frac{\partial a3}{\partial a2}\frac{\partial a2}{\partial x} = a3(2x)+a1(1)(1) = (a2-z)2x + x^2 = (x+y-z)2x + x^2$$

Somme sur les chemins entre ϕ et x (rétropropagation)

$\phi(x,y,z) = x^2(x+y-z)$ on veut $\frac{\partial\phi}{\partial x}, \frac{\partial\phi}{\partial y}, \frac{\partial\phi}{\partial z}$

$$\frac{\partial\phi}{\partial y} = \frac{\partial\phi}{\partial a3}\frac{\partial a3}{\partial a2}\frac{\partial a2}{\partial y}$$

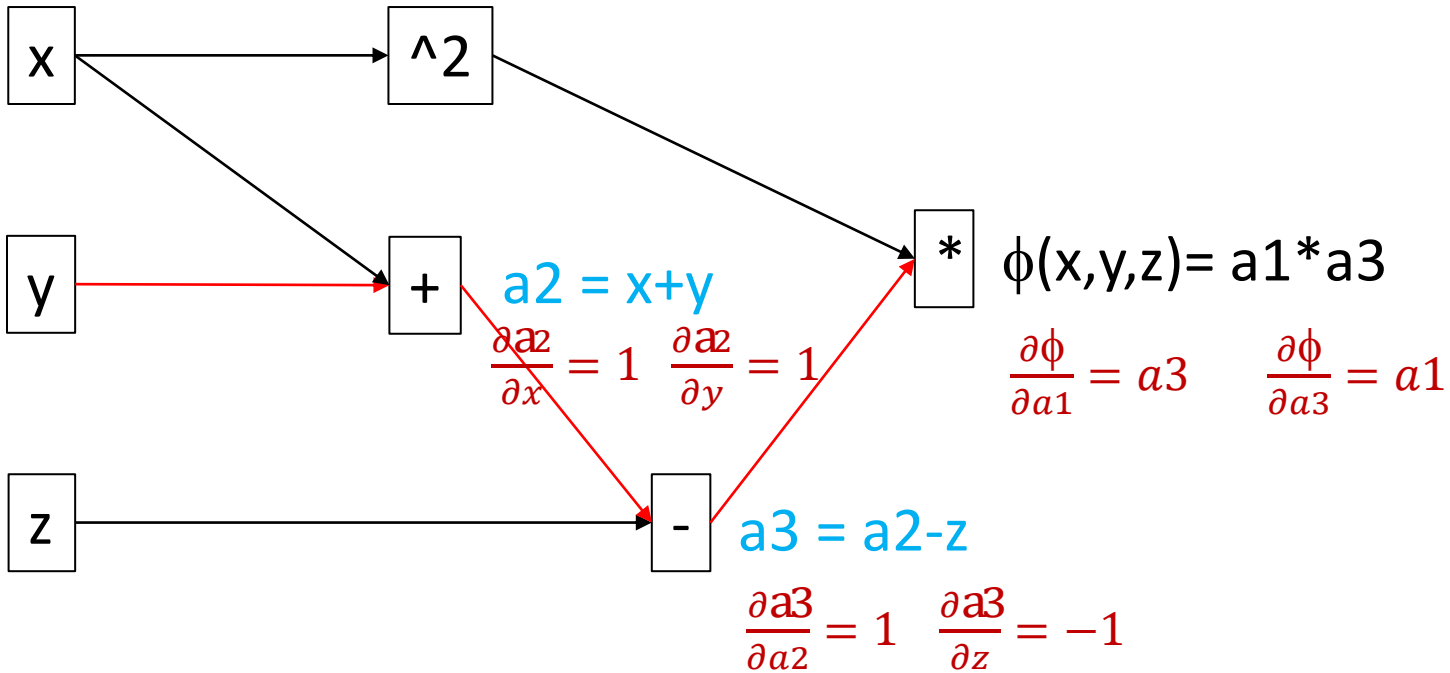

Autre exemple (à développer)

NB: On a toujours la possibilité de vérifier avec la méthode de différentiation "classique"

$\phi(x,y,z) = x^2(x+y-z)$ on veut $\frac{\partial\phi}{\partial x}, \frac{\partial\phi}{\partial y}, \frac{\partial\phi}{\partial z}$

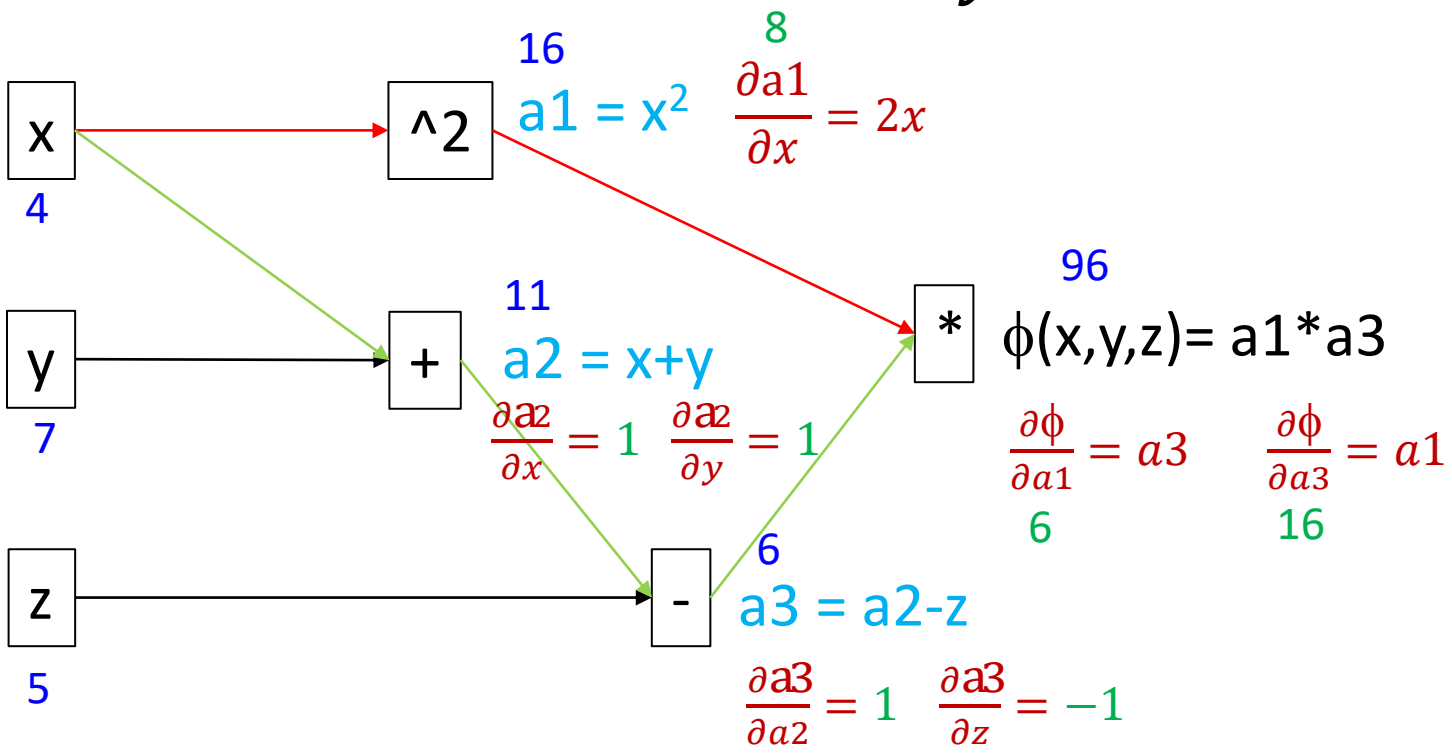

Finalement grâce aux valeurs propagées (bleues) on peut maintenant retro-propager les valeurs des dérivées (vertes)

$$\frac{\partial\phi}{\partial x} = \overset{6}{\frac{\partial\phi}{\partial a1}}\,\overset{8}{\frac{\partial a1}{\partial x}} + \overset{16}{\frac{\partial\phi}{\partial a3}}\,\overset{1}{\frac{\partial a3}{\partial a2}}\,\overset{1}{\frac{\partial a2}{\partial x}} = a3(2x)+a1(1)(1) = (a2-z)2x + x^2 = (x+y-z)2x + x^2 = 64$$

Différentiation automatique

Soit **u**=(u,u') et **v**=(v,v') avec:

- **u+v** = (u+v, u'+v')
- **u**.**v** = (uv,u'v+v'u)
- $\mathbf{u}^n = (u^n, nu^{n-1})$
- a.**u** = (a.u,au')
- cos(**u**) = (cos (u), u'sin(u))
- …

Exemple: $f(x)=3x^2+2x-1$, calculer f'(3)

x = (3,0) → f(**x**) = $f((x,1))=3(x,1)^2+2(x,1)-1(1,0) = 3(x^2,2x)+(2x,2)-(1,0)$

→ f((3,1)) = (27,18)+(6,2)-(1,0) = (32,20) = (f(3),f'(3))

Calculer f'(10): f((10,1))=(300,60)+(40,2)-(1,0)=(339, 62)

Exercice: Pour $f(x)=\cos(2x)\exp(3x^2-2x+3)$, calculer f'(12)

Solution

$f(x)= \cos(2x).\exp(3x^2-2x+3)$

- $\boldsymbol{\varphi}(\mathbf{u}) = \boldsymbol{\varphi}((u,u')) = (\varphi(u),u'\varphi'(u))$

$f(\mathbf{x}) = f((x,1))= \cos(2.(x,1)).\exp(3(x,1)^2-2(x,1)+3(1,0))$

$=(\cos(2x),2\sin(2x)).(\exp(3x^2-2x+3),(6x-2)\exp(3x^2-2x+3))$

$f((12,1))=(\cos(24),2\sin(24))(e^{411},70e^{411})$

$= (\cos(24)e^{411}, 2\sin(24)\, e^{411}+70e^{411}\cos(24))$

$=(\cos(24)\, e^{411}, 2e^{411}\,(\sin(24)+35\cos(24))$

$\rightarrow f'(12)=2e^{411}\,(\sin(24)+35\cos(24)$

$f((2,1)) = (\cos(4)\, e^{11},2\sin(4)e^{11}+10e^{11}\cos(4))$

$\rightarrow f'(2)=2e^{11}(\sin(4)+5\cos(4))$

Utilisation dans notre exemple

$\phi(x,y,z) = x^2(x+y-z)$

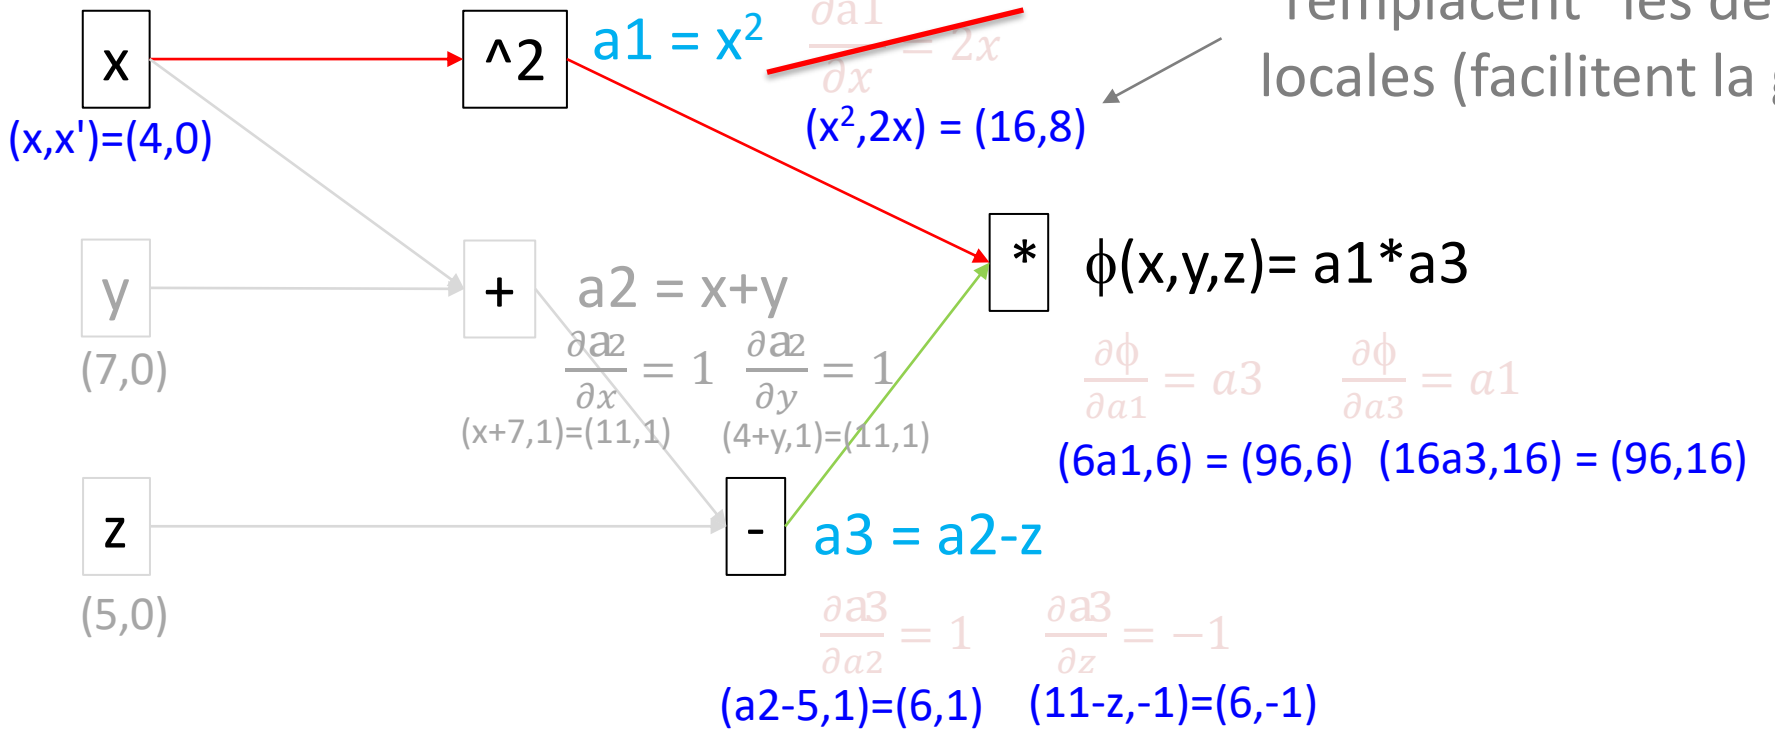

Nos nouveaux objets "remplacent" les dérivées locales (facilitent la gestion)

En pratique: rétropropagation

$\phi(x,y,z) = x^2(x+y-z)$

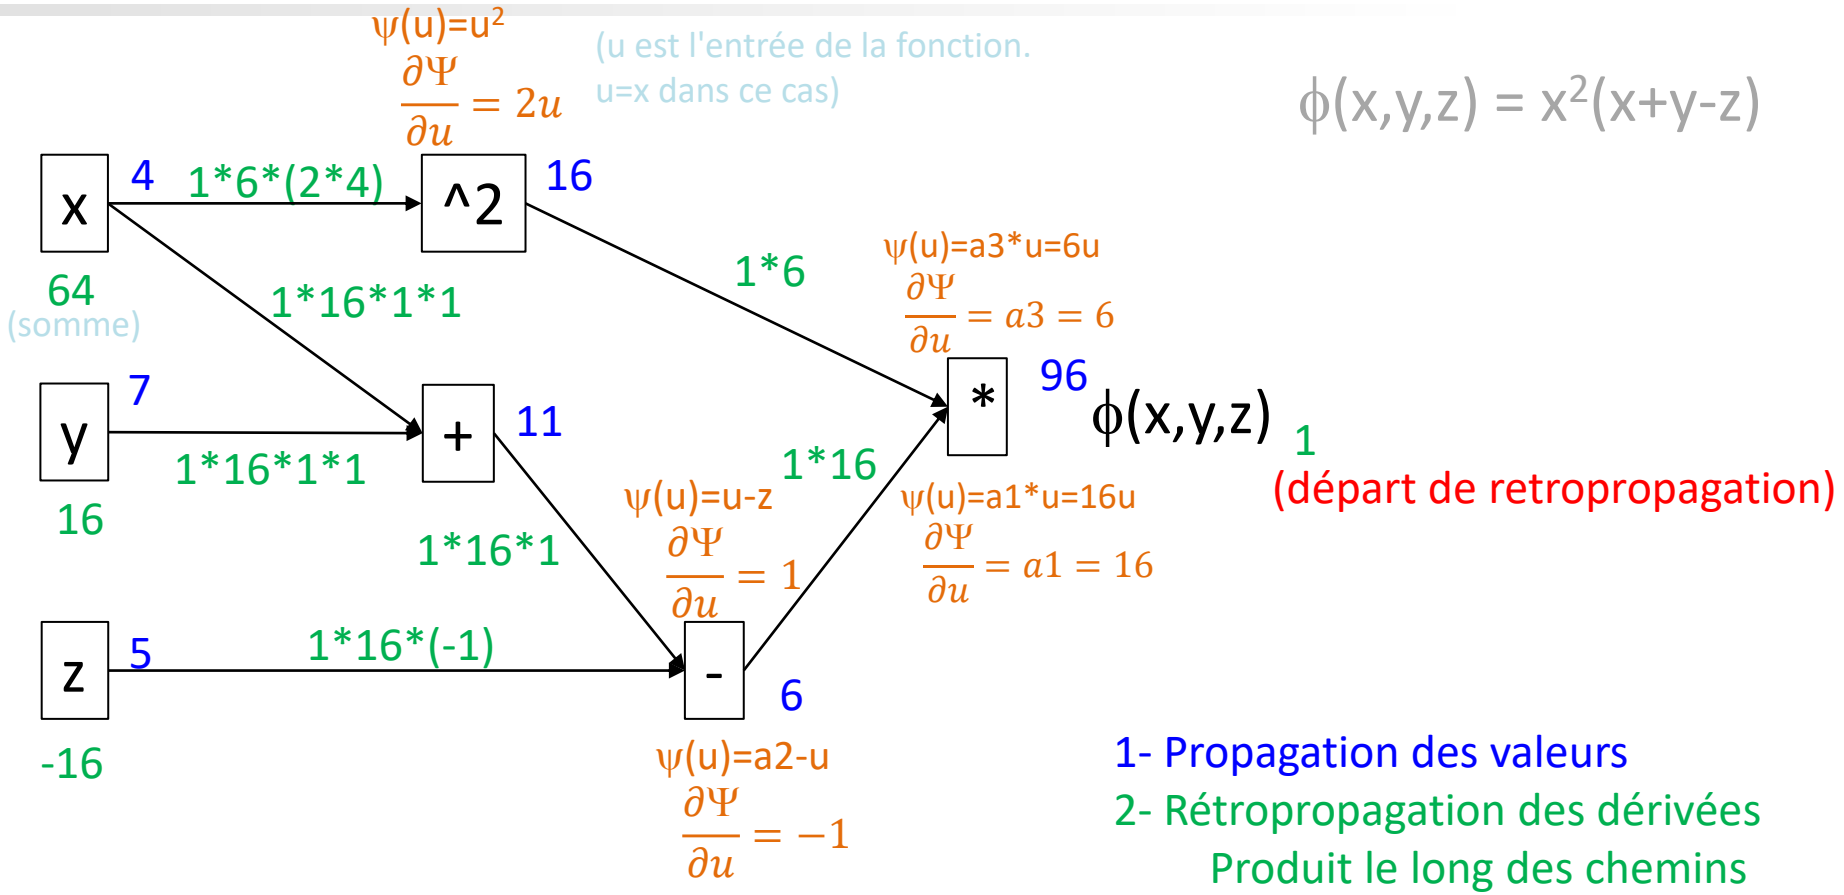

1- Propagation des valeurs

2- Rétropropagation des dérivées

Produit le long des chemins

Somme aux jonctions

16

$$\frac{\partial\phi}{\partial y} = x^2$$

-16

$$\frac{\partial\phi}{\partial z} = -x^2$$